ECONOMETRIA I

Prof. Carlos Briceño Sotelo

Universidad Adolfo Ibañez

UNIDAD 1: Introducción y Repaso Estadístico

Tema 1: Introducción

Breve repaso de inferencia estadística

Repaso: probabilidad y estadística

- **Tema 1:** Variables Aleatorias y funciones de distribución.
- **Tema 2:** Estadísticos de distribuciones: Esperanza, mediana, desviación estándar y varianza.
- **Tema 3:** Relaciones entre variables: independencia, covarianza, correlación.
- **Tema 4:** Esperanzas condicionales, esperanzas iteradas.
- **Tema 5:** Distribuciones importantes.

TODOS LOS ALUMNOS DEBEN REVISAR LOS APÉNDICES A, B y C DE WOOLDRIDGE (2010)
ESTA CLASE DE REPASO NO SUSTITUYE LA REVISIÓN INDIVIDUAL!

Repaso: probabilidad y estadística

- **Tema 1: Variables Aleatorias y funciones de distribución.**
- Tema 2: Estadísticos de distribuciones: Esperanza, mediana, desviación estándar y varianza.
- Tema 3: Relaciones entre variables: independencia, covarianza, correlación.
- Tema 4: Esperanzas condicionales, esperanzas iteradas.
- Tema 5: Distribuciones importantes.

Repaso: probabilidad y estadística

- **Tema 1: Variables Aleatorias y funciones de distribución.**

A. Probabilidad y estadística

B. Experimento estadístico

C. Variables aleatorias

D. Función de distribución

1A. Probabilidad y estadística

- **<u>Probabilidad</u>:** estudia los eventos para comprender la aleatoriedad de los datos en una muestra.

- **<u>Estadística</u>:** la matemática utilizada para recolectar, organizar, e interpretar datos numéricos.
  - *Hace inferencia acerca de la realidad (población) a partir del comportamiento de la muestra (una parte de la población).*

- La ***probabilidad*** y la ***estadística*** se relacionan porque los datos estadísticos se analizan para ver si se pueden obtener conclusiones acerca de algún fenómeno y para predecir eventos futuros.

1B. Experimento estadístico

- **Experimento:** procedimiento que puede repetirse infinitas veces y que tiene un conjunto de resultados bien definidos (se le llama el ***"espacio muestral")***
  - *Ejemplo: lanzar un dado puede resultar en 1, 2, 3, 4, 5 ó 6 puntos*

1C. Variables Aleatorias

- **Variable aleatoria (v.a.):** una regla (o función) que asigna un valor numérico a cada resultado posible del experimento.
  - Ejemplo: se define la variable aleatoria

$$\mathbf{X} = \{\textbf{número de puntos en la cara del dado que resultó del lanzamiento}\}$$

$$\boldsymbol{X} = \{\mathbf{1}, \mathbf{2}, \mathbf{3}, \mathbf{4}, \mathbf{5}, \mathbf{6}\}$$

- **Otra definición:** Variable numérica cuyo valor desconocemos a priori pero a la cual podemos asignar una distribución de probabilidad (función).

1C. Variables Aleatorias

- **Tipos de variables aleatorias:**
  - **Variable aleatoria discreta**: número finito (o infinito pero contable) de valores. Ejemplo: edad, sexo, tiempo enfermo medido en horas.
  - **Variable aleatoria continua**: toma cantidad de valores imposibles de contar. Ejemplo: ingreso, tiempo, precio.

1C. Variables Aleatorias

Variables aleatorias discretas

- Distribución de Variable Aleatoria caracterizada por:
  - Función de Distribución de **Probabilidad** (**fdp**)
  - Función de Distribución **Acumulada** (**fda**)

1D. FDP: Función de Distribución de Probabilidad: ejemplo

Evolución de la estructura etárea en Chile (1990 vs 2020)

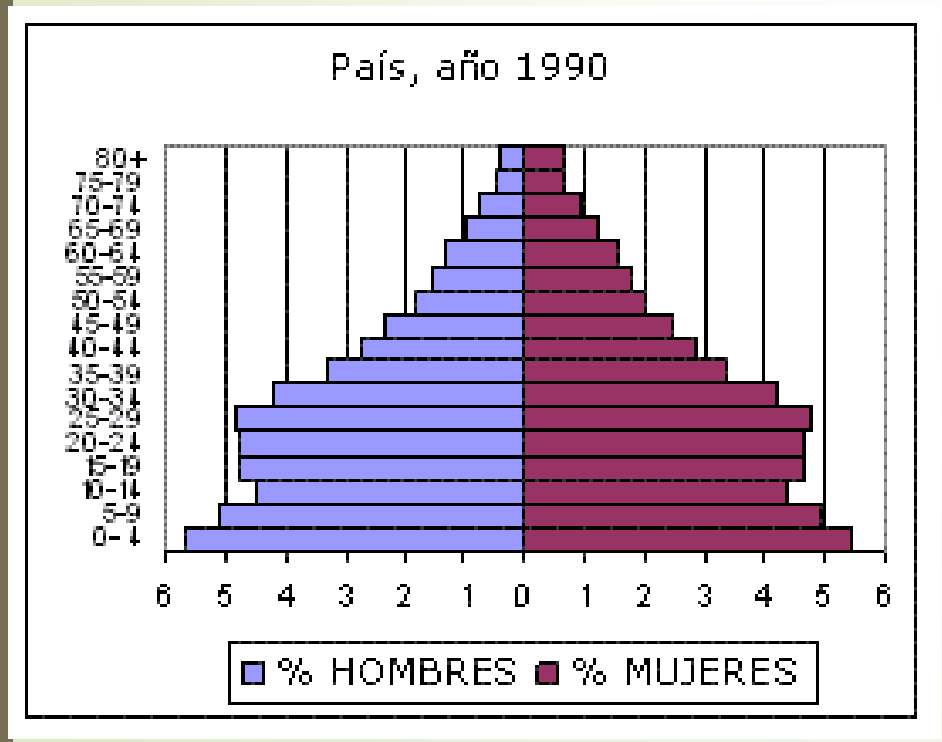

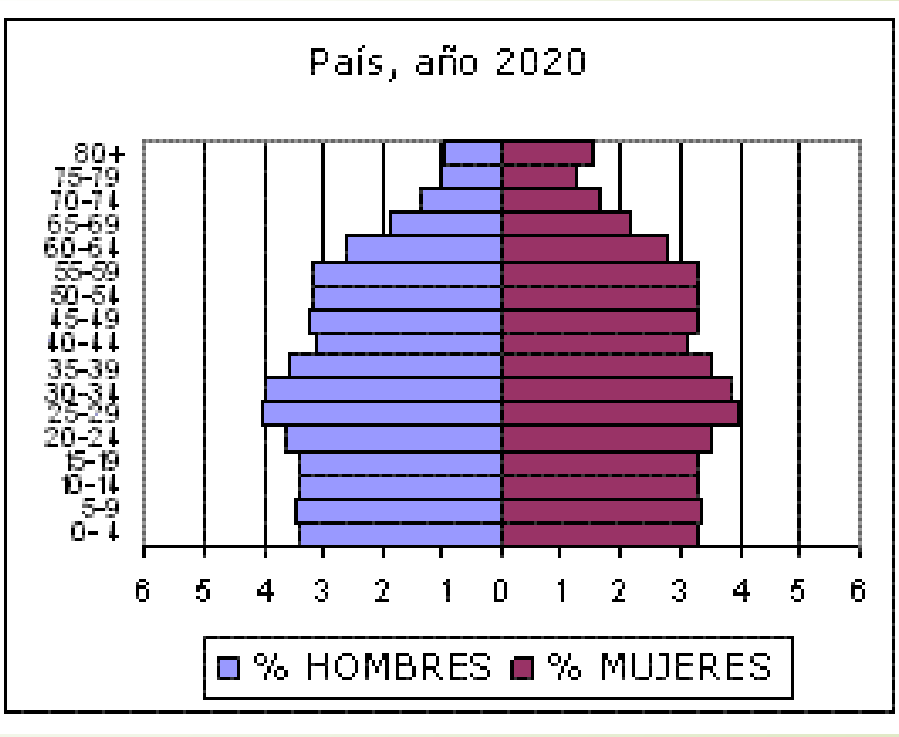

Fuente: Banco Central en base a Encuesta Casen.

1D. FDP: Función de Distribución de Probabilidad

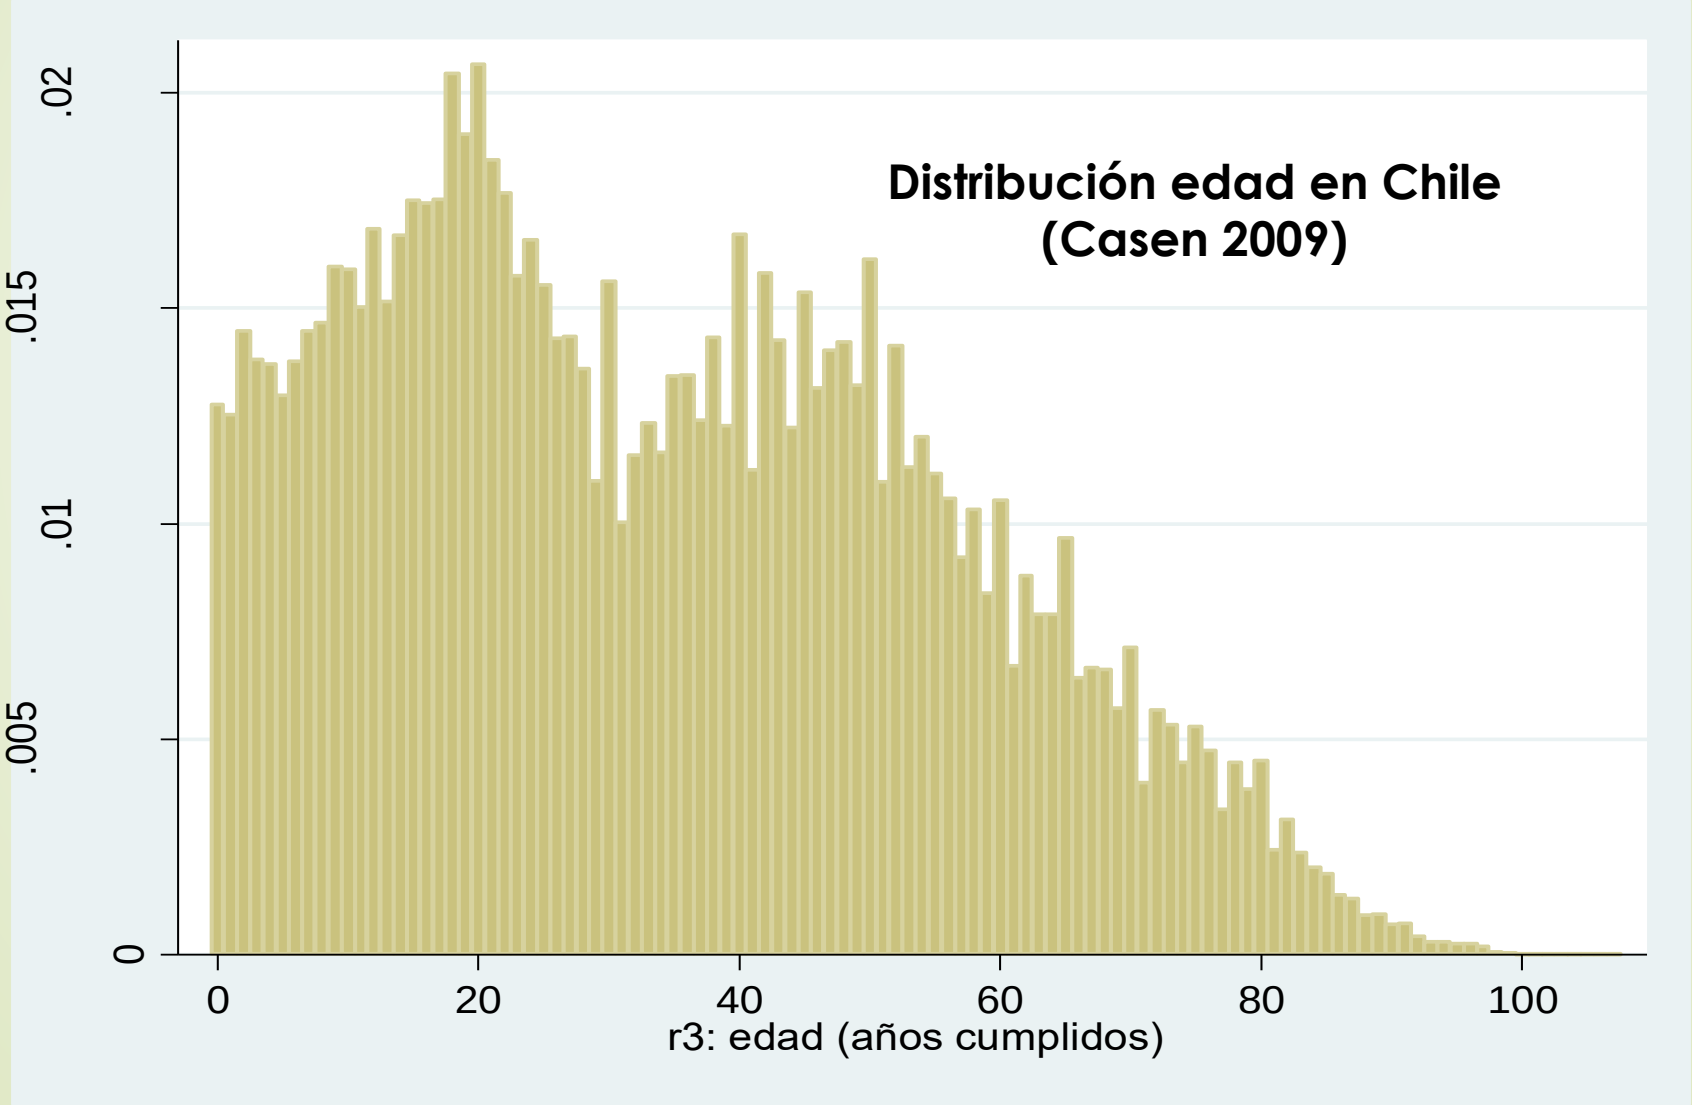

1D. FDA: Función de distribución acumulada

- Función de distribución acumulada (fda) es una regla que especifica, para cada valor x, cuál es la probabilidad de que $X \leq x$:
  - *Se denomina $F(x)$:*

$$F(x) = P(X \leq x) = Pr(1) + Pr(2) + \cdots + Pr(x)$$

  - Ejemplo: lanzamiento de dado. ¿Cuál es la probabilidad que en un lanzamiento se obtengan 3 puntos o menos?

$$F(3) = Pr(X \leq 3) = Pr(1) + Pr(2) + Pr(3) =$$
$$= \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{3}{6} = \frac{1}{2}$$

1D. Variables Aleatorias y función de distribución

Variable aleatoria continua

- **Función de Densidad de Probabilidad (fdp):** debido a que una Variable Aleatoria continua puede tomar sus valores posibles en un continuo, la ***fdp*** utilizada para variables discretas no es aplicable a las variables continuas.
  - En su lugar, la probabilidad viene recogida por la **función de densidad de probabilidad**. La **fdp** también se conoce como densidad.
  - La probabilidad de que una Variable Aleatoria continua sea igual a x es cero.

1D. Variables Aleatorias y función de distribución

Variable aleatoria continua

- **Función de Densidad Acumulada (fda):** estima la probabilidad de que $X \leq x$. Se expresa como $F(x)$ y debe cumplir las siguientes condiciones:

$$0 \leq F(x) \leq 1$$

b) $\int_{-\infty}^{\infty} f(x)dx = 1$

1D. Ejemplo: distribución del tiempo dedicado al estudio de una prueba

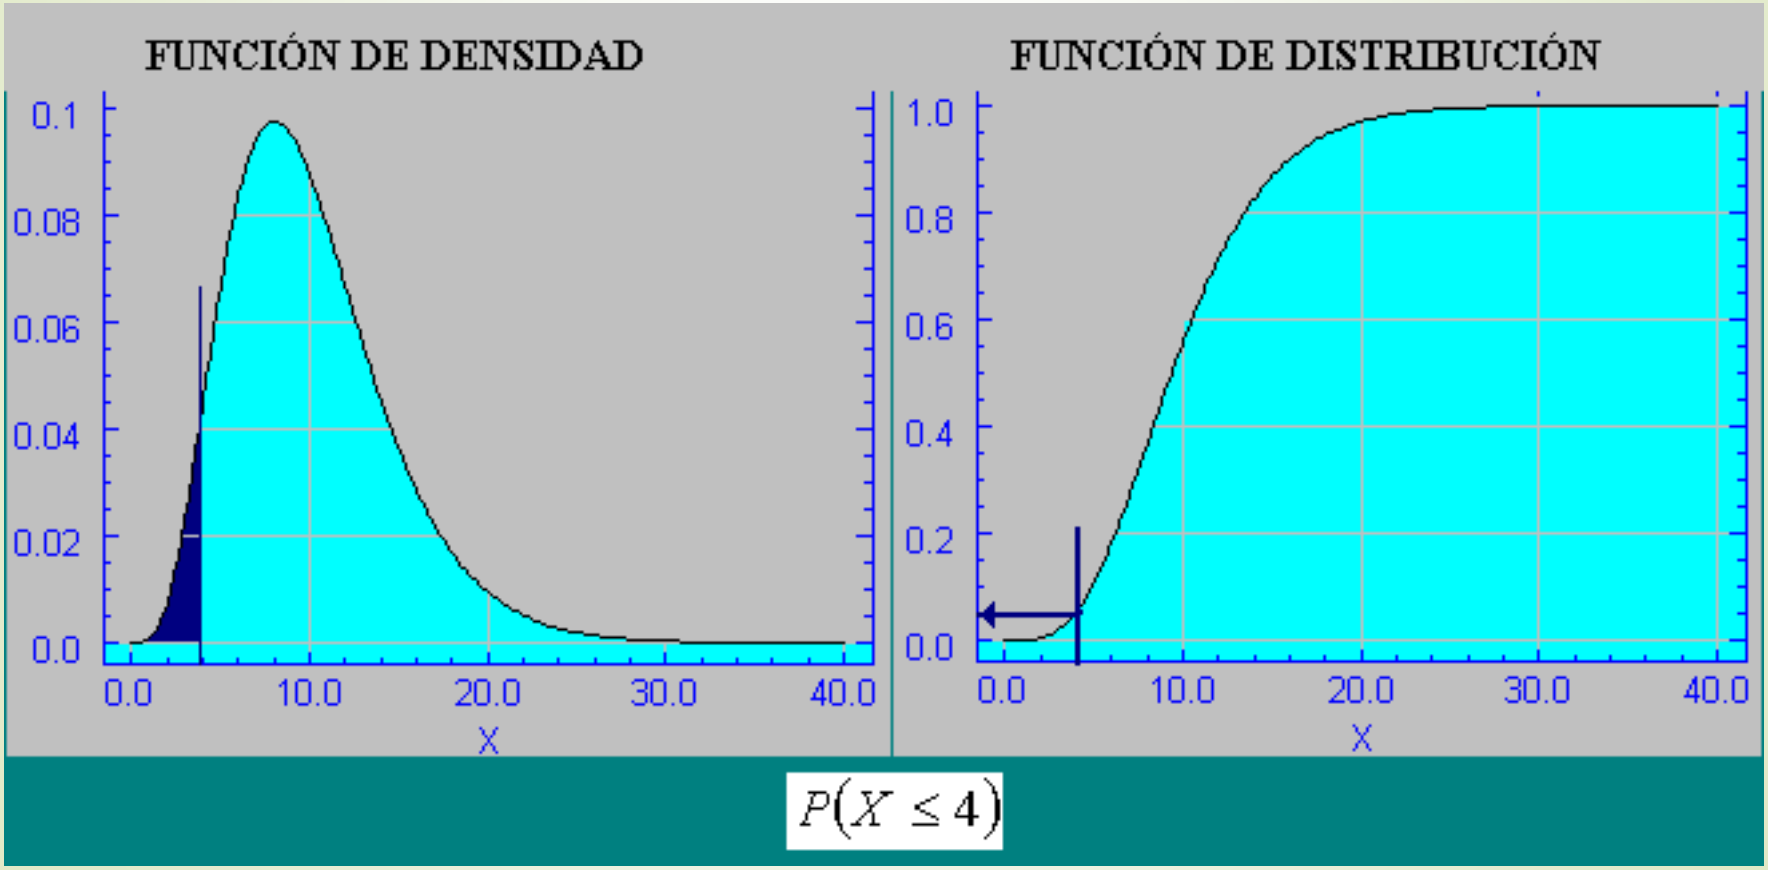

Repaso: probabilidad y estadística

- Tema 1: Variables Aleatorias y funciones de distribución.
- **Tema 2: Estadísticos de distribuciones: Esperanza, mediana, desviación estándar y varianza.**
- Tema 3: Relaciones entre variables: independencia, covarianza, correlación.
- Tema 4: Esperanzas condicionales, esperanzas iteradas.
- Tema 5: Distribuciones importantes.

Repaso: probabilidad y estadística

- **Tema 2: Estadísticos de distribuciones: Esperanza, mediana, desviación estándar y varianza.**

A. Medidas de tendencia central: Esperanza (media, valor esperado), Mediana, Moda

B. Medidas de dispersión: Varianza; Desviación Standard

C. Variables standarizadas

2A. Esperanza o valor esperado

- Más utilizada en econometría: **Esperanza ($E[X]$) o valor esperado**
  - *La definición se corresponde con un promedio ponderado según la probabilidad de los valores del recorrido y, por lo tanto, se corresponde con la idea de un valor medio teórico.*
  - ***Intuición:*** *el valor esperado de una variable aleatoria X es el valor que toma en promedio luego de varias repeticiones del experimento:*

$$E(x) = \mu = \begin{cases} \int_{-\infty}^{+\infty} x f(x) dx & caso\ continuo \\ \sum_{\forall x} x_i \Pr(x_i) & caso\ discreto \end{cases}$$

2A. Mediana y moda

- **Mediana**
  - Divide población (ordenada) en 2 partes con igual probabilidad
  - Corresponde al percentil 50% de una distribución
  - Diferencias con esperanza:
    - *No lineal (no depende de variables determinadas)*
    - *Más robusto ante presencia de valores extremos*

- **Moda o Modo**
  - La moda de un conjunto de números es el número que aparece más a menudo.

2B. Medidas de dispersión: varianza y desviación estándar

- La ***varianza*** resume la distancia promedio entre valores de la variable aleatoria X y su valor esperado.

- Medida de dispersión definida como la esperanza del cuadrado de la desviación de dicha variable respecto a su media.

- Para una variable aleatoria X, sea $E(X) = \mu$. Entonces, la varianza se define como:

$$Var(X) = \sigma^2 = E[(X - \mu)^2] = E(X^2) - \mu^2$$

2B. Medidas de dispersión: varianza y desviación estándar

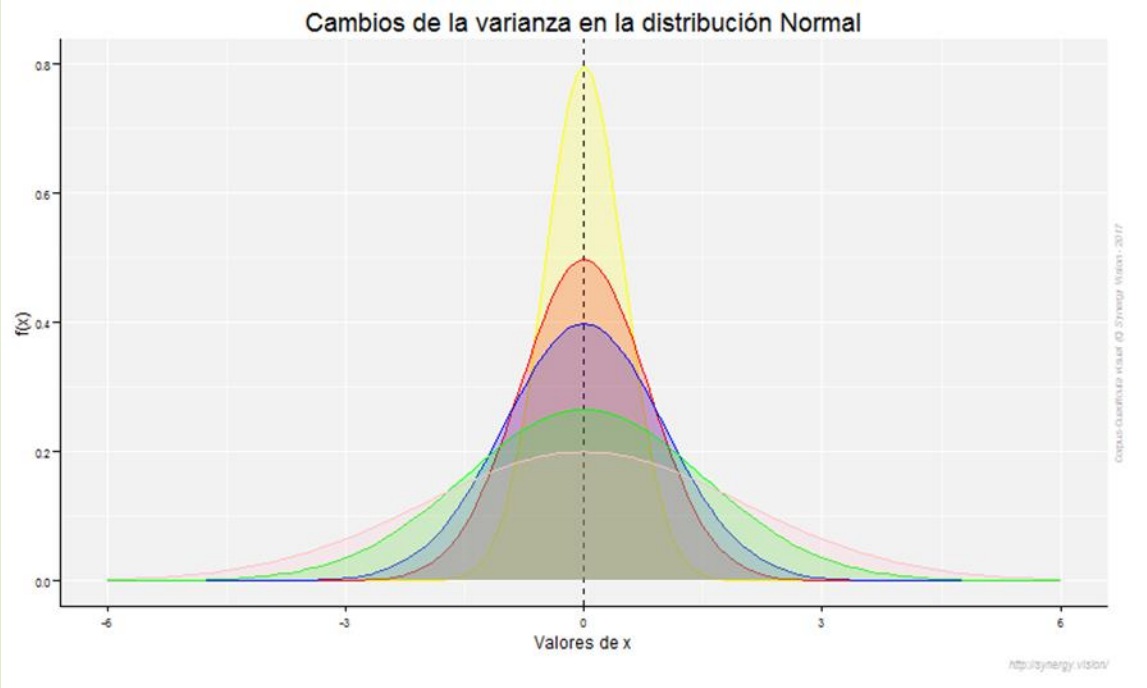

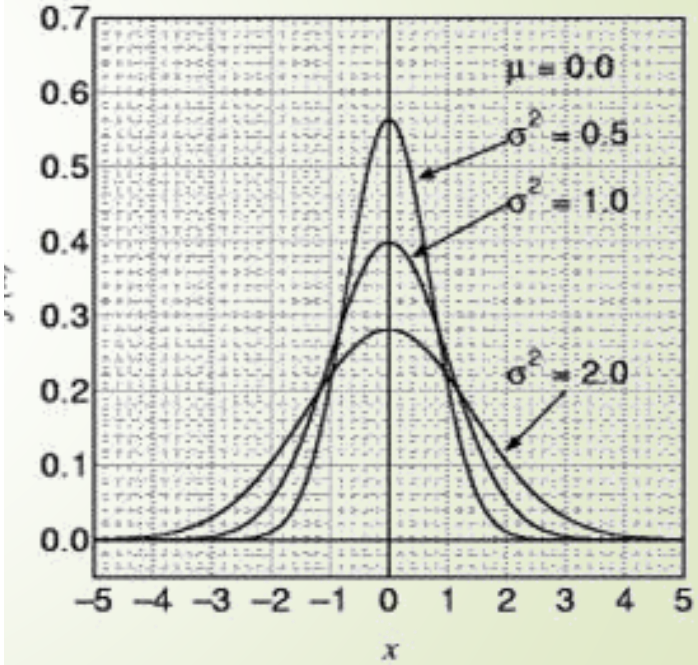

2B. Medidas de dispersión: varianza y desviación estándar

- **Desviación estándar:** dispersión medida en la misma unidad que la variable aleatoria original.

$$Desv.Std.(X) = \sigma = \sqrt{Var(X)} = \sqrt{\sigma^2}$$

- Es una variable aleatoria que corresponde a la raíz cuadrada positiva de la varianza.

2B. Variable estandarizada

- Proceso sencillo y de utilidad para comparar **distribuciones** o **variables** que están expresadas en unidades diferentes.

- La llevamos a una distribución normal estándar (por eso, a veces, se le denomina “normalización” o “estandarización”).

- Para estandarizar una variable aleatoria: se le resta la media y se la divide por la desviación estándar:

$$\boldsymbol{Z = \frac{X - \mu}{\sigma} \sim N(0, 1)}$$

$$Por\ lo\ tanto\text{:}\ E(Z) = 0 \quad y \quad Var(Z) = sd(Z) = 1$$

2C. Variable estandarizada

- A este proceso suele conocérsele como **estandarización de la variable aleatoria** X, y a Z **como variable aleatoria estandarizada.**

- Es importante recordar que en el denominador aparece la desviación estándar y no la varianza.

2C. Variable estandarizada: ejemplo

- La temperatura durante septiembre está distribuida normalmente con media 18,7ºC y desviación standard 5ºC.

- Calcule la probabilidad de que la temperatura durante septiembre esté por debajo de 21ºC.

$$Z = \frac{X-\mu}{\sigma} = \frac{21-18{,}7}{5} = 0,46$$

- Ahora, vamos a la tabla y para el valor de $Z = 0{,}46$, tenemos que la probabilidad es de **0,6772**.

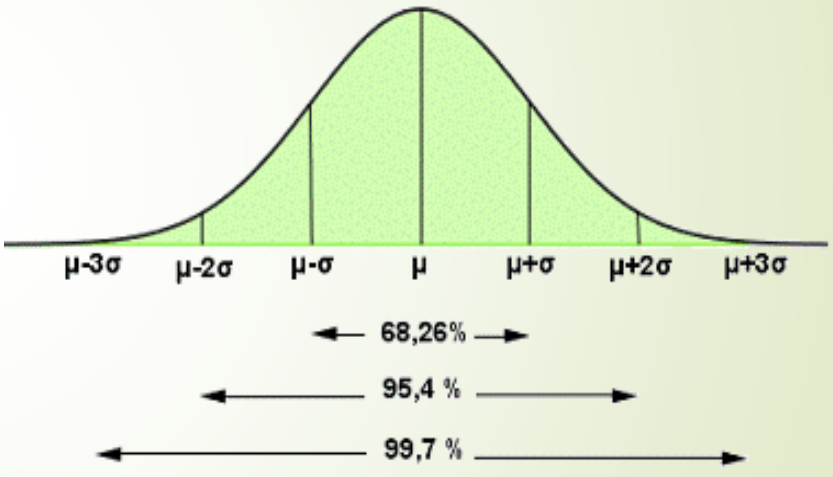

Con ± 1,96 σ queda comprendido entre ambos valores el 95%

2C. Variable estandarizada: ejemplo

- Ahora, vamos a la tabla y para el valor de $Z = 0{,}46$, tenemos que la probabilidad es de **0,6772**.

Tabla de distribución normal.

zi	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
-0,5	0,3085	0,3050	0,3015	0,2980	0,2945	0,2911	0,2877	0,2843	0,2809	0,2775
-0,4	0,3445	0,3409	0,3372	0,3335	0,3299	0,3263	0,3227	0,3191	0,3156	0,3120
-0,3	0,3820	0,3782	0,3744	0,3707	0,3669	0,3631	0,3594	0,3556	0,3519	0,3482
-0,2	0,4207	0,4168	0,4129	0,4090	0,4051	0,4012	0,3974	0,3935	0,3897	0,3859
-0,1	0,4601	0,4562	0,4522	0,4482	0,4443	0,4403	0,4364	0,4325	0,4285	0,4246
0,0	0,4999	0,5039	0,5079	0,5119	0,5159	0,5199	0,5239	0,5279	0,5318	0,5358
0,1	0,5398	0,5437	0,5477	0,5517	0,5556	0,5596	0,5635	0,5674	0,5714	0,5753
0,2	0,5792	0,5831	0,5870	0,5909	0,5948	0,5987	0,6025	0,6064	0,6102	0,6140
0,3	0,6179	0,6217	0,6255	0,6292	0,6330	0,6368	0,6405	0,6443	0,6480	0,6517
0,4	0,6554	0,6590	0,6627	0,6664	0,6700	0,6736	0,6772	0,6808	0,6843	0,6879

Repaso: probabilidad y estadística

- Tema 1: Variables Aleatorias y funciones de distribución.
- Tema 2: Estadísticos de distribuciones: Esperanza, mediana, desviación estándar y varianza.
- **Tema 3: Relaciones entre variables: independencia, covarianza, correlación.**
- Tema 4: Esperanzas condicionales, esperanzas iteradas.
- Tema 5: Distribuciones importantes.

Repaso: probabilidad y estadística

- **Tema 3: Relaciones entre variables: independencia, covarianza, correlación.**

  A. Independencia estadística

  B. Medidas de asociación: covarianza y correlación

3A. Independencia: concepto clave

- Se dice que dos variables aleatorias X e Y son independientes si el conocimiento del valor de una de las variables no ofrece información sobre el valor de la otra.

- Específicamente, las variables aleatorias X e Y son independientes si la distribución condicionada de Y dado X es igual a la distribución marginal de Y.

3A. Independencia: concepto clave

- X *e* Y *son* ***independientes*** $\Leftrightarrow$

$$\Leftrightarrow f_{X,Y}(x,y) = f_X(x) \cdot f_Y(y)$$

$$\Leftrightarrow \Pr(X = x, Y = y) = \Pr(X = x) \cdot \Pr(Y = y)$$

Intuición: *el hecho que* X *tome algún valor no afecta la probabilidad de que* Y *tome valores, y viceversa*.

Discusión: ¿tienen relación la compra de pañales con la compra de cerveza?

3A. Independencia: concepto clave

1. Un caso clásico: Pañal y Cerveza

Big data está bien empleado para ayudar al departamento de marketing de Walmart con la toma de decisiones. El investigador de mercado de Walmart descubrió que cuando los clientes varones visitan el departamento de bebés para elegir pañales para sus pequeños, es muy probable que compren un par de cervezas. Por lo tanto, Walmart colocó cerveza al lado del pañal lo que había llevado a que las ventas de cervezas y pañales aumentaran significativamente.

Fuente: https://www.octoparse.es/blog/data-mining-explicada-con-10-historias#

3B. Medidas de asociación: covarianza y correlación

- Miden cómo varía una variable aleatoria en función de otra, en promedio.

- **Covarianza**: mide grado de dependencia lineal entre dos variables aleatorias. La magnitud no es fácil de interpretar pero el signo tiene intuición directa:
  - *Signo positivo: se mueven juntas.*
  - *Signo negativo: se mueven en dirección opuesta.*

- Se denomina $Cov(X, Y)$:

$$Cov(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E(XY) - \mu_X \mu_Y$$

3B. Medidas de asociación: covarianza y correlación

- El **coeficiente de correlación** es una medida relativa:

$$Corr(X,Y) = \frac{Cov(X,Y)}{sd(X) \cdot sd(Y)}$$

- Tiene el mismo signo (e interpretación) que $Cov(x,y)$ pero es adimensional (siempre entre -1 y 1)

3B. Medidas de asociación: covarianza y correlación

- $Corr(X, Y) = 0$ sí y sólo si $Cov(X, Y) = 0$
- Si X e Y son independientes, $Corr(X, Y) = 0$
- **Sin embargo,** $Corr(X, Y) = 0$ no implica independencia.
- Rango: $-1 \leq Corr(X, Y) \leq 1$

Repaso: probabilidad y estadística

- Tema 1: Variables Aleatorias y funciones de distribución.
- Tema 2: Estadísticos de distribuciones: Esperanza, mediana, desviación estándar y varianza.
- Tema 3: Relaciones entre variables: independencia, covarianza, correlación.
- **Tema 4: Esperanzas condicionales, esperanzas iteradas.**
- Tema 6: Distribuciones importantes.

Repaso: probabilidad y estadística

- **Tema 4: Esperanzas condicionales, esperanzas iteradas.**

A. Esperanzas condicionales

B. Propiedad de esperanza condicional

C. Esperanzas iteradas

4A. Esperanzas condicionales

- Si X e Y no son variable independientes, conocer algo acerca de X puede ayudar a predecir Y.

- $E[X|Y]$ es una <u>función</u> que indica para cada valor de Y, la esperanza de X para los individuos con dicho valor de Y.

$$E(g(x)|Y = y) = \begin{cases} \int_{-\infty}^{+\infty} g(x) f(x|y) dx & \textit{caso continuo} \\ \sum_{\forall x} g(x_i) \Pr(x_i|y) & \textit{caso discreto} \end{cases}$$

4A. Esperanzas condicionales

$$E(g(x)|Y=y) = \begin{cases} \int_{-\infty}^{+\infty} g(x) f(x|y) dx & caso\ continuo \\ \sum_{\forall x} g(x_i) \Pr(x_i|y) & caso\ discreto \end{cases}$$

- **Propiedades:**
  - $E[g(X)|X] = g(X)$
  - $E[g(X) \cdot Y + h(X)|X] = g(X) * E[Y|X] + h(X)$
  - X, Y independientes $\rightarrow E[X|Y] = E[X] \rightarrow Cov(X,Y) = 0$

4B. Propiedad de esperanza condicional

- La **esperanza condicional** $E[Y|X]$ es el **mejor predictor condicional** de Y, ya que minimiza el error cuadrático medio:

$$g(X) = E[Y|X] \; minimiza \;\; E\left[\left(Y - g(X)\right)^2\right]$$

$$\mathrm{ECM} = \frac{1}{n}\sum_{i=1}^{n}(\hat{Y}_i - Y_i)^2.$$

4B. Propiedad de esperanza condicional

- **Varianza condicional**:

$$Var(Y|X) = E[(Y - E[Y|X])^2|X] = E[Y^2|X] - E[Y|X]^2$$

- Si X e Y son independientes ➔ $Var(Y|X) = Var(Y)$

4C. Esperanzas iteradas

- **Esperanzas iteradas:**

$$E[Y] = E_X\big[E[Y|X]\big]$$

- **X discreto:**

$$E[Y] = \sum_{x_i} E[Y|X = x_i] \cdot Pr(X = x_i)$$

- **Ejemplo:**
  - *¿Cuál es la nota promedio del curso si sé que el promedio entre los hombre fue 5.1, entre las mujeres 5.5 y las mujeres representan el 60% del curso?*

Repaso: probabilidad y estadística

- Tema 1: Variables Aleatorias y funciones de distribución.
- Tema 2: Estadísticos de distribuciones: Esperanza, mediana, desviación estándar y varianza.
- Tema 3: Relaciones entre variables: independencia, covarianza, correlación.
- Tema 4: Esperanzas condicionales, esperanzas iteradas.
- **Tema 5: Distribuciones importantes.**

Repaso: probabilidad y estadística

Tema 5: Distribuciones importantes.

A. Distribución normal o Gaussiana

B. Distribución χ^2

C. Distribución t de Student

D. Distribución F

5A. Distribución Normal

- Distribución continua y simétrica, más habitual en estadística y econometría, porque:
  - *Frecuentemente se cumple*
  - *Suponer que una variable aleatoria tiene distribución normal simplifica los cálculos probabilísticos*

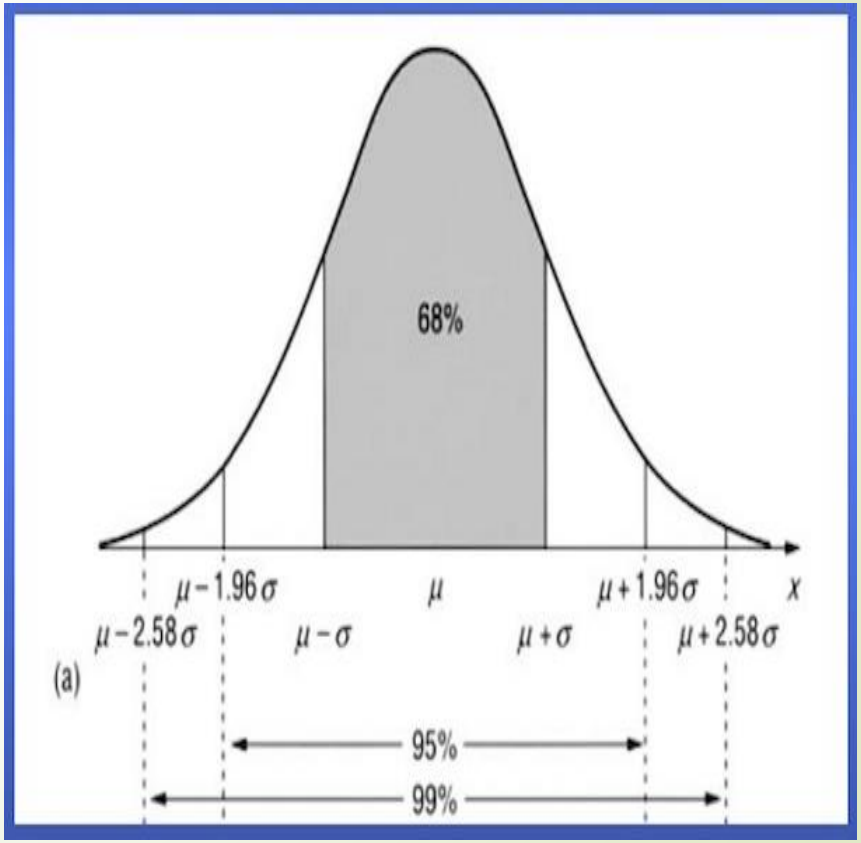

5A. Distribución Normal

- **Función de distribución de $N(\mu, \sigma^2)$:**

$$\phi(x) = f(x) = \frac{1}{\sqrt{2\Pi\sigma^2}} exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

$$\Phi(x) = F(x) = Pr(X < x) = \int_{-\infty}^{x} f(x)dx$$

- **Propiedades:**
  - Si $X, Y \sim N(\cdot) \rightarrow (aX + bY + c) \sim N(\cdot)$
  - Si $X \sim N(\mu, \sigma^2) \rightarrow \frac{X-\mu}{\sigma^2} \sim N(0,1)$

5A. Teorema Central del Límite

- **Teorema central del límite**: las medias de muestras grandes y aleatorias son aproximadamente normales.

- El **teorema** del **límite central** es un **teorema** fundamental de probabilidad y estadística.

- Si Y_i es una variable aleatoria independiente e idénticamente distribuida (**iid**) tal que $\mathrm{E}[Y_i] = \mu$ y $\mathrm{Var}(Y_i) = \sigma^2$, entonces (bajo ciertos supuestos adicionales):

$$Z_n = \left(\frac{\overline{Y_n} - \mu}{\sigma / \sqrt{n}} \right) \xrightarrow{d} Normal(0,1)$$

5B. Distribución χ^2

- Es la suma de n variables aleatorias independientes, con ***distribución normal estándar, elevadas al cuadrado***. La distribución depende de n, los *"grados de libertad"*.

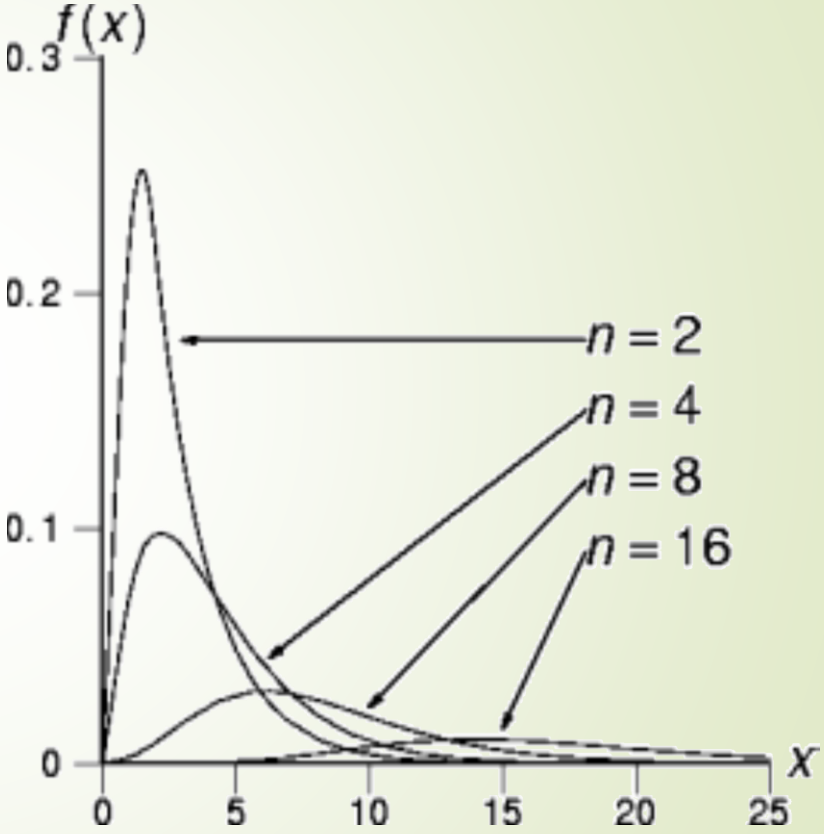

5B. Distribución χ^2

- Ejemplo: si las variables aleatorias z_1, z_2, z_3 son independientes y cada una distribuye normal estándar, entonces

$$(z_1^2 + z_2^2 + z_3^2) \sim \chi_3^2$$

- Distribución con soporte positivo, asimétrica

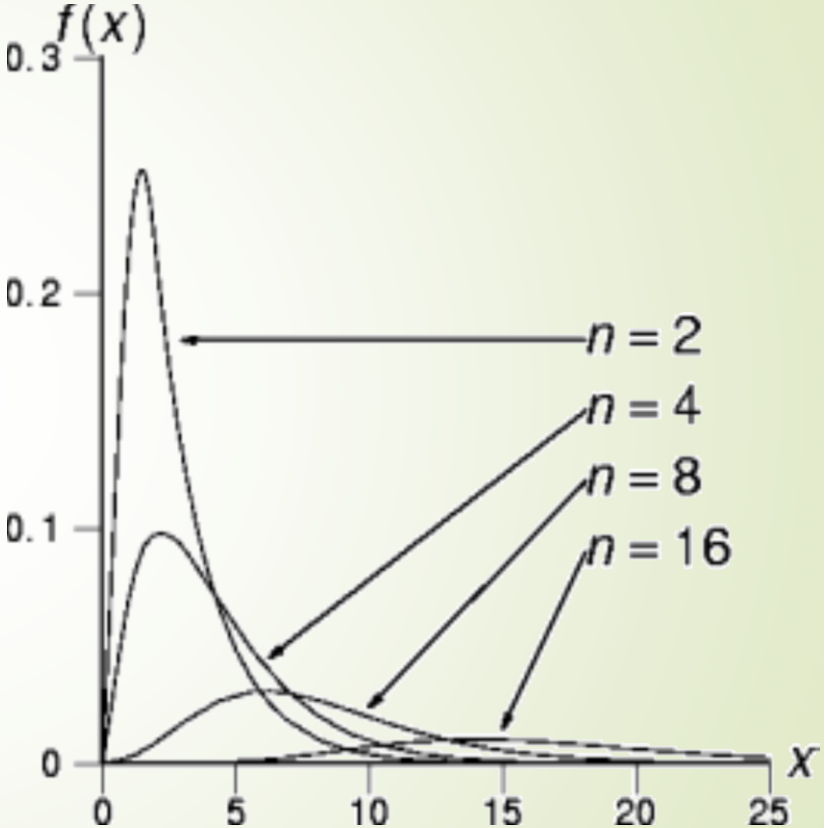

5C. Distribución t de Student

- Distribución t de Student con N grados de libertad: ratio de Normal y raíz de χ^2:

$$Y \sim N(0,1)$$
$$X \sim \chi^2{}_N$$
$$Y, X \; independientes$$
$$\rightarrow T = \frac{Y}{\sqrt{X/_N}} \sim t_N$$

5C. Distribución t de Student

- La distribución t es simétrica: para $30+$ observaciones, se aproxima bastante bien a la distribución Normal estándar.

- Se parece a la distribución normal pero tiene colas más gruesas. Es una especie de Normal para muestras pequeñas.

5D. Distribución Fisher-Snedecor o F

- Distribución útil en análisis de regresión múltiple.
- Distribución con soporte positivo, asimétrica.
- Distribución de Fisher-Snedecor (o distribución F) con n_1 grados de libertad en el numerador y n_2 en el denominador: ratio de 2 chi-cuadrados divididas por sus grados de Libertad:

$$X_1 \sim \chi^2_{n_1}$$

$$X_2 \sim \chi^2_{n_2}$$

$$X_1, X_2 \; independientes$$

$$F = \frac{X_1/n_1}{X_2/n_2} \sim F(n_1, n_2)$$

Breve repaso de inferencia estadística