Econometría I

Prof. Carlos Briceño Sotelo

Universidad Adolfo Ibañez

UNIDAD 2: Modelo de Regresión Lineal Simple

Resumen de la Unidad 2

Temas de la Unidad 2

1. Introducción: estructura de datos y tipos de variables
2. El modelo de regresión lineal: terminología y conceptos.
3. Estimación empleando el método de mínimos cuadrados ordinarios (*MCO, MiCO, OLS*).
4. Medidas de ajuste del método MCO.
5. Propiedades de los estimadores bajo los supuestos clásicos de MCO.
6. Inferencia Estadística

Temas de la Unidad 2

1. **Introducción: estructura de datos y tipos de variables**
2. El modelo de regresión lineal: terminología y conceptos.
3. Estimación empleando el método de mínimos cuadrados ordinarios (*MCO, MiCO, OLS*).
4. Medidas de ajuste del método MCO.
5. Propiedades de los estimadores bajo los supuestos clásicos de MCO.
6. Inferencia Estadística

1. Introducción: Estructura de datos y variables:

A. Estructura de datos económicos

B. Tipos de variables

C. Universo *versus* Muestra

Estructura de datos económicos

Corte transversal:

- Los datos de corte transversal son datos sobre una o más variables recopiladas en el mismo momento. Las unidades muestrales pueden ser individuos, familias, empresas, países, u otras unidades de análisis.
- Los datos de corte transversal tienen algunos problemas como la **heterogeneidad** (variabilidad de los resultados estimados entre distintos estudios), aun cuando se obtengan mediante muestreo aleatorio.
- Los datos de corte transversal se denotan con el subíndice i (por ejemplo, Y_i, X_i).

Estructura de datos económicos

Corte transversal/Ejemplos:

- Censo de población y vivienda del INE
- Encuestas de opinión y electorales
- SIMCE (Sistema de Medición de la Calidad de la Educación)
- Informe PISA (Programme for International Student Assessment)
- EPS (Estudios Previsionales de la Subsecretaría de Previsión Social)
- EFH (Encuesta Financiera de Hogares)
- Temperatura en un momento determinado en varios lugares, etc.

Estructura de datos económicos

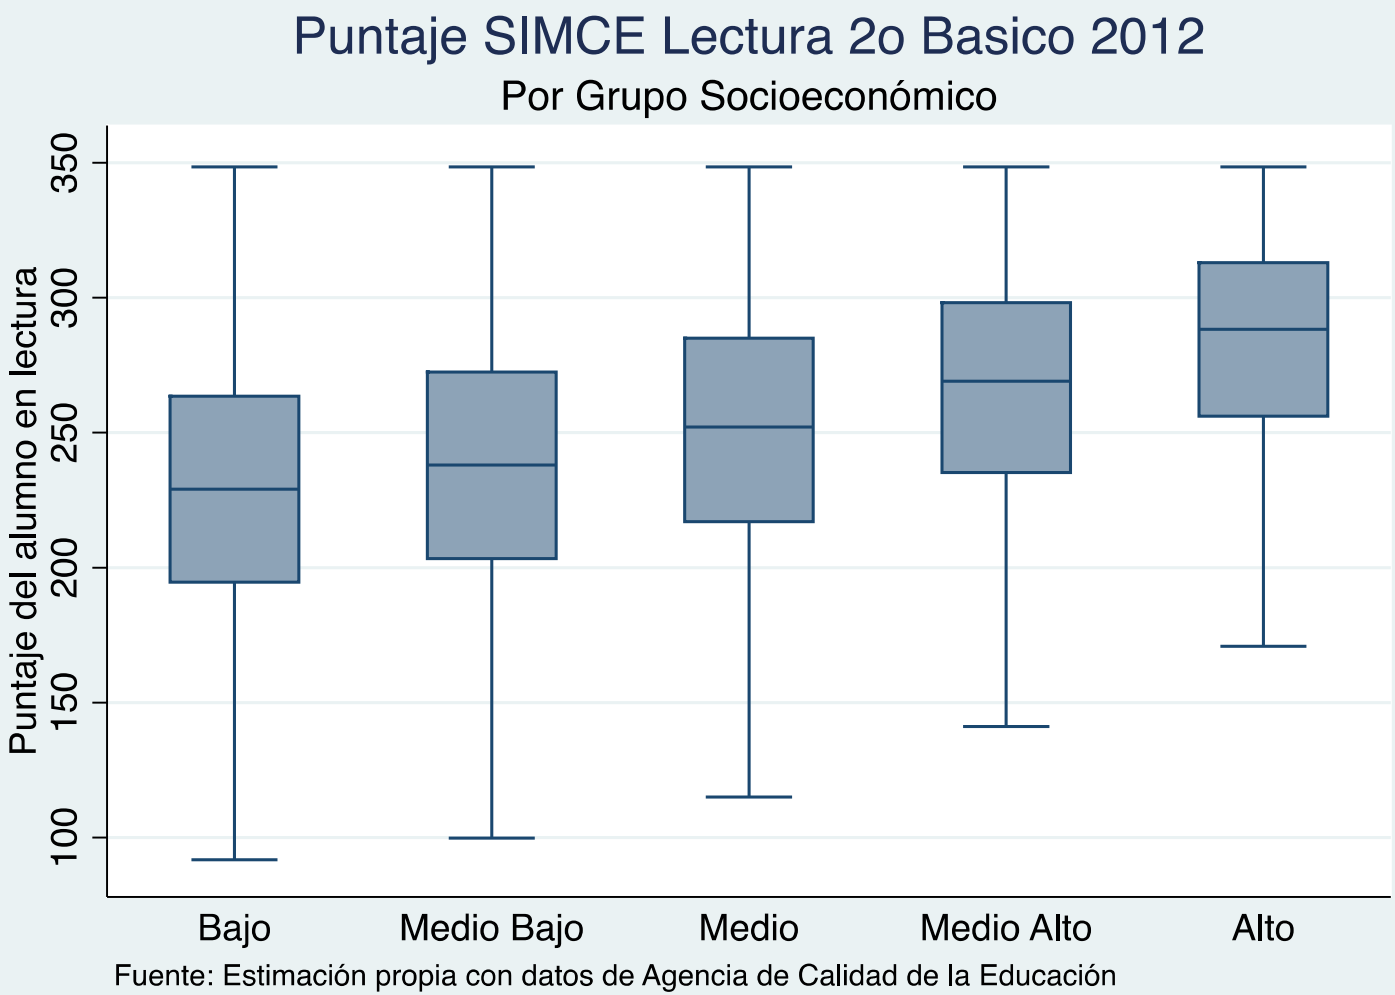

Estructura de datos económicos

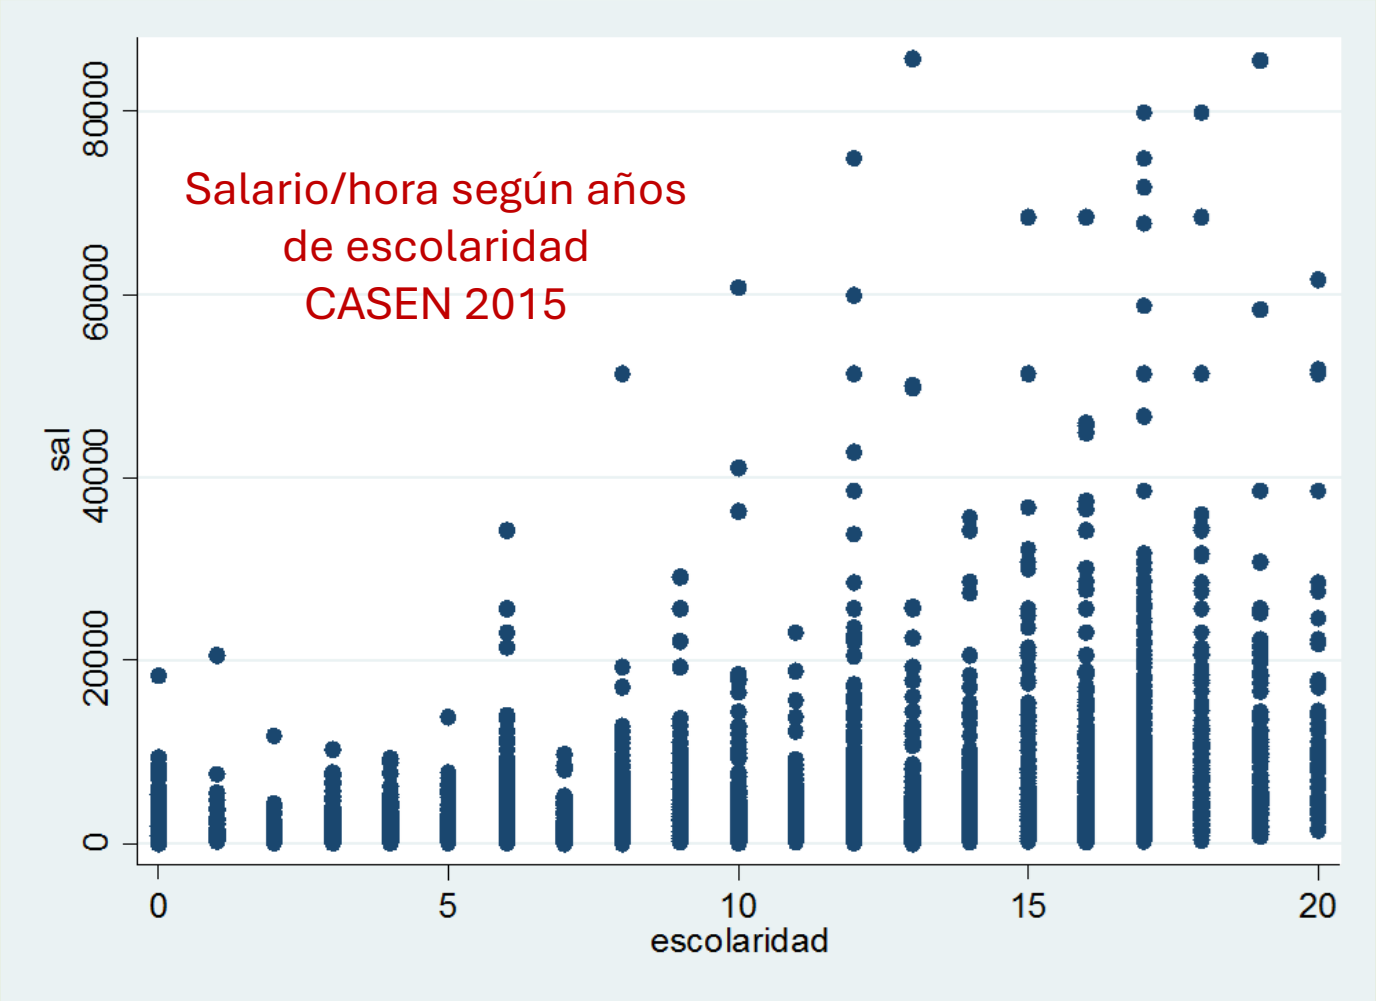

Fuente: elaboración propia con datos CASEN 2015.

Estructura de datos económicos

Series de tiempo:

- **Una serie de tiempo es un conjunto de observaciones (o valores) que toma una variable en diferentes momentos del tiempo.**
- Los datos de alta frecuencia se recopilan durante un período de tiempo extremadamente corto (por ejemplo, operaciones en los mercados de valores y divisas).
- Algunos problemas de este tipo de datos incluyen **autocorrelación** (elementos cercanos en el espacio o en el tiempo se parecen más entre sí que con respecto a elementos más lejanos) y **no estacionariedad** (la media y varianza no son constantes en el tiempo).
- Los datos de series de tiempo se denotan con el subíndice t (por ejemplo, Y_t, X_t).

Estructura de datos económicos

Series de tiempo/ Ejemplos:

- ***Indicadores diarios:*** precios de las acciones, valor del dólar, valor de la UF, informes meteorológicos.
- ***Indicadores semanales:*** oferta monetaria.
- ***Indicadores mensuales*:** tasa de desempleo e IPC
- **Indicadores *trimestrales:*** PIB
- **Indicadores *anuales:*** presupuestos gubernamentales
- **Indicadores *quinquenales:*** censo de empresas manufactureras
- **Indicadores *cada diez años:*** censo de población
- A veces, los datos de un indicador se recopila con múltiples periodicidades (por ejemplo, PIB trimestral y anual).

Estructura de datos económicos

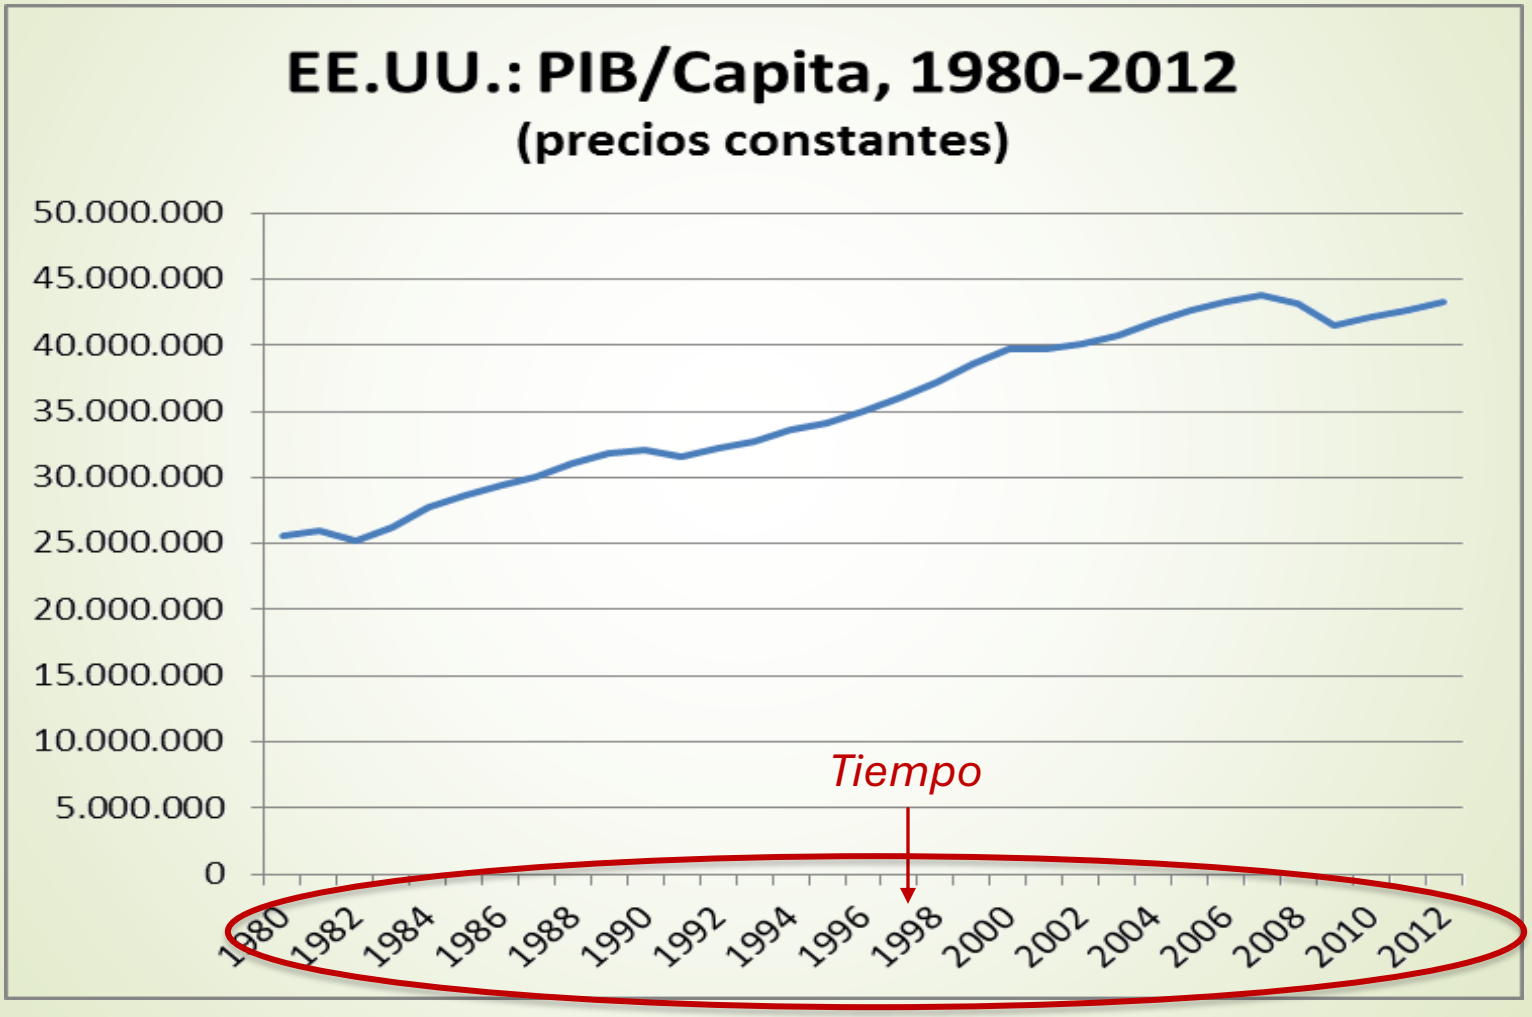

Fuente: Elaboración propia en base a World Economic Outlook Database 2012, FMI.

Estructura de datos económicos

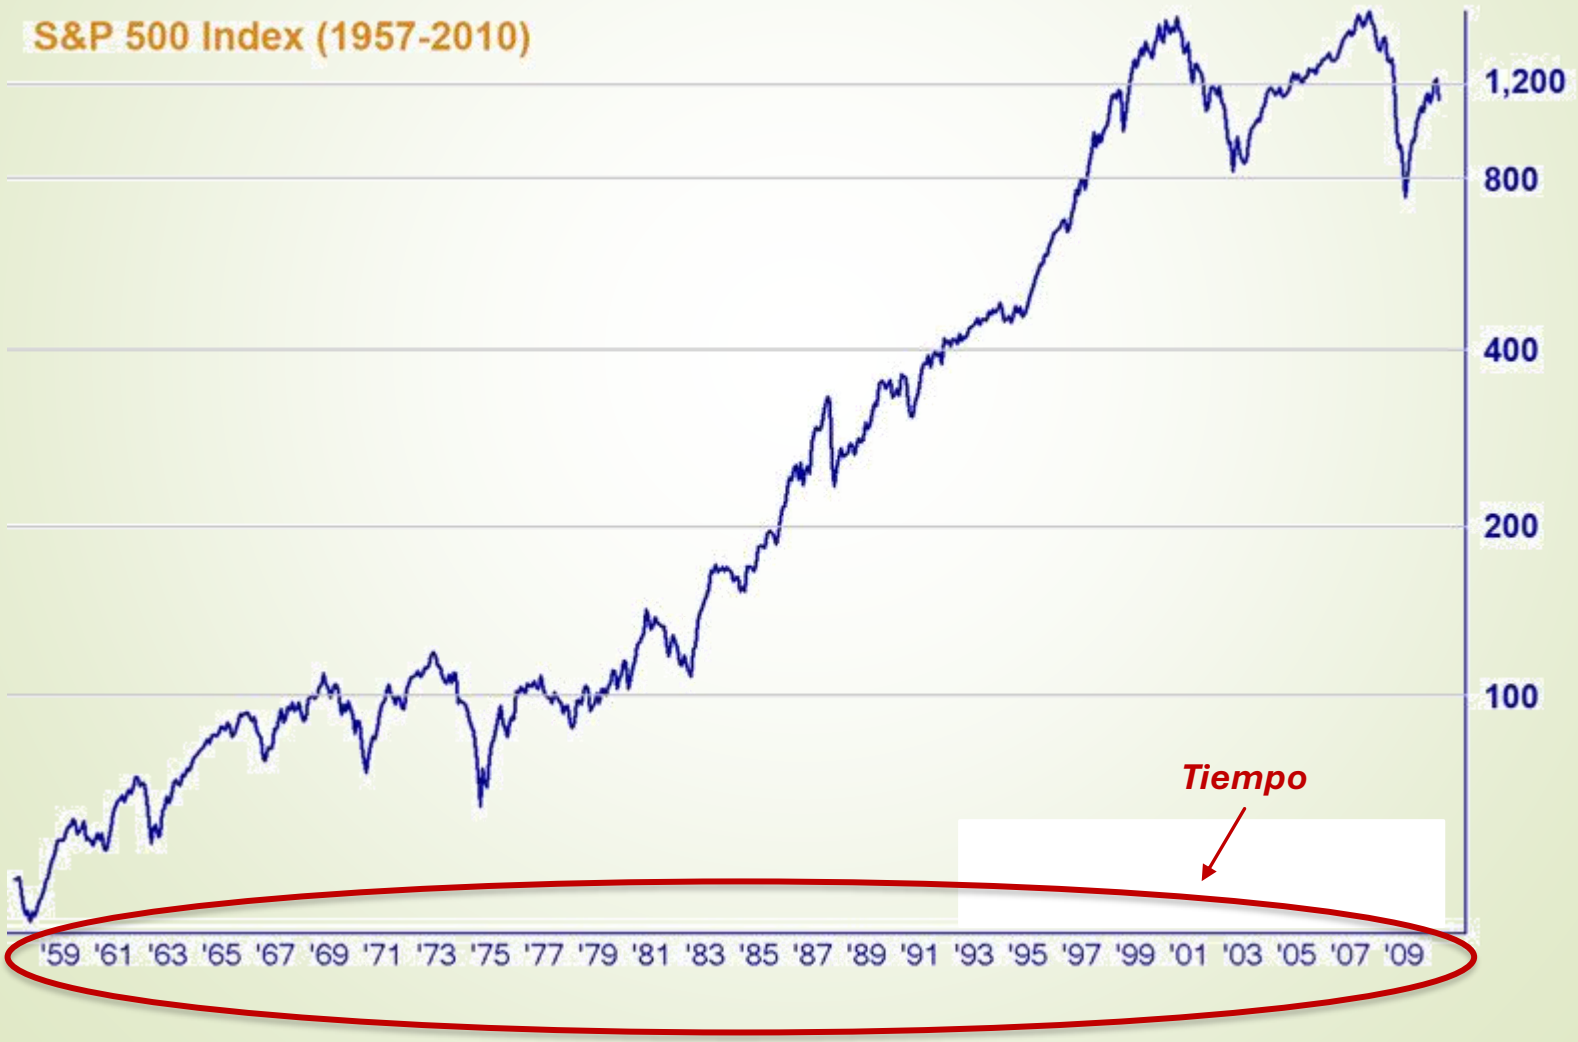

Estructura de datos económicos

Datos de panel o longitudinales:

- **Los datos de panel combinan características de datos de series de tiempo y de corte transversal.**
- Por ejemplo, para estimar una función de producción, podemos tener datos sobre varias empresas (el aspecto transversal) durante un período de tiempo (el aspecto de la serie temporal). Los datos de panel plantean varios desafíos para el análisis de regresión (por ejemplo, heterogeneidad y autocorrelación al mismo tiempo).
- Las observaciones del panel se denotan con el doble subíndice it (por ejemplo, Y_{it}, X_{it}).

Estructura de datos económicos

TABLA 16.16
Tasa de desempleo y salario por hora en el sector manufacturero, en Estados Unidos, Canadá y Reino Unido, 1980-2006.

Fuente: *Economic Report of the President*, enero de 2008, tabla B-109.

Año	Sal_EUA	Desemp_EUA	Sal_CAN	Desemp_CAN	Sal_RU	Desemp_RU
1980	55.9	7.1	49.0	7.3	47.1	6.9
1981	61.6	7.6	53.8	7.3	47.5	9.7
1982	67.2	9.7	60.1	10.7	45.1	10.8
1983	69.3	9.6	64.3	11.6	41.9	11.5
1984	71.6	7.5	65.0	10.9	39.8	11.8
1985	75.3	7.2	65.0	10.2	42.3	11.4
1986	78.8	7.0	64.9	9.3	52.0	11.4
1987	81.3	6.2	69.6	8.4	64.5	10.5
1988	84.1	5.5	78.5	7.4	74.8	8.6
1989	86.6	5.3	85.5	7.1	73.5	7.3

Tipos de variables

- **Variables cuantitativas:**
  - **Variables que se pueden medir numéricamente.**
  - Ejemplos:
    - Precio
    - Tamaño (metros cuadrados)
    - Número de dormitorios
    - Número de baños

Variables cuantitativas: ejemplos

Prueba SIMCE matemáticas (4º básico, 2018)

```
. sum ptje_mate educm gse rural
```

Variable	Obs	Mean	Std. Dev.	Min	Max
ptje_mate	6,179	252.1592	30.0189	131	366
educm	6,557	11.00063	2.477234	0	19.5
gse	6,568	2.31623	1.154713	1	5
rural	6,568	.3651035	.4814958	0	1

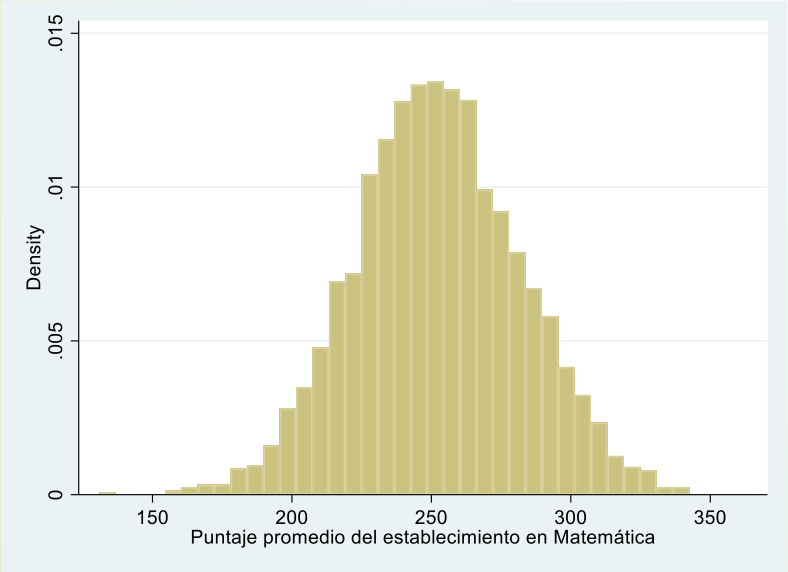

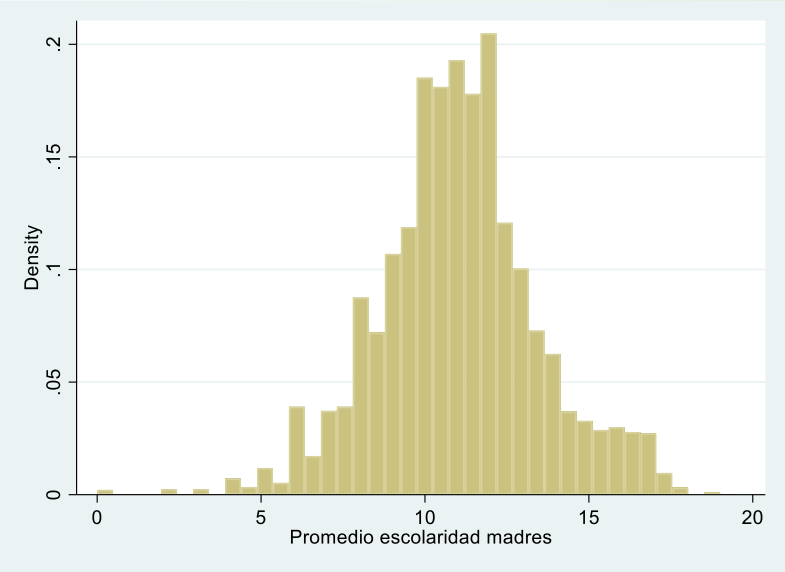

Variables cuantitativas: ejemplos

Prueba SIMCE matemáticas (4º básico, 2018)

```
. sum ptje_mate educm gse rural
```

Variable	Obs	Mean	Std. Dev.	Min	Max
ptje_mate	6,179	252.1592	30.0189	131	366
educm	6,557	11.00063	2.477234	0	19.5
gse	6,568	2.31623	1.154713	1	5
rural	6,568	.3651035	.4814958	0	1

```
. tab rural
```

rural	Freq.	Percent
0	4,170	63.49
1	2,398	36.51
Total	6,568	100.00

```
. tab gse
```

Código de grupo socioeconómico	Freq.	Percent
Bajo	1,847	28.12
Medio bajo	2,225	33.88
Medio	1,461	22.24
Medio alto	642	9.77
Alto	393	5.98
Total	6,568	100.00

Tipos de variables

- **Variables de información cualitativa:**
  - **No se pueden medir numéricamente**
  - Ejemplos:
    - Rural vs urbano
    - Grupo socioeconómico
    - Grupo de ingresos

Tipos de variables

- **Tipos de variables cualitativas:**
  - **Variables categóricas:** se asigna un valor numérico a cada categoría de la variable, pero el número asignado no indica valor
    - Ejemplo: “Bajo”=1, “Medio bajo”=2, “Medio”=3, etc.
  - **Variable binaria (o dummy):** toma valor $[0,1]$ para una dimensión cualitativa de interés
    - Ejemplo: rural =1, urbano=0

Variables cualitativas: ejemplos

Precios y características de departamentos en Viña del Mar, Febrero 2020

barrio	Freq.	Percent
Agua Santa	29	14.50
Centro	32	16.00
Forestal	9	4.50
Libertad	42	21.00
Quinta Vergara	16	8.00
Recreo	16	8.00
Reñaca	56	28.00
Total	200	100.00

Demografía de Estudiantes de Econometría 2015

Sex (1=Female) (0=Male)	Freq.	Percent	Cum.
0	54	49.09	49.09
1	56	50.91	100.00
Total	110	100.00	

Universo *versus* Muestra

- En la práctica, deseamos describir características de una población, pero es muy costoso obtener datos de la población (Ejemplo: censos *vs* Encuesta CASEN)
- Una forma eficiente de estimar las características de una población es con una **muestra**.
- Un **muestreo aleatorio** bien diseñado permite construir una muestra representativa de la población.
- La **inferencia estadística** permite obtener conclusiones sobre una población desde una muestra.

Universo *versus* Muestra

Población

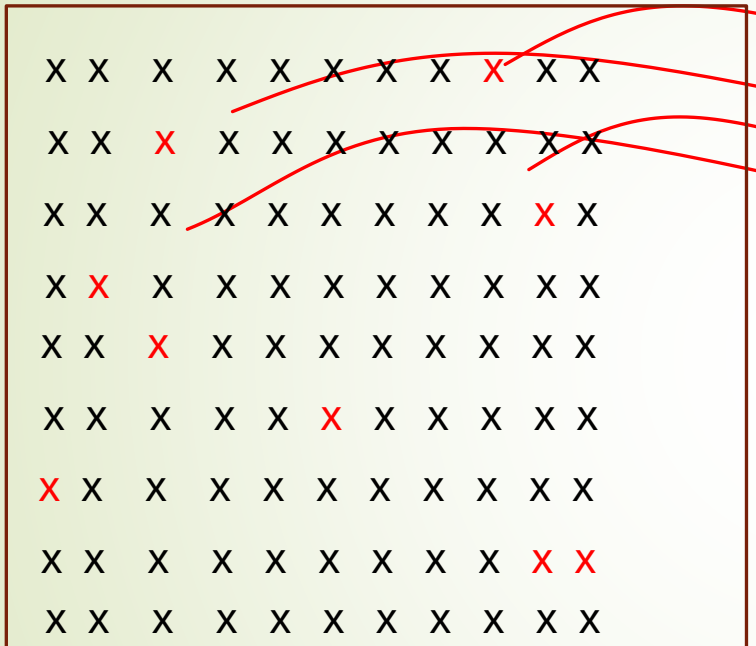

Media → μ
Varianza → σ^2
Desv. Standard → σ

Parámetros poblacionales

Muestra

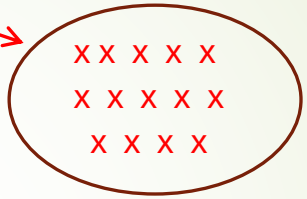

Media → $\bar{X}$

Varianza → $\frac{S^2}{N}$

Desv. Standard → $\frac{S}{\sqrt{N}}$

Estimadores de los parámetros de la población (que no observamos)

¿Qué tan buenos estimadores son de los parámetros poblacionales?

1. Si la muestra es aleatoria, se puede demostrar que $E(\bar{X}) = \mu$
2. Con mayor tamaño muestral, menor varianza y desviación estándar (mayor precisión o eficiencia)

Parámetros de la muestra

$$\boldsymbol{Media\ muestral} = \frac{X_1 + X_1 + \cdots X_N}{N} = \bar{X}$$

$$\boldsymbol{Varianza\ muestral} = \mathrm{s}^2 = \frac{(X_1 - \bar{X})^2 + (X_2 - \bar{X})^2 + \cdots + (X_N - \bar{X})^2}{N - 1}$$

$$\boldsymbol{Desv.Std.muestral} = s = \sqrt{\mathrm{s}^2} = \sqrt{\frac{(X_1 - \bar{X})^2 + (X_2 - \bar{X})^2 + \cdots + (X_N - \bar{X})^2}{N - 1}}$$

Temas de la Unidad 2

1. Introducción: estructura de datos y tipos de variables
2. **El modelo de regresión lineal: terminología y conceptos.**
3. Estimación empleando el método de mínimos cuadrados ordinarios (*MCO, MiCO, OLS*).
4. Medidas de ajuste del método MCO.
5. Propiedades de los estimadores bajo los supuestos clásicos de MCO.
6. Inferencia Estadística

2. El modelo de regresión lineal

A. El modelo de regresión lineal
B. Terminología y conceptos
C. Modelo de regresión lineal simple (MRLS)
D. MRLS: terminología y especificación

Terminología y Conceptos

La Econometría tiene tres aplicaciones principales:

1. **Descripción:** Describir la realidad económica
2. **Predicción:** Predecir actividad económica o decisiones futuras
3. **Causalidad:** Corroborar hipótesis sobre teorías económicas

➨ **En todos los casos, nos interesa la relación entre las variables X e Y**

Terminología y Conceptos

1. **Descripción:** Describir la realidad económica
   - ¿Cómo una variable X se mueve "junto" con una variable Y?

2. **Predicción:** Predecir actividad económica o decisiones futuras
   - ¿Cómo pueden los movimientos de X predecir movimientos en Y?

3. **Causalidad:** Corroborar hipótesis sobre teorías económicas
   - ¿Cuál es el efecto o la consecuencia de un cambio en X sobre Y?

Terminología y Conceptos

¿Cómo podemos aproximar o estimar esta relación $y \approx f(x)$?

- **Ejemplo 1:** y = precio de un departamento, x = tamaño (metros cuadrados)

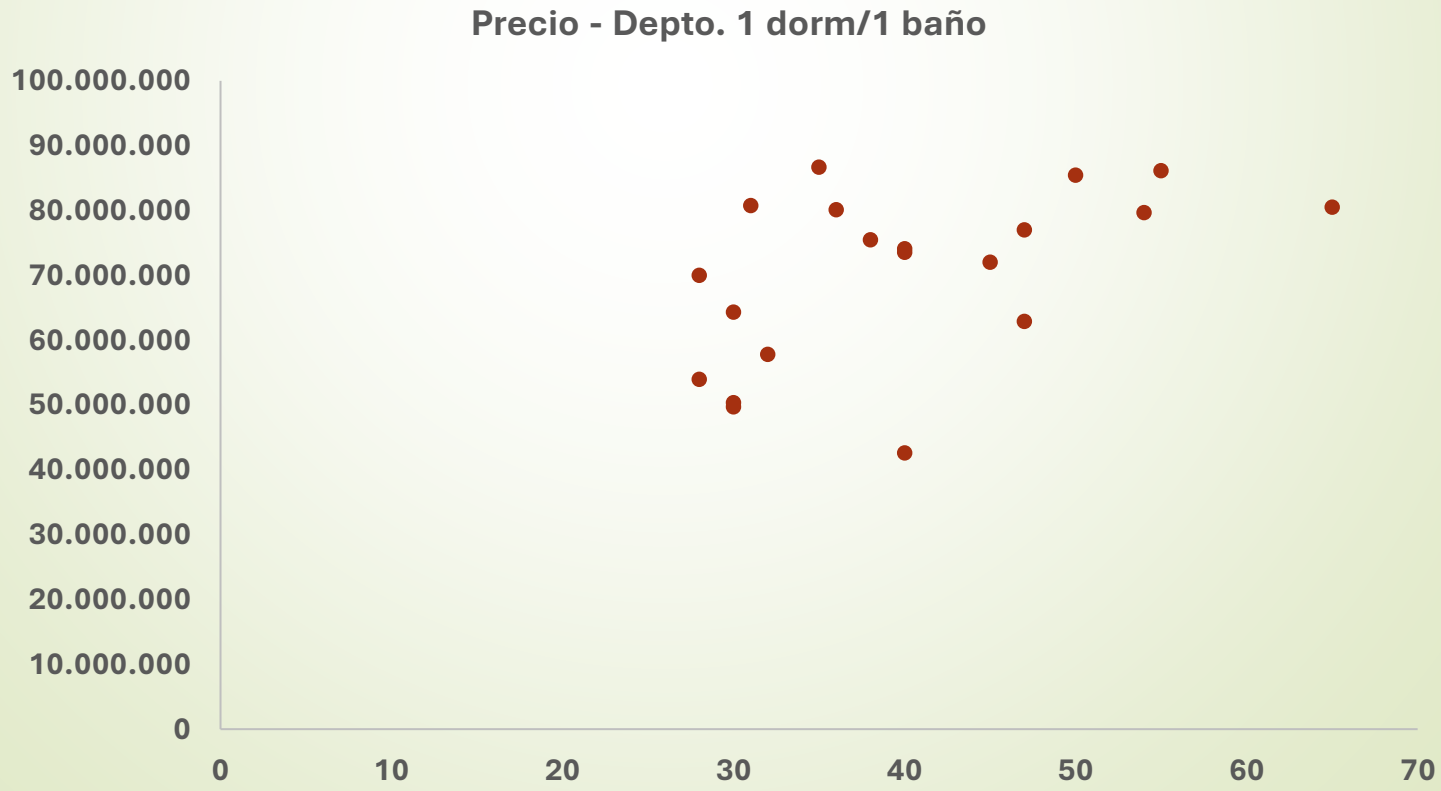

Terminología y Conceptos

- **Análisis de regresión:** método estadístico para estimar relaciones económicas de manera cuantitativa.
- Busca explicar los cambios en una variable (LHS, regresando, dependiente, explicada) como función de otra(s) variable(s) (RHS, regresores, independientes, explicativas).

Terminología y Conceptos

- Se propone esta relación en una **ecuación**.

Regresión simple (una variable aleatoria explicativa)
$y \approx f(x_1)$

Regresión múltiple (varias variables aleatorias explicativas)
$y \approx f(x_1, x_2, x_3)$

  - La ***variable explicada*** $\boldsymbol{y}$ puede ser, por ejemplo, precio
  - Las ***variables explicativas*** pueden ser, por ejemplo, tamaño (x_1), número de dormitorios (x_2), y ubicación/barrio (x_3).
  - La función $f(\cdot)$ explica la relación entre las variables aleatorias.

Terminología y Conceptos

Término de error:

- Incluso en el caso más simple, la variación de Y puede explicarse por variación en X, pero también por otros factores.
- Por eso hemos escrito, hasta ahora, una aproximación: $y \approx f(x)$
- Esos otros factores pueden ser de distinta naturaleza:
  - Variables omitidas
  - Error de medición de las variables
  - Estimar el fenómeno con la forma funcional equivocada
  - Factores aleatorios (debidos al azar)

Terminología y Conceptos

Término de error:

- En econometría, esta variación que no se puede explicar con variables, se introduce al modelo con un término denominado **"*error* estocástico."**
  - Al incluir el ***error*** en una ecuación de regresión, dejamos atrás la aproximación $y \approx f(x)$ para expresar la relación entre x e y como:

$$y = f(x) + u$$

Donde u representa el error estocástico.

Terminología y Conceptos

Causa y efecto:

- Muchas veces nos interesa conocer si el cambio en una variable económica ***causa*** un cambio en otra.
- Por ejemplo: *si el precio aumenta en x%, ¿en cuánto cambiará la demanda?*
- Esto sugiere una relación donde la demanda depende del precio, y de otras variables también.

- **¡ATENCIÓN! El análisis de regresión no puede demostrar causalidad, aún cuando sus estimaciones son estadísticamente significativas.**

Modelo de regresión lineal simple (MRLS)

Función de regresión lineal:

- Ejemplo del caso más simple: $\boldsymbol{Y = \beta_0 + \beta_1 X}$
- Esta función dice que Y (variable explicada) es una función lineal de X (variable explicativa).
- X e Y son variables aleatorias (por ejemplo, tamaño y precio de departamento).
- $\boldsymbol{\beta_0}$ **y** $\boldsymbol{\beta_1}$ se denominan "coeficientes" y son los **parámetros del modelo**: describen la relación cuantitativa entre las variables X e Y.

Modelo de regresión lineal simple (MRLS)

Función de regresión lineal:

- $\boldsymbol{\beta_0}$ es el coeficiente del intercepto u ordenada al origen, llamado también la **constante del modelo**. Indica el valor de Y cuando X es cero (muchas veces no tiene sentido económico, como el tamaño de un departamento, pero es su definición).

- $\boldsymbol{\beta_1}$ es el coeficiente de la **pendiente**. Indica la cantidad de cambio en Y cuando X cambia en una unidad.

MRLS: Motivación

- **Ejemplo 1: precio de departamento de 1 dormitorio y tamaño**
  - Ecuación: $\boldsymbol{precio = \beta_0 + \beta_1 tamaño}$

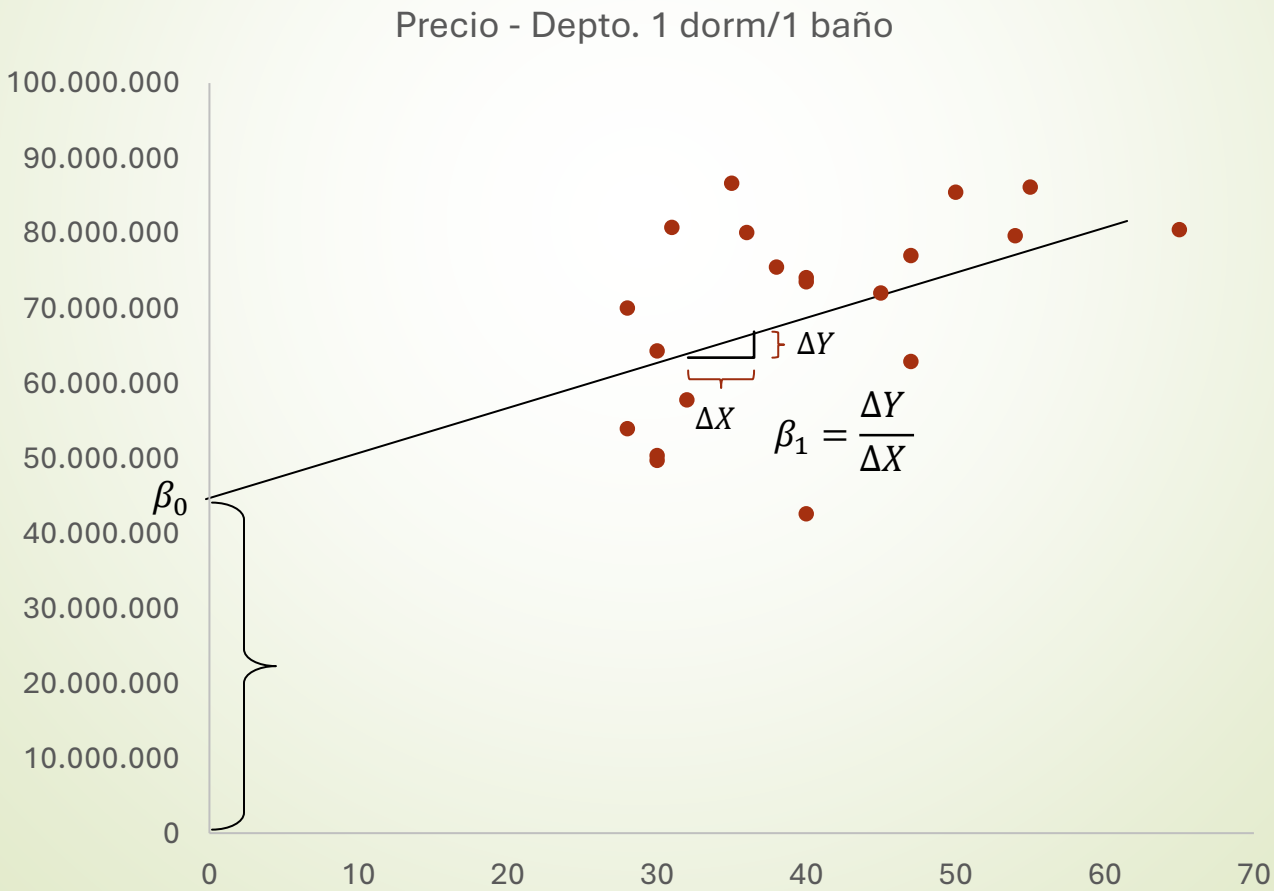

MRLS: Motivación

- **Ejemplo 1: precio de departamento de 1 dormitorio y tamaño**

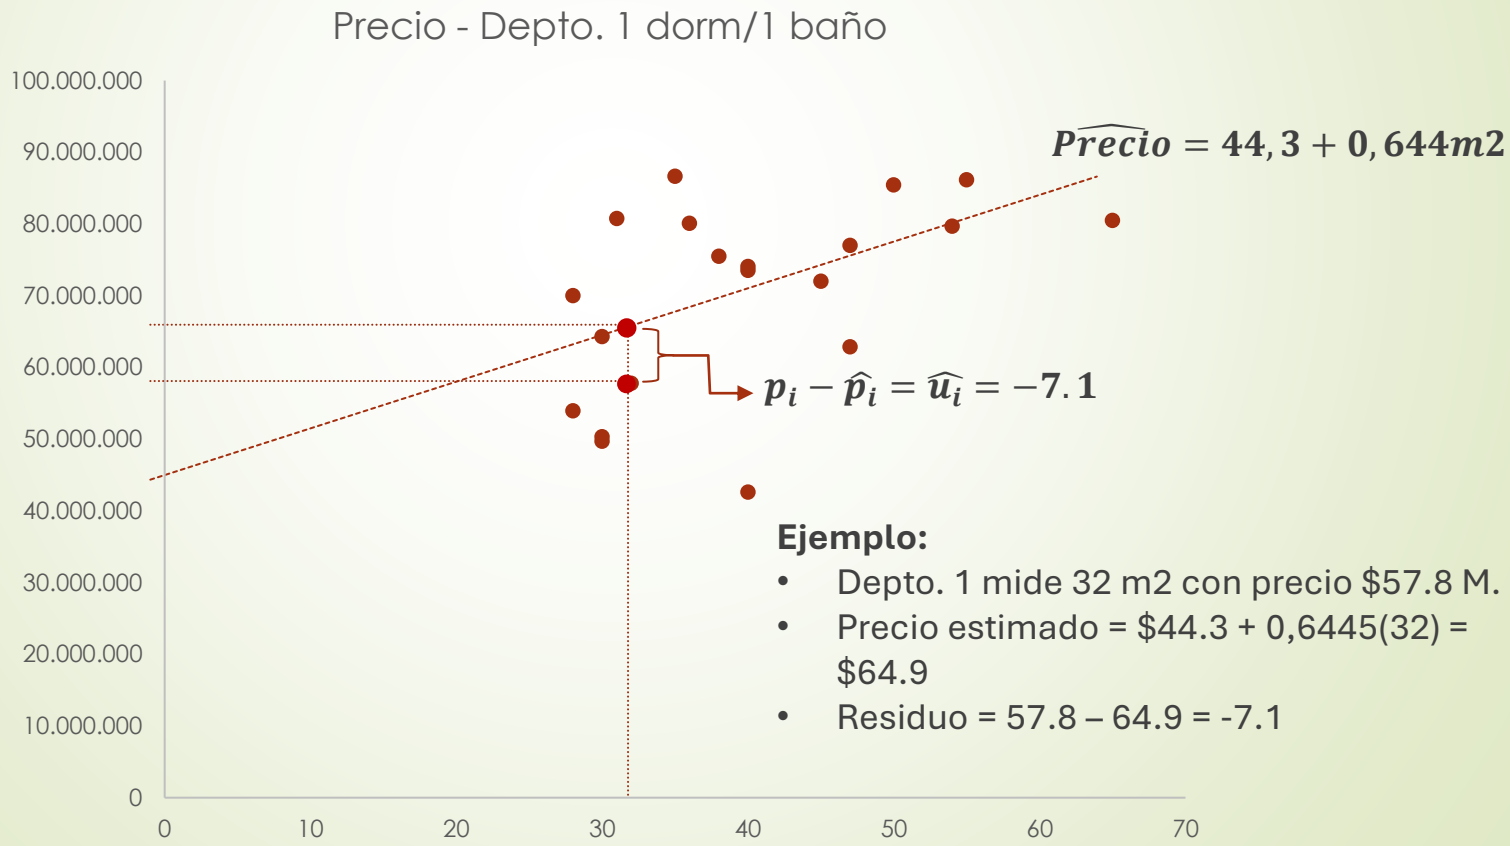

Ejemplo:

- Depto. 1 mide 32 m2 con precio $57.8 M.
- Precio estimado = $44.3 + 0,6445(32) = $64.9
- Residuo = 57.8 – 64.9 = -7.1

MRLS: terminología y especificación

$$\boldsymbol{y} = \boldsymbol{f}(\boldsymbol{x}) + \boldsymbol{u}$$

- La función $f(x)$ puede tomar diversas formas:
  - Lineal
  - Cuadrática
  - Exponencial, entre otras.

- La forma *específica* se conoce como la **forma funcional**. La forma que adopte $f(x)$ será importante en el análisis.

MRLS: terminología y especificación

- Algunas formas funcionales comunes:

Forma funcional	Tipo de Ecuación
Lineal	$Y = \alpha + \beta X$
Log-lineal (doble logarítmica)	$\ln(Y) = \alpha + \beta \ln(X)$
Semi-logarítmica	$\ln(Y) = \alpha + \beta X$
Lineal-recíproco	$Y = \alpha + \frac{\beta}{X}$
Log-recíproco	$\ln(Y) = \alpha + \frac{\beta}{X}$
Lineal log	$Y = \alpha + \beta \ln(X)$

MRLS: terminología y especificación

- **Ejemplo 2: salario y escolaridad**
  - ¿Cuál es el efecto de un año adicional de educación en el salario/hora en Chile?

Salario/hora y Escolaridad en Chile

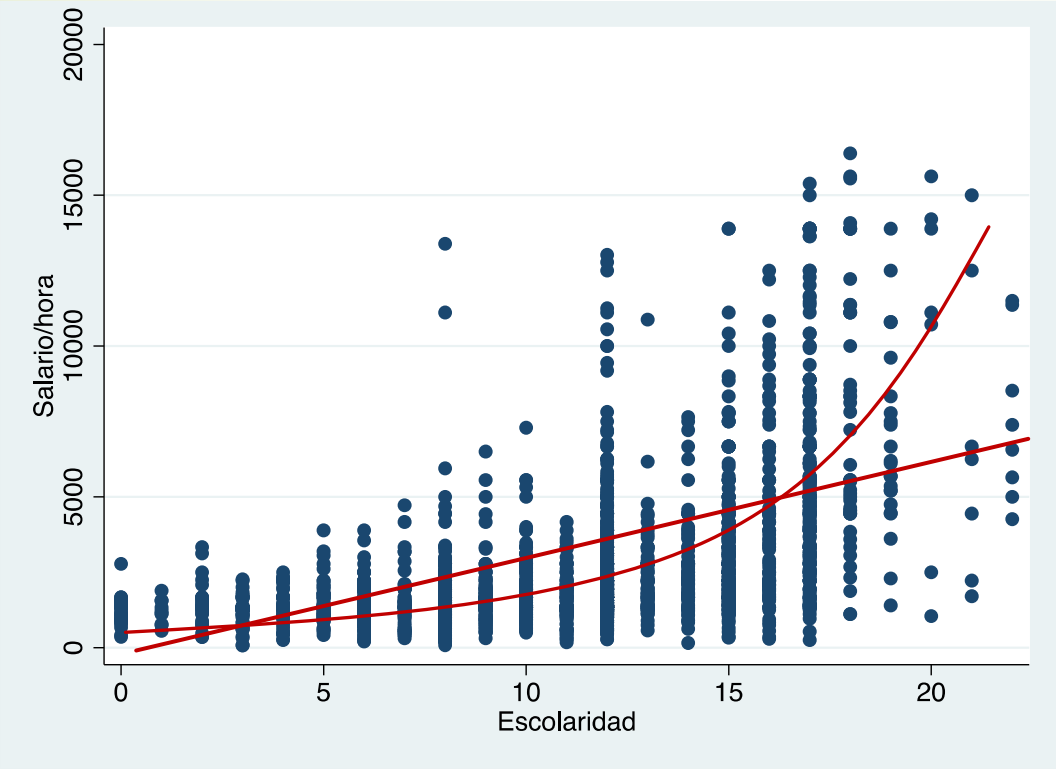

$$y = f(x) + u$$

$$Salario = f(esc) + u$$

Fuente: Encuesta CASEN 2015. Población entre 25-65 años que trabaja 40+ horas.

MRLS: terminología y especificación

Salario/hora y Escolaridad en Chile

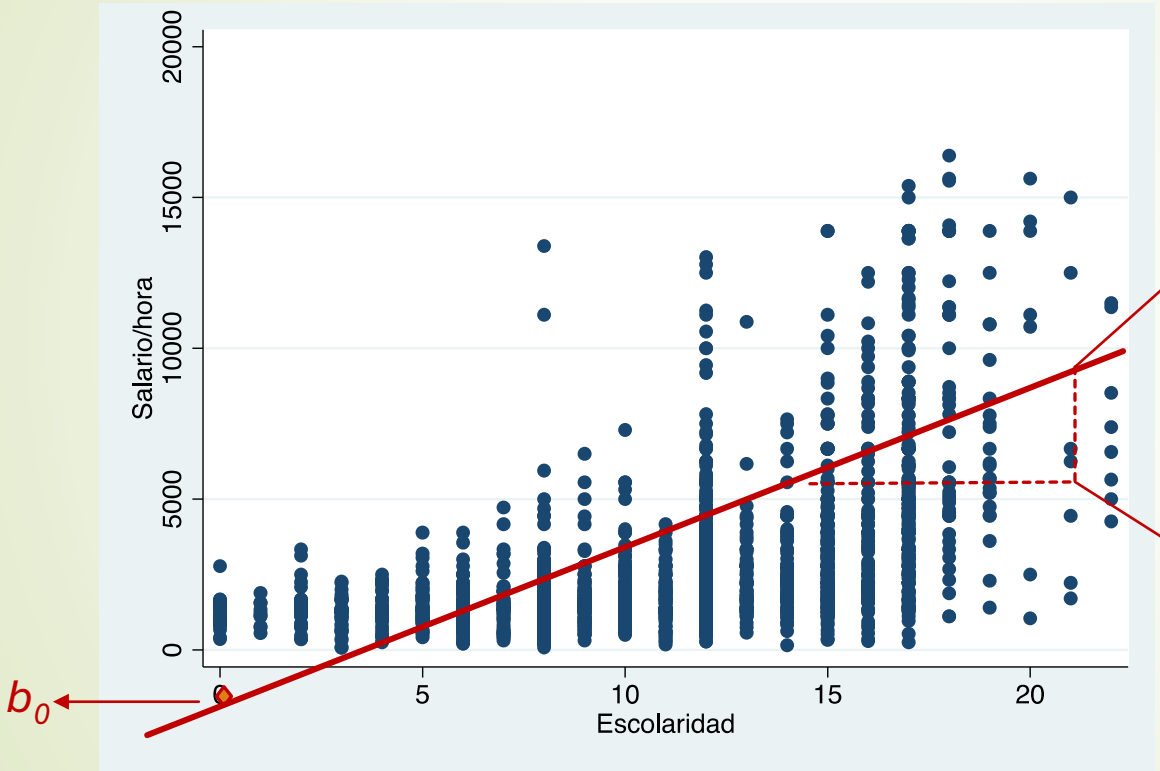

Fuente: Encuesta CASEN 2015. Población entre 25-65 años que trabaja 40+ horas.

$$y = f(x) + u$$

$$Salario = f(esc) + u$$

$$Salario = \beta_0 + \beta_1 \cdot esc + u$$

$$\widehat{Salario} = -416 + 251Esc$$

salario	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
esc	251.124	25.11694	10.00	0.000	201.695	300.5531
_cons	-416.1899	285.8958	-1.46	0.147	-978.8204	146.4407

MRLS: terminología y especificación

- Más generalmente, se puede plantear una relación entre *y* y *x*

$$\boldsymbol{y = \beta_0 + \beta_1 x + \mathrm{u}}$$

Modelo de regresión lineal simple

Sistemática *(explicada por x)*

No sistemática *(no explicada por x)*

$$Ejemplo: \quad Salario = \beta_0 + \beta_1 Esc + u$$

Sistemática *(explicada por Esc)*

No sistemática *(no explicada por Esc)*

MRLS: terminología y especificación

- **Ejemplo 2: escolaridad y salario:**

$$Salario = \beta_0 + \beta_1 Esc + u$$

- Esta relación predice el **nivel de salario/hr. según el nivel de escolaridad de una persona**.
  - b_1 es la pendiente de una línea recta que describe la relación entre salario/hora y escolaridad:

$$E(Salario|esc) = \beta_0 + \beta_1 Esc + E(u)$$

  - *Pero* $E(u) = 0$, *por lo que:*

$$E(Salario|esc) = \beta_0 + \beta_1 Esc$$

MRLS: terminología y especificación

- **Ejemplo 2: escolaridad y salario**

$$Salario = \beta_0 + \beta_1 Esc + u$$

- Esta estimación también entrega información sobre cuánto cambiará el salario si aumenta la escolaridad.

- Es decir, predice ***cambios marginales:***
  - El efecto marginal de un año adicional de escolaridad es $\beta_1 | \Delta u = 0$:

$$\beta_1 = \frac{Cambio\ salario}{cambio\ escolaridad} = \frac{\Delta Salario}{\Delta Escolaridad} \rightarrow \boldsymbol{\Delta Salario = \beta_1 \Delta Escolaridad}$$

MRLS: terminología y especificación

- **Ejemplo 2: escolaridad y salario:**

$$Salario = \beta_0 + \beta_1 Esc + u$$

- Esta relación no se cumple exactamente para todas las personas. La realidad es más compleja.
  - ¿Qué otros factores pueden incidir en el nivel de salario?
  - Se puede expresar:

$$Salario = \beta_0 + \beta_1 Esc + otros\ factores$$

Temas de la Unidad 2

1. Introducción: estructura de datos y tipos de variables
2. El modelo de regresión lineal: terminología y conceptos.
3. **Estimación empleando el método de mínimos cuadrados ordinarios (MCO, MiCO, OLS).**
4. Medidas de ajuste del método MCO.
5. Propiedades de los estimadores bajo los supuestos clásicos de MCO.
6. Inferencia Estadística

3. Estimación empleando el método de Mínimos Cuadrados Ordinarios (MCO, MiCO, OLS)

A. Estimación.
B. Recta de regresión y predicción del modelo.
C. Valores ajustados (predichos) y residuos.
D. Bondad de ajuste.
E. Unidades de medida y forma funcional.

MCO: Estimación

- La regresión estimada con muestra de datos se denomina recta de regresión o línea de regresión.
- ¿Es una buena representación de la **Función de Regresión Poblacional (FRP)**? ¿Bajo qué condiciones?

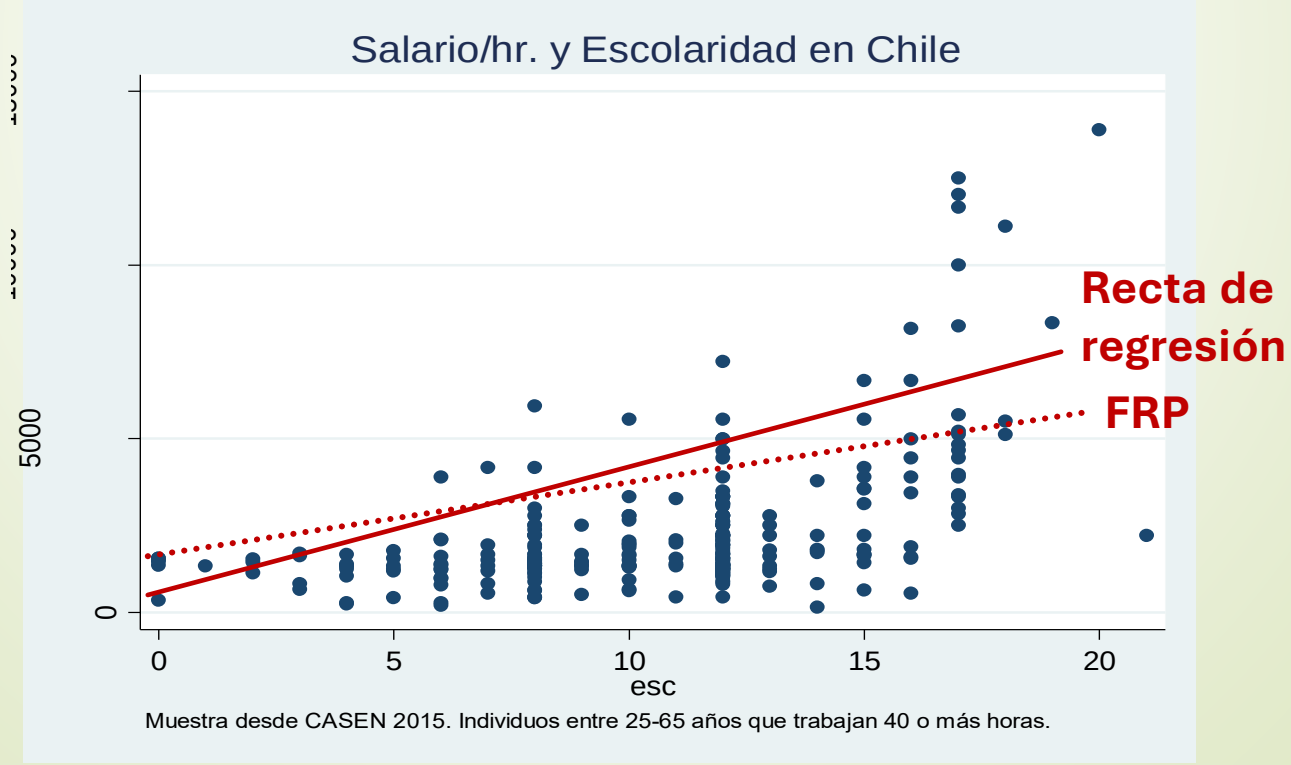

MCO: Estimación

- **Modelo econométrico** a ser estimado con datos: **FUNCIÓN DE REGRESIÓN POBLACIONAL(FRP)**

$$\boldsymbol{y_i = \beta_0 + \beta_1 x_i}$$

  - El subíndice $\boldsymbol{i}$ indica el nivel de observación → ¿qué miden los datos?
  - $\boldsymbol{y_i}$ es valor y de individuo i, $\boldsymbol{x_i}$ es el valor de x del individuo i, $\boldsymbol{u_i}$ es el término de error del individuo i (contiene todos los factores que afectan y_i pero que no se miden con x_i).
  - $\boldsymbol{\beta_0}$ y $\boldsymbol{\beta_1}$ son los parámetros de la FRP, es decir, el intercepto y la pendiente en la población, respectivamente.
  - Con datos observados para (x_i, y_i) se pueden estimar estos parámetros.

MCO: Estimación

- **Modelo estimado:** los estimadores se denominan $\widehat{\beta_0}$ y $\widehat{\beta_1}$
  - El "gorrito" encima de los parámetros indica que fueron estimados desde la muestra.
  - Con la estimación $\widehat{\beta_0}$ y $\widehat{\beta_1}$ podemos predecir el valor de y_i:

    RECTA DE REGRESIÓN DE MCO $\rightarrow \boldsymbol{\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i}$

  - Esta es una **estimación**, es decir que, usualmente, $\hat{y}_i \neq y_i$
  - Buscamos la mejor estimación posible. ¿En qué sentido?

MCO: Estimación

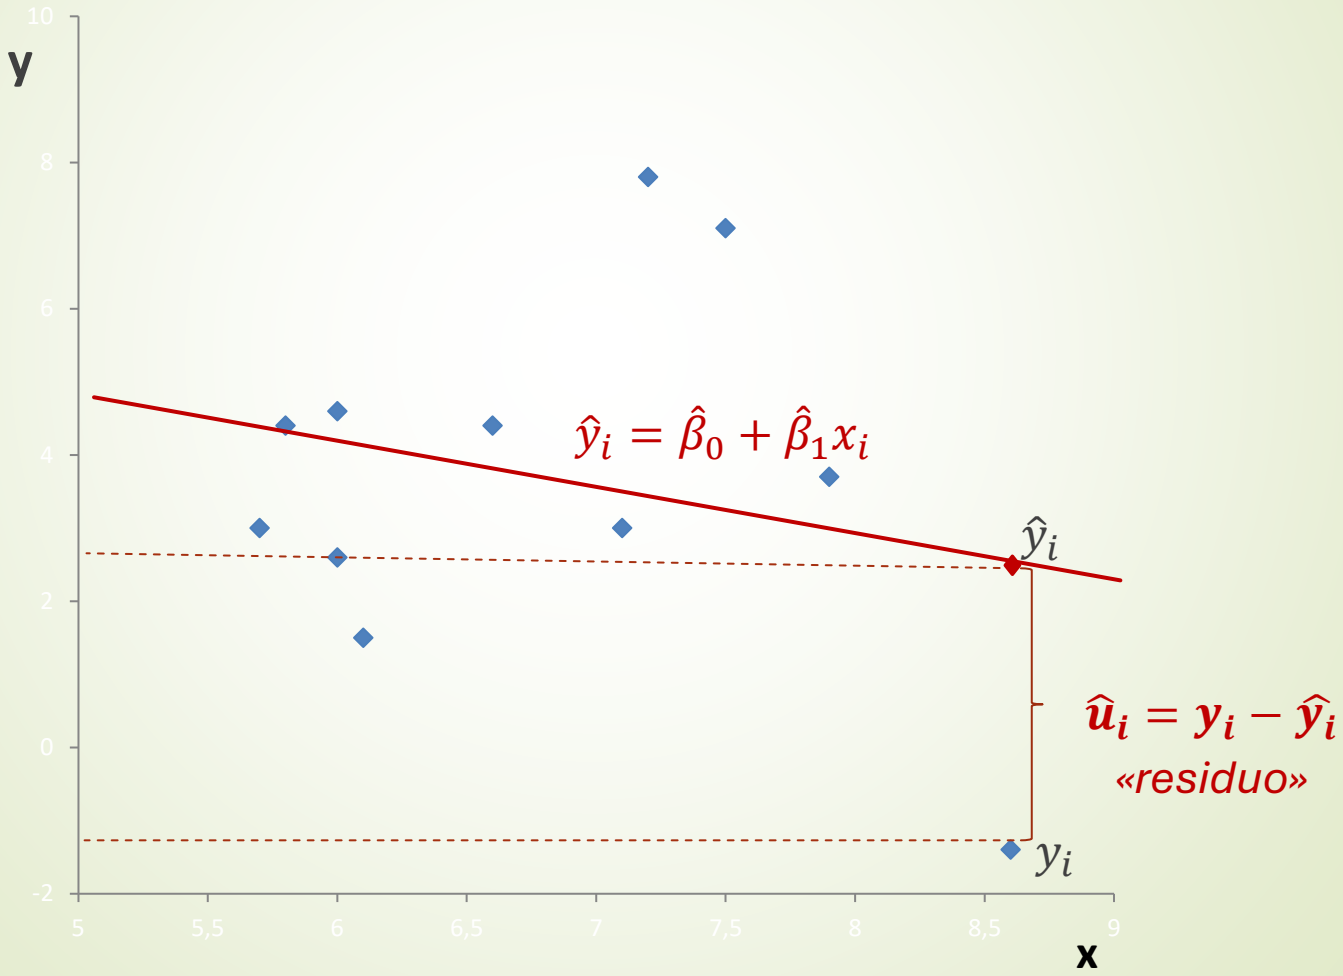

MCO: Estimación

- **Residuo** de la observación i: diferencia entre el valor observado y_i y el valor predicho (o valor ajustado) $\hat{y}_i$

- Con la estimación $\hat{\beta}_0$ y $\hat{\beta}_1$ podemos predecir valores de y_i:

$$\hat{u}_i = y_i - \hat{y}_i$$

$$\hat{u}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$$

- Cada observación i tiene un residuo.

- ¿Cómo obtenemos los estimadores $\hat{\beta}_0$ y $\hat{\beta}_1$?

- **Objetivo: minimizar la distancia (residuo) entre las predicciones $\hat{y}_i$ y los valores observados y_i**

MCO: Estimación

- **Mínimos cuadrados ordinarios (MCO):** busca $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimicen la suma de los cuadrados de los residuos:

$$\min_{\{\hat{\beta}_0,\hat{\beta}_1\}} \sum_{i=1}^{n} \hat{u}_i^2$$

$$\min_{\{\hat{\beta}_0,\hat{\beta}_1\}} \sum_{i=1}^{n} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

- ***TAREA: Demuestre cómo se obtienen los estimadores por MCO (Wooldridge, 2010, Apéndice Cap. 2).***

MCO: Estimación

- Los **estimadores de MCO** de este modelo están dados por:

$$\hat{\beta}_{MCO} = \frac{\sum(x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sum(x_i - \bar{x})^2}$$

Covarianza entre x e y

Varianza de x

$$\hat{\alpha}_{MCO} = \bar{y} - \hat{\beta}_{MCO} \cdot \bar{x}$$

- Observe que $\hat{\beta}_{MCO}$ es simplemente la covarianza muestral entre x y y, dividida por la varianza muestral de x

- Esto tiene sentido porque β es igual a la covarianza poblacional dividida entre la varianza de x cuando $E(u) = 0$ y $Cov(x, u) = 0$

MCO: Estimación

Ejemplo Numérico:

id_firma	y_i	x_i	$(y_i - \bar{y})$	$(x_i - \bar{x})$	$(x_i - \bar{x})^2$	$(x_i - \bar{x}) \cdot (y_i - \bar{y})$	$\hat{y}_i$	$\hat{u}_i = y_i - \hat{y}_i$
1	3874.025	90						
2	530.91	40						
3	59.498	20						
4	393.827	30						
Media								
Suma								

Ahora, trabajemos en MS Excel

MCO: Estimación

Ejemplo Numérico:

id_firma	y_i	x_i	$(y_i - \bar{y})$	$(x_i - \bar{x})$	$(x_i - \bar{x})^2$	$(x_i - \bar{x}) \cdot (y_i - \bar{y})$	$\hat{y}_i$	$\hat{u}_i = y_i - \hat{y}_i$
1	3874.025	90	2659.46	45	2025	119675.7	3763.764	110.261
2	530.91	40	-683.655	-5	25	3418.275	931.3206	-400.411
3	59.498	20	-1155.067	-25	625	28876.67	-201.6567	261.155
4	393.827	30	-820.7379	-15	225	12311.07	364.832	28.995
Media	1214.565	45						
Suma			0	0	2900	164281.72	4858.26	0

$$\hat{\beta}_{MCO} = \frac{\sum(x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sum(x_i - \bar{x})^2} = 56.65$$

$$\hat{\alpha}_{MCO} = \bar{y} - \hat{\beta}_{MCO} \cdot \bar{x} = -1334.63$$

```
. reg y x

      Source |       SS       df       MS              Number of obs =       4
-------------+------------------------------           F(  1,     2) =   77.06
       Model |  9306373.15     1  9306373.15           Prob > F      =  0.0127
    Residual |   241528.66     2   120764.33           R-squared     =  0.9747
-------------+------------------------------           Adj R-squared =  0.9621
       Total |  9547901.81     3  3182633.94           Root MSE      =  347.51

------------------------------------------------------------------------------
           y |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
           x |   56.64887   6.453129     8.78   0.013     28.88329    84.41444
       _cons |  -1334.634   338.4049    -3.94   0.059    -2790.673    121.4048
------------------------------------------------------------------------------
```

MCO: Estimación

RESUMEN:

- El **modelo estadístico** (o **modelo econométrico**) está dado por:

$$\begin{cases} y_i = \alpha + \beta \cdot x_i + u_i \\ E[u_i] = 0 \\ E[u_i|x_i] = 0 \end{cases}$$

  - y_i es la **variable explicada,** dependiente, LHS o regresando
  - x_i es la **variable explicativa**, independiente, RHS o regresor
  - u_i es el **término de error** o determinantes no observados.

- Los **estimadores de MCO** de este modelo están dados por:

$$\boldsymbol{\widehat{\beta}_{MCO} = \frac{\sum(x_i - \overline{x}) \cdot (y_i - \overline{y})}{\sum(x_i - \overline{x})^2}}$$

$$\boldsymbol{\widehat{\alpha}_{MCO} = \overline{y} - \widehat{\beta}_{MCO} \cdot \overline{x}}$$

MCO: Estimación

RESUMEN:

- Los **valores predichos** por el modelo están dados por:

$$\boldsymbol{\hat{y}_i} = \hat{\alpha} + \hat{\beta} \cdot x_i = \left(\bar{y} - \hat{\beta} \cdot \bar{x}\right) + \hat{\beta} \cdot x_i = \bar{y} + \hat{\beta} \cdot (x_i - \bar{x})$$

- Los **residuos de la regresión** están dados por:

$$\boldsymbol{\widehat{u_i}} = y_i - \left(\hat{\alpha} + \hat{\beta} \cdot x_i\right) = y_i - \hat{y}_i$$

- La **suma de residuos al cuadrado** (SRC) corresponde a:

$$SRC = \sum \widehat{u_i}^2 = \sum (y_i - \hat{y}_i)^2$$

MCO: Recta de Regresión y Predicción

Propiedades algebraicas de los estimadores MCO (se cumplen siempre por construcción)

- El promedio de los valores predichos corresponde al promedio de $\boldsymbol{y}$ en la muestra, es decir, $\overline{\hat{\boldsymbol{y}}} = \overline{\boldsymbol{y}}$
- La suma de los residuos del modelo (y, por ende, el promedio muestral de ellos) es igual a 0, es decir, $\sum \widehat{\boldsymbol{u_i}} = \boldsymbol{0}$
- La suma de los productos $(\widehat{u_i} \cdot x_i)$, es decir, la covarianza muestral entre los regresores y los residuos de MCO, es igual a 0 (ortogonalidad), es decir, $\sum \widehat{\boldsymbol{u_i}} \cdot \boldsymbol{x_i} = \boldsymbol{0}$
- La suma de los productos $(\widehat{u_i} \cdot \hat{y}_i)$ es igual a 0 (ortogonalidad), es decir, $\sum \widehat{\boldsymbol{u_i}} \cdot \hat{\boldsymbol{y}}_{\boldsymbol{i}} = \boldsymbol{0}$

MCO: Recta de Regresión y Predicción

Ejemplo: Salario horario versus escolaridad

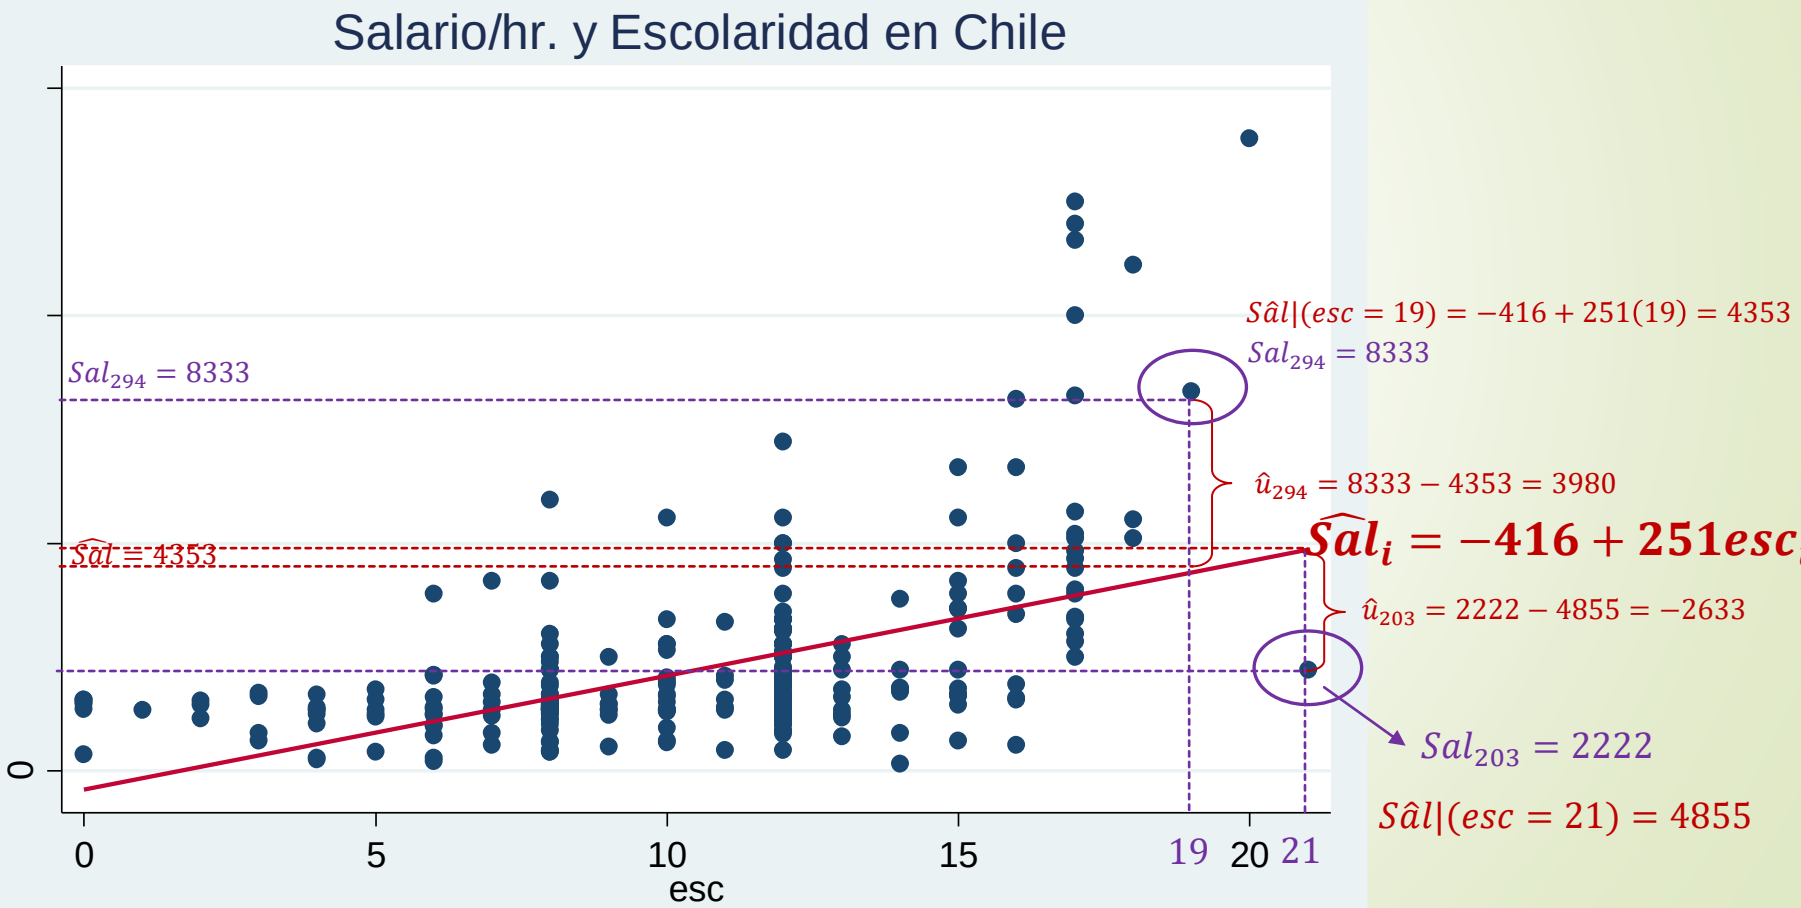

Muestra desde CASEN 2015. Individuos entre 25-65 años que trabajan 40 o más horas.

MCO: Recta de Regresión y Predicción

Estimador MCO:

$$\hat{\beta}_{MCO} = \frac{\sum(x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sum(x_i - \bar{x})^2}$$

$$\hat{\alpha}_{MCO} = \bar{y} - \hat{\beta}_{MCO} \cdot \bar{x}$$

Recta de regresión MCO:

$$\hat{y}_i = \hat{\alpha} + \hat{\beta} x_i$$

Después de estimar la regresión, cabe preguntarse:

1. *¿Qué tan "bueno" es el ajuste del modelo a los datos?*
2. *¿Bajo qué supuestos/modelo son $\hat{\alpha}$ y $\hat{\beta}$ "buenos" estimadores?*
3. *¿Cuándo se puede interpretar $\hat{\beta}$ como un efecto causal?*
4. *¿Cómo se construye un intervalo de confianza para $\hat{\alpha}$ y $\hat{\beta}$?*

Temas de la Unidad 2

1. Introducción: estructura de datos y tipos de variables
2. El modelo de regresión lineal: terminología y conceptos.
3. Estimación empleando el método de mínimos cuadrados ordinarios (*MCO, MiCO, OLS*).
4. **Medidas de ajuste del método MCO.**
5. Propiedades de los estimadores bajo los supuestos clásicos de MCO.
6. Inferencia Estadística

4. Medidas de ajuste del método MCO

A. MCO: bondad de ajuste y dispersión
B. Unidades de medida y forma funcional

MCO: Bondad de ajuste y dispersión

- Queremos saber: **¿qué tan bien se ajusta la recta de la regresión a los datos?**
- Definimos los siguientes conceptos:

STC (Suma total de los cuadrados ó TSS):

$$STC \equiv \sum_{i=1}^{n} (y_i - \bar{y})^2$$

Variación muestral de y_i (del valor observado)

SEC (Suma explicada de los cuadrados ó ESS):

$$SEC \equiv \sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2$$

Variación muestral de $\hat{y}_i$ (del valor predicho)

SRC (Suma de los residuos al cuadrado ó RSS):

$$SRC \equiv \sum_{i=1}^{n} \hat{u}_i{}^2$$

Variación muestral de $\hat{u}_i$ (del residuo, lo que **no** predice el modelo)

MCO: Bondad de ajuste y dispersión

- Dado que podemos escribir:

$$y_i = \hat{y}_i + \hat{u}_i$$

- Entonces, podemos mostrar que la variación total de y es igual a la suma de la variación del valor predicho $\hat{y}$ y la variación de los residuos $\hat{u}$:

$$STC = SEC + SRC$$

MCO: Bondad de ajuste y dispersión

- **Bondad de ajuste:** es una medida de qué tan bien la regresión ajusta a los datos disponibles:

$$R^2 = \frac{SEC}{STC} = 1 - \frac{SRC}{STC}$$

  - Es la proporción de la variación total explicada por el modelo.
  - No tiene unidades de medida.
  - Su valor está entre 0 y 1; a veces se multiplica x 100 y expresa en %.

MCO: Bondad de ajuste y dispersión

- **Error estándar de la regresión**: corresponde al estimador de la desviación estándar del error de la regresión.
- Nunca observamos el error u_i pero sí su homólogo muestral, el residuo $\hat{u}_i$
- Se define el EER como:

$$\boldsymbol{s_{\hat{u}} = \sqrt{s_{\hat{u}}^2} = \sqrt{\frac{\sum \hat{u}_i^2}{n - \#parametros}}}$$

  - *# parámetros* corresponde al número de parámetros del modelo. En el caso de la regresión lineal simple es 2.
  - Mide la dispersión de las observaciones entorno a la recta de la regresión.
  - Unidades de medida son las mismas que la variable dependiente.

MCO: Bondad de ajuste y dispersión

- **Modelo a estimar:** $salario = \beta_0 + \beta_1 esc$
- **Bondad de Ajuste:** $R^2 = \frac{SEC}{STC} = \frac{\boldsymbol{ESS}}{\boldsymbol{TSS}}$
- **Error estándar de la regresión:** $s_{\hat{u}} = \sqrt{s_{\hat{u}}^2} = \sqrt{\frac{\sum \hat{u}_i^2}{n-\#pars}} = \sqrt{\frac{\boldsymbol{RSS}}{\boldsymbol{df}}}$

```
. reg salario esc

      Source |       SS           df       MS      Number of obs   =       300
-------------+----------------------------------   F(1, 298)       =     99.96
       Model |  286521448         1  286521448    Prob > F        =    0.0000
    Residual |  854142568       298  2866250.23   R-squared       =    0.2512
-------------+----------------------------------   Adj R-squared   =    0.2487
       Total | 1.1407e+09       299  3814929.82   Root MSE        =      1693

------------------------------------------------------------------------------
     salario |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
         esc |    251.124   25.11694    10.00   0.000      201.695    300.5531
       _cons |  -416.1899   285.8958    -1.46   0.147    -978.8204    146.4407
------------------------------------------------------------------------------
```

MCO: Unidades de medida y forma funcional

- ¿Qué ocurre con las estimaciones MCO cuando cambian las unidades de medida de la variable explicada o de las variables explicativas?

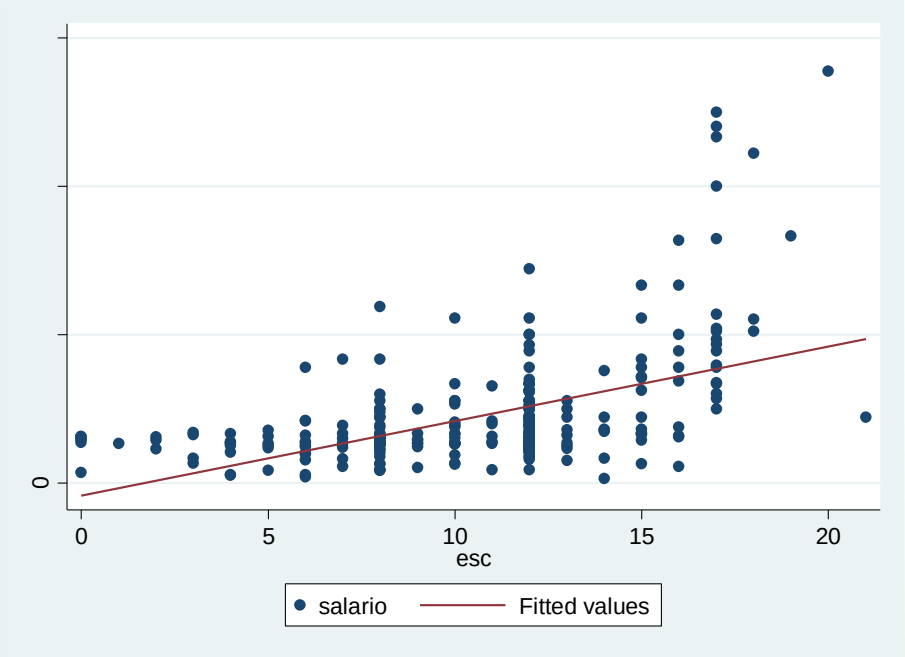

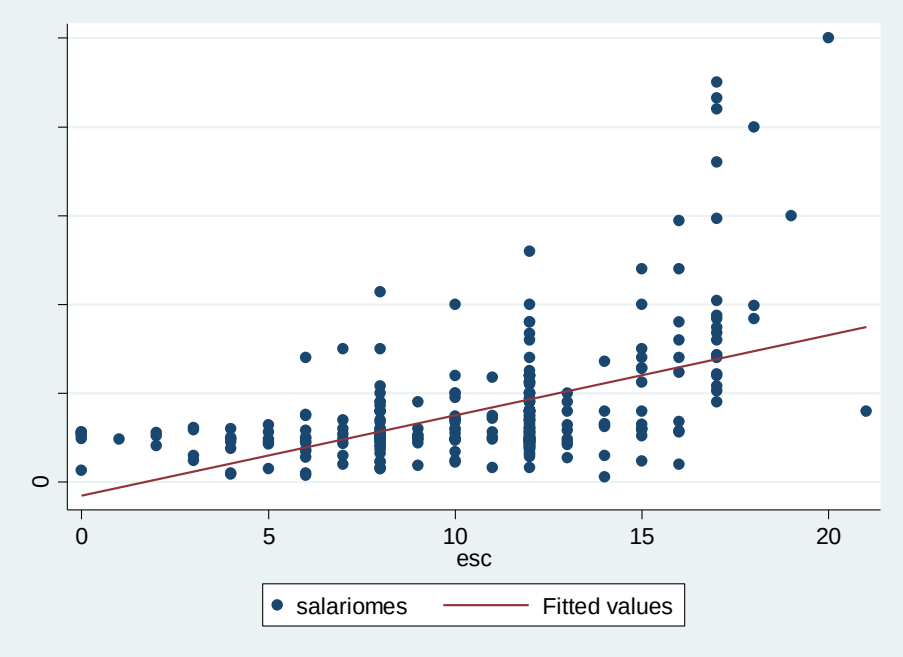

MCO: Unidades de medida y forma funcional

- **¿Qué ocurre con los resultados si cambian la medidas de las variables empleadas en la regresión?**

- <u>Cambio de medida de la variable explicada (Y)</u>:

  Sea $y_2 = c_1 \cdot y$. Si $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$, entonces $\widehat{y_2} = c_1\hat{\beta}_0 + c_1\hat{\beta}_1 x$

- <u>Cambio de medida de la variable explicativa (X)</u>:

  Sea $x_2 = c_1 \cdot x$. Si $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$, entonces $\hat{y} = \hat{\beta}_0 + \frac{1}{c_1}\hat{\beta}_1 x_2$

MCO: Unidades de medida y forma funcional

Cambio de medida de la variable explicada (Y)

```
. reg salario esc

      Source |       SS           df       MS      Number of obs   =       300
-------------+----------------------------------   F(1, 298)       =     99.96
       Model |  286521448         1  286521448    Prob > F        =    0.0000
    Residual |  854142568       298  2866250.23   R-squared       =    0.2512
-------------+----------------------------------   Adj R-squared   =    0.2487
       Total | 1.1407e+09       299  3814929.82   Root MSE        =      1693

------------------------------------------------------------------------------
     salario |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
         esc |   251.124   25.11694    10.00   0.000     201.695    300.5531
       _cons |  -416.1899   285.8958    -1.46   0.147   -978.8204    146.4407
------------------------------------------------------------------------------

. gen salariomes=salario*180

. reg salariomes esc

      Source |       SS           df       MS      Number of obs   =       300
-------------+----------------------------------   F(1, 298)       =     99.96
       Model |  9.2833e+12         1  9.2833e+12   Prob > F        =    0.0000
    Residual |  2.7674e+13       298  9.2867e+10   R-squared       =    0.2512
-------------+----------------------------------   Adj R-squared   =    0.2487
       Total |  3.6958e+13       299  1.2360e+11   Root MSE        =    3.0e+05

------------------------------------------------------------------------------
  salariomes |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
         esc |   45202.32   4521.049    10.00   0.000     36305.09    54099.55
       _cons |  -74914.17   51461.24    -1.46   0.147    -176187.7    26359.32
------------------------------------------------------------------------------
```

MCO: Unidades de medida y forma funcional

Cambio de medida de la variable explicativa (X)

```
. reg salario esc

      Source |       SS           df       MS      Number of obs   =       300
-------------+----------------------------------   F(1, 298)       =     99.96
       Model |  286521448         1  286521448    Prob > F        =    0.0000
    Residual |  854142568       298  2866250.23   R-squared       =    0.2512
-------------+----------------------------------   Adj R-squared   =    0.2487
       Total | 1.1407e+09       299  3814929.82   Root MSE        =      1693

------------------------------------------------------------------------------
     salario |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
         esc |   251.124   25.11694    10.00   0.000     201.695    300.5531
       _cons |  -416.1899   285.8958    -1.46   0.147    -978.8204    146.4407
------------------------------------------------------------------------------

. gen escmeses=esc*12

. reg salario escmeses

      Source |       SS           df       MS      Number of obs   =       300
-------------+----------------------------------   F(1, 298)       =     99.96
       Model |  286521448         1  286521448    Prob > F        =    0.0000
    Residual |  854142568       298  2866250.23   R-squared       =    0.2512
-------------+----------------------------------   Adj R-squared   =    0.2487
       Total | 1.1407e+09       299  3814929.82   Root MSE        =      1693

------------------------------------------------------------------------------
     salario |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
    escmeses |    20.927   2.093078    10.00   0.000    16.80791    25.04609
       _cons |  -416.1899   285.8958    -1.46   0.147    -978.8204    146.4407
------------------------------------------------------------------------------
```

MCO: Unidades de medida y forma funcional

- **¿Cómo se abordan relaciones económicas que no son lineales con regresión lineal?**
- Regresión lineal → lineal **en los parámetros**
- Se pueden transformar las variables de manera no-lineal

MCO: Unidades de medida y forma funcional

- **Ejemplo: relación ingresos y educación**
  - Relación lineal: se interpreta como el efecto lineal de 1 año adicional de escolaridad sobre el salario
  - ¿Qué sucede si el impacto de la escolaridad aumenta con el nivel? Es decir, pasar de 16 a 17 años de escolaridad tiene mayor impacto que pasar de 7 a 8 años
    - *Rendimiento creciente* de la educación
  - Una forma funcional posible (y más realista) es:

$$\boldsymbol{Ingreso = \exp(\beta_0 + \beta_1 \cdot esc)}$$

MCO: Unidades de medida y forma funcional

Relación Lineal

$$salario = \beta_0 + \beta_1 \cdot esc$$

Relación Exponencial

$$salario = \exp(\beta_0 + \beta_1 \cdot esc)$$

Relación "linealizada"

$$\ln(salario) = \beta_0 + \beta_1 \cdot esc$$

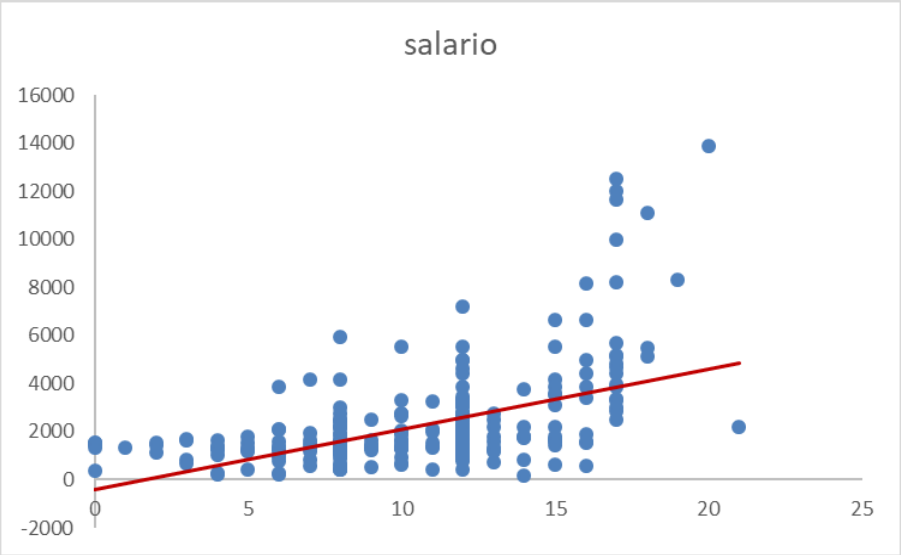

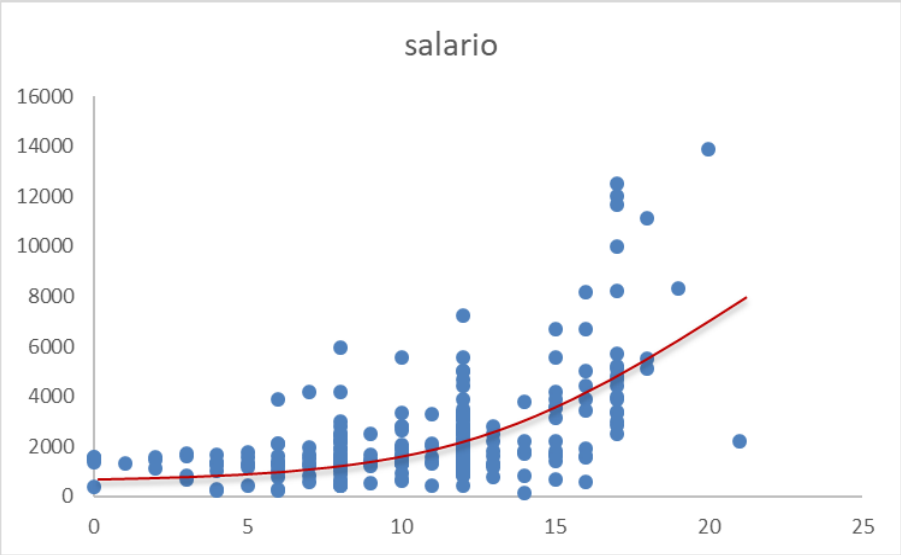

$$\widehat{Salario} = -416.19 + 251.12 \cdot esc$$

$$\widehat{lnSalario} = 6.555 + 0.0871 \cdot esc$$

MCO: Unidades de medida y forma funcional

```
. gen lnsalario=log(salario)

. reg lnsalario esc

      Source |       SS           df       MS      Number of obs   =       300
-------------+----------------------------------   F(1, 298)       =    100.38
       Model |  34.4884019         1  34.4884019   Prob > F        =    0.0000
    Residual |  102.390223       298  .343591353   R-squared       =    0.2520
-------------+----------------------------------   Adj R-squared   =    0.2495
       Total |  136.878625       299  .457788044   Root MSE        =    .58617

------------------------------------------------------------------------------
   lnsalario |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
         esc |   .0871257   .0086962    10.02   0.000     .0700119    .1042395
       _cons |   6.554792   .0989856    66.22   0.000     6.359992    6.749591
------------------------------------------------------------------------------
```

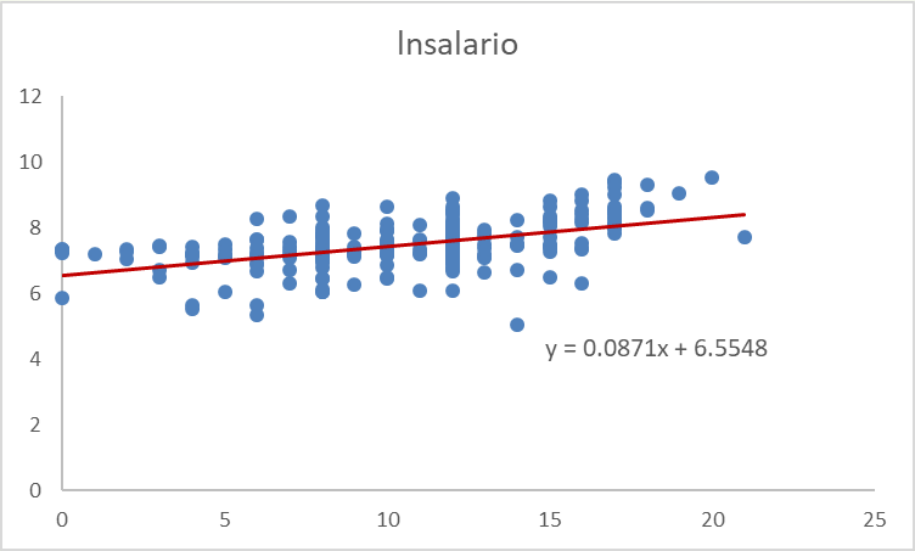

Temas de la Unidad 2

1. Introducción: estructura de datos y tipos de variables
2. El modelo de regresión lineal: terminología y conceptos.
3. Estimación empleando el método de mínimos cuadrados ordinarios (*MCO, MiCO, OLS*).
4. Medidas de ajuste del método MCO.
5. **Propiedades de los estimadores bajo los supuestos clásicos de MCO.**
6. Inferencia Estadística

5. Propiedades de los estimadores bajo los supuestos clásicos del MCO

A. MCO: supuestos clásicos
B. Propiedades de los estimadores de MCO

MCO: supuestos clásicos

- **Supuesto 1 (S1)**: **Modelo lineal en los parámetros**

  En el modelo poblacional, la variable explicada, y, está relacionada con la variable explicativa, x, y con el error (o perturbación), u, de la manera siguiente:

$$y_i = \alpha + \beta \cdot x_i + u_i$$

  donde α y β son los parámetros poblacionales correspondientes al intercepto y a la pendiente, respectivamente. Es decir, los parámetros tienen una relación lineal con y, aun cuando y o x entren no-linealmente en el modelo.

MCO: supuestos clásicos

- **Supuesto 2 (S2): Muestra aleatoria**

  Se cuenta con una muestra de N observaciones de los pares $(y_i, x_i)_{i=1}^{N}$, proveniente de un muestreo aleatorio del modelo estadístico definido por los supuestos anteriores.

- **Supuesto 3 (S3): No hay multicolinealidad**

  No hay relaciones lineales perfectas entre las variables x que conforman el modelo, es decir, no hay información redundante.

MCO: supuestos clásicos

- **Supuesto 4 (S4)**: **Exogeneidad**

La esperanza condicional en X del error es nula, es decir,

$$E[u_i|x_i] = 0$$

Si X es no-estocástica, entonces,

$$E[u_i] = 0$$

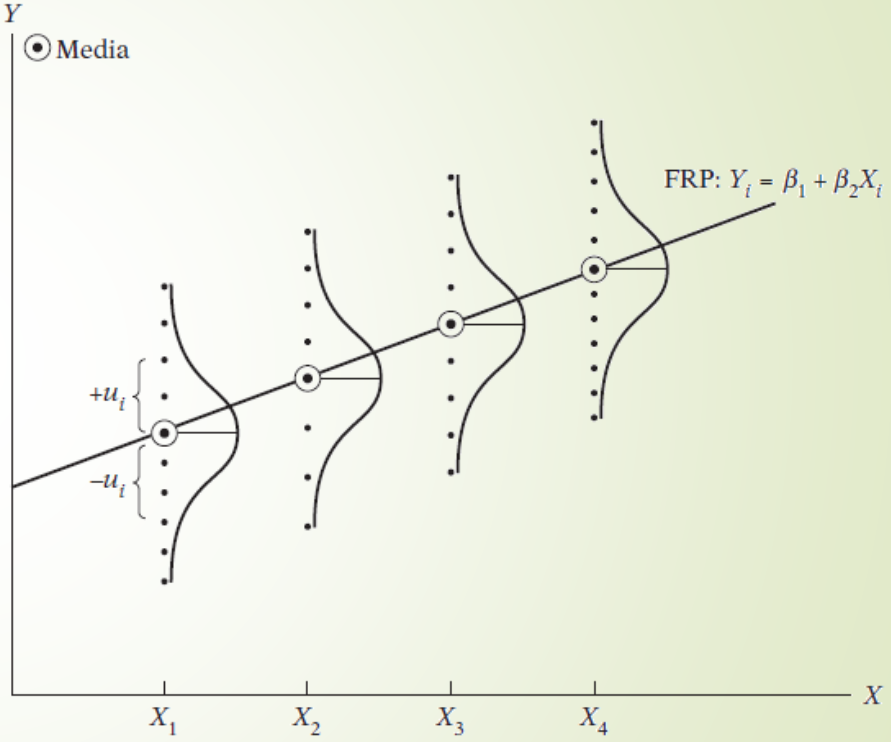

Este supuesto permite llegar al resultado crítico de MCO:

$$E(y_i|X) = \beta X + E(u_i|X)$$
$$E(y_i|X) = \beta X$$

Es decir, el modelo estimado representa a la Función de Regresión Poblacional.

MCO: supuestos clásicos

- **Supuesto 5a ($S5a$): Homocedasticidad o varianza constante de u_i**

  La varianza de la perturbación es la misma, sin importar el valor de x. Simbólicamente, tenemos que:

$$
\begin{aligned}
var(u_i) &= E[u_i - E(u_i|x_i)]^2 \\
&= E\left(u_i^2 \middle| x_i\right), \text{ por el } \textbf{Supuesto 4 (S4)} \\
&= E\left(u_i^2\right), \text{ si } x_i \text{ son variables no-estocásticas} \\
&= \sigma^2
\end{aligned}
$$

MCO: supuestos clásicos

- **Supuesto 5a ($S5a$): Homocedasticidad o varianza constante de u_i**

$$var(u_i) = \sigma^2$$

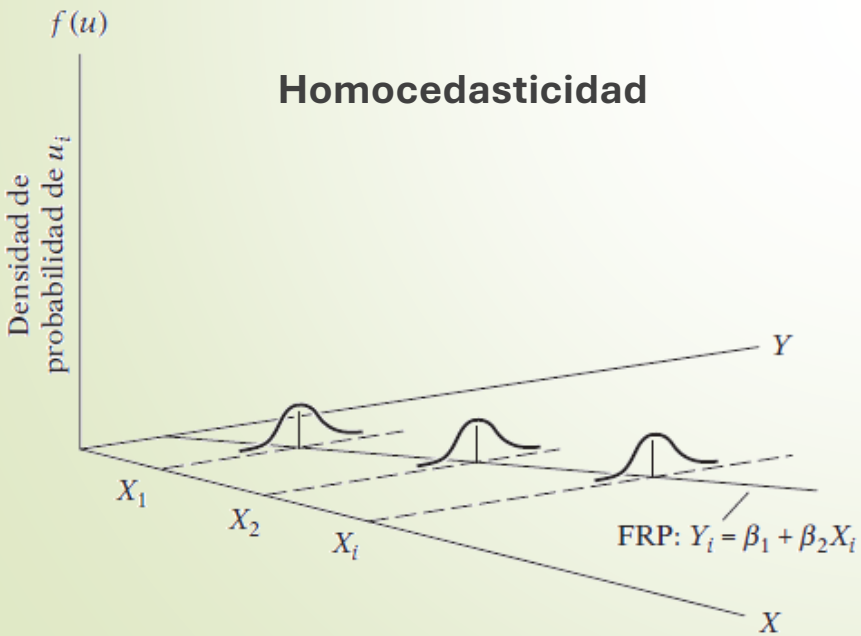

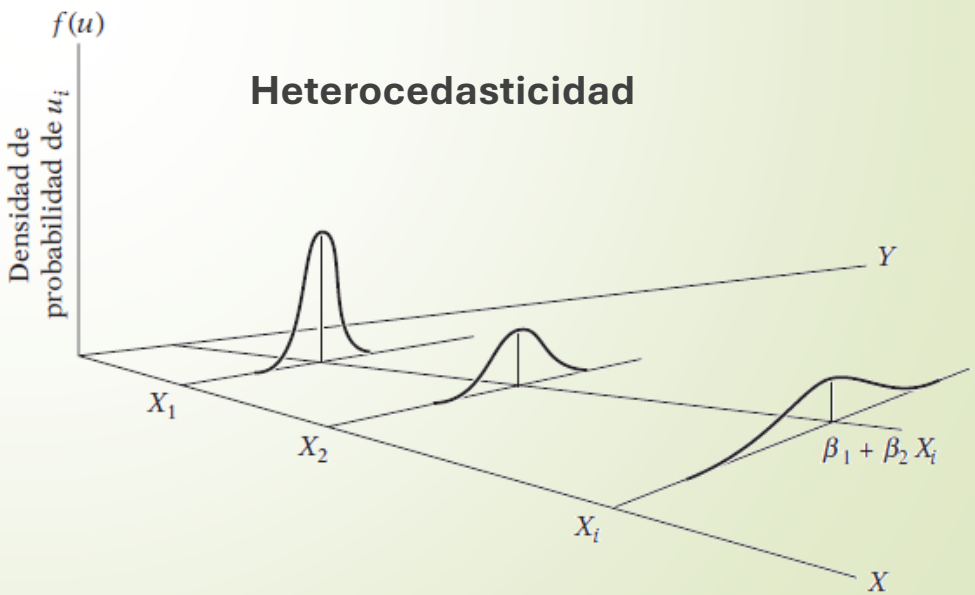

MCO: supuestos clásicos

- **Supuesto 5b ($S5b$): No hay autocorrelación en el error**

  Dados dos valores cualesquiera de x, x_i y x_j ($i \neq j$), la correlación entre dos errores u_i y u_j cualesquiera ($i \neq j$) es cero.

  Es decir, las observaciones son muestreadas independientemente:

$$cov(u_i, u_j | x_i, x_j) = 0$$

$$cov(u_i, u_j) = 0, \text{ si } x \text{ es no-estocástica}$$

MCO: supuestos clásicos

- **Supuesto 5b ($S5b$): No hay autocorrelación en el error**

$$cov(u_i, u_j | x_i, x_j) = 0$$
$$cov(u_i, u_j) = 0, \text{ si } x \text{ es no-estocástica}$$

Correlación serial positiva

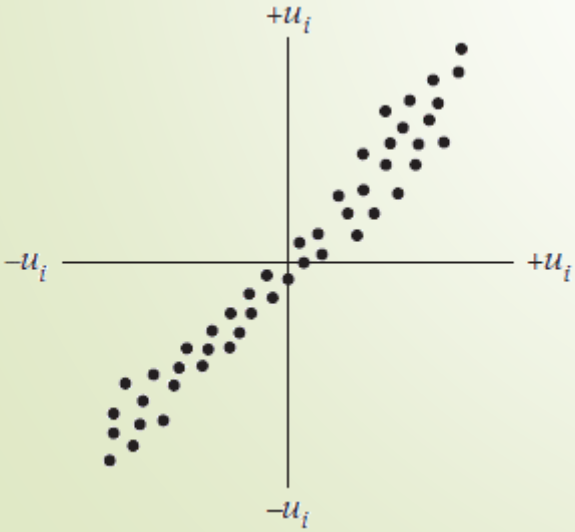

Correlación serial negativa

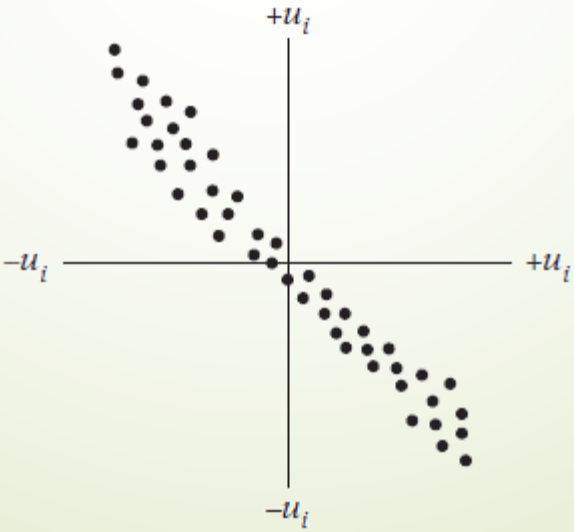

Correlación serial cero

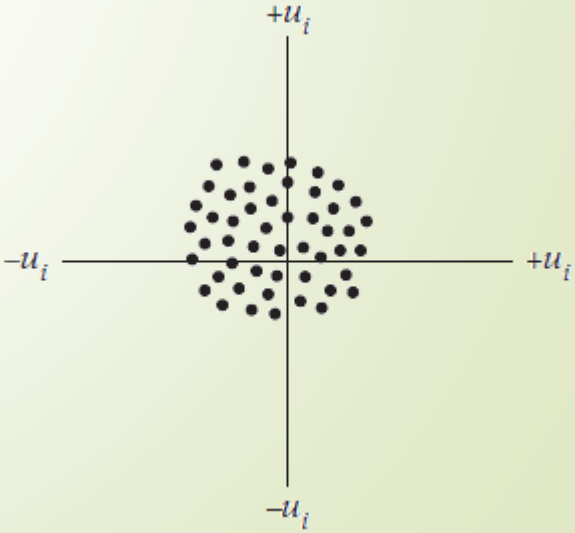

MCO: supuestos clásicos

- **Supuesto 6 (S6)**: **Regresores no-estocásticos, o regresores independientes del término de error**

  Los regresores son fijos o no-estocásticos en el sentido de que sus valores están fijos en muestras repetidas. Este supuesto se puede relajar si x y u son independientemente distribuidos, es decir,

$$cov(x_i, u_i) = 0$$

MCO: supuestos clásicos (adicionales)

- **Supuesto Adicional 1 (SA1): Tamaño de muestra**

  El número de observaciones N debe ser mayor que el número de variables explicativas.

- **Supuesto Adicional 2 (SA2): Naturaleza de la variable x**

  No todos los valores de x en una muestra determinada deben ser iguales, es decir,

$$\sum (x_i - \bar{x})^2 \neq 0$$

  Además, no puede haber valores atípicos (*outliers*) de la variable x, es decir, valores muy diferentes en relación con el resto de las observaciones.

MCO: supuestos clásicos (adicionales)

- **Supuesto Adicional 3 (SA3)**: **Modelo correctamente especificado**

  El modelo de regresión está correctamente especificado, por lo que no presenta error o sesgo de especificación en el modelo empleado para el análisis empírico.

Propiedades de los estimadores de MCO

- Ya se discutieron las **propiedades algebraicas** de las estimaciones MCO.
- Ahora se vuelve al modelo poblacional para estudiar las **propiedades estadísticas** de MCO.
- Es decir, **ahora se consideraran $\widehat{\beta}_{MCO}$ y $\widehat{\alpha}_{MCO}$ como estimadores de los parámetros β y α que aparecen en el modelo poblacional**.
- Se estudiarán las propiedades de las distribuciones de los $\hat{\beta}_{MCO}$ y $\hat{\alpha}_{MCO}$ que resultan de las diversas muestras aleatorias que es posible obtener de la población.

Propiedades de los estimadores de MCO

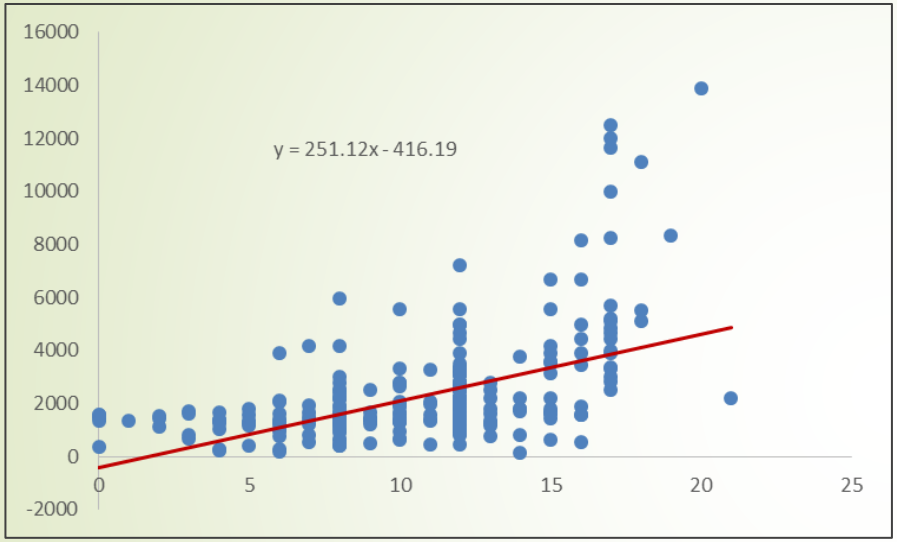

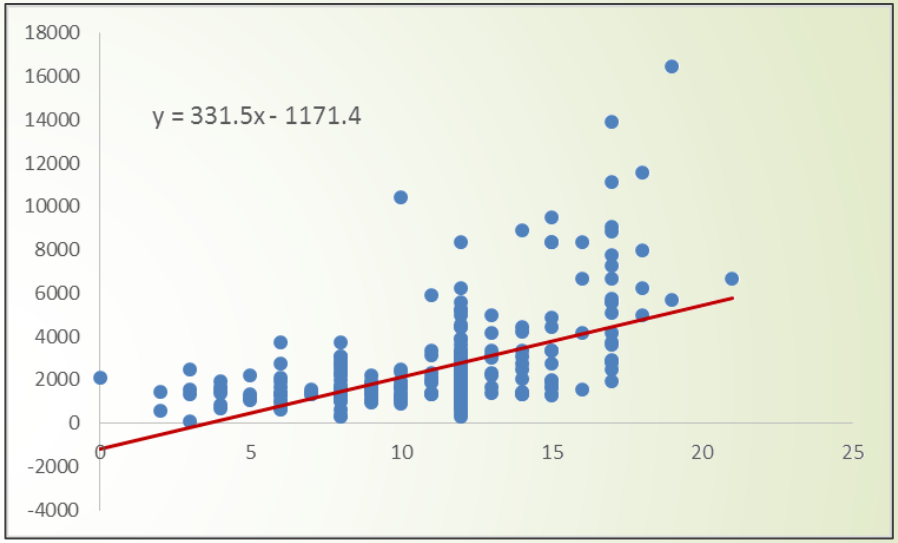

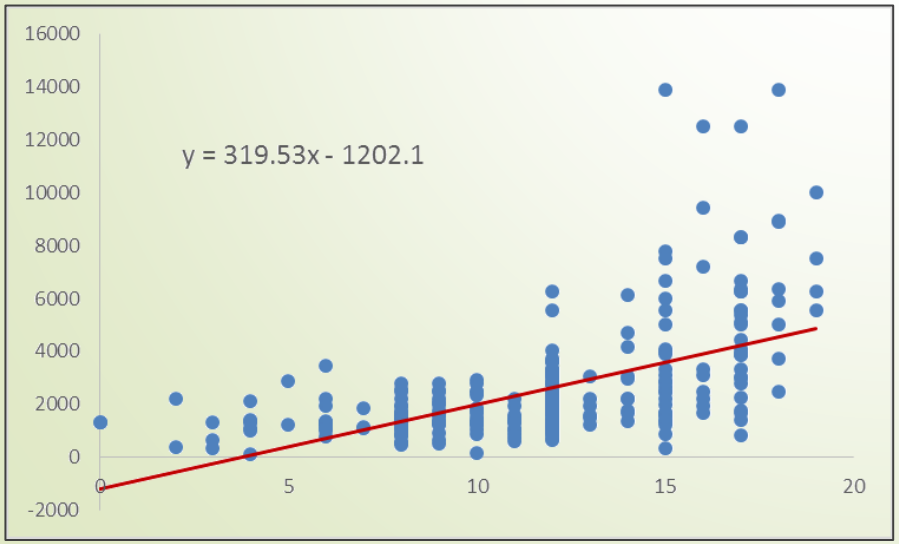

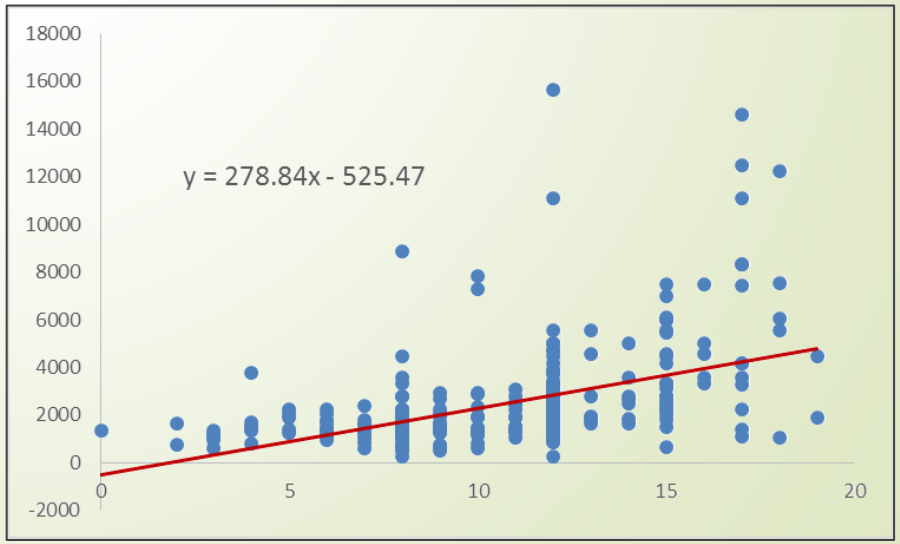

Propiedades de los estimadores de MCO

- **¿Para qué sirven los supuestos de MCO?**
  - Nos permiten usar los parámetros muestrales para sacar conclusiones acerca de los parámetros poblacionales
- **¿Son realistas?**
  - No necesariamente.
  - **En muchas ocasiones, no se cumplen, pero se puede solucionar la situación con ajustes**.
  - En otras ocasiones, no se cumplen y se debe convivir con esa situación…

Propiedades de los estimadores de MCO

- Bajo los supuestos anteriores, se puede mostrar que los estimadores obtenidos por MCO son
  - Insesgados
  - Consistentes
  - Eficientes
- Más aún, según el *Teorema de Gauss-Markov*, los estimadores de MCO son **MELI (mejores estimadores lineales e insesgados)**.

Propiedades de MCO: Insesgamiento

- **<u>Propiedad</u>: Los estimadores de MCO son insesgados**

  Bajo los supuestos $S1$, $S2$, $S4$ y $SA2$, tenemos que:

$$E[\hat{\alpha}] = \alpha$$
$$E[\hat{\beta}] = \beta$$

- <u>Intuición</u>: el valor esperado de una variable aleatoria X es el valor que toma en promedio luego de varias repeticiones del experimento.

- <u>TAREA</u>: Demostrar esta propiedad de los estimadores MCO (Wooldridge, 2010, pp. 50-51)

Propiedades de MCO: Consistencia

- **<u>Propiedad:</u>** **Los estimadores de MCO son consistentes**

  Bajo los supuestos $S1 - S6$ (excepto $S5a$) y $SA1 - SA2$, tenemos que

$$plim[\hat{\alpha}] = \alpha$$
$$plim[\hat{\beta}] = \beta$$

- **<u>Intuición</u>**: Decimos que $\widehat{\theta_N}$ es un estimador consistente de θ si y sólo si $\widehat{\theta_N}$ converge en probabilidad a θ a medida que N tiende a infinito.

- **<u>Idea</u>**: Ley de los Grandes Números

$$\{Y_i\}_{i=1}^{N}\ i.i.d.\ con\ E[Y_i] = \mu \Longrightarrow \left(\frac{1}{N}\sum Y_i\right) \xrightarrow{p} \mu \Leftrightarrow plim(\bar{Y}) = \mu$$

Propiedades de MCO: Eficiencia

- Para analizar la eficiencia de los estimadores MCO, se requiere obtener la varianza de $\hat{\alpha}$ y $\hat{\beta}$.

- Bajo los supuestos clásicos, especialmente $S5a$ (**Homocedasticidad**), se puede probar que:
$$\boldsymbol{Var(y_i|X)} = Var(\alpha + \beta \cdot x_i + u_i|X) = Var(u_i|X) = \boldsymbol{\sigma^2}$$

Propiedades de MCO: Eficiencia

- **<u>Estimador insesgado de σ^2:</u>**

$$\widehat{\sigma^2} = \frac{SRC}{N-2} = \frac{\sum \hat{u}_i^2}{N-2} = \frac{\sum (y_i - \hat{y}_i)^2}{N-2}$$

- Luego, se pueden derivar las varianzas de los estimadores de los parámetros por MCO:

$$Var(\hat{\alpha}|X) = \frac{\sigma^2 \sum {x_i}^2}{N \sum (x_i - \bar{x})^2}$$

$$Var(\hat{\beta}|X) = \frac{\sigma^2}{\sum (x_i - \bar{x})^2}$$

- Demostración: ver apuntes Profesor Fajnzylber, pp. 25-27.

Propiedades de MCO: Eficiencia

- **<u>Propiedad:</u>** **Los estimadores de MCO son eficientes**

  Bajo los supuestos $S1 - S6$ y $SA1 - SA2$, tenemos que

$$Var(\widehat{\alpha_{MCO}}) \leq Var(\widehat{\alpha_2})$$
$$Var(\widehat{\beta_{MCO}}) \leq Var(\widehat{\beta_2})$$

  Donde $Var(\widehat{\alpha_2})$ y $Var(\widehat{\beta_2})$ son estimadores de varianza alternativos cualesquiera.

- **<u>Intuición</u>**: si se cumplen los supuestos clásicos, el estimador de MCO es el estimador de mínima varianza, es decir, el que reduce al mínimo la suma de errores al cuadrado.

- Nótese que para llegar a esto, se deben obtener estimadores insesgados y consistentes de $\hat{\alpha}$, $\hat{\beta}$ y $\widehat{\sigma^2}$.

Propiedades de MCO: MELI (BLUE)

- **Teorema de Gauss-Markov:**

  "Dados los supuestos del modelo clásico de regresión lineal, los estimadores de mínimos cuadrados, dentro de la clase de estimadores lineales insesgados, tienen varianza mínima, es decir, son MELI (mejores estimadores lineales insesgados)."

Temas de la Unidad 2

1. Introducción: estructura de datos y tipos de variables
2. El modelo de regresión lineal: terminología y conceptos.
3. Estimación empleando el método de mínimos cuadrados ordinarios (*MCO, MiCO, OLS*).
4. Medidas de ajuste del método MCO.
5. Propiedades de los estimadores bajo los supuestos clásicos de MCO.
6. **Inferencia Estadística**

6. Inferencia Estadística

A. Propiedades de los estimadores de MCO
B. Inferencia estadística con los estimadores de MCO

Propiedades de los estimadores de MCO

- En muestras lo suficientemente grandes ($N \gtrsim 30$), los estimadores MCO tienen distribución normal:

$$\hat{\alpha} \sim N\left(\alpha, \frac{\sigma^2 \sum x_i^2}{n \sum (x_i - \bar{x})^2}\right) \qquad \hat{\beta} \sim N\left(\beta, \frac{\sigma^2}{\sum (x_i - \bar{x})^2}\right)$$

- Normalizados, se pueden escribir como:

$$\frac{\hat{\alpha} - \alpha}{\sqrt{Var(\hat{\alpha})}} \sim N(0,1) \qquad \frac{\hat{\beta} - \beta}{\sqrt{Var(\hat{\beta})}} \sim N(0,1)$$

Propiedades de los estimadores de MCO

- Como ya se vio anteriormente, dado que casi nunca se conoce σ^2, se puede estimar desde la muestra:

$$\hat{\sigma}^2 = \frac{1}{N-2}\left(\sum_{i=1}^{n} \hat{u}_i^2\right)$$

Donde $\mathrm{N} - 2 = df = N - \#parámetros\ estimados$ son los **grados de libertad** (*degree of freedom*).

- Así, la nueva distribución normalizada con el estimador de la varianza distribuirá t de Student:

$$\frac{\hat{\alpha} - \alpha}{\sqrt{\frac{\hat{\sigma}^2 \sum x_i^2}{n \sum (x_i - \bar{x})^2}}} \sim t_{N-2} \qquad \frac{\hat{\beta} - \beta}{\sqrt{\frac{\hat{\sigma}^2}{\sum (x_i - \bar{x})^2}}} \sim t_{N-2}$$

Inferencia estadística con los estimadores de MCO

- Conociendo la distribución de los estimadores MCO $\hat{\alpha}$ y $\hat{\beta}$, se puede realizar **inferencia estadística**:
  - Se pueden construir **intervalos de confianza** alrededor de $\hat{\alpha}$ y $\hat{\beta}$.
  - Se pueden realizar **contrastes de hipótesis** acerca de los valores de $\hat{\alpha}$ y $\hat{\beta}$.
  - Se pueden estimar los **p-valores** para $\hat{\alpha}$ y $\hat{\beta}$ (no lo haremos, pero es fácil).

Intervalos de confianza para un parámetro poblacional

- Bajo los supuestos del modelo lineal clásico, es fácil construir un **intervalo de confianza** para un parámetro poblacional β_i.

- A los intervalos de confianza se les llama también ***estimaciones por intervalo***, porque proporcionan un rango de valores posibles para el parámetro poblacional y no sólo una estimación puntual:

$$\widehat{\boldsymbol{\beta}}_{\boldsymbol{i}} \pm \boldsymbol{t}_{\boldsymbol{df},\boldsymbol{colas},\boldsymbol{\alpha}\%} \cdot \boldsymbol{sd}\left(\widehat{\boldsymbol{\beta}}_{\boldsymbol{i}}\right)$$

Intervalos de confianza para un parámetro poblacional

- Para el ejemplo anterior:

$$t_{(df=4192-4-1=4187,2\ colas,95\%)} = 1.96$$

$$IC_{\widehat{\beta}} = \hat{\beta} \pm t_{df,colas,\alpha\%} \cdot sd(\hat{\beta})$$

$$IC_{\widehat{\beta}} = \hat{\beta} \pm t_{(4187,2\ colas,95\%)} \cdot \sqrt{Var(\hat{\beta})}$$

$$IC_{\widehat{\beta}} = 0.0022698 \pm 1.96 \cdot 0.0007052$$
$$= \mathbf{[0.0008872, 0.0036523]}$$

Intervalos de confianza para un parámetro poblacional

```
. reg rend10_nota est_madr ive mujer edad

      Source |       SS           df       MS      Number of obs   =     4,192
-------------+----------------------------------   F(4, 4187)      =    171.92
       Model |  194.111983         4  48.5279958   Prob > F        =    0.0000
    Residual |  1181.90055     4,187  .282278612   R-squared       =    0.1411
-------------+----------------------------------   Adj R-squared   =    0.1402
       Total |  1376.01253     4,191  .328325586   Root MSE        =     .5313

------------------------------------------------------------------------------
 rend10_nota |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
    est_madr |   .0240433   .0025821     9.31   0.000      .018981    .0291057
         ive |   .0022698   .0007052     3.22   0.001     .0008872    .0036523
       mujer |    .131665    .016464     8.00   0.000     .0993869    .1639432
        edad |  -.0656592   .0031904   -20.58   0.000     -.071914   -.0594043
       _cons |   5.936366   .0742541    79.95   0.000     5.790788    6.081943
------------------------------------------------------------------------------
```

Inferencia estadística con los estimadores de MCO

Ejemplo:

- Se estima el siguiente modelo de regresión de salario por horar ($/hora) en escolaridad (medida en años) :

$$salario = \beta_0 + \beta_1 escolaridad + u$$

- Estimación con MCO de una muestra de 300 personas arroja el siguiente resultado (se reportan los errores estándar debajo de los coeficientes estimados):

$$\widehat{salario} = -416.1899 + \quad 251.124 \quad escolaridad$$
$$(285.8958) \qquad (25.11694)$$

Inferencia estadística con los estimadores de MCO

Ejemplo:

$$\widehat{salario} = -416.1899 + \quad 251.124 \quad escolaridad$$
$$(285.8958) \quad (25.11694)$$

- **Interpretación de coeficientes:**
  - $\hat{\beta}_0 = -416.1899$: salario predicho por el modelo si $esc = 0$. No es muy intuitivo porque las personas no tienen salarios negativos.
  - $\hat{\beta}_1 = 251.124$: efecto de 1 año adicional de escolaridad en el salario del individuo. Cada año adicional de escolaridad provoca un aumento del salario horario de $251.

Inferencia estadística con los estimadores de MCO

Ejemplo:

$$\widehat{salario} = -416.1899 + \quad 251.124 \quad escolaridad$$
$$(285.8958) \quad (25.11694)$$

- **Intervalo de confianza** de $\hat{\beta}_1$ al 95% (v. c. $t_{299} = 1.96793$):

$$251.124 \pm 1.96793 \times 25.11694 = [201.695\,, 300.5531]$$

- **Contraste de hipótesis:** el más común es al 5%

$$H_0: \beta_1 = 0$$
$$H_1: \beta_1 \neq 0$$

  - Regla de rechazo: rechazar H_0 si $t_{observado} > t_{crítico} = 1.96793$

$$t_{observado} = \frac{251.124 - 0}{25.11694} = 9.9982$$

  - Como $t_{observado} > 1.96793$, se rechaza H_0.

Inferencia estadística con los estimadores de MCO

SEC

STC

Grados de libertad = N – 2

Nro. Observaciones= N

```
. reg salario esc

      Source |       SS           df       MS      Number of obs   =       300
-------------+----------------------------------   F(1, 298)       =     99.96
       Model |  286521448         1  286521448     Prob > F        =    0.0000
    Residual |  854142568       298  2866250.23    R-squared       =    0.2512
-------------+----------------------------------   Adj R-squared   =    0.2487
       Total | 1.1407e+09       299  3814929.82    Root MSE        =     1693

------------------------------------------------------------------------------
     salario |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
         esc |    251.124   25.11694    10.00   0.000     201.695    300.5531
       _cons |   -416.1899   285.8958    -1.46   0.147    -978.8204    146.4407
------------------------------------------------------------------------------
```

Estimación MCO
R2 =(SEC/STC)

Inferencia estadística

Estimadores de coeficientes $\widehat{\beta}_0$ (_cons) y $\widehat{\beta}_1$ (esc)

Error Estándar:

$$\frac{\widehat{\sigma}^2}{\sum(x_i-\overline{x})^2} \quad y \quad \frac{\widehat{\sigma}^2 \sum x_i^2}{n\sum(x_i-\overline{x})^2},$$

respectivamente

Estadísticos t_{obs} para $H_0: \beta_1 = 0$ y $H_0: \beta_0 = 0$, respectiva//.

P-valores de contrastes de hipótesis $H_0: \beta_1 = 0$ y $H_0: \beta_0 = 0$, respectiva//.

Intervalos de confianza al 95% de $\widehat{\beta}_1$ y $\widehat{\beta}_0$, respectiva//.