Econometría I

Prof. Carlos Briceño Sotelo

Universidad Adolfo Ibañez

UNIDAD 3: Modelo de Regresión Lineal Múltiple

Resumen de la Unidad 3

Resumen de la Unidad 3

1. Introducción y motivación
2. Repaso de Álgebra Matricial
3. Estimación: Mínimos Cuadrados Ordinarios (MCO)
4. Bondad de Ajuste
5. Propiedades de los estimadores bajo los supuestos clásicos de MCO.
6. Inferencia: Estimación del Intervalo de Confianza y Test de Hipótesis

Resumen de la Unidad 3

1. **Introducción y motivación**
2. Repaso de Álgebra Matricial
3. Estimación: Mínimos Cuadrados Ordinarios (MCO)
4. Bondad de Ajuste
5. Propiedades de los estimadores bajo los supuestos clásicos de MCO.
6. Inferencia: Estimación del Intervalo de Confianza y Test de Hipótesis

Motivación: ¿Qué queremos estimar con una regresión?

- Estimar relaciones entre variables para:
  - Contrastar teorías económicas.
  - Predecir valores futuros de variables económicas
  - Evaluar políticas públicas y decisiones de negocios

- En última instancia, queremos estimar el **"efecto causal"** de un cambio en X sobre Y.

Motivación: ¿Qué queremos estimar con una regresión?

- En la Unidad anterior, el Modelo de Regresión Lineal Simple (MRLS) fue una buena forma de partir pero tenía una importante limitación:

Es muy difícil obtener conclusiones ceteris paribus del efecto de X sobre Y, ya que el supuesto clave de que todos los demás factores que afectan a Y no están correlacionados con X, a menudo, no es realista.

Motivación: ¿Qué queremos estimar con una regresión?

- El **análisis de regresión múltiple** es más adecuado para un análisis *ceteris paribus:* permite controlar *de manera explícita* muchos otros factores que afectan en forma simultánea a la variable explicada.

- Debido a que los modelos de regresión múltiple pueden aceptar diversas variables explicativas (<u>que tal vez estén correlacionadas</u>), es posible inferir causalidad en casos en los que el MRLS podría no dar buenos resultados.

Motivación: ¿Qué queremos estimar con una regresión?

- Si al modelo se le agregan factores útiles para explicar Y, entonces puede explicarse más de la variación en Y → **Mejor predicción del modelo!**

- Además, permite incorporar relaciones con formas funcionales muy generales.

- Es el método más utilizado para análisis empírico en Economía.

Motivación: Ejemplo

- Ejemplo: **Rendimiento Alumnos JUNAEB**

Editor de Datos (Navegación) - [JUNAEB]

Archivo Edición Ver Datos Herramientas

run[1] 19354546

	run	regco	sename	est_madr	conhijos	mujer	edad	muni	ive	trat2010	rend10_nota	rend10_asist
1	19354546	15	1	6	0	0	14	1	79.01	0	5.6	93
2	19041877	4	0	12	0	0	15	0	56.62	0	5.9	96
3	19177361	1	0	.	0	1	15	0	.	1	5.8	92
4	19012994	5	0	8	0	0	15	0	.	1	5.9	97
5	19067176	13	0	7	0	0	14	1	86.22	0	5.3	98
6	18951868	8	0	9	0	1	15	1	67.14	0	5.4	99
7	19099270	4	0	12	0	0	15	0	58.66	1	5	85
8	23091422	.	.	.	.	.	.	.	.	0	6.6	91
9	19015774	5	0	9	0	1	14	1	73.08	1	5.1	97
10	19280765	13	0	3	0	0	15	1	85.7	1	5.1	91
11	18958363	14	0	6	0	1	15	0	89.74	1	5.4	93
12	19073974	8	0	8	0	1	14	1	84.04	1	4.9	85
13	19248333	14	0	11	0	0	14	0	87.74	1	6	90
14	18773323	8	0	12	0	1	15	1	77.32	0	6	99
15	18568760	5	0	18	0	0	16	0	50.05	1	5	95
16	19178981	4	0	12	0	1	15	0	73.36	1	6.1	92
17	18967399	7	0	12	0	0	15	1	67.22	1	5.5	98
18	19433650	1	0	8	0	1	14	1	84.14	1	5	100
19	19129152	7	0	8	0	0	15	1	86.07	1	5.6	100
20	17668916	13	0	3	0	0	19	1	78.95	1	4.9	86
21	19286655	8	0	8	0	0	14	1	67.14	0	5.8	99
22	18771458	8	0	12	0	0	16	0	75.36	0	4.8	86
23	19388830	13	0	10	0	0	14	1	83.45	1	4.6	98
24	18892785	7	0	.	0	1	16	0	87.79	1	5.6	100
25	18963097	10	0	10	0	1	15	1	66.48	1	4.8	94
26	19230259	13	0	2	0	0	15	1	85.66	1	5.5	92

Variables

Filtrar variables aquí

Nombre	Etiqueta
run	
regco	codigo de region ...
sename	ha pasado por la r...
est_madr	a►os de escolarid...
conhijos	tiene hijos
mujer	
edad	
muni	
ive	
trat2010	
rend10_nota	

Variables | Copia temporal

Propiedades

Variables	
Nombre	run
Etiqueta	
Typo	long
Formato	%12.0g
Etiqueta de valor	
Notas	
Datos	
Nombre de archiv	JUNAEB.dta
Etiqueta	
Notas	
Variables	12
Observaciones	4,884
Tamaño	104.93K

Activo Vars: 12 Orden: Dataset Obs: 4.884 Fltro: Apagado Modo: Navegación CAP NUM

Clases BD_IM... Recibi... Modul... Tema ... Modul... Tema ... Tema ... 2 - Sta... Editor ... ESP 15:22

Motivación: Ejemplo

- Ejemplo: **Rendimiento Alumnos JUNAEB**

$$\boldsymbol{nota_i = \alpha + \beta est_{madre_i} + u_i},$$

donde $\beta = \frac{\Delta nota}{\Delta est_madre}$ *ceteris paribus*, es decir, si $E(u|est_{madre}) = 0$

Motivación: Ejemplo

- Ejemplo: **Rendimiento Alumnos JUNAEB**

$$\boldsymbol{nota_i = \alpha + \beta_1\, est_madre_i + \beta_2\, ive_i + \beta_3\, mujer_i + \beta_4\, edad_i + u_i}$$

Donde $\beta_1 = \frac{\Delta nota}{\Delta est_madre}$

cuando $\Delta ive = \Delta sexo = \Delta edad = 0$, es decir, permanecen constantes!

Además, $E(u|est_madre, ive, sexo, edad) = 0$

Motivación: Ejemplo

- Ejemplo: **Rendimiento Alumnos JUNAEB**

$$\boldsymbol{nota_i = \alpha + \beta_1\, est_madre_i + \beta_2\, ive_i + \beta_3\, mujer_i + \beta_4\, edad_i + u_i}$$

Motivación: Terminología

- Comparada con un MRLS, en el que se relaciona $notas$ con *educación de la madre*, la estimación anterior extrae $sexo$, $edad$ e ive *(índice de vulnerabilidad escolar)* del error y las incluye **de manera explícita** en la ecuación.

- Dado que $sexo$, $edad$ e ive aparecen en la ecuación, sus coeficientes miden el efecto *ceteris paribus* de $sexo$ sobre $notas$ *(y otros)*, que también son de interés.

Motivación: Terminología

- Como en la regresión simple, aquí también habrá que hacer supuestos acerca de la relación de u con las variables explicativas $sexo$, $edad$ e $índice\ de\ vulnerabilidad\ (ive)$.

- **Sin embargo, como aparecen el *sexo, la edad y el índice de vulnerabilidad (ive)* de manera explícita, se podrá medir el efecto de la educación de la madre sobre las notas, manteniendo constante el *sexo, edad e ive*.**

Motivación: Terminología

- Una vez que se incluye una variable adicional, **¿por qué no otras?...**

- **Modelo General de Regresión Lineal con k Variables Explicativas (FRP)**

$$\boldsymbol{y = \alpha + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + u}$$

Donde: α = constante

β_j = parámetro de pendiente asociado a la variable x_j $\forall j = 1, \ldots, k$

u = término de error

Motivación: Terminología

- El modelo tiene $k + 1$ parámetros (k pendientes + la constante).

- **Supuesto clave: la media condicionada es nula, es decir,**

$$\boldsymbol{E(u|x_1, x_2, \dots, x_k) = 0}$$

- Esto implica que:

$$\boldsymbol{E(y|x_1, x_2, \dots, x_k) = \alpha + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k}$$

Motivación: Terminología

- En una muestra:

$$y_i = \widehat{y_i} + \widehat{u_i}$$

$$y_i = \hat{\alpha} + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3 + \cdots + \hat{\beta}_k x_k + \widehat{u_i}$$

$$\widehat{u_i} = y_i - \left(\hat{\alpha} + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3 + \cdots + \hat{\beta}_k x_k\right)$$

- MCO resuelve el problema:

$$\boldsymbol{\min_{\{\widehat{\alpha},\widehat{\beta}_1,\widehat{\beta}_2,\widehat{\beta}_3,\ldots,\widehat{\beta}_k\}} \sum_{i=1}^{N} (\widehat{u_i})^2 = (\widehat{u_1} + \widehat{u_2} + \widehat{u_3} + \cdots + \widehat{u_k})^2}$$

Motivación: Terminología

- MCO resuelve el problema:

$$\min_{\{\hat{\alpha},\hat{\beta}_1,\hat{\beta}_2,\hat{\beta}_3,\ldots,\hat{\beta}_k\}} \sum_{i=1}^{N} (\widehat{u_i})^2 = (\widehat{u_1} + \widehat{u_2} + \widehat{u_3} + \cdots + \widehat{u_k})^2$$

- Para N observaciones:

$$\widehat{u_1} = y_1 - \left(\hat{\alpha} + \hat{\beta}_1 x_{11} + \hat{\beta}_2 x_{21} + \hat{\beta}_3 x_{31} + \cdots + \hat{\beta}_k x_{k1}\right)$$

$$\widehat{u_2} = y_2 - \left(\hat{\alpha} + \hat{\beta}_1 x_{12} + \hat{\beta}_2 x_{22} + \hat{\beta}_3 x_{32} + \cdots + \hat{\beta}_k x_{k2}\right)$$

$$\ldots$$

$$\widehat{u_N} = y_N - \left(\hat{\alpha} + \hat{\beta}_1 x_{1N} + \hat{\beta}_2 x_{2N} + \hat{\beta}_3 x_{3N} + \cdots + \hat{\beta}_k x_{kN}\right)$$

Motivación: MCO en forma matricial

Se expresa en forma matricial:

$$\begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & \cdots & x_{k1} \\ \vdots & & \ddots & \vdots \\ 1 & x_{1n} & \cdots & x_{kn} \end{bmatrix} \cdot \begin{bmatrix} \alpha \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix} + \begin{bmatrix} u_1 \\ \vdots \\ u_n \end{bmatrix}$$

Lo cual equivale a la ecuación matricial: $\boldsymbol{Y} = \boldsymbol{X}\hat{\boldsymbol{\beta}} + \boldsymbol{u}$

$$Y = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix} un\ vector\ columna\ de\ N \times 1$$

Motivación: MCO en forma matricial

$$Y = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix} un\ vector\ columna\ de\ N \times 1$$

$$X = \begin{bmatrix} 1 & x_{11} & \cdots & x_{k1} \\ \vdots & & \ddots & \vdots \\ 1 & x_{1n} & \cdots & x_{kn} \end{bmatrix} una\ matriz\ de\ N \times (K+1)$$

$$\beta = \begin{bmatrix} \alpha \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix} un\ vector\ columna\ de\ (K+1) \times 1$$

$$u = \begin{bmatrix} u_1 \\ \vdots \\ u_n \end{bmatrix} \quad un\ vector\ columna\ de\ N \times 1$$

Motivación: MCO en forma matricial

- Nótese que:

$$\min_{\{\widehat{\alpha},\widehat{\beta}_1,\widehat{\beta}_2,\widehat{\beta}_3,\ldots,\widehat{\beta}_k\}} \sum_{i=1}^{N}(\widehat{u_i})^2 = (\widehat{u_1} + \widehat{u_2} + \widehat{u_3} + \cdots + \widehat{u_k})^2$$

se puede expresar como:

$$\min_{\{\widehat{\boldsymbol{\beta}}\}} \widehat{\boldsymbol{u}}'\widehat{\boldsymbol{u}} = \left(\boldsymbol{Y} - \boldsymbol{X}\widehat{\boldsymbol{\beta}}\right)'\left(\boldsymbol{Y} - \boldsymbol{X}\widehat{\boldsymbol{\beta}}\right)$$

Motivación: MCO en forma matricial

- Aplicando el criterio de Minimización de la Suma de Residuos al Cuadrado, se puede demostrar que el estimador de MCO de todos los parámetros está dado por la siguiente ecuación:

$$\widehat{\boldsymbol{\beta}_{MCO}} = \begin{bmatrix} \boldsymbol{\alpha} \\ \boldsymbol{\beta}_1 \\ \vdots \\ \boldsymbol{\beta}_k \end{bmatrix} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{Y}$$

Motivación: MCO en forma matricial

- Demostración: Inicio punto 3.
- Pero antes…

Resumen de la Unidad 3

1. Introducción y motivación
2. **Repaso de Álgebra Matricial**
3. Estimación: Mínimos Cuadrados Ordinarios (MCO)
4. Bondad de Ajuste
5. Propiedades de los estimadores bajo los supuestos clásicos de MCO.
6. Inferencia: Estimación del Intervalo de Confianza y Test de Hipótesis

Repaso: Álgebra matricial

- **<u>Matriz</u>:** tabla rectangular de números. Se denominan con letras mayúsculas. Matriz $A_{m\times n}$ tiene m filas y n columnas.

$$A_{m\times n} = \left[a_{ij}\right]_{m\times n} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & & a_{2n} \\ \vdots & & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}_{m\times n}$$

Repaso: Álgebra matricial

- **<u>Matriz cuadrada</u>:** mismo número de filas y columnas.
- **<u>Vectores</u>:**
  - **Vector fila:** matriz de dimensión $1 \times n$:
    $\begin{bmatrix} a_{11} & a_{12} \cdots & a_{1n} \end{bmatrix}$
  - **Vector columna:** matriz de dimensión $m \times 1$: $\begin{bmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{m1} \end{bmatrix}$
- **<u>Matriz diagonal</u>:** matriz que sólo tiene elementos en la diagonal:

$$A_{m\times n} = \left[a_{ij}\right]_{m\times n} = \begin{bmatrix} a_{11} & 0 & \cdots & 0 \\ 0 & a_{22} & & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \cdots & a_{mn} \end{bmatrix}_{m\times n}$$

Repaso: Álgebra matricial

- **<u>Matriz de identidad</u>:** matriz cuadrada que sólo tiene elementos en la diagonal y son todos iguales a 1:

$$I_{n\times n} = \left[a_{ij}\right]_{n\times n} = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix}_{n\times n}$$

- **<u>Matriz nula</u>:** matriz con 0 en todos los elementos:

$$0_{m\times n} = \left[a_{ij}\right]_{m\times n} = \begin{bmatrix} 0 & 0 & \cdots & 0 \\ 0 & 0 & & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix}_{m\times n}$$

Repaso: Álgebra matricial

- **<u>Suma</u>:** sólo se pueden sumar (o restar) matrices "conformables", es decir, de la misma dimensión:

$$A_{m\times n} + B_{m\times n} = \left[a_{ij} + b_{ij}\right]_{m\times n}$$

- Ejemplo: $\begin{bmatrix} 2 & -1 & 7 \\ -4 & 5 & 0 \end{bmatrix} + \begin{bmatrix} 1 & 0 & -4 \\ 4 & 2 & 3 \end{bmatrix} = \begin{bmatrix} 3 & -1 & 3 \\ 0 & 7 & 3 \end{bmatrix}$

- **<u>Multiplicación por un escalar</u>:** Sea α una constante. Entonces,

$$\alpha \cdot A_{m\times n} = \left[\alpha \cdot a_{ij}\right]_{m\times n}$$

- Ejemplo: Si $\gamma = 2$ y $A = \begin{bmatrix} 2 & -1 & 7 \\ -4 & 5 & 0 \end{bmatrix}$, entonces

$$\boldsymbol{\gamma A} = \begin{bmatrix} 4 & -2 & 14 \\ -8 & 10 & 0 \end{bmatrix}$$

Repaso: Álgebra matricial

- **<u>Multiplicación matricial</u>:** el orden de las matrices importa. Sólo se puede realizar si las matrices son "conformables", es decir, si el número de columnas de la matriz que pre-multiplica es igual al número de filas de la matriz que post-multiplica:

$$A_{m\times n} \times B_{n\times p} = C_{m\times p}$$

$$AB = \left[\sum_{i=1}^{m} a_{ij} \cdot b_{jk}\right]$$

- Ejemplo:

$$\begin{bmatrix} 2 & -1 & 0 \\ -4 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 & 6 & 0 \\ -1 & 2 & 0 & 1 \\ 3 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 12 & -1 \\ -1 & -2 & -24 & 1 \end{bmatrix}$$

Repaso: Álgebra matricial

Multiplicación matricial: Propiedades

i. $(\alpha + \beta)A = \alpha A + \beta A$

ii. $\alpha(A + B) = \alpha A + \alpha B$

iii. $(\alpha\beta)A = \alpha(\beta A)$

iv. $\alpha(AB) = (\alpha A)B$

v. $A + B = B + A$

vi. $(A + B) + C = A + (B + C)$

vii. $(AB)C = A(BC)$

viii. $A(B + C) = AB + AC$

ix. $(A + B)C = AC + BC$

x. $IA = AI = A$

xi. $A + 0 = 0 + A = A$

xii. $A - A = 0$

xiii. $A0 = 0A = 0$

xiv. $AB \neq BA$ (incluso cuando ambos productos estén definidos)

Repaso: Álgebra matricial

- **<u>Transpuesta</u>:** Sea $A_{m\times n} = \left[a_{ij}\right]_{m\times n}$. Entonces, la transpuesta de A es:

$$A'_{m\times n} = \left[a_{ji}\right]_{n\times m}$$

- Ejemplo:

$$A = \begin{bmatrix} 2 & -1 & 7 \\ -4 & 5 & 0 \end{bmatrix}$$

$$A' = \begin{bmatrix} 2 & -4 \\ -1 & 5 \\ 7 & 0 \end{bmatrix}$$

Repaso: Álgebra matricial

<u>Propiedades de la transposición:</u>

i. $(A')' = A$

ii. $(\alpha \cdot A)' = \alpha A'$ (si α es un escalar)

iii. $(A + B)' = A' + B'$

iv. $(AB)' = B'A'$ donde $A_{m\times n}$ y $B_{n\times p}$

v. $x'x = \sum_{i=1}^{n} x_i^2$ donde x es un vector columna $n \times 1$

Repaso: Álgebra matricial

<u>Propiedades de la transposición:</u>

i. Si A es una matriz con dimensión $n \times p$, cuyas filas son vectores fila $(1 \times p)$ $a_1, a_2, \dots, a_n$, entonces se puede expresar:

$$A = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{bmatrix}_{n \times p} \quad \leftrightarrow \quad A' = [a_1' \quad a_2' \quad a_3' \quad \dots \quad a_n']$$

vii. Matriz simétrica: es aquella matriz cuadrada para la que se cumple que $A' = A$

viii. Si la matriz X es $(n \times k)$, entonces $X'X$ es simétrica (y cuadrada).

Repaso: Álgebra matricial

- **<u>Inversa</u>:** La matriz $A_{m\times n}$ tiene inversa A^{-1} si y sólo si $A^{-1}A = AA^{-1} = I_n$. Si existe una inversa de A, se dice que A es invertible o no singular.

- **Propiedades de la inversa:**

i. Si existe una inversa, es única.

ii. $(\alpha A)^{-1} = \frac{1}{\alpha}A^{-1}$ si $\alpha \neq 0$ y A es invertible.

iii. $(AB)^{-1} = B^{-1}A^{-1}$ si ambas matrices son $n \times n$ e invertibles.

iv. $(A')^{-1} = (A^{-1})'$

Repaso: Álgebra matricial

<u>Ejemplo de Inversa de una matriz</u>:

- Sea $A = \begin{pmatrix} 3 & 5 \\ 1 & 4 \end{pmatrix}$. Encuentre su matriz inversa.
- La matriz inversa se define como $A^{-1} = \frac{[Adj(A)]'}{|A|}$
- Sea $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$. Entonces, su adjunta será $Adj(A) = A^d = \begin{pmatrix} d & -c \\ -b & a \end{pmatrix}$
- Por lo tanto,
  - $A^d = \begin{pmatrix} 4 & -1 \\ -5 & 3 \end{pmatrix} \rightarrow (A^d)' = \begin{pmatrix} 4 & -5 \\ -1 & 3 \end{pmatrix}$
  - $|A| = \begin{vmatrix} 3 & 5 \\ 1 & 4 \end{vmatrix} = (3 \cdot 4) - (5 \cdot 1) = 7 \neq 0$
  - $A^{-1} = \frac{(A^d)'}{|A|} = \frac{\begin{pmatrix} 4 & -5 \\ -1 & 3 \end{pmatrix}}{7}$
  - $\boldsymbol{A^{-1} = \begin{pmatrix} 4/7 & -5/7 \\ -1/7 & 3/7 \end{pmatrix}}$

Resumen de la Unidad 3

1. Introducción y motivación
2. Repaso de Álgebra Matricial
3. **Estimación: Mínimos Cuadrados Ordinarios (MCO)**
4. Bondad de Ajuste
5. Propiedades de los estimadores bajo los supuestos clásicos de MCO.
6. Inferencia: Estimación del Intervalo de Confianza y Test de Hipótesis

Estimación por MCO

- Sea el modelo:

$$\boldsymbol{Y} = \boldsymbol{X\beta} + \boldsymbol{U}$$

- Donde $Y_{n\times 1}$, $X_{n\times(k+1)}$, $\beta_{(k+1)\times 1}$, $U_{n\times 1}$

- Al igual que lo visto en el modelo de regresión simple, MCO busca encontrar el vector $\hat{\beta}$ (es decir, los $\hat{\beta}_j$) que minimizan la suma de los residuos al cuadrado (los $\hat{u}_i^2$), lo que se puede expresar como el siguiente ejercicio de optimización:

$$\min_{\{\widehat{\boldsymbol{\beta}}\}} \boldsymbol{S}(\widehat{\boldsymbol{\beta}}) = \sum_{i=1}^{N} \widehat{\boldsymbol{u}}_i^2 = \widehat{\boldsymbol{U}}'\widehat{\boldsymbol{U}}$$

Estimación por MCO: Obtención de los estimadores

1. Expresión del modelo	$Min\ S(\hat{B}) = \sum_{i}^{n} \hat{u}_i^2 = \hat{U}'\hat{U}$
2. Reemplazar $\hat{U}'\hat{U}$	$S(\hat{B}) = (Y - X\hat{B})'(Y - X\hat{B})$
3. Propiedad de la transpuesta	$S(\hat{B}) = (Y' - \hat{B}'X')(Y - X\hat{B})$
4. Multiplicar términos.	$S(\hat{B}) = Y'Y - \hat{B}'X'Y - Y'X\hat{B} + \hat{B}'X'X\hat{B}$
5. Agrupar términos del centro, $2\hat{B}'X'Y$ es forma lineal y $\hat{B}'X'X\hat{B}$ es forma cuadrática.	$S(\hat{B}) = Y'Y - 2\hat{B}'X'Y + \hat{B}'X'X\hat{B}$
6. Derivada parcial de forma lineal y forma cuadrática.	$\min_{\hat{B}} S(\hat{B}) = \frac{\partial S(\hat{B})}{\partial \hat{B}'} = 0 \rightarrow -2X'Y + 2X'X\hat{B} = 0$
7. Resolver minimización.	$2X'X\hat{B} = 2X'Y$
8. Dividir por 2 y pre-multiplicar ambos lados por $(X'X)^{-1}$.	$\mathbf{\hat{B} = (X'X)^{-1}X'Y}$

Estimación por MCO: Obtención de los estimadores

Nota explicativa paso Paso 5:

- Para agrupar los términos en el paso 5, es importante reconocer que los dos términos son un escalar, es decir, el producto de las matrices es un número, y es el mismo número.

- Se pueden agrupar como $2\hat{B}'X'Y$ o como $2Y'X\hat{B}$. Será práctico agrupar los términos como $2\hat{B}'X'Y$ por la siguiente razón: para los vectores columna $a_{n\times 1}$ y $x_{n\times 1}$.

Estimación por MCO: Obtención de los estimadores

Nota explicativa paso Paso 5:

- Se pueden definir dos formas lineales:
  - Forma lineal 1: $f(x) = a'x$ cuya derivada es igual a: $\frac{\partial f(x)}{\partial x} = a'$
  - Forma lineal 2: $f(x) = x'a$ cuya derivada es igual a: $\frac{\partial f(x)}{\partial x} = a$
- Entonces, habiendo agrupado los términos del centro de la expresión como $-2\hat{B}'X'Y$, se toma la derivada parcial de ese término con respecto a $\widehat{B'}$ y se obtiene $-2X'Y$

Estimación por MCO: Ejemplo

- Usted está interesado en estimar el siguiente modelo (dispone de 90 observaciones):

$$\boldsymbol{demandaX_i = \alpha + \beta_1 precioX_i + \beta_2 ingreso_i + \beta_3 precioY_i + u_i}$$

- Las matrices $(X'X)^{-1}$ y $(X'Y)$ están dadas por:

$$(X'X)^{-1} = \begin{pmatrix} 5 & -3 & 2 & 0 \\ -3 & 6 & 3 & -4 \\ 2 & 3 & 2 & 3 \\ 0 & -4 & 3 & 4 \end{pmatrix} \qquad (X'Y) = \begin{pmatrix} 3 \\ 2 \\ 1 \\ 4 \end{pmatrix}$$

- Encuentre los estimadores de MCO

- **RESPUESTA:**

$$\hat{\beta}_{MCO} = (X'X)^{-1}(X'Y) = \begin{pmatrix} 11 \\ -10 \\ 26 \\ 11 \end{pmatrix}$$

$$\boldsymbol{demandaX_i = 11 - 10 \cdot precioX_i + 26 \cdot ingreso_i + 11 \cdot precioY_i}$$

Resumen de la Unidad 3

1. Introducción y motivación
2. Repaso de Álgebra Matricial
3. Estimación: Mínimos Cuadrados Ordinarios (MCO)
4. **Bondad de Ajuste**
5. Propiedades de los estimadores bajo los supuestos clásicos de MCO.
6. Inferencia: Estimación del Intervalo de Confianza y Test de Hipótesis

Bondad de ajuste

- La variación total de y_i es igual a la suma de la variación del valor predicho $\hat{y}_i$ y la variación de los residuos:

STC = SEC + SRC

  - *Suma total de cuadrados:* $STC = \sum(y_i - \bar{y})^2$
  - *Suma explicada de cuadrados:* $SEC = \sum(\hat{y}_i - \bar{y})^2$
  - *Suma de residuos al cuadrado:* $SRC = \sum \hat{u}_i^2 = \sum(y_i - \hat{y}_i)^2$

Bondad de ajuste

- **Bondad de ajuste:** se define el R^2 como la Fracción de la varianza total de Y que es explicada por el modelo:

$$R^2 = \frac{SEC}{STC} = 1 - \frac{SRC}{STC}$$

- Pero si agregamos muuuuchas variables, el R^2 siempre crece!!!

- **Entonces, se define el R^2_{ajust}:**

$$\boldsymbol{R^2_{ajust} = 1 - \left(1 - R^2\right)\left[\frac{n-1}{n-k}\right]}$$

Bondad de ajuste: Ejemplo

- Ejemplo: **Rendimiento Alumnos JUNAEB**

$$\boldsymbol{nota_i = \alpha + \beta_1\, est_madre_i + \beta_2\, ive_i + \beta_3\, mujer_i + \beta_4\, edad_i + u_i}$$

- STC = 1376,01253
- SEC = 194,111983
- SRC = 1181,9055
- N = 4192

$$R^2 = \frac{SEC}{STC} = 1 - \frac{SRC}{STC} = \frac{194.111983}{1376.01253} = 1 - \frac{1181.90055}{1376.01253} = 0.1411$$

$$R^2_{ajus} = 1 - (1 - R^2)\left[\frac{n-1}{n-k}\right] = 1 - (0.8589)\left[\frac{4191}{4187}\right] = 0.1402$$

Bondad de ajuste

- R^2 nunca disminuye, por lo tanto no es el criterio para ver si una variable debe incluirse o no en regresión.
  - Esta pregunta se responde si es que la variable tiene algún efecto (estadísticamente significativo) en la población.

- R^2 servirá para responder si un grupo de variables es importante para explicar la variación de y.

Bondad de ajuste

- **¿Es R^2 bajo un problema?**
  - No siempre (aunque suele ser mejor tener un R^2 alto).
  - Aun cuando los regresores en su conjunto no expliquen gran parte de la variación de y, es posible que las estimaciones MCO sean estimaciones confiables del efecto *ceteris paribus* de cada regresor particular.

Resumen de la Unidad 3

1. Introducción y motivación
2. Repaso de Álgebra Matricial
3. Estimación: Mínimos Cuadrados Ordinarios (MCO)
4. Bondad de Ajuste
5. **Propiedades de los estimadores bajo los supuestos clásicos de MCO.**
6. Inferencia: Estimación del Intervalo de Confianza y Test de Hipótesis

Recta de regresión y predicción del modelo

- Una vez obtenido el vector de coeficientes, $\hat{B}$, se expresa la recta de la regresión de la siguiente forma:

$$\boldsymbol{\widehat{y_i} = \widehat{\alpha} + \widehat{\beta_1} x_1 + \widehat{\beta_2} x_2 + \widehat{\beta_3} x_3 + \cdots + \widehat{\beta_k} x_k}$$

- Con los coeficientes estimados, se puede predecir el valor de $\boldsymbol{\widehat{y_i}}$ para cada individuo.

- También se puede estimar el residuo de cada individuo:

$$\boldsymbol{\widehat{u_i} = y_i - \widehat{y_i}}$$

Estimación por MCO: Ejemplo

run	est_madr	mujer	edad	ive	rend10_nota	notagorro	ugorro
19354546	6	0	14	79.01	5.6	5.340731	0.2592688
19041877	12	0	15	56.62	5.9	5.368512	0.5314879
19177361		1	15		5.8		
19012994	8	0	15		5.9		
19067176	7	0	14	86.22	5.3	5.38114	-0.0811396
18951868	9	1	15	67.14	5.4	5.451925	-0.0519247
19099270	12	0	15	58.66	5	5.373142	-0.3731422
23091422					6.6		
19015774	9	1	14	73.08	5.1	5.531066	-0.4310665
19280765	3	0	15	85.7	5.1	5.218127	-0.1181269
18958363	6	1	15	89.74	5.4	5.431092	-0.0310917
19073974	8	1	14	84.04	4.9	5.5319	-0.6318998
19248333	11	0	14	87.74	6	5.480763	0.519237
18773323	12	1	15	77.32	6	5.547161	0.4528389
18568760	18	0	16	50.05	5	5.4322	-0.4322004
19178981	12	1	15	73.36	6.1	5.538173	0.5618272
18967399	12	0	15	67.22	5.5	5.392571	0.1074286
19433650	8	1	14	84.14	5	5.532127	-0.5321269
19129152	8	0	15	86.07	5.6	5.339183	0.2608166
...	...	...	...	...	...	...	...

Interpretación de Resultados

- La regresión múltiple permite interpretar los coeficientes como **efectos parciales** de cada variable manteniendo las demás constantes (*ceteris paribus*), sin haber obtenido los datos de esa forma:

$$\Delta\hat{y}_i = \Delta\hat{\alpha} + \widehat{\beta_1}\Delta x_1 + \widehat{\beta_2}\Delta x_2 + \widehat{\beta_3}\Delta x_3 + \cdots + \widehat{\beta_k}\Delta x_k$$

- **Por lo tanto,**

$$\hat{\beta}_1 = \frac{\Delta\hat{y}}{\Delta x_1} \quad si \underbrace{\Delta x_2 = \Delta x_3 = \Delta x_4 = \cdots = \Delta x_k = 0}_{\textbf{\textit{Ceteris Paribus!!!!}}}$$

- **En nuestro modelo:**

$$\widehat{nota}_i = 5.94 + 0.024 \cdot \text{est_madre}_i + 0.002 \cdot ive_i + 0.13 \cdot sexo_i - 0.066 \cdot edad_i$$

Valores ajustados y residuos

- Una vez que se estiman los coeficientes $\hat{B}$, se puede estimar el valor ajustado para cada observación.
- Por ejemplo, se puede predecir la nota de un niño con…
  - 12 años de estudios de la madre
  - de 15 años de edad
  - Mujer
  - que asiste a un establecimiento educacional con IVE 77.32%
- Revisar tabla anterior.
- El residuo es igual a la diferencia entre el valor observado y el valor predicho:

$$\widehat{u_i} = y_i - \hat{y}_i$$

$$0.4528389 = 6 - 5.547161$$

Estimación por MCO: Ejemplo

run	est_madr	mujer	edad	ive	rend10_nota	notagorro	ugorro
19354546	6	0	14	79.01	5.6	5.340731	0.2592688
19041877	12	0	15	56.62	5.9	5.368512	0.5314879
19177361		1	15		5.8		
19012994	8	0	15		5.9		
19067176	7	0	14	86.22	5.3	5.38114	-0.0811396
18951868	9	1	15	67.14	5.4	5.451925	-0.0519247
19099270	12	0	15	58.66	5	5.373142	-0.3731422
23091422					6.6		
19015774	9	1	14	73.08	5.1	5.531066	-0.4310665
19280765	3	0	15	85.7	5.1	5.218127	-0.1181269
18958363	6	1	15	89.74	5.4	5.431092	-0.0310917
19073974	8	1	14	84.04	4.9	5.5319	-0.6318998
19248333	11	0	14	87.74	6	5.480763	0.519237
18773323	12	1	15	77.32	6	5.547161	0.4528389
18568760	18	0	16	50.05	5	5.4322	-0.4322004
19178981	12	1	15	73.36	6.1	5.538173	0.5618272
18967399	12	0	15	67.22	5.5	5.392571	0.1074286
19433650	8	1	14	84.14	5	5.532127	-0.5321269
19129152	8	0	15	86.07	5.6	5.339183	0.2608166
...	...	...	...	...	...	...	...

Propiedades algebraicas de los estimadores por MCO

1. Media muestral de los residuos igual a 0 $\Rightarrow \overline{\widehat{u_i}} = 0$

2. $\mathrm{Cov}(\mathrm{x_i}, \widehat{\mathrm{u_i}}) = 0$ y $\mathrm{Cov}(\widehat{\mathrm{y_i}}, \widehat{\mathrm{u_i}}) = 0$ (independencia condicional y ruido blanco)

3. El punto $(\bar{y}, \bar{x}_1, \bar{x}_2, \dots, \bar{x}_k)$ está siempre en la línea de recta de regresión de MCO:

$$\bar{y} = \hat{\alpha} + \hat{\beta}_1 \bar{x}_1 + \hat{\beta}_2 \bar{x}_2 + \cdots + \hat{\beta}_k \bar{x}_k$$

Propiedades algebraicas de los estimadores por MCO

- Nótese que las dos primeras propiedades son consecuencia inmediata del conjunto de ecuaciones empleadas para obtener las estimaciones de MCO.
  - Las condiciones de primer orden determinan que la suma de los residuos sea cero.
  - Las ecuaciones restantes son de la forma $\sum_{i=1}^{N} x_{ij}\widehat{u_i} = 0$, lo que significa que la covarianza entre cada regresor y $\widehat{u_i}$ es cero.
- La propiedad (3) es consecuencia inmediata de la propiedad (1).

Propiedades estadísticas de los estimadores $\widehat{\beta}$

- Valores esperados de $\hat{\beta}$'s: **los coeficientes de la regresión lineal son aleatorios.**
- Cada muestra obtenida aleatoriamente produce estimaciones distintas de los valores verdaderos en la población.
- Por lo tanto, los estimadores de β por MCO tienen propiedades estadísticas.

Propiedades estadísticas de los estimadores $\widehat{\beta}$

- Hay que recordar que las propiedades estadísticas no tienen nada que ver con la muestra de que se trate, sino con la propiedad de los estimadores cuando el muestreo aleatorio se hace repetidas veces.

¡No tiene sentido hablar de las propiedades estadísticas de un conjunto de estimaciones obtenidas de una sola muestra!

Supuestos de MCO en forma matricial

- ***Supuesto 1 (S1)***: **Linealidad en los parámetros:** $\mathrm{Y} = X\beta + \varepsilon$

- ***Supuesto 2 (S2)***: **Muestreo aleatorio**, es decir, $(X_i, Y_i) \sim iid$ (independientes e idénticamente distribuidas).

- ***Supuesto 3 (S3)***: **Ausencia de multicolinealidad perfecta**, es decir, que las columnas de X son linealmente independientes (no hay información redundante), o que $X'X \; es \; invertible$.

Supuestos de MCO en forma matricial

- ***Supuesto 4 (S4)***: **Esperanza condicional nula:** $E[u|X_1, X_2, X_3, \dots, X_k] = 0$

- ***Supuesto 5 (S5)***: **Homocedasticidad y ausencia de correlación entre los errores**

$$Var(u|X) = \sigma^2 I_N = \begin{bmatrix} \sigma^2 & \dots & 0 \\ \vdots & \sigma^2 & \vdots \\ 0 & \dots & \sigma^2 \end{bmatrix}$$

- ***Supuesto 6 (S6)***: **Normalidad de los errores:** $\varepsilon|X \sim Normal(0, \sigma^2 I_N)$

Supuesto (S4): Distribución del error

¿Cómo distribuye el error si se cumple el supuesto de que la media condicional es nula?

$$E[y|x] = \alpha + \beta \cdot x$$

$$E[u|X_1, X_2, X_3, \dots, X_k] = 0$$

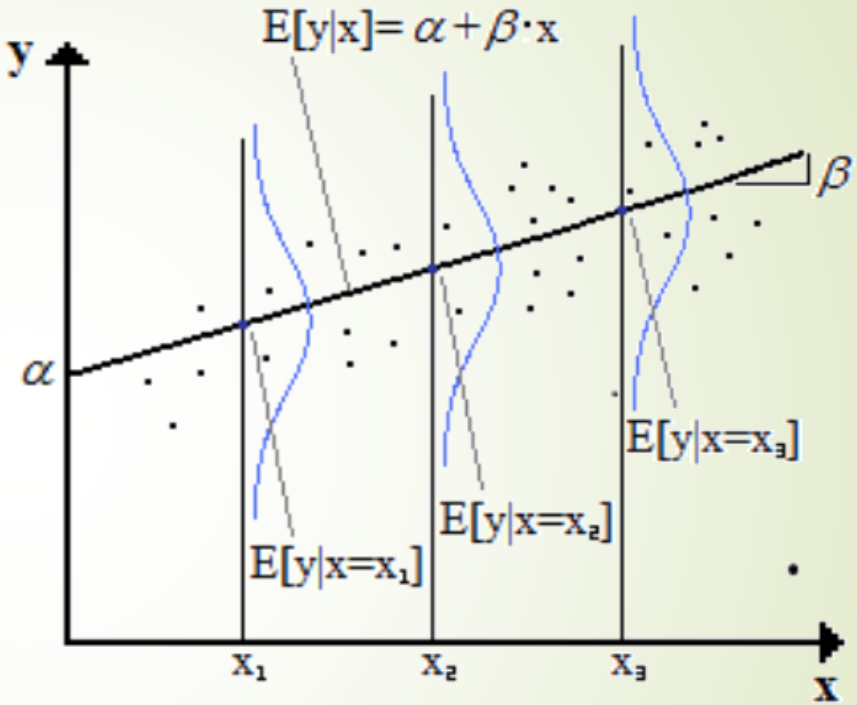

Estas ecuaciones indican que el valor promedio de los factores no observables son el mismo en todas las fracciones de la población determinados por los valores de x y que este promedio común es necesariamente igual al promedio de u en toda la población

Supuesto (S4): Distribución del error

- Cuando se satisface el Supuesto (S4), se suele decir que se tienen **variables explicativas exógenas**.

- Si por alguna razon x_j esta correlacionada con u, entonces se dice que x_j es una **variable explicativa endógena**.

Supuesto (S4): Distribución del error

- **<u>Diferencia entre Supuesto 4 y Supuesto 3:</u>**
  - El Supuesto S3 (ausencia de multicolinealidad perfecta) descarta ciertas relaciones entre los regresores y no tiene ***nada*** que ver con el error (en términos prácticos, si se "corre" MCO, se satisface).
  - Desgraciadamente, nunca se sabrá con seguridad si el valor promedio de los factores no observables, en efecto, no está relacionado con las variables explicativas (S4). **¡Pero este es el supuesto crítico!**

Supuestos de MCO: propiedades

- Supuestos S1 a S4, implican las siguientes propiedades:
  - El estimador de MCO es **insesgado**:

$$E\left[\widehat{\beta_{MCO}}\right] = \beta$$

  - El estimador de MCO es **consistente**:

$$plim\left(\widehat{\beta_{MCO}}\right) = \beta$$

- **Teorema de Gauss-Markov:**
  - Bajo los Supuestos S1 a S5, el estimador de MCO es el **Mejor Estimador Lineal Insesgado (MELI)**, es decir, es el estimador de mínima varianza entre los estimadores lineales e insesgados.

Supuestos de MCO: propiedades

- **Bajo los Supuesto (S1) a (S6) (muestra pequeña):**
  - El estimador de MCO se distribuye como Normal Multivariada.

$$\hat{\beta} \sim N(\mu, \Sigma)$$

- **Bajo los Supuestos (S1) a (S5) (muestra grande):**
  - El estimador de MCO converge en distribución a una Normal Multivariada.

$$\widehat{\beta} \overset{d}{\sim} N(\mu, \Sigma)$$

Supuestos de MCO: Matriz de Varianza y Covarianza

- Una **variable aleatoria** tiene una **varianza**, dada por

$$Var(x) = E[(x - E[x])^2]$$
$$= E[x^2] - E[x]^2$$

- Un **vector aleatorio** tiene una "**matriz de varianzas-covarianzas**", dada por:

$$\boldsymbol{Var(X) = E[(X - E[X])(X - E[X])']}$$

Supuestos de MCO: Matriz de Varianza y Covarianza

$$\boldsymbol{Var(X) = E[(X - E[X])(X - E[X])']}$$

Ejemplo: $X = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$

$$Var(X) = E\left[\begin{bmatrix} x_1 - E[x_1] \\ x_2 - E[x_2] \end{bmatrix} \cdot \begin{bmatrix} x_1 - E[x_1] \\ x_2 - E[x_2] \end{bmatrix}'\right]$$

$$= E\left[\begin{bmatrix} x_1 - E[x_1] \\ x_2 - E[x_2] \end{bmatrix} \cdot [x_1 - E[x_1]\,, \quad x_2 - E[x_2]]\right]$$

$$= E\left[\begin{bmatrix} (x_1 - E[x_1])^2 & (x_1 - E[x_1])(x_2 - E[x_2]) \\ (x_1 - E[x_1])(x_2 - E[x_2]) & (x_2 - E[x_2])^2 \end{bmatrix}\right]$$

$$= \begin{bmatrix} Var(x_1) & Cov(x_1, x_2) \\ Cov(x_1, x_2) & Var(x_2) \end{bmatrix}$$

Supuestos de MCO: Matriz de Varianza y Covarianza

- **Ejemplo:** si debemos estimar la regresión: $\boldsymbol{y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2}$
- Bajo los supuestos S1-S5, tenemos que los estimadores por MCO son:

$$\widehat{\boldsymbol{\beta_{MCO}}} = (\boldsymbol{X'X})^{-1}\boldsymbol{X'Y}$$

$$\boldsymbol{Var}\left(\widehat{\boldsymbol{\beta_{MCO}}}|\boldsymbol{X}\right) = \boldsymbol{\sigma^2}(\boldsymbol{X'X})^{-1}$$

$$= \begin{bmatrix} Var(\widehat{\beta_0}|X) & Cov(\widehat{\beta_0},\widehat{\beta_1}|X) & Cov(\widehat{\beta_0},\widehat{\beta_2}|X) \\ Cov(\widehat{\beta_0},\widehat{\beta_1}|X) & Var(\widehat{\beta_1}|X) & Cov(\widehat{\beta_1},\widehat{\beta_2}|X) \\ Cov(\widehat{\beta_0},\widehat{\beta_2}|X) & Cov(\widehat{\beta_1},\widehat{\beta_2}|X) & Var(\widehat{\beta_2}|X) \end{bmatrix}$$

- El estimador insesgado de la varianza de la regresión se obtiene mediante:

$$\widehat{\boldsymbol{\sigma^2}} = \frac{\boldsymbol{SRC}}{\boldsymbol{N-(K+1)}} = \frac{\sum_i^n \widehat{\boldsymbol{u}}_i^2}{\boldsymbol{N-(K+1)}} = \frac{\widehat{\boldsymbol{U}}'\widehat{\boldsymbol{U}}}{\boldsymbol{N-(K+1)}}$$

donde K es el número de regresores incluidos (2 en nuestro ejemplo)

Supuestos de MCO: Matriz de Varianza y Covarianza

$$nota_i = \alpha + \beta_1\, est_madre_i + \beta_2\, ive_i + \beta_3\, mujer_i + \beta_4\, edad_i + u_i$$

Covariance matrix of coefficients of **regress** model

e(V)	est_madr	ive	mujer	edad	_cons
est_madr	6.667e-06				
ive	5.420e-07	4.973e-07			
mujer	1.284e-06	-1.237e-08	.00027106		
edad	1.662e-06	-2.874e-07	9.937e-08	.00001018	
_cons	-.00012258	-.00003862	-.00015754	-.00011435	.00551368

Supuestos de MCO: Teorema de Gauss-Markov

- Si bien se sabe que MCO es insesgado, no es el único estimador insesgado.
- Bajo los Supuestos S1-S5, los estimadores MCO son MELI (Mejores Estimadores Lineales Insesgados) → Teorema de Gauss-Markov.}
- Este teorema justifica el uso del método de MCO en lugar de otros diversos estimadores.

Supuestos de MCO: Teorema de Gauss-Markov

- También se sabe que la heterocedasticidad (insatisfacción del supuesto S5) no ocasiona sesgo.
- Sin embargo, en presencia de heterocedasticidad, los estimadores de MCO ya no son los de menor varianza entre los estimadores lineales insesgados.
- Más adelante en el curso se analiza un estimador que perfecciona los estimadores de MCO en presencia de heterocedasticidad.

Resumen de la Unidad 3

1. Introducción y motivación
2. Repaso de Álgebra Matricial
3. Estimación: Mínimos Cuadrados Ordinarios (MCO)
4. Bondad de Ajuste
5. Propiedades de los estimadores bajo los supuestos clásicos de MCO.
6. **Inferencia: Estimación del Intervalo de Confianza y Test de Hipótesis**

Inferencia

- **Recordemos:** La **inferencia estadística** es el conjunto de métodos y técnicas que permiten inducir, a partir de la **información empírica proporcionada por una muestra,** cual es el comportamiento de una determinada **población** con un **riesgo de error medible** en términos de probabilidad.

- Ejemplo: en base a un modelo estimado, ¿con qué nivel de confianza (probabilidad de error) se puede decir que $\widehat{\beta_{MCO}}$ es distinto de 0?

Inferencia

- **Hasta este punto, contamos con todos los elementos para estimar los parámetros y sus varianzas**.

- Para realizar inferencia, sin embargo, requerimos de algún supuesto acerca de la distribución de los estimadores del modelo.

Inferencia estadística en el Modelo de Regresión Lineal Múltiple (MRLM)

- Hasta ahora, se han realizado un conjunto de **supuestos bajo los cuales MCO es insesgado**. También se obtuvieron y discutieron los sesgos ocasionados por las variables omitidas.

- Se obtuvieron las **varianzas de los estimadores de MCO** empleando los supuestos de Gauss-Markov.

- Asimismo, se mostró que **esta varianza es la menor de entre los estimadores lineales insesgados.**

Inferencia estadística en el Modelo de Regresión Lineal Múltiple (MRLM)

- **Conocer el valor esperado y la varianza de los estimadores de MCO sirve para describir la "precisión" de los estimadores de MCO.**

- **Sin embargo, para realizar inferencia estadística no sólo se necesita conocer estos dos primeros datos asociados a $\widehat{\beta_i}$: se requiere conocer toda la distribución muestral de los $\widehat{\beta_i}$**

- Aun bajo los supuestos de Gauss-Markov, la distribución de $\widehat{\beta_i}$ puede tener casi cualquier forma.

Inferencia estadística en el Modelo de Regresión Lineal Múltiple (MRLM)

- Cuando se condiciona sobre los valores de las variables independientes en la muestra, es claro que la **distribución muestral de los estimadores de MCO depende de la distribución subyacente de los errores.**

- Para hacer manejables las distribuciones de muestreo de los $\widehat{\beta}_i$ **se supondrá que, en la población, el error no observado esta *distribuido normalmente***. Esto se conoce como **supuesto de normalidad**.

Inferencia estadística en el Modelo de Regresión Lineal Múltiple (MRLM)

Supuestos del Modelo Lineal Clásico (MLC):

- Cuando aplicamos el MRLM en corte transversal (características de distintos agentes en un momento determinado del tiempo), y asumimos que se cumplen los Supuestos S1 a S6, hablamos de los **Supuestos del Modelo Lineal Clásico (MLC):**

$$Y|X \sim Normal(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k, \sigma^2)$$

Inferencia estadística en el Modelo de Regresión Lineal Múltiple (MRLM)

Teorema: Distribuciones de muestreo normales

Bajo los supuestos S1 a S6 del Modelo Lineal Clásico, condicionalmente en los valores muestrales de los regresores,

$$\hat{\beta}_i \sim Normal\left[\beta_i, Var\left(\hat{\beta}_i\right)\right],$$

Donde $$Var\left(\hat{\beta}_i\right) = \frac{\sigma^2}{STC_i\left(1-R_i^2\right)}$$

Por lo tanto,

$$\frac{\left(\hat{\beta}_i - \beta_i\right)}{sd\left(\hat{\beta}_i\right)} \sim Normal(0,1).$$

¿Es realista este supuesto?

- El argumento que justifica la distribución normal de los errores es más o menos como esto:

  "Como u es la suma de muchos factores distintos no observados que afectan a y, se puede apelar al ***Teorema Central del Límite (TCL)*** *para concluir que u tiene una distribución aproximadamente normal".*

¿Es realista este supuesto?

- Aunque el Teorema Central del Límite puede satisfacerse en tales casos, **la aproximación normal puede ser "mala" dependiendo de cuántos factores aparezcan en $\mathbf{u}$** y de qué tan diferentes sean sus distribuciones.

- Otro problema serio con el argumento del Teorema Central del Límite es que **supone que todos los factores no observados afectan a Y por separado en forma aditiva**. Nada garantiza que esto sea así: si u es una complicada función de los factores no observados, entonces el argumento del Teorema Central del Límite no puede emplearse.

¿Es realista este supuesto?

- **En realidad, que una regresión pueda suponerse normalidad de u es una cuestión empírica (que se debe verificar en la práctica o en el caso concreto).**

- Por ejemplo, no hay un teorema que diga que *wage* (salario) condicional en *educación*, *experiencia* y *antigüedad,* esté distribuido normalmente. En todo caso, un razonamiento sencillo sugiere que, en realidad, ocurre lo contrario: como *wage* (salario) nunca puede ser menor a cero, no puede tener, estrictamente hablando, una distribución normal (véase el ejemplo de salario mínimo)

¿Es realista este supuesto?

- Sin embargo, en la práctica, uno puede preguntarse si la distribución condicional del salario se “aproxima” a la normalidad.

- Con frecuencia, usando una transformación, en especial logarítmica, se obtiene una distribución que es cercana a la normal!

Prueba t: un parámetro poblacional

- Se trata de probar la hipótesis acerca de un β_i en particular.
- Recuerde que los β_i son características desconocidas de la población que nunca se conocerán con certeza.
- Aun así, se pueden hacer *hipótesis* acerca del valor de β_i y, después, usar la inferencia estadística para probarlas.

Prueba t: un parámetro poblacional

Teorema: Distribución t para estimadores estandarizados

Bajo los supuestos S1 a S6 del MRLM,

$$\frac{(\hat{\beta}_i - \beta_i)}{sd(\hat{\beta}_i)} \sim t_{n-k-1}$$

Donde $k+1$ es la cantidad de parámetros desconocidos en el modelo poblacional $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + u$ (k parámetros de pendiente y el intercepto β_0).

Prueba t: un parámetro poblacional

$$H_0: \beta_i > 0$$
$$H_1: \beta_i \leq 0$$

FIGURA 4.3

Regla de rechazo de 5% para la alternativa H_1: $\beta_j < 0$ con 18 *gl*.

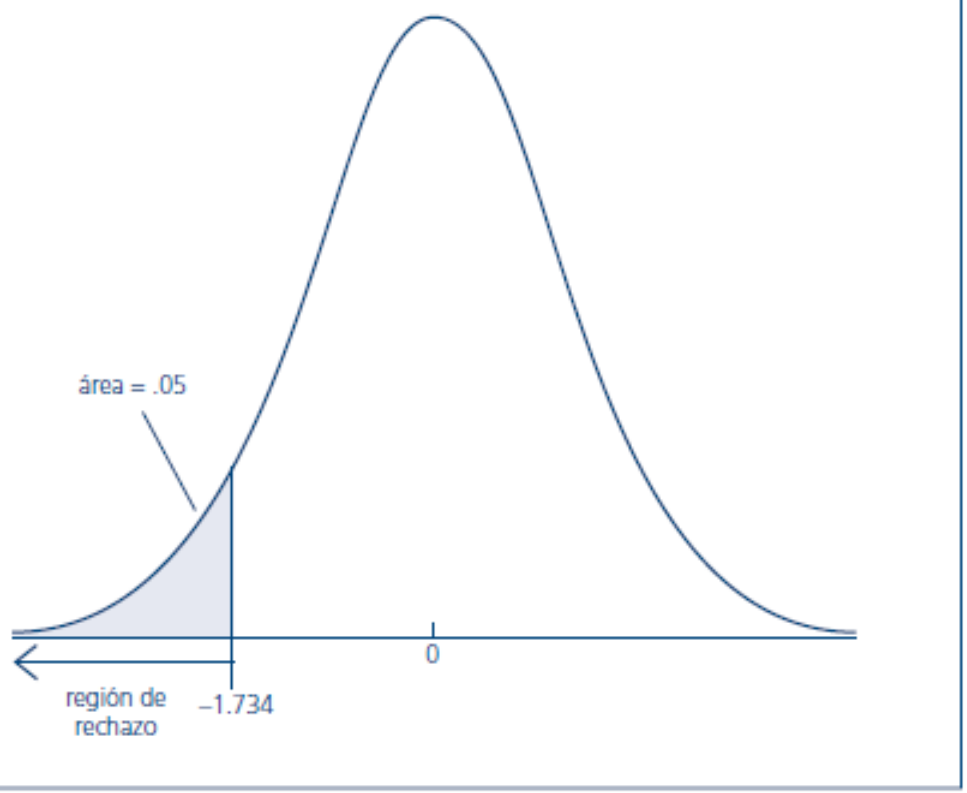

Prueba t: un parámetro poblacional

$$H_0: \beta_i < 0$$
$$H_1: \beta_i \geq 0$$

FIGURA 4.2

Regla de rechazo de 5% para la alternativa H_1: $\beta_j > 0$ con 28 *gl*.

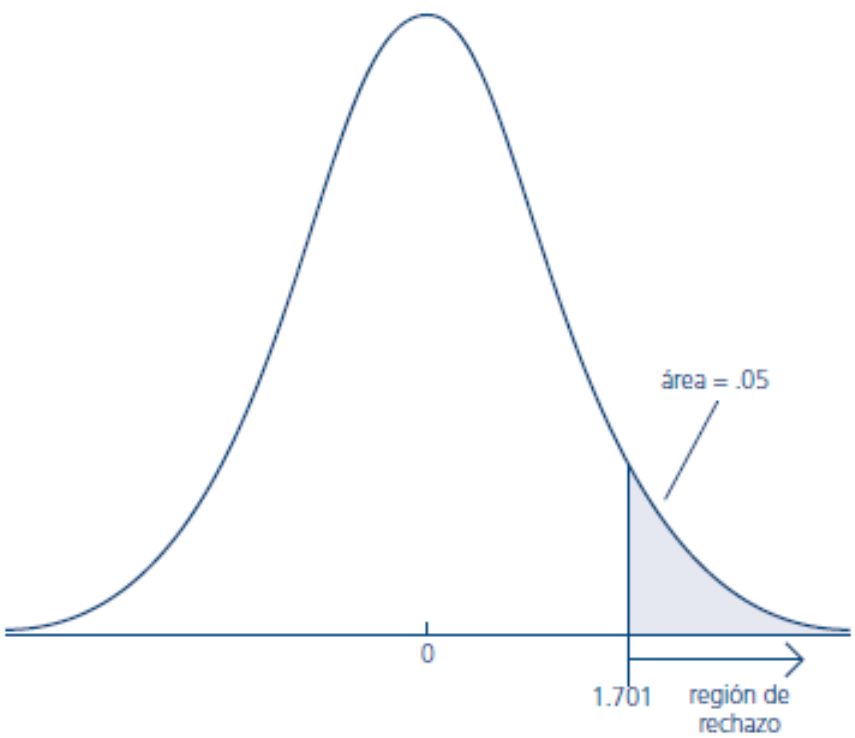

Prueba t: un parámetro poblacional

$$H_0: \beta_i = 0$$
$$H_1: \beta_i \neq 0$$

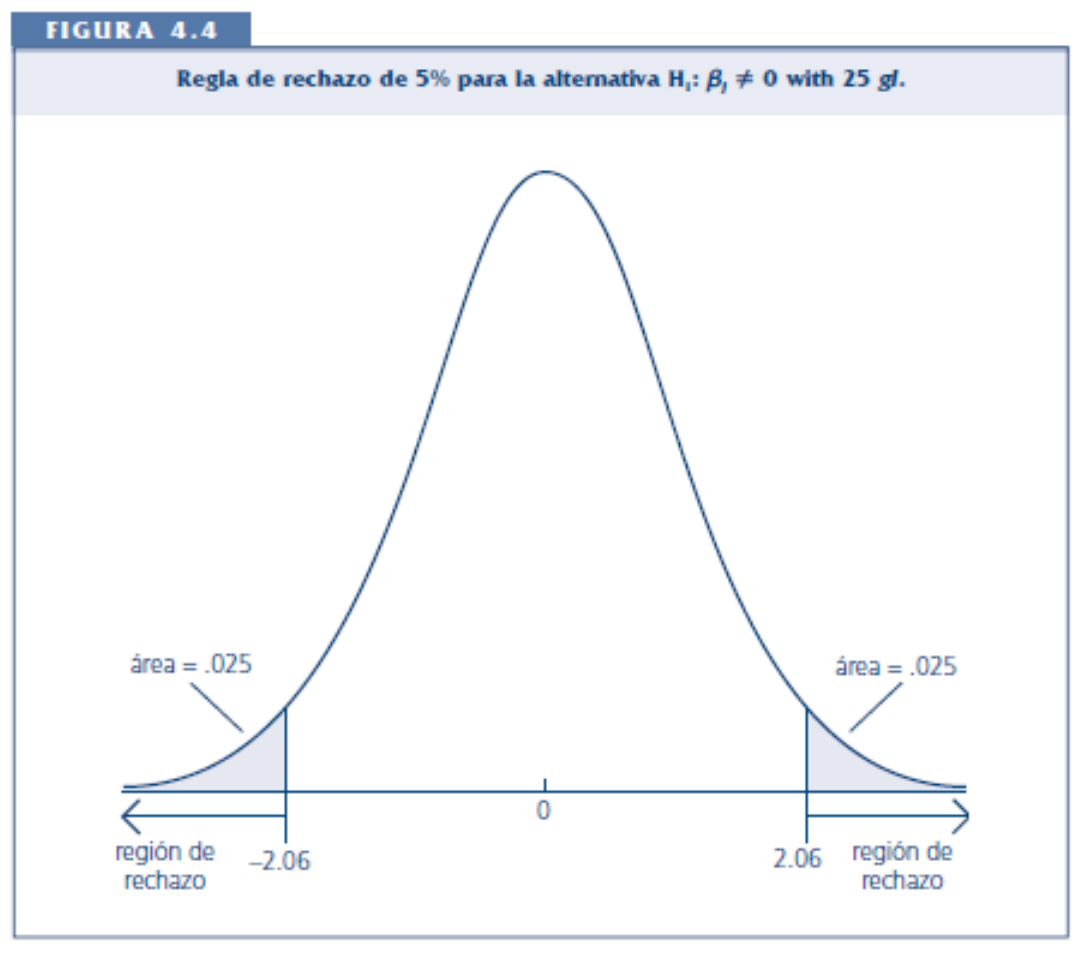

Prueba *t*: ejemplo

OBJETIVO: Deseamos saber si el IVE tiene un efecto estadísticamente significativo al 95% de confianza, *ceteris paribus*.

1. **Planteamos la hipótesis nula y alternativa:**

$$H_0: \beta_2 = 0 \qquad H_1: \beta_2 \neq 0$$

2. **Calculamos el estadístico:** $t_{\widehat{\beta}} = \frac{\widehat{\beta}_2 - \beta_2}{sd(\widehat{\beta}_2)} \xrightarrow{d} N(0,1)$

Puedo obtener la desviación estándar (varianza) de los estimadores a partir de $Var\left(\widehat{\beta_{MCO}}|X\right) = \sigma^2 (X'X)^{-1}$, donde $\widehat{\sigma^2} = \frac{SRC}{N-(K+1)}$.

$$t_{\widehat{\beta}} = \frac{0.0022698 - 0}{0.0007052} = 3.22$$

Prueba t: ejemplo

3. **Revisamos (comparamos) el valor crítico o de rechazo (Tabla t):**

$$Valor\ Crítico\ VC(t_{4192-5}, 95\%, 2\ colas) = 1.96$$

$$\rightarrow \quad |t| > VC$$

$$\rightarrow \quad 3.22 > 1.96$$

4. **Concluímos:** A partir de los resultados anteriores, se concluye que, con un 95% de confianza, el IVE parece estar correlacionado con la nota ("explica la nota") manteniendo todo lo demás constante (el IVE es estadísticamente significativo al 95% de confianza).

Otras pruebas de hipótesis acerca de $\boldsymbol{\beta_i}$

- Aunque $\boldsymbol{H_0}: \boldsymbol{\beta_i} = \mathbf{0}$ es la hipótesis más común, algunas veces se desea probar si β_i es igual a alguna otra constante dada. Dos ejemplos usuales son $\boldsymbol{\beta_i} = \mathbf{1}$ y $\boldsymbol{\beta_i} = \mathbf{-1}$.
- En general, si la hipótesis nula se establece como:

$$H_0: \beta_i = a_i$$

donde a_i es el valor hipotético de β_i, entonces el estadístico t apropiado es:

$$T_{\widehat{\beta}} = \frac{\left(\hat{\beta}_i - a_i\right)}{sd\left(\hat{\beta}_i\right)} \xrightarrow{d} N(0,1)$$

- $\boldsymbol{¿H_0: \beta_i > a_i?}$ → **TAREA!!!**

Prueba *t*: Cálculo del *p-value*

- Hasta ahora, se ha hablado de cómo probar hipótesis empleando un procedimiento clásico: una vez establecida la hipótesis alternativa, se elige un nivel de significancia, el cual determina un valor crítico.

- Pero, no existe un nivel de significancia “correcto”

- Elegir de antemano un nivel de significancia hace que quede oculta información útil acerca del resultado de la prueba de hipótesis.

Prueba *t*: Cálculo del *p-value*

- Existe otra forma de abordar el problema: dado el valor observado del estadístico t, **¿cuál es el menor nivel de significancia al que se habría rechazado la hipótesis nula?** Este nivel se conoce como el **valor-*p* *(p-value)***de la prueba.

- **Esto significa que valores-*p* *(p-value) pequeños* son evidencia *en contra de* la hipótesis nula, mientras que valores-*p* *(p-value) grandes,* proporcionan *poca evidencia en contra de* H_0.**

- Como el valor-*p* *(p-value)* es una probabilidad, su valor es <u>siempre</u> un número entre cero y uno.

Prueba *t*: Cálculo del *p-value*

- OJO: NO existe un nivel de significancia “correcto”(por ejemplo, ¿es mejor 95% o 99% de significancia?
- Dado el valor observado del estadístico t, **¿cuál es el menor nivel de significancia al que se habría rechazado la hipótesis nula?**
- Este nivel se conoce como el ***valor-p (p-value)***de la prueba.

Prueba *t*: Cálculo del *p-value*

- **Interpretación:**
  - ***p-values pequeños* son evidencia *en contra de* la hipótesis nula.**
  - ***p-values grandes* proporcionan *poca evidencia en contra de* H_0.**

- Como el valor-*p (p-value)* es una probabilidad, su valor es <u>siempre</u> un número entre cero y uno.

Prueba *t*: Cálculo del *p-value*

- En el ejemplo anterior, **¿cómo se calcula e interpreta el *p-value* del IVE?**

1. Calculamos el estadístico $t_{\widehat{\beta}}$:

$$t_{\widehat{\beta}}(df = 4192 - 4 - 1 = 4187{,}2\ colas, 95\%)$$
$$= \frac{0.0022698 - 0}{0.0007052} = 3.2186$$

Prueba *t*: Cálculo del *p-value*

2. **Buscamos en la Tabla de Distribución *t*** una respuesta para la pregunta: ¿cuál es el **menor nivel de significancia** al que se habría rechazado la hipótesis nula, dado que tenemos 4192 observaciones y estamos estimando 4 parámetros ($\mathrm{df} = n - k - 1 = 4187$?

$$p - value = 0.001298$$

NOTA: En Excel, este resultado se puede obtener con la función T.DIST.2T(x,df)

3. **Concluimos:** Para valores-*p* menores que éste, ya no puedo rechazar la hipótesis nula.

Intervalos de confianza para un parámetro poblacional

- Bajo los supuestos del modelo lineal clásico, es fácil construir un **intervalo de confianza** para un parámetro poblacional β_i.

- A los intervalos de confianza se les llama también ***estimaciones por intervalo***, porque proporcionan un rango de valores posibles para el parámetro poblacional y no sólo una estimación puntual:

$$\widehat{\boldsymbol{\beta}}_{\boldsymbol{i}} \pm \boldsymbol{t}_{\boldsymbol{df},\boldsymbol{colas},\boldsymbol{\alpha}\%} \cdot \boldsymbol{sd}\left(\widehat{\boldsymbol{\beta}}_{\boldsymbol{i}}\right)$$

Intervalos de confianza para un parámetro poblacional

- Para el ejemplo anterior:

$$t_{(df=4192-4-1=4187,2\ colas,95\%)} = 1.96$$

$$IC_{\widehat{\beta}} = \hat{\beta} \pm t_{df,colas,\alpha\%} \cdot sd(\hat{\beta})$$

$$IC_{\widehat{\beta}} = \hat{\beta} \pm t_{(4187,2\ colas,95\%)} \cdot \sqrt{Var(\hat{\beta})}$$

$$IC_{\widehat{\beta}} = 0.0022698 \pm 1.96 \cdot 0.0007052$$
$$= \mathbf{[0.0008872, 0.0036523]}$$

Prueba de hipótesis para combinación de parámetros

- Con frecuencia se tienen que probar hipótesis en las que interviene más de un parámetro poblacional.
- Por ejemplo, considere el siguiente modelo que emplea información de la Encuesta Longitudinal de Empresas, V Ola (ELE-5, MINECON):

Prueba de hipótesis para combinación de parámetros

$$\text{ventas}_i = \\ = \alpha + \beta_1 \text{inversión_id}_i + \beta_2 \text{gasto_publicidad}_i + \beta_3 \text{patrimonio}_i \\ + \beta_4 \text{trabajadores}_i + u_i$$

- **Hipótesis:**

$$H_0: \hat{\beta}_1 = \hat{\beta}_2 \qquad H_1: \hat{\beta}_1 \neq \hat{\beta}_2$$

$$T_{\hat{\beta}} = \frac{\hat{\beta}_1 - \hat{\beta}_2}{sd(\hat{\beta}_1 - \hat{\beta}_2)} \xrightarrow{d} N(0,1)$$

$$T_{\hat{\beta}} = \frac{137.9\,33 - 23.89999}{sd(\hat{\beta}_1 - \hat{\beta}_2)} = ? \qquad \rightarrow \qquad ¿\, sd(\hat{\beta}_1 - \hat{\beta}_2)?$$

NO CORRESPONDE A $sd(\hat{\beta}_1) - sd(\hat{\beta}_2)$!!!

Prueba de hipótesis para combinación de parámetros

$$sd(\widehat{\beta}_1 - \widehat{\beta}_2) = \sqrt{Var(\widehat{\beta}_1 - \widehat{\beta}_2)} = \{Var(\widehat{\beta}_1) + Var(\widehat{\beta}_2) - 2Cov(\widehat{\beta}_1, \widehat{\beta}_2)\}^{1/2}$$

- STATA permite obtener la matriz de varianza-covarianzas para estos cálculos (**Lo verán en el Labotario de Rstudio)**

```
. estat vce

Covariance matrix of coefficients of regress model
```

e(V)	inversio~d	gasto_pu~d	patrimonio	trabajad~s	_cons
inversion_id	12.072688				
gasto_publ~d	-.84813683	4.5176325			
patrimonio	-.00997344	-.00783575	.00062781		
trabajadores	566.93887	-3599.927	-8.006701	47762367	
_cons	-74081.028	-435835.94	-8850.0553	-4.659e+09	1.108e+13

- A partir de esta información podemos realizar nuestro test:

$$sd(\hat{\beta}_1 - \hat{\beta}_2) = \{12.072688 + 4.5176325 - 2(-0.84813683)\}^{1/2} = 4.47022$$

$$T_{\widehat{\beta}} = \frac{137.9\,33 - 23.89999}{4.47022} = 25.50948$$

Reparametrización

- En algunas situaciones, el interés se centra en una **combinación lineal de los parámetros** de un modelo.
  - En estos casos**, puede ser mejor reparametrizar el modelo, de manera que dicha combinación sea un parámetro del modelo transformado**
- <u>Ejemplo:</u> deseamos testear $H_0: \alpha_1 + \alpha_2 = 0$ en el modelo

$$Y_i = \alpha_0 + \alpha_1 X_{1i} + \alpha_2 X_{2i} + \varepsilon_i$$

Reparametrización

- **<u>Alternativa 1:</u>** $t = \frac{\widehat{\alpha_1}+\widehat{\alpha_2}-0}{\sqrt{Var(\widehat{\alpha_1})+Var(\widehat{\alpha_2})+2\cdot Cov(\widehat{\alpha_1},\widehat{\alpha_2})}} \sim t_{N-k-1}$

- **<u>Alternativa 2</u>: Reparametrizar**

$$\theta = \alpha_1 + \alpha_2 \quad \rightarrow \alpha_2 = \theta - \alpha_1$$

$$\therefore Y_i = \alpha_0 + \alpha_1 X_{1i} + (\theta - \alpha_1) X_{2i} + \varepsilon_i$$

$$\rightarrow ME: \; Y_i = \alpha_0 + \boldsymbol{\alpha_1} \cdot (\boldsymbol{X_{1i}} - \boldsymbol{X_{2i}}) + \boldsymbol{\theta} \cdot \boldsymbol{X_{2i}} + \varepsilon_i$$

Por lo tanto, $H_0: \alpha_1 + \alpha_2 = 0$ puede expresarse *como* $H_0: \theta = 0$ en el modelo reparametrizado. El test se obtiene sólo mirando el *output* de la nueva regresión, viendo si el coeficiente de X_{2i} es significativo.

Prueba F: restricciones lineales múltiples

- Ya se ha visto cómo probar si una determinada variable (una única restricción) no tiene efecto parcial sobre la variable explicada usando el estadístico t.

- Sin embargo, es frecuente la necesidad de probar **hipótesis *múltiples*** de manera simultánea acerca de los parámetros $\hat{\beta}_1, \hat{\beta}_2, \hat{\beta}_3, \dots, \hat{\beta}_k$

- A una prueba de restricciones múltiples se le llama **prueba de hipótesis múltiple o prueba de hipótesis conjunta.**

Prueba F: restricciones lineales múltiples

- En nuestro ejemplo anterior, suponga que se desea probar la hipótesis nula de que, una vez controlados el patrimonio y el número de trabajadores, los estadísticos que miden el gasto en publicidad e I+D no tienen efecto sobre las ventas.

- En términos de los parámetros del modelo, la hipótesis nula se establece de la manera siguiente:

$$H_0: \hat{\beta}_1 = 0, \hat{\beta}_2 = 0 \qquad H_1: H_0 \; no \; es \; verdadera$$

Prueba F: restricciones lineales múltiples

- **La hipótesis alternativa (H_1) se satisface si AL MENOS uno de los $\widehat{\beta}_1$ y $\widehat{\beta}_2$ es diferente de cero.**

- <u>Atajo:</u> construir un estadístico t para cada una de las variables. **Esta opción NO es la adecuada. Un estadístico *t* determinado sirve para probar una hipótesis que no condicione con ninguna restricción a otros parámetros.**

Prueba F: caso general

- Se necesita una manera de probar ***conjuntamente*** las restricciones de exclusión. ¿Qué hacer?
- Si hay más de una restricción, no se puede aplicar un test t, pero sí un **test F** a partir del **modelo no restringido** (modelo original) *versus* el **modelo restringido:**

$$F = \frac{(SRC_R - SRC_{NR})/r}{SRC_{NR}/(N-k-1)} \sim Fisher(r, N-k-1)$$

donde SRC_R y SRC_{NR} son las sumas de residuos al cuadrado de los modelos restringido y no restringido, respectivamente, N es el número de observaciones, k es el número de regresores, y r es el número de restricciones.

Prueba F: caso general

- En el **modelo no restringido:**

$$\text{ventas}_i = \\ = \alpha + \beta_1 \text{inversión_id}_i + \beta_2 \text{gasto_publicidad}_i \\ + \beta_3 \text{patrimonio}_i + \beta_4 \text{trabajadores}_i + \boldsymbol{u_{NRi}}$$

Se desea testear la hipótesis conjunta:

$$H_0: \begin{Bmatrix} \hat{\beta}_1 = 0 \\ y \\ \hat{\beta}_2 = 0 \end{Bmatrix} \qquad H_1: \begin{Bmatrix} \hat{\beta}_1 \neq 0 \\ o \\ \hat{\beta}_2 \neq 0 \end{Bmatrix}$$

- En el **modelo restringido, se impone H_0** y se reagrupan los términos hasta quedar como un MRLM:

$$\text{ventas}_i = \alpha + \beta_3 \text{patrimonio}_i + \beta_4 \text{trabajadores}_i + \boldsymbol{u_{Ri}}$$

Prueba F: caso general

$$H_0: \begin{Bmatrix} \hat{\beta}_1 = 0 \\ y \\ \hat{\beta}_2 = 0 \end{Bmatrix}$$

$$H_1: \begin{Bmatrix} \hat{\beta}_1 \neq 0 \\ o \\ \hat{\beta}_2 \neq 0 \end{Bmatrix}$$

FIGURA 4.7

Valor crítico correspondiente a 5% y región de rechazo en la distribución $F_{3,60}$.

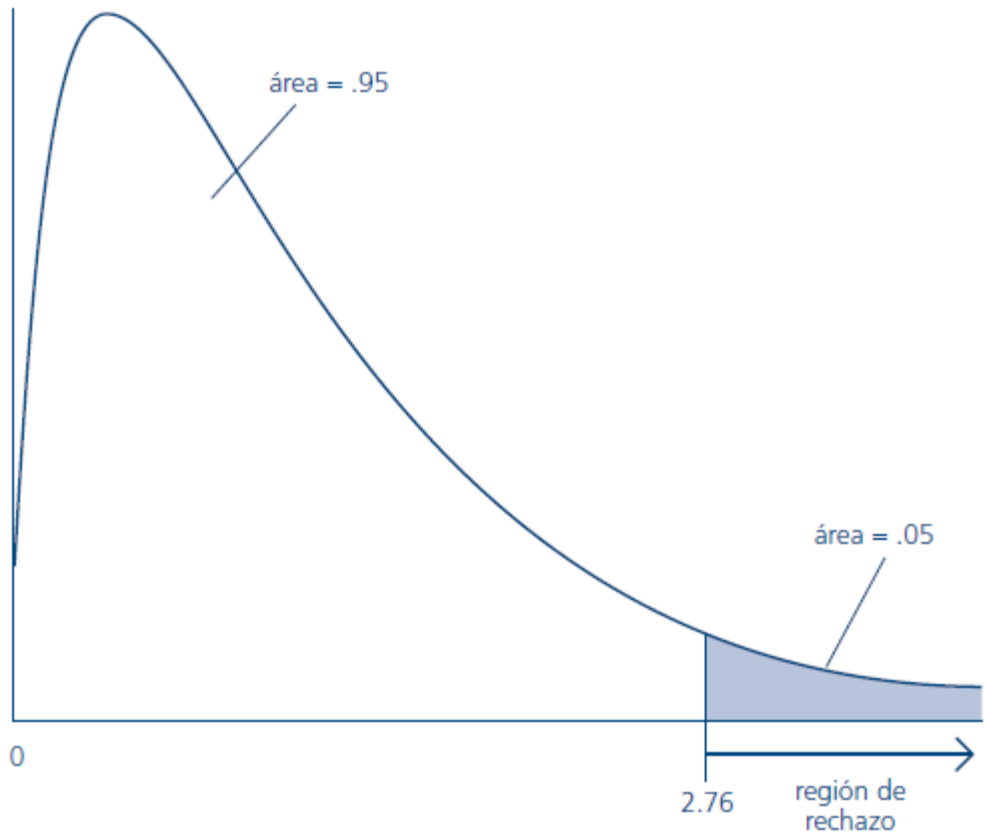

Prueba F: otros ejemplos

- **<u>Modelo no restringido:</u>**

$$Y_i = \alpha_0 + \alpha_1 X_{1i} + \alpha_2 X_{2i} + \varepsilon_i$$

- **Modelo restringido bajo H_0: $\alpha_1 = \alpha_2$**

$$Y_i = \alpha_0 + \alpha_2 X_{1i} + \alpha_2 X_{2i} + \varepsilon_i = \alpha_0 + \alpha_2 (X_{1i} + X_{2i}) + \varepsilon_i$$

- **Modelo restringido bajo H_0: $\alpha_1 = 3$**

$$Y_i = \alpha_0 + 3X_{1i} + \alpha_2 X_{2i} + \varepsilon_i \Rightarrow (Y_i - 3X_{1i}) = \alpha_0 + \alpha_2 X_{2i} + \varepsilon_i$$

- **Modelo restringido bajo H_0: $\alpha_1 = 2\alpha_2 + 3$**

$$Y_i = \alpha_0 + (2\alpha_2 + 3)X_{1i} + \alpha_2 X_{2i} + \varepsilon_i \Rightarrow$$
$$(Y_i - 3X_{1i}) = \alpha_0 + \alpha_2 (X_{2i} + 2X_{1i}) + \varepsilon_i$$

Forma R^2 del estadístico F: hipótesis de exclusión

- Cuando H_0 incluye <u>sólo</u> hipótesis de exclusión (por ejemplo, $\beta_1 = \beta_2 = \cdots = \beta_k = 0$), el test F puede obtenerse a partir del R^2 de ambos modelos:

$$\boldsymbol{F = \frac{\left(R_{NR}^2 - R_R^2\right)/r}{\left(1 - R_{NR}^2\right)/(N - K - 1)} \sim Fisher(r, N - K - 1)}$$

Forma R^2 del estadístico F: test de significancia global

- Cuando H_0 corresponde a la hipótesis de que **todas las pendientes son iguales a cero,**

$$\beta_1 = \beta_2 = \cdots = \beta_k = 0$$

el modelo restringido tiene R^2 nulo y el test F se expresa simplemente a partir del R^2 del modelo original:

$$\boldsymbol{F = \frac{R^2/(K)}{(1-R^2)/(N-K-1)} \sim Fisher(K, N-K-1)}$$

- Esta hipótesis nula es muy pesimista: establece que *ninguna* de las variables explicativas tiene efecto sobre y. **Enunciada en términos de los parámetros, la hipótesis nula dice que todos los parámetros de pendiente son cero.**

Forma R^2 del estadístico F: test de significancia global

$$\boldsymbol{F = \frac{R^2/(K)}{(1-R^2)/(N-K-1)} \sim Fisher(K, N-K-1)}$$

$$F = \frac{R^2/(K)}{(1-R^2)/(N-K-1)} = \frac{0{,}4887/4}{(1-0{,}4887)/(2819-5)} = 672{,}3995$$

Efectos de los ajustes de escala de los datos sobre MCO

- **¿Qué efecto tiene sobre la inferencia estadística el cambio (re-escalamiento) en las unidades de medida de las variables?**
- No afecta al coeficiente de determinación R^2
- Cuando se re-escalan las variables, tanto los coeficientes como los errores standard, los intervalos de confianza, los estadísticos t y los estadísticos F se modifican de una manera tal que se preservan todos los efectos medidos y los resultados de las pruebas.
- Sin embargo, es **FUNDAMENTAL** conocer la escala de medición de los datos para una **CORRECTA INTERPRETACIÓN DE LOS EFECTOS MARGINALES!**
- Veámoslo con un par de ejemplos…