Econometría I

Prof. Carlos Briceño Sotelo

Universidad Adolfo Ibañez

UNIDAD 4: Causalidad y Diseño

Resumen de la Unidad 4

Resumen de la Unidad 4

1. Análisis de la propiedad de insesgamiento
2. Formas funcionales, elección de regresores e interpretación de coeficientes
3. Más sobre R^2 y especificación de modelos
4. Predicción y análisis de residuos
5. Multicolinealidad
6. Heterocedasticidad
7. Causalidad, experimentos naturales y validez de los modelos
8. Resumiendo… con un ejemplo

Resumen de la Unidad 4

1. **Análisis de la propiedad de insesgamiento**
2. Formas funcionales, elección de regresores e interpretación de coeficientes
3. Más sobre R^2 y especificación de modelos
4. Predicción y análisis de residuos
5. Multicolinealidad
6. Heterocedasticidad
7. Causalidad, experimentos naturales y validez de los modelos
8. Resumiendo… con un ejemplo

Análisis de la propiedad de insesgamiento

¿Por qué cuando NO se cumple el Supuesto 4 de Exogeneidad (esperanza condicional nula del error) decimos que tendremos estimadores por MCO sesgados?

(Es decir, que los $\left[\widehat{\beta_{MCO}}\right]$ no cumplirán la propiedad de insesgamiento revisada anteriormente)

Insesgamiento: Variable omitida relevante

- Anteriormente dijimos que el incumplimiento del supuesto de esperanza condicional nula sesgaba los parámetros MCO estimados:

$$\boldsymbol{E}[u|\boldsymbol{X_1}, \boldsymbol{X_2}, \boldsymbol{X_3}, \dots, \boldsymbol{X_k}] \neq \boldsymbol{0}$$

- Ahora es el momento de:
  - Demostrar explícitamente el problema de sesgo.
  - Determinar la dirección y la magnitud de este sesgo.
- La determinación del sesgo ocasionado por la omisión de una variable es un ejemplo de **análisis de error de especificación.**

Insesgamiento: Variable omitida relevante

- Supongamos que el **Modelo Correcto (MC)** es el siguiente:

$$\boldsymbol{MC}\text{: } Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i \quad con\ E[u_i|X_{1i}, X_{2i}] = 0$$

- Sin embargo, nosotros excluimos X_{2i}, resultando en el siguiente **Modelo Estimado (ME)**:

$$\boldsymbol{ME}\text{: } Y_i = \beta_0 + \beta_1 X_{1i} + \boldsymbol{\varepsilon_i}$$

- Note que ε_i incluye a la variable omitida:

$$\boldsymbol{\varepsilon_i = \beta_2 X_2 + u}$$

Insesgamiento: Variable omitida relevante

- La recta de la ecuación estimada para el **Modelo Estimado (ME)** es:

$$\tilde{Y} = \widetilde{\beta_0} + \boldsymbol{\widetilde{\beta_1}} X_1$$

- Se puede demostrar que: $E\left(\widetilde{\beta_1} \mid X_1\right) = \beta_1 + \boldsymbol{\beta_2 \widehat{\phi}}$

- $\boldsymbol{\beta_2}$ mide el efecto (ignorado) de X_2 en Y
- $\boldsymbol{\widehat{\phi}}$ es el coeficiente de regresión de X_2 en X_1

Insesgamiento: Variable omitida relevante

- Por lo tanto,

$$\boldsymbol{Sesgo = E(\widetilde{\beta_1}) - \beta_1 = \beta_2 \widehat{\phi}}$$

- **Pregunta importante:**
  1) ¿Será el estimador $\widetilde{\beta_1}$ insesgado en el Modelo Estimado (ME)?

- **Respuesta:**
  1) La exclusión de X_{2i} **sesga todos los coeficientes.** Sólo en casos especiales esto no sucede:
     i. Cuando la variable omitida no es **relevante, es decir,** $\beta_2 = 0$
     ii. Cuando la variable omitida no **está correlacionada** con la variable introducida de interés, es decir, $\mathrm{Cov}(X_{1i}, X_{2i}) = 0$

Insesgamiento: Variable omitida relevante

- Por lo tanto,

$$\boldsymbol{Sesgo = E(\widetilde{\beta_1}) - \beta_1 = \beta_2 \widehat{\phi}}$$

- **Preguntas importantes:**

  1) ¿Sólo la varianza de $\widetilde{\beta_1}$ en el Modelo Estimado se verá afectada en relación a la varianza obtenida para el Modelo Correcto (MC)?

- **Respuestas:**

  1) No. Afecta la varianza de **todos** los estimadores

Ejemplo de variable omitida relevante

$$M1: pesokg = \beta_0 + \beta_1 tallacm$$
$$M2: pesokg = \beta_0 + \beta_1 tallacm + \beta_2 edad$$
$$M3: edad = \alpha_0 + \alpha_1 tallacm$$

- El Modelo 2 agrega una variable explicativa al Modelo 1
- El Modelo 3 relaciona ambas variables explicativas

- **¿Qué podemos concluir de los resultados?**

Ejemplo de variable omitida relevante

	(Modelo 1)	(Modelo 2)	(Modelo 3)
VARIABLES	**Peso_kg**	**Peso_kg**	**Edad**
Talla_cm	0.732***	0.716***	0.111***
	(0.00222)	(0.00300)	(0.000833)
Edad		0.148***	
		(0.0182)	
Constante	-62.22***	-62.01***	-1.425***
	(0.292)	(0.293)	(0.109)
Observaciones	21,531	21,531	21,531
Suma Residuos Cuadrados (SRC)	933910.48	931039.687	130966.97
Suma Total Cuadrados (STC)	5642696.43	5642696.43	238434.42

Errores estándar entre paréntesis

*** p<0.01, ** p<0.05, * p<0.1

Ejemplo de variable omitida relevante

- **¿Qué podemos concluir de los resultados?**

- **El β_1 del Modelo 1 estaba sesgado**: esto se debe a que incorporaba en el error una variable explicativa correlacionada con la variable independiente ($tallacm$).

- Esto se puede observar ya que la variable omitida ($edad$) es estadísticamente significativa (Modelo 2), es decir, "edad explica el peso", y está correlacionada con la variable $tallacm$ según el Modelo 3.

Variable omitida relevante: signo del sesgo

$$MC\colon\ Y_i = \beta_0 + \beta_1 X_{1i} + \boldsymbol{\beta_2 X_{2i}} + u_i$$
$$ME\colon\ Y_i = \widetilde{\beta_0} + \boldsymbol{\widetilde{\beta_1}} X_{1i} + u_i$$

$$Variable\ omitida\colon \boldsymbol{X_{2i}}$$
$$Estimador\ sesgado\colon \boldsymbol{\widetilde{\beta_1}}$$

	$\boldsymbol{Corr(X_1, X_2) > 0}$	$\boldsymbol{Corr(X_1, X_2) < 0}$
$\beta_2 > 0$	Sesgo positivo	Sesgo negativo
$\beta_2 < 0$	Sesgo negativo	Sesgo positivo

Insesgamiento: Variable omitida relevante

- **¿Cómo se podría determinar la magnitud y orientación del sesgo en función de la información disponible en el ejemplo?**
- La correlación entre $tallacm$ y $edad$ es positiva. Por lo tanto, **el sesgo debiese ser positivo**:

$$M3: edad = \alpha_0 + \alpha_1 tallacm \quad \rightarrow \quad edad = -1.425 + 0.111 \cdot tallacm$$

- Esto implica que:
  - $E(\widetilde{\beta_1} \mid X_1) = \beta_1 + \boldsymbol{\beta_2 \widehat{\phi}}$
  - $Sesgo(\widetilde{\beta_1}) = E(\widetilde{\beta_1}) - \beta_1 = \boldsymbol{\beta_2 \widehat{\phi} > 0}$

Insesgamiento: Variable omitida relevante

- Sesgo positivo, por lo cual β_1 está sobreestimado en el Modelo 1.
- β_2 es positivo (Modelo 2) y $\hat{\phi}$ es positivo (Modelo 3).
- Por lo tanto, el sesgo es positivo y β_1 estaría sobreestimando el efecto de $tallacm$.

Insesgamiento: Variable irrelevante o "intrusa"

- Supongamos que el modelo correcto es el siguiente:

$$MC: Y_i = \beta_0 + \beta_1 X_{1i} + u_i \qquad con\ E[u_i|X_{1i}] = 0$$

- Sin embargo, **incluimos una variable irrelevante**:

$$ME: Y_i = \beta_0 + \beta_1 X_{1i} + \boldsymbol{\beta_2 X_{2i}} + u_i$$

Insesgamiento: Variable irrelevante o “intrusa”

- **Pregunta:**

  ¿Será el estimador $\widehat{\beta_1}$ insesgado en el ME?

- **Respuesta:**

  La inclusión de una variable irrelevante **no sesga** el estimador de $\widehat{\beta_1}$

Insesgamiento: Variable irrelevante o “intrusa”

- **Pregunta:**

  ¿Será la varianza de $\widehat{\beta_1}$ en ME mayor o menor que aquella en Modelo Correcto?

- **Respuesta:**

  Puede afectar la varianza de los estimadores. La varianza de $\widehat{\beta_1}$ en ME puede ser mayor que aquella en MC si la variable agregada tiene poco poder explicativo (aumenta el $\widehat{\sigma^2}$ del modelo) y, más aún, si está correlacionada con X_{1i}.

Resumen de la Unidad 4

1. Análisis de la propiedad de insesgamiento
2. **Formas funcionales, elección de regresores e interpretación de coeficientes**
3. Más sobre R^2 y especificación de modelos
4. Predicción y análisis de residuos
5. Multicolinealidad
6. Heterocedasticidad
7. Causalidad, experimentos naturales y validez de los modelos
8. Resumiendo… con un ejemplo

Formas funcionales e interpretación de coeficientes

- En esta sección, veremos algunas variaciones y extensiones de las formas funcionales, las cuales suelen encontrarse en el trabajo aplicado.

- Analizamos dos grupos de variables:
  1. Variables continuas
  2. Variables discretas que representan información cualitativa

Formas funcionales e interpretación de coeficientes

- **Ejemplo:**

- **<u>Modelo a estimar:</u>**

$$ln(Salario_i) = \alpha_0 + \alpha_1 Mujer_i + \alpha_2 Escolaridad_i + \alpha_3 Exp_i + \\ + \alpha_4 {Exp_i}^2 + \alpha_5 Casado_i + \varepsilon_i$$

- **<u>Modelo estimado:</u>**

$$ln(\widehat{Salario_i}) \\ = 10.39 - 0.26 \cdot Mujer_i + 0.10 \cdot Escolaridad_i + 0.02 \cdot Exp_i - \\ - 0.0002 \cdot {Exp_i}^2 + 0.05 \cdot Casado_i$$

Formas funcionales e interpretación de coeficientes

- **Ejemplo:**

- La forma de **interpretar** los coeficientes estimados depende de una serie de factores vinculados con la variable explicada y los regresores:

  - ¿La variable de interés está medida en niveles, en logaritmo o es un término cuadrático?
  - ¿La variable es continua o binaria o categórica?
  - ¿Hay alguna interacción entre el regresor e y?

Interpretación de Regresores Continuos en niveles

- ***<u>Caso 1</u>: Regresores en niveles (caso más habitual)***

$$Salario_i = \beta_0 + \beta_1 Escolaridad_i + \varepsilon_i$$

  - En este caso, el **efecto marginal** de la escolaridad sobre el salario coincide con β_1. Por lo tanto, el coeficiente estimado se interpreta como la variación en el salario que acompañaría un aumento de 1 unidad en la escolaridad (en este caso, sin controlar por otras variables):

$$\boxed{\Delta Salario_i = \beta_1 \cdot \Delta Escolaridad_i}$$

$$\frac{\partial Salario_i}{\partial Escolaridad_i} = \beta_1 \rightarrow \frac{\Delta Salario_i}{\Delta Escolaridad_i} = \beta_1$$

Interpretación de Regresores Continuos en logaritmos

- ***<u>Caso 2</u>: Variable explicativa y explicada expresadas en términos logarítmicos***

$$ln(Salario_i) = \beta_0 + \beta_1 ln(Escolaridad_i) + \varepsilon_i$$

$$\boxed{\frac{\Delta Salario_i}{Salario_i} = \beta_1 \cdot \frac{\Delta Escolaridad_i}{Escolaridad_i}}$$

$$\frac{\partial \ln(Salario_i)}{\partial \ln(Escolaridad_i)} = \beta_1 \rightarrow \frac{\frac{\Delta Salario_i}{Salario_i}}{\frac{\Delta Escolaridad_i}{Escolaridad_i}}$$

- En este caso, **β_1 tiene interpretación de Elasticidad!**

Interpretación de Regresores Continuos en logaritmos

- ***<u>Caso 3</u>: Variable explicada expresada en términos logarítmicos***

$$ln(Salario_i) = \beta_0 + \beta_1 Escolaridad_i + \varepsilon_i$$

$$\boxed{\frac{\Delta Salario_i}{Salario_i} = \beta_1 \cdot \Delta Escolaridad_i}$$

$$\frac{\partial \ln(Salario_i)}{\partial Escolaridad_i} = \beta_1 \rightarrow \frac{\frac{\Delta Salario_i}{Salario_i}}{\Delta Escolaridad_i}$$

- En este caso, **β_1 tiene interpretación de Semi-elasticidad!**

Interpretación de Regresores Continuos en logaritmos

- ***Resumiendo…***

Modelo	Variable explicada	Regresor	Interpretación de β_1
Nivel-Nivel	y	x	$\Delta y = \beta_1 \Delta x \rightarrow \frac{\Delta y}{\Delta x} = \beta_1$
Nivel-Log	y	$\log(x)$	$\Delta y = \left(\frac{\beta_1}{100}\right) \%\Delta x \rightarrow \frac{\Delta y}{\%\Delta x} = \left(\frac{\beta_1}{100}\right) \%$
Log-Nivel	$\log(y)$	x	$\%\Delta y = (100\beta_1)\, \Delta x \rightarrow \frac{\%\Delta y}{\Delta x} = (100\beta_1)$
Log-Log	$\log(y)$	$\log(x)$	$\%\Delta y = \beta_1 \%\Delta x \rightarrow \frac{\%\Delta y}{\%\Delta x} = \beta_1$

Interpretación de Regresores Continuos en logaritmos

```
. reg ln_ventas ln_patrimonio trabajadores

      Source |       SS           df       MS      Number of obs   =     4,490
-------------+----------------------------------   F(2, 4487)      =   4742.71
       Model |  17867.4187         2  8933.70937   Prob > F        =    0.0000
    Residual |    8452.044     4,487  1.88367372   R-squared       =    0.6789
-------------+----------------------------------   Adj R-squared   =    0.6787
       Total |  26319.4627     4,489  5.86310153   Root MSE        =    1.3725

------------------------------------------------------------------------------
    ln_ventas |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
ln_patrimonio |   .6745991   .0070715    95.40   0.000     .6607356    .6884626
 trabajadores |   .0002214    .000025     8.87   0.000     .0001725    .0002703
        _cons |   5.305045   .0885105    59.94   0.000      5.13152    5.478569
------------------------------------------------------------------------------
```

- Cuando el <u>patrimonio</u> aumenta en un 1%, las ventas aumentan en un 0,67%, manteniendo todo lo demás constante. **¡Elasticidad!**
- Cuando aumenta el <u>número de trabajadores</u> en uno, aumenta en 0,022% las ventas (100*β_1), *ceteris paribus*. **¡Semi-elasticidad!**

Interpretación de Regresores Continuos en logaritmos

- **El uso de $\ln(\cdot)$** conduce a coeficientes con una interpretación interesante, ya que pueden ignorarse las unidades de medición de las variables porque los coeficientes de pendiente no varían ante un cambio de unidades.

- **Cuando la variable $y > 0$**, los modelos en los que se emplea $\log(y)$ o $\ln(y)$ como variable explicativa suelen satisfacer mejor los supuestos del MLC que los modelos en los que se emplea la variable y en forma lineal.

- **Variables estrictamente positivas** suelen tener distribuciones condicionales que son heterocedásticas o asimétricas. Empleando logaritmos, ambos problemas pueden atenuarse, o incluso eliminarse.

Interpretación de Regresores Continuos en logaritmos

- Además, en algunos casos, **el empleo de logaritmos suele atenuar el problema de magnitud de la variable**. Esto hace las estimaciones menos sensibles a observaciones atípicas (o extremas) de los regresores o regresandos.

- **Cuando una variable es una cantidad positiva de dinero, suele emplearse su logaritmo.** Esto se ha visto en el caso de variables tales como sueldos, salarios, ventas y valor de mercado de las empresas; éstas tienen la característica común de ser cantidades enteras grandes.

Interpretación de Regresores Continuos en logaritmos

- Variables que se miden en años —como educación, experiencia, antigüedad, edad, etc.— usualmente aparecen en su forma original.

- Variables que son una proporción o un porcentaje —como tasa de desempleo y tasa de detención o criminalidad— pueden aparecer ya sea en su forma original o en forma logarítmica, aunque hay una tendencia a usarlas en su forma lineal.

- Una limitación de los logaritmos es que **no pueden usarse si una variable toma valores negativos o cero**.

Interpretación de Regresores Continuos cuadráticos

- ***<u>Caso 4</u>: Funciones cuadráticas del regresor***

Las funciones cuadráticas se emplean también con bastante frecuencia en economía para captar efectos marginales crecientes o decrecientes.

$$Salario_i = \alpha_0 + \alpha_1 \cdot Experiencia_i + \alpha_2 \cdot {Experiencia_i}^2 + \varepsilon_i$$

$$Efecto\ Marginal = \frac{\partial Salario_i}{\partial Experiencia_i} = \alpha_1 + 2 \cdot \alpha_2 \cdot Experiencia_i$$

Interpretación de Regresores Continuos cuadráticos

```
. reg yaut exp exp2

      Source |       SS           df       MS      Number of obs   =   102,775
-------------+----------------------------------   F(2, 102772)    =    685.69
       Model |  7.4684e+14         2  3.7342e+14   Prob > F        =    0.0000
    Residual |  5.5969e+16   102,772  5.4459e+11   R-squared       =    0.0132
-------------+----------------------------------   Adj R-squared   =    0.0131
       Total |  5.6716e+16   102,774  5.5185e+11   Root MSE        =    7.4e+0

------------------------------------------------------------------------------
        yaut |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
         exp |   17596.24   573.8541    30.66   0.000     16471.49    18720.99
        exp2 |  -308.4713   15.30486   -20.16   0.000    -338.4686    -278.474
       _cons |   420521.3   3315.869   126.82   0.000     414022.2    427020.3
------------------------------------------------------------------------------
```

- La ecuación estimada indica que experiencia tiene un efecto decreciente sobre el ingreso.
- $Año\ 5\ a\ 6 = 17.596 - 2 * 308 * 5 = 14.516$
- $Año\ 20\ a\ 21 = 17.596 - 2 * 308 * 20 = 5.276$

Interpretación de Regresores Continuos cuadráticos

FIGURA 6.1

Relación cuadrática entre $\widehat{wage}$ y *exper*.

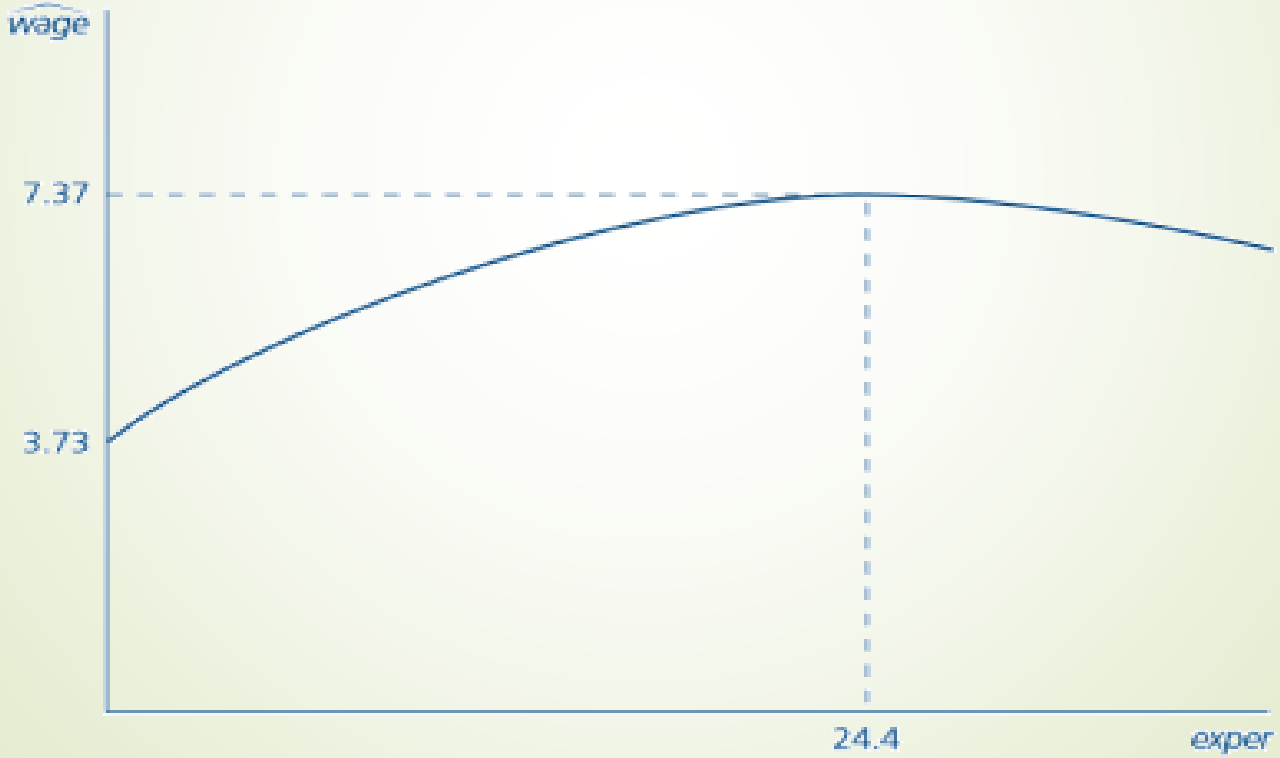

Interpretación de Regresores Continuos: interacciones

- ***<u>Caso 5</u>: Interacción entre regresores***
  - Efecto parcial de una variable depende de la magnitud de otra variable explicativa
  - Algunas veces es natural que el efecto parcial, la elasticidad o la semi-elasticidad de la variable explicada respecto a una variable explicativa dependa de la magnitud de otra variable explicativa.

$$Salario_i = \alpha_0 + \alpha_1 Esc_i + \alpha_2 Experiencia_i +$$
$$+\alpha_3(\boldsymbol{Esc_i \cdot Experiencia_i}) + \varepsilon_i$$

$$Efecto\ Marginal = \frac{\partial Salario_i}{\partial Experiencia_i} = \alpha_2 + \alpha_3 \cdot Escolaridad_i$$

Interpretación de Regresores Continuos: interacciones

```
. reg yaut educ exp exp_educ

      Source |       SS           df       MS      Number of obs   =   102,601
-------------+----------------------------------   F(3, 102597)    =   6263.07
       Model |  8.7675e+15         3  2.9225e+15   Prob > F        =    0.0000
    Residual |  4.7874e+16   102,597  4.6662e+11   R-squared       =    0.1548
-------------+----------------------------------   Adj R-squared   =    0.1548
       Total |  5.6642e+16   102,600  5.5206e+11   Root MSE        =    6.8e+05

------------------------------------------------------------------------------
        yaut |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
        educ |   72092.57   858.3495    83.99   0.000     70410.22    73774.93
         exp |   773.1396   352.9215     2.19   0.028     81.41803    1464.861
    exp_educ |   1720.409   61.26483    28.08   0.000     1600.331    1840.487
       _cons |      49465   5280.777     9.37   0.000     39114.75    59815.25
------------------------------------------------------------------------------
```

- ¿Cómo obtengo el efecto parcial de la experiencia sobre el salario?
- ¿Cómo aplico test de hipótesis sobre la escolaridad o la experiencia?
- ¿Debo utilizar test t o F? (Recordar lo aprendido en la parte anterior)

Interpretación de Regresores Continuos: interacciones

```
. reg yaut educ exp exp_educ

      Source |       SS           df       MS      Number of obs   =   102,601
-------------+----------------------------------   F(3, 102597)    =   6263.07
       Model |  8.7675e+15         3  2.9225e+15   Prob > F        =    0.0000
    Residual |  4.7874e+16   102,597  4.6662e+11   R-squared       =    0.1548
-------------+----------------------------------   Adj R-squared   =    0.1548
       Total |  5.6642e+16   102,600  5.5206e+11   Root MSE        =    6.8e+05

------------------------------------------------------------------------------
        yaut |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
        educ |   72092.57   858.3495    83.99   0.000     70410.22    73774.93
         exp |   773.1396   352.9215     2.19   0.028     81.41803    1464.861
    exp_educ |   1720.409   61.26483    28.08   0.000     1600.331    1840.487
       _cons |      49465   5280.777     9.37   0.000     39114.75    59815.25
------------------------------------------------------------------------------
```

Interpretación de Regresores Cualitativos: Dicotómicas

- **Dicotómica (binaria/*dummy*):**
  - Toma 2 modalidades o valores solamente
  - Se la representa matemáticamente con $\mathbf{0/1}$
  - Ejemplos:
    - Sexo: hombre=1, mujer=0
    - Zona: urbano=0, rural=1
    - Padece una enfermedad: Sí=1, No=0
    - Resultado de una prueba: Aprueba=1, Reprueba=0

Interpretación de Regresores Cualitativos: Politómicas

- **Politómica (o categórica):**
  - Puede tomar más de 2 modalidades o valores o categorías
  - **Nominal:** No se puede definir un orden natural entre sus categorías. Ejemplo, raza, religión, estado civil, etc.
  - **Ordinal:** Es posible establecer relaciones de orden entre las categorías, rango militar, clase social, grupo socio económico, nivel de escolaridad alcanzado, etc.

Interpretación de Regresores Cualitativos: Politómicas

- **Politómica (o categórica):**
  - **Por Intervalo:** Proceden de variables cuantitativas agrupadas en intervalos. Permiten introducir no linealidades.

Ejemplo: discretización de los niveles educativos (variable continua) para permitir que sea no lineal:

- Nivel 1: Básica Incompleta= educación entre 0 y 7 años,
- Nivel 2: Básica Completa=educación igual a 8 años,
- Nivel 3: Media Incompleta=educación entre 9 y 11 años,
- Nivel 4: Media Completa= educación igual a 12 años,
- Nivel 5: Educación Superior= educación superior a 12 años

Interpretación de Regresores Cualitativos: Politómicas

- **Politómica (o categórica):**
  - Existen variables que pueden ser medidas en escala nominal, ordinal o cuantitativa. Por ejemplo, el tipo de educación (privada, subvencionada, pública) es nominal, el nivel de educación (básica, media, terciaria, universitaria, postgraduada) es ordinal, y el número de años de educación (0, 1, 2, . . .) es cuantitativa.

Interpretación de Regresores Cualitativos: Politómicas

- **Interacciones:**
  - **Múltiples categorías**
    - **Ejemplo: sexo * estado civil →** Mujer soltera, mujer casada, mujer con otro estado civil, hombre soltero, hombre casado, hombre con otro estado civil
  - **Cualitativa × cuantitativa**
    - **Ejemplo:** sexo * edad → Hombre de 18 a 30 años, hombre de 31 a 50, hombre de más de 50 años, mujer de 18 a 30 años, mujer de 31 a 50, mujer de más de 50 años

Interpretación de Regresores Cualitativos: Politómicas

- **Interacciones:**

- **Múltiples escalas:** existen variables que pueden ser medidas en **escala nominal, ordinal o cuantitativa**.
- Por ejemplo, el tipo de educación (privada, subvencionada, pública) es **nominal,** el nivel de educación (básica, media, terciaria, universitaria, postgraduada) es **ordinal**, y el número de años de educación (0, 1, 2, . . .) es **cuantitativa**.

Interpretación de Regresores Cualitativos: Lo básico

- En una regresión, **sólo tiene sentido incluir regresores categóricos de tipo dicotómicos**. ¿Por qué?

- Un regresor dicotómico puede afectar:

  - **La constante** → configuración clásica
  - **La pendiente** → interacción variable dicotómica-variable continua
  - **La constante y la pendiente** → configuración clásica + interacción variable dicotómica-variable continua
  - ¿Se podría afectar también órdenes superiores (**curvatura**) de una relación? → interacción variable dicotómica-variable continua cuadrática

Variable Explicada Cualitativa

- Muchas veces la variable explicada es una **dicotomía** (compra o no, trabaja o no, vota o no, derecha/izquierda -intención política-, etc.) o la elección entre **múltiples alternativas** disponibles (qué medio de transporte emplear, a qué universidad asistir, qué carrera estudiar, etc.)

- Próxima Unidad!

Interpretación de Regresores Cualitativos Binarios

- ***<u>Caso 1</u>: Inclusión de una variable binaria como único regresor***

Variable $\boldsymbol{Mujer_i} = \begin{cases} \mathbf{1} & \textbf{si es mujer} \\ \mathbf{0} & \textbf{si es hombre} \end{cases}$

$$Salario_i = \alpha_0 + \boldsymbol{\alpha_1 Mujer_i} + \varepsilon_i$$

Modelo para hombres: $E[Salario_i | Mujer_i = 0] = \alpha_0$

Modelo para mujeres: $E[Salario_i | Mujer_i = 1] = \alpha_0 + \boldsymbol{\alpha_1}$

$$\boldsymbol{\alpha_1} = E[Salario_i | Mujer_i = 1] - E[Salario_i | Mujer_i = 0]$$

Interpretación de Regresores Cualitativos Binarios

$$salario = \beta_0 + \beta_1 mujer + u$$

```
. tab mujer [weight=expr]
(frequency weights assumed)
```

mujer	Freq.	Percent	Cum.
0	8,259,369	47.26	47.26
1	9,215,544	52.74	100.00
Total	17,474,913	100.00	

```
. reg yaut mujer [weight=expr]
(analytic weights assumed)
(sum of wgt is   9.1542e+06)
```

Source	SS	df	MS
Model	1.1468e+15	1	1.1468e+15
Residual	7.1429e+16	137,455	5.1965e+11
Total	7.2576e+16	137,456	5.2799e+11

Number of obs	=	137,457
F(1, 137455)	=	2206.86
Prob > F	=	0.0000
R-squared	=	0.0158
Adj R-squared	=	0.0158
Root MSE	=	7.2e+05

	yaut	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
β	mujer	-182860.2	3892.531	-46.98	0.000	-190489.5	-175230.9
α	_cons	553487.7	2690.599	205.71	0.000	548214.2	558761.3

Interpretación de Regresores Cualitativos Binarios

Lo único que me dice es que, **en promedio**, *ceteris paribus* (considerando el error!), las mujeres ganan $\$\mathbf{182.860}$ **menos** que los hombres.

```
. bysort mujer: sum yaut [weight=expr] if e(sample)
```

Ingreso promedio de los hombres (α del modelo anterior)

```
-> mujer = 0
(analytic weights assumed)

    Variable |        Obs        Weight        Mean   Std. Dev.       Min        Max
-------------+---------------------------------------------------------------------
        yaut |     73,634     4780463    553487.7   877190.6         83   1.10e+08
```

Ingreso promedio de las mujeres ($\alpha + \beta$ del modelo anterior)

```
-> mujer = 1

    Variable |        Obs        Weight        Mean   Std. Dev.       Min        Max
-------------+---------------------------------------------------------------------
        yaut |     63,823     4373766    370627.5   496600.7         33   3.46e+07
```

Pero sabemos/sospechamos que el error no es ruido blanco, por lo cual debemos controlar por otras variables...

Interpretación de Regresores Cualitativos Binarios

- ***<u>Caso 2</u>: Inclusión de una variable binaria y una variable "continua"***

$$Salario_i = \alpha_0 + \alpha_1 Mujer_i + \alpha_2 Escolaridad_i + \varepsilon_i$$

```
. reg yaut mujer educ [weight=expr]
(analytic weights assumed)
(sum of wgt is   9.1388e+06)
```

Source	SS	df	MS
Model	1.1450e+16	2	5.7250e+15
Residual	6.1049e+16	137,210	4.4493e+11
Total	7.2499e+16	137,212	5.2837e+11

Number of obs	=	137,213
F(2, 137210)	=	12867.32
Prob > F	=	0.0000
R-squared	=	0.1579
Adj R-squared	=	0.1579
Root MSE	=	6.7e+05

yaut	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
mujer	-197984.4	3606.416	-54.90	0.000	-205052.9	-190915.9
educ	83771.06	550.4378	152.19	0.000	82692.21	84849.91
_cons	116475.2	3801.803	30.64	0.000	109023.8	123926.7

Interpretación de Regresores Cualitativos Binarios

- **La variable *dummy* se representa gráficamente como un desplazamiento del intercepto entre hombres y mujeres**. En la figura anterior se muestra el caso $\alpha_1 < 0$, es decir, los hombres ganan una cantidad fija mayor que las mujeres.

- Esta diferencia no depende de la cantidad de educación, y esto explica por qué las líneas de salario-educación de hombres y mujeres son <u>paralelas</u>.

Interpretación de Regresores Cualitativos Binarios

FIGURA 7.1

Gráfica de *wage* = $\beta_0 + \delta_0$ *female* + β_1 *educ* en la que $\delta_0 < 0$.

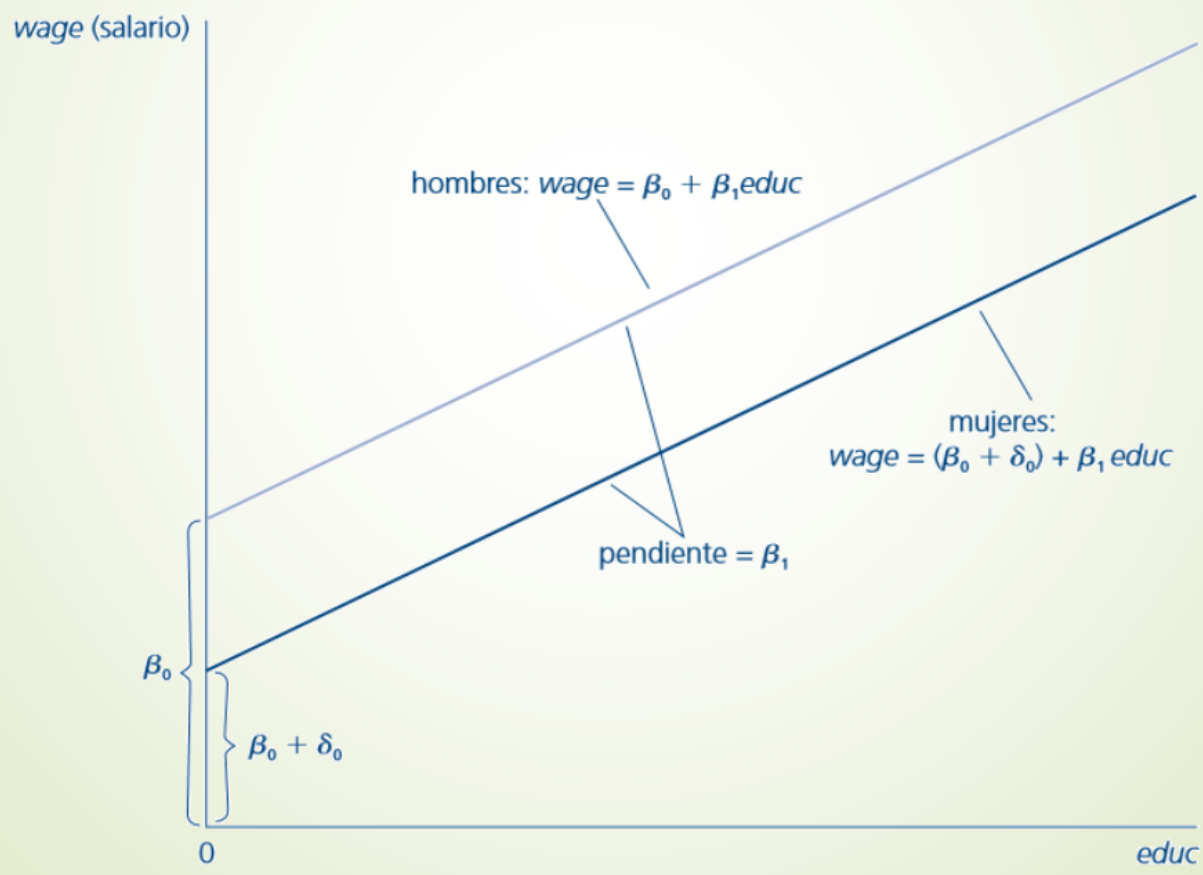

Interpretación de Regresores Cualitativos Binarios

- ¿Por qué no se incluye también otra variable binaria indicadora de "hombre"? **¡Esto sería redundante!** (Colinealidad perfecta: $hombre + mujer = 1$) → **Cuidado! Siempre $g - 1$ variables binarias y un intercepto!**

- El intercepto para hombres es α_0. El intercepto para mujeres es α_0+α_1. Dado que hay dos grupos, sólo se necesitan dos interceptos. Esto significa que además de α_0 sólo se necesita usar una variable binaria; se eligió incluir una variable binaria para mujeres.

Interpretación de Regresores Cualitativos Binarios

- En el modelo anterior, se eligió hombres como **grupo base o grupo de referencia (*benchmark*)**, es decir, el grupo contra el que se hacen las comparaciones. A esto se debe que α_0 sea el intercepto para hombres y α_1 sea la diferencia entre los interceptos para hombres y para mujeres.
- **¡Hacerlo al revés es análogo!**

```
. reg yaut hombre [weight=expr]
(analytic weights assumed)
(sum of wgt is   9.1542e+06)

      Source |       SS           df       MS      Number of obs   =   137,457
-------------+----------------------------------   F(1, 137455)    =   2206.86
       Model |  1.1468e+15         1  1.1468e+15   Prob > F        =    0.0000
    Residual |  7.1429e+16   137,455  5.1965e+11   R-squared       =    0.0158
-------------+----------------------------------   Adj R-squared   =    0.0158
       Total |  7.2576e+16   137,456  5.2799e+11   Root MSE        =    7.2e+05

------------------------------------------------------------------------------
        yaut |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
      hombre |   182860.2   3892.531    46.98   0.000     175230.9    190489.5
       _cons |   370627.5   2812.912   131.76   0.000     365114.2    376140.8
```

Interpretación de Regresores Cualitativos Binarios

- No hay cambios importantes si agregamos más regresores.
- Tomando hombres como grupo base, “controlamos” por edad, años de educación, experiencia y experiencia cuadrática:

```
. reg yaut mujer edad educ exp exp2 [weight=expr]
(analytic weights assumed)
(sum of wgt is   6.9943e+06)

      Source |       SS           df       MS      Number of obs   =   102,601
-------------+----------------------------------   F(5, 102595)    =   5149.48
       Model |  1.1929e+16         5  2.3859e+15   Prob > F        =    0.0000
    Residual |  4.7534e+16   102,595  4.6332e+11   R-squared       =    0.2006
-------------+----------------------------------   Adj R-squared   =    0.2006
       Total |  5.9464e+16   102,600  5.7957e+11   Root MSE        =    6.8e+0

------------------------------------------------------------------------------
        yaut |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
       mujer |  -202198.6   4327.461   -46.72   0.000    -210680.3   -193716.8
        edad |   8205.586   185.0369    44.35   0.000     7842.916    8568.256
        educ |   105285.6   697.9054   150.86   0.000     103917.7    106653.5
         exp |   8563.053   573.7641    14.92   0.000     7438.483    9687.623
        exp2 |  -151.6095   15.10576   -10.04   0.000    -181.2166   -122.0024
       _cons |  -359140.9   9391.922   -38.24   0.000      -377549   -340732.9
```

Interpretación de Regresores Cualitativos Binarios

Cuando algunos de los regresores se definen como variables dicotómicas, no hay cambios en el método de MCO ni en la teoría estadística. Sólo se observan cambios en la **interpretación del coeficiente** de la variable binaria.

```
. reg yaut mujer edad educ exp exp2 [weight=expr]
(analytic weights assumed)
(sum of wgt is   6.9943e+06)

      Source |       SS           df       MS      Number of obs   =   102,601
-------------+----------------------------------   F(5, 102595)    =   5149.48
       Model |  1.1929e+16         5  2.3859e+15   Prob > F        =    0.0000
    Residual |  4.7534e+16   102,595  4.6332e+11   R-squared       =    0.2006
-------------+----------------------------------   Adj R-squared   =    0.2006
       Total |  5.9464e+16   102,600  5
```

Si se toman un hombre y una mujer con los mismos niveles de educación, experiencia y edad, la mujer gana, en promedio, $202.199 menos que el hombre.

```
------------------------------------------------------------------------------
        yaut |      Coef.   Std. Err.
-------------+----------------------------------------------------------------
       mujer |  -202198.6   4327.461
        edad |   8205.586   185.0369
        educ |   105285.6   697.9054    150.86   0.000     103917.7    106653.5
         exp |   8563.053   573.7641     14.92   0.000     7438.483    9687.623
        exp2 |  -151.6095   15.10576    -10.04   0.000    -181.2166   -122.0024
       _cons |  -359140.9   9391.922    -38.24   0.000      -377549   -340732.9
------------------------------------------------------------------------------
```

Interpretación de Regresores Cualitativos Binarios

- Cada uno de los ejemplos anteriores puede considerarse relevante en el análisis de política.

- Un caso especial del análisis de política es la **evaluación de programas**, en donde interesa conocer el efecto de programas económicos o sociales sobre las personas, las empresas, los vecindarios, las ciudades, etcétera.

- En el caso más sencillo, existen **dos grupos de personas**. El "**grupo de control**" no participa en el programa; el "grupo experimental" o "**grupo bajo tratamiento**" es sometido a la política o programa.

Interpretación de Regresores Cualitativos Binarios

Incorporación de DOS regresores dicotómicos

```
. reg yaut mujer jefe_hog edad educ exp exp2 [weight=expr]
(analytic weights assumed)
(sum of wgt is   6.9943e+06)

      Source |       SS           df       MS      Number of obs   =   102,601
-------------+----------------------------------   F(6, 102594)    =   4574.76
       Model |  1.2551e+16         6  2.0919e+15   Prob > F        =    0.0000
    Residual |  4.6912e+16   102,594  4.5726e+11   R-squared       =    0.2111
-------------+----------------------------------   Adj R-squared   =    0.2110
       Total |  5.9464e+16   102,600  5.7957e+11   Root MSE        =    6.8e+05

------------------------------------------------------------------------------
        yaut |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
       mujer |  -162313.5   4433.029   -36.61   0.000    -171002.2   -153624.9
    jefe_hog |   172015.2   4664.292    36.88   0.000     162873.3    181157.2
        edad |   6071.878   192.7134    31.51   0.000     5694.162    6449.594
        educ |   104595.5   693.5807   150.81   0.000     103236.1      105955
         exp |   7651.916   570.5363    13.41   0.000     6533.672     8770.16
        exp2 |  -127.0383   15.02147    -8.46   0.000    -156.4801   -97.59637
       _cons |    -367830     9333.3   -39.41   0.000    -386123.1   -349536.8
------------------------------------------------------------------------------
```

- **¿Cuántos interceptos tiene el modelo ahora? ¿Cuáles son?**
- **¿Sobre qué base está construido?**
- **Interpretemos los coeficientes asociados a los regresores dicotómicos**

Interpretación de Regresores Cualitativos Categóricos

¿Cómo incorporamos una variable politómica como regresor?

```
. tab glosa_ELE1
```

Glosa Act. Econ◆mica a nivel de letra	Freq.	Percent	Cum.
ACTIVIDADES INMOBILIARIAS, EMPRESARIA..	1,048	10.26	10.26
AGRICULTURA, GANADERIA, CAZA Y SILVIC..	712	6.97	17.23
COMERCIO AL POR MAYOR Y AL POR MENOR;..	2,279	22.31	39.55
CONSTRUCCION	993	9.72	49.27
EXPLOTACION DE MINAS Y CANTERAS	453	4.44	53.71
HOTELES Y RESTAURANTES	983	9.62	63.33
INDUSTRIAS MANUFACTURERAS	1,220	11.95	75.28
INTERMEDIACION FINANCIERA	583	5.71	80.99
OTRAS ACTIVIDADES DE SERVICIOS COMUNI..	503	4.93	85.91
SUMINISTRO DE ELECTRICIDAD, GAS Y AGUA	316	3.09	89.00
TRANSPORTE, ALMACENAMIENTO Y COMUNICA..	1,123	11.00	100.00
Total	10,213	100.00	

- **¿Cómo puedo incorporar esta información relevante en un modelo para explicar las ventas de las empresas en Chile?**
- **¿Cómo se interpreta correctamente?**

Interpretación de Regresores Cualitativos Categóricos

Incorporación de regresor politómico

- Si se incorpora directamente, no es posible interpretar adecuadamente sus efectos sobre las ventas. ¿Por qué?

```
. reg ventas_mill sector_ec patrimonio trabajadores

      Source |       SS           df       MS      Number of obs   =     5,070
-------------+----------------------------------   F(3, 5066)      =    293.41
       Model |  2.3972e+13         3  7.9905e+12   Prob > F        =    0.0000
    Residual |  1.3796e+14     5,066  2.7233e+10   R-squared       =    0.1480
-------------+----------------------------------   Adj R-squared   =    0.1475
       Total |  1.6193e+14     5,069  3.1946e+10   Root MSE        =    1.7e+05

------------------------------------------------------------------------------
 ventas_mill |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
   sector_ec |  -2498.525   839.0669    -2.98   0.003    -4143.459   -853.5908
  patrimonio |   .0006669   .0000231    28.92   0.000     .0006217    .0007121
trabajadores |   12.08833   2.981804     4.05   0.000     6.242706    17.93396
       _cons |    25121.8   5582.794     4.50   0.000     14177.11    36066.49
------------------------------------------------------------------------------
```

- **¿Qué hacemos entonces?**

Interpretación de Regresores Cualitativos Categóricos

Incorporación de regresor politómico

Solución:

- Para una variable con g categorías, creamos g variables *dummy,* una por cada categoría:
  - $= 1$ si la categoría está activa para la observación
  - $= 0$ en cualquier otro caso
- Usamos $g - 1$ *dummies* en la regresión, dejando una fuera (por ejemplo, "Transporte"). Esa categoría será el "***benchmark***".
- El intercepto del modelo incluirá el efecto del *benchmark*.

Interpretación de Regresores Cualitativos Categóricos

Incorporación de regresor politómico

```
. reg ventas_mill patrimonio_mill trabajadores sector_act_inm_emp sector_silvoagro sector_c
> omercio sector_constr sector_mineria sector_hotyrest sector_manufact sector_financi secto
> r_servic sector_electgasagua

      Source |       SS           df       MS      Number of obs   =     5,070
-------------+----------------------------------   F(12, 5057)     =     81.43
       Model |  2.6224e+13        12  2.1854e+12   Prob > F        =    0.0000
    Residual |  1.3571e+14     5,057  2.6836e+10   R-squared       =    0.1619
-------------+----------------------------------   Adj R-squared   =    0.1600
       Total |  1.6193e+14     5,069  3.1946e+10   Root MSE        =    1.6e+05

------------------------------------------------------------------------------
        ventas_mill |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
----------------------------------------------------------------------------------
    patrimonio_mill |   .6649779   .0231096    28.77   0.000     .6196731    .7102827
       trabajadores |   12.69327   2.968043     4.28   0.000     6.874621    18.51192
 sector_act_inm_emp |   -4688.54   10135.47    -0.46   0.644    -24558.45    15181.37
   sector_silvoagro |  -10974.09   11530.47    -0.95   0.341     -33578.8    11630.63
    sector_comercio |   9709.633   8979.795     1.08   0.280    -7894.655    27313.92
      sector_constr |  -3349.939     9624.5    -0.35   0.728    -22218.13    15518.25
     sector_mineria |   103615.3   13142.23     7.88   0.000     77850.83    129379.8
    sector_hotyrest |   -4454.25   10004.88    -0.45   0.656    -24068.15    15159.66
    sector_manufact |    9461.29   9565.862     0.99   0.323    -9291.944    28214.52
     sector_financi |   12242.92   12830.09     0.95   0.340    -12909.61    37395.45
      sector_servic |  -3604.511   12567.72    -0.29   0.774    -28242.68    21033.66
sector_electgasagua |  -9417.065   15202.69    -0.62   0.536    -39220.93     20386.8
              _cons |   4450.094   7205.519     0.62   0.537    -9675.845    18576.03
----------------------------------------------------------------------------------
```

Resto de Sectores

Transporte

Interpretación de Regresores Cualitativos: interacciones

- **Interacciones en las que intervienen variables dicotómicas:**
  - Inclusión de dos variables binarias más su interacción.
  - Inclusión de una variable binaria interactuando con una variable “continua”.

Interpretación de Regresores Cualitativos: interacciones

- ***<u>Caso 3</u>: Inclusión de dos variables binarias más su interacción.***

- Así como variables con un significado cuantitativo pueden estar relacionadas en los modelos de regresión, también pueden estarlo las variables binarias.
- Queremos observar, por ejemplo, si existe un efecto específico sobre el salario para las mujeres jefas de hogar (grupo considerado particularmente vulnerable):

$$Salario_i = \alpha_0 + \alpha_1 esc_i + \alpha_2 exp_i + \alpha_3 exp^2 +$$
$$+\alpha_4 \boldsymbol{mujer_i} + \alpha_5 \boldsymbol{jefehog_i} + \boldsymbol{\alpha_6}(\boldsymbol{mujer_i} * \boldsymbol{jefehog_i}) + \varepsilon_i$$

Interpretación de Regresores Cualitativos: interacciones

```
. reg yaut educ exp exp2 mujer jefe_hog mujer_jefehog [weight=expr]
(analytic weights assumed)
(sum of wgt is   6.9943e+06)

      Source |       SS           df       MS      Number of obs   =   102,601
-------------+----------------------------------   F(6, 102594)    =   4431.07
       Model |  1.2238e+16         6  2.0397e+15   Prob > F        =    0.0000
    Residual |  4.7226e+16   102,594  4.6031e+11   R-squared       =    0.2058
-------------+----------------------------------   Adj R-squared   =    0.2058
       Total |  5.9464e+16   102,600  5.7957e+11   Root MSE        =    6.8e+05

------------------------------------------------------------------------------
        yaut |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
        educ |   98118.01   668.6099   146.75   0.000     96807.55    99428.48
         exp |   11914.27   552.3743    21.57   0.000     10831.63    12996.92
        exp2 |   -154.306   15.03735   -10.26   0.000    -183.7791    -124.833
       mujer |  -73739.37   6148.485   -11.99   0.000    -85790.32   -61688.42
    jefe_hog |   284335.7   5926.889    47.97   0.000     272719.1    295952.3
mujer_jefehog |  -155025.7   8862.521   -17.49   0.000    -172396.1   -137655.2
       _cons |  -173214.9   6147.091   -28.18   0.000    -185263.1   -161166.6
------------------------------------------------------------------------------
```

Interpretación de Regresores Cualitativos: interacciones

- **Interpretación:**

- ***Benchmark:*** $mujer = 0$ y $jefe\ de\ hogar = 0$ corresponde al grupo de los hombres no jefes de hogar, que es el grupo base, ya que esto elimina mujer, jefe de hogar y mujer jefa de hogar:

- El intercepto para hombres jefes de hogar puede determinarse haciendo $mujer = 0$ y $jefe\ de\ hogar = 1$; esto da un intercepto de $-173214\ (_cons)+284335(jefe_hog)$, y así sucesivamente.

		Mujer	
		0 : No	1 : Sí
Jefe de hogar	0 : No	−173.214,9	−246.954,3
	1 : Sí	111.120,8	−155.025,7

Interpretación de Regresores Cualitativos: interacciones

```
.
. tab ecivil
```

estado civil	Freq.	Percent	Cum.
casado(a)	74,595	28.06	28.06
conviviente o pareja sin acuerdo de uni	32,844	12.36	40.42
conviviente civil (con acuerdo de uni|	111	0.04	40.46
anulado(a)	266	0.10	40.56
separado(a)	11,056	4.16	44.72
divorciado(a)	3,059	1.15	45.87
viudo(a)	12,938	4.87	50.74
soltero(a)	130,944	49.26	100.00
Total	265,813	100.00	

```
. gen casado=1 if ecivil==1 | ecivil==2 | ecivil==3
(158,263 missing values generated)

. replace casado=0 if casado==.
(158,263 real changes made)

. tab ecivil casado
```

estado civil	casado 0	casado 1	Total
casado(a)	0	74,595	74,595
conviviente o pareja	0	32,844	32,844
conviviente civil (co	0	111	111
anulado(a)	266	0	266
separado(a)	11,056	0	11,056
divorciado(a)	3,059	0	3,059
viudo(a)	12,938	0	12,938
soltero(a)	130,944	0	130,944
Total	158,263	107,550	265,813

***Benchmark*: hombres casados**

```
.
. gen mujer_solt=1 if mujer==1 & casado==0
(180,741 missing values generated)

. replace mujer_solt=0 if mujer_solt==.
(180,741 real changes made)

. gen mujer_casada=1 if mujer==1 & casado==1
(211,950 missing values generated)

. replace mujer_casada=0 if mujer_casada==.
(211,950 real changes made)

. gen hombre_solt=1 if mujer==0 & casado==0
(192,622 missing values generated)

. replace hombre_solt=0 if hombre_solt==.
(192,622 real changes made)
```

Interpretación de Regresores Cualitativos: interacciones

```
. reg yaut educ exp exp2 edad mujer_solt mujer_casada hombre_solt

      Source |       SS           df       MS      Number of obs   =   102,601
-------------+----------------------------------   F(7, 102593)    =   3269.00
       Model |  1.0330e+16         7  1.4757e+15   Prob > F        =    0.0000
    Residual |  4.6312e+16   102,593  4.5141e+11   R-squared       =    0.1824
-------------+----------------------------------   Adj R-squared   =    0.1823
       Total |  5.6642e+16   102,600  5.5206e+11   Root MSE        =    6.7e+0

------------------------------------------------------------------------------
        yaut |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
        educ |   98108.55   695.7646   141.01   0.000     96744.86    99472.24
         exp |   6984.296   548.2923    12.74   0.000      5909.65    8058.942
        exp2 |  -119.2427   14.06328    -8.48   0.000    -146.8065   -91.67881
        edad |   6807.903   186.5235    36.50   0.000     6442.319    7173.487
  mujer_solt |    -247986    5756.36   -43.08   0.000    -259268.4   -236703.6
mujer_casada |  -221314.7   5842.945   -37.88   0.000    -232766.8   -209862.6
 hombre_solt |  -137728.1   5981.105   -23.03   0.000      -149451   -126005.2
       _cons |  -216547.5   9949.888   -21.76   0.000    -236049.2   -197045.9
------------------------------------------------------------------------------
```

Benchmark: hombres casados

- **Hombres solteros ganan 137.728 menos, *ceteris paribus*.**
- **Mujeres solteras ganan 247.986 menos, *ceteris paribus*.**
- **Mujeres casadas ganan 221.314 menos, *ceteris paribus*.**

Interacciones de Regresores: Cualitativos y Cuantitativos

- ***<u>Caso 4</u>: Inclusión de una variable binaria interactuando con una variable "continua"***

- También hay ocasiones en las que los regresores dicotómicos interactúan con variables explicativas continuas. Esto permite introducir **cambios en las pendientes de la regresión**.

- Continuando con el ejemplo del salario, suponga que se desea saber si el rendimiento de la educación es el mismo para los hombres que para las mujeres, considerando una diferencia constante entre los salarios de hombres y de mujeres (una diferencia de la que ya previamente se han encontrado evidencias):

$$Salario_i = \alpha_0 + \alpha_1 \boldsymbol{Mujer_i} + \alpha_2 \boldsymbol{Educ_i} + \alpha_3 (\boldsymbol{Mujer_i \cdot Educ_i}) + \varepsilon_i$$

Interacciones de Regresores: Cualitativos y Cuantitativos

$$Salario_i = \alpha_0 + \alpha_1 Mujer_i + \alpha_2 Educ_i + \alpha_3 (Mujer_i \cdot Educ_i) + \varepsilon_i$$

$$Salario_i = (\alpha_0 + \alpha_1 Mujer_i) + (\alpha_2 + \alpha_3 Mujer_i) \cdot educ_i + \varepsilon_i$$

$$Salario_{mujer} = (52370 - 18116) + (95610 - 34267) \cdot educ_i$$

$$Salario_{mujer} = 34254 + 61343 \cdot educ_i$$

$$Salario_{hombre} = 52370 + 95610 \cdot educ_i$$

Source	SS	df	MS
Model	1.0300e+16	3	3.4333e+15
Residual	6.3515e+16	137,209	4.6291e+11
Total	7.3815e+16	137,212	5.3796e+11

Number of obs	=	137,213
F(3, 137209)	=	7416.74
Prob > F	=	0.0000
R-squared	=	0.1395
Adj R-squared	=	0.1395
Root MSE	=	6.8e+05

yaut		Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
mujer	α_1	-18116.87	6682.832	-2.71	0.007	-31215.1	-5018.645
educ	α_2	95610.73	789.7971	121.06	0.000	94062.74	97158.71
mujer_educ	α_3	-34267.41	1134.239	-30.21	0.000	-36490.5	-32044.33
_cons	α_0	52370.38	4512.903	11.60	0.000	43525.18	61215.59

Interacciones de Regresores: Cualitativos y Cuantitativos

$$Salario_i = (\alpha_0 + \alpha_1 Mujer_i) + (\alpha_2 + \alpha_3 Mujer_i) \cdot educ_i + \varepsilon_i$$

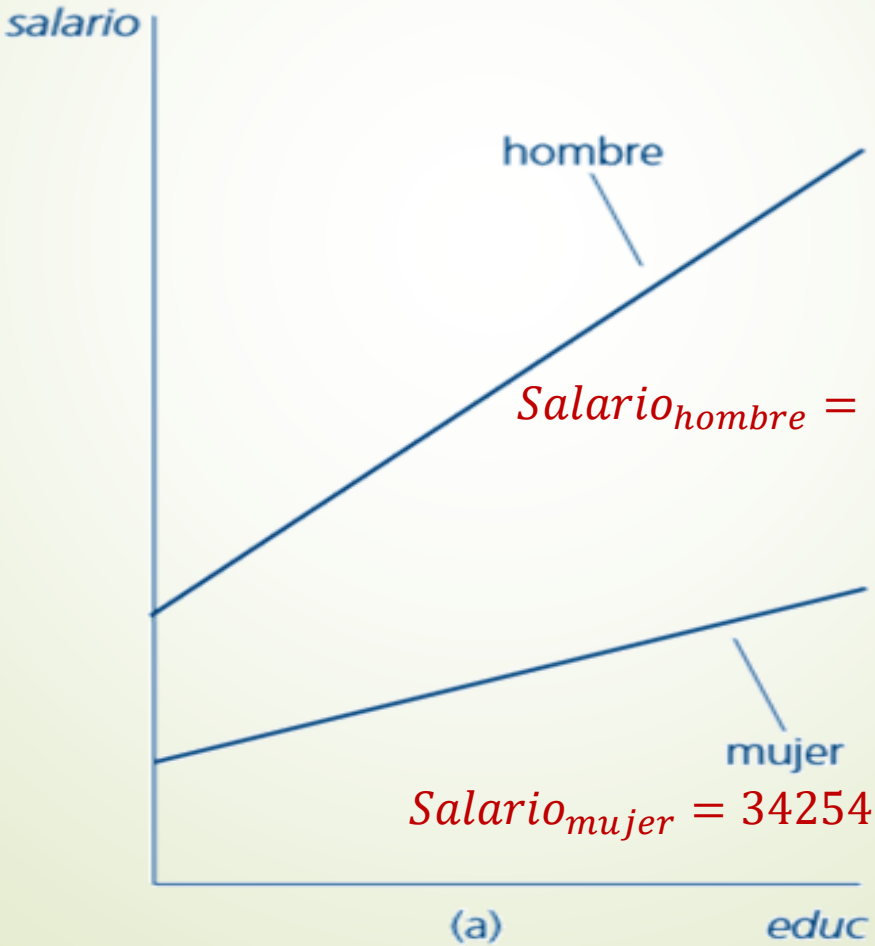

$$Salario_{hombre} = 52370 + 95610 \cdot educ_i$$

$$Salario_{mujer} = 34254 + 61343 \cdot educ_i$$

Resumen de la Unidad 4

1. Análisis de la propiedad de insesgamiento
2. Formas funcionales, elección de regresores e interpretación de coeficientes
3. **Más sobre R^2 y especificación de modelos**
4. Predicción y análisis de residuos
5. Multicolinealidad
6. Heterocedasticidad
7. Causalidad, experimentos naturales y validez de los modelos
8. Resumiendo… con un ejemplo

Más sobre R^2...

- Elegir un conjunto de variables explicativas con base en la magnitud del coeficiente de determinación, R^2, puede conducir a modelos sin sentido.
- Una varianza grande del error puede ser contrarrestada con un tamaño de muestra grande (LGN): si se tienen suficientes datos, es posible que se puedan estimar con precisión los efectos parciales, aun cuando no se hayan controlado muchos de los factores no observados.

Más sobre R^2...

- **MITO**: R^2 bajo significa que hay endogeneidad. FALSO. R^2 bajo significa que hay diversos factores que afectan a y que no han sido tomados en cuenta. Sin embargo, esto **NO** significa que los factores en u están correlacionados con los regresores.
- **REALIDAD**: que R^2 sea pequeño implica que la varianza del error es relativamente grande en relación con la varianza de y, lo cual significa que es posible que sea difícil estimar con precisión los β_j.

Más sobre R^2...

- R^2 estima σ_u^2 mediante SRC/n, que se sabe que está sesgado.
  - ¿Por qué no sustituir SRC/n por $SRC/(n-k-1)$?
  - Además, también se puede usar $STC/(n-1)$ en lugar de STC/n, ya que el primero es un estimador insesgado de σ_y^2.

- Luego:

$$\bar{R}^2_{Ajustado} = 1 - \frac{SRC/(n-k-1)}{STC/(n-1)}$$

Más sobre R^2...

- La característica más atractiva de $\bar{R}^2$ es que impone una sanción a la adición de más regresores a un modelo. **¡Depende de manera explícita de k!**

- Si se agrega una variable explicativa a la regresión, SRC disminuye, pero lo mismo ocurre con los grados de libertad en la regresión. $SRC/(n-k-1)$ puede aumentar o disminuir cuando se agrega un nuevo regresor a la estimación.

- **En algunos casos, se desea elegir un modelo que no tenga regresores redundantes, y para esto puede servir el R^2_{Ajus}.**

Más sobre R^2...

- **Modelos Anidados**: un modelo (el restringido) es un caso especial del otro (el no restringido)
  - ¿Cuál modelo elegir?
  - Se usa una **Prueba** $\boldsymbol{F}$: determina si el conjunto de variables adicionales es significativa. Esto permite determinar entre el modelo anidado y el modelo general.

- **Modelos No Anidados:**
  - Tienen diferentes variables o forma funcional
  - Se selecciona entre ellos comparando R^2_{Ajus}

Más sobre R^2: Modelos anidados

Source	SS	df	MS
Model	7.9085e+13	17	4.6521e+12
Residual	8.2671e+13	3,858	2.1429e+10
Total	1.6176e+14	3,875	4.1744e+10

Number of obs	=	3,876
F(17, 3858)	=	217.10
Prob > F	=	0.0000
R-squared	=	0.4889
Adj R-squared	=	0.4867
Root MSE	=	1.5e+05

ventas_mill	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
inversion_id_mill	137.4332	2.988492	45.99	0.000	131.5741	143.2924
gasto_publicidad_mill	26.20488	1.772785	14.78	0.000	22.7292	29.68057
patrimonio_mill	.5167406	.0212391	24.33	0.000	.4750997	.5583816
region1	-10515.47	22820.81	-0.46	0.645	-55257.47	34226.54
region2	40112.78	12831.86	3.13	0.002	14954.9	65270.66
region3	-4413.567	14721.42	-0.30	0.764	-33276.08	24448.95
region4	-7835.944	14036.7	-0.56	0.577	-35356.01	19684.12
region5	-5073.776	8783.564	-0.58	0.564	-22294.65	12147.1
region6	-533.737	12232.86	-0.04	0.965	-24517.23	23449.75
region7	-8910	11659.24	-0.76	0.445	-31768.87	13948.87
region8	9983.244	8965.74	1.11	0.266	-7594.798	27561.29
region9	-6795.783	13756.64	-0.49	0.621	-33766.77	20175.2
region10	-5740.19	11921.94	-0.48	0.630	-29114.09	17633.71
region11	-8093.619	34657.98	-0.23	0.815	-76043.32	59856.08
region12	-7117.399	22822.97	-0.31	0.755	-51863.63	37628.83
region14	-11287.4	17670.8	-0.64	0.523	-45932.41	23357.61
region15	-7466.665	26494.34	-0.28	0.778	-59410.91	44477.58
_cons	8255.29	3274.264	2.52	0.012	1835.837	14674.74

$H_0: \beta_1 = \beta_2 = \beta_3 = \cdots = 0$ *(todos los β´s regionales)*

Se construye el estadístico F:

$$F = \frac{(R^2_{NR} - R^2_R)/r}{(1 - R^2_{NR})/(N - K - 1)}$$

$$F = \frac{(0{,}4889 - 0{,}4870)/14}{(1 - 48{,}89)/(3858)}$$

$$F = 1{,}0244$$

F *crítico* $= 1{,}83 \therefore$ No se rechaza H_0

```
. reg ventas_mill inversion_id_mill gasto_publicidad_mill patrimonio_mill
```

Source	SS	df	MS
Model	7.8771e+13	3	2.6257e+13
Residual	8.2986e+13	3,872	2.1432e+10
Total	1.6176e+14	3,875	4.1744e+10

Number of obs	=	3,876
F(3, 3872)	=	1225.11
Prob > F	=	0.0000
R-squared	=	0.4870
Adj R-squared	=	0.4866
Root MSE	=	1.5e+05

ventas_mill	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
inversion_id_mill	137.403	2.988648	45.97	0.000	131.5435	143.2624
gasto_publicidad_mill	26.18288	1.767342	14.81	0.000	22.71787	29.64789
patrimonio_mill	.5184476	.021193	24.46	0.000	.4768972	.5599981
_cons	8329.79	2383.98	3.49	0.000	3655.814	13003.77

Más sobre R^2: Modelos No Anidados

Source	SS	df	MS
Model	7.9085e+13	17	4.6521e+12
Residual	8.2671e+13	3,858	2.1429e+10
Total	1.6176e+14	3,875	4.1744e+10

Number of obs	=	3,876
F(17, 3858)	=	217.10
Prob > F	=	0.0000
R-squared	=	0.4889
Adj R-squared	=	0.4867
Root MSE	=	1.5e+05

ventas_mill	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
inversion_id_mill	137.4332	2.988492	45.99	0.000	131.5741	143.2924
gasto_publicidad_mill	26.20488	1.772785	14.78	0.000	22.7292	29.68057
patrimonio_mill	.5167406	.0212391	24.33	0.000	.4750997	.5583816
region1	-50628.25	25775.96	-1.96	0.050	-101164	-92.45238
region3	-44526.35	18981.67	-2.35	0.019	-81741.42	-7311.278
region4	-47948.73	18455.89	-2.60	0.009	-84132.95	-11764.51
region5	-45186.56	14858.62	-3.04	0.002	-74318.06	-16055.06
region6	-40646.52	17130.48	-2.37	0.018	-74232.18	-7060.859
region7	-49022.78	16719.61	-2.93	0.003	-81802.9	-16242.67
region8	-30129.54	14966.93	-2.01	0.044	-59473.39	-785.6916
region9	-46908.57	18244.07	-2.57	0.010	-82677.51	-11139.63
region10	-45852.97	16903.38	-2.71	0.007	-78993.38	-12712.56
region11	-48206.4	36670.94	-1.31	0.189	-120102.7	23689.88
region12	-47230.18	25777.43	-1.83	0.067	-97768.88	3308.515
region13	-40112.78	12831.86	-3.13	0.002	-65270.66	-14954.9
region14	-51400.18	21355.66	-2.41	0.016	-93269.65	-9530.716
region15	-47579.45	29078	-1.64	0.102	-104589.2	9430.271
_cons	48368.07	12421.62	3.89	0.000	24014.5	72721.65

- Modelos no son anidados: poseen variables diferentes.
- Modelo 2 sería el preferido por tener R^2_{Ajus} más alto.

```
. reg ventas_mill inversion_id_mill gasto_publicidad_mill patrimonio_mill region2
```

Source	SS	df	MS
Model	7.9001e+13	4	1.9750e+13
Residual	8.2755e+13	3,871	2.1378e+10
Total	1.6176e+14	3,875	4.1744e+10

Number of obs	=	3,876
F(4, 3871)	=	923.85
Prob > F	=	0.0000
R-squared	=	0.4884
Adj R-squared	=	0.4879
Root MSE	=	1.5e+05

ventas_mill	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
inversion_id_mill	137.4436	2.984899	46.05	0.000	131.5915	143.2958
gasto_publicidad_mill	26.28834	1.765402	14.89	0.000	22.82713	29.74954
patrimonio_mill	.5178902	.0211669	24.47	0.000	.4763909	.5593895
region2	41513.69	12632.6	3.29	0.001	16746.5	66280.89
_cons	6830.58	2424.281	2.82	0.005	2077.591	11583.57

Resumen de la Unidad 4

1. Análisis de la propiedad de insesgamiento
2. Formas funcionales, elección de regresores e interpretación de coeficientes
3. Más sobre R^2 y especificación de modelos
4. **Predicción y análisis de residuos**
5. Multicolinealidad
6. Heterocedasticidad
7. Causalidad, experimentos naturales y validez de los modelos
8. Resumiendo… con un ejemplo

Predicción y análisis de residuos

- Anteriormente, se definieron los valores predichos o ajustados de MCO, $\hat{y}_i$, así como sus residuos, $\widehat{u_i} = y_i - \hat{y}_i$.
- Si bien las predicciones son útiles, están sujetas a variaciones de muestreo, debido a que se obtienen a partir de los estimadores de MCO.
- En esta sección, se muestra cómo obtener intervalos de confianza para una predicción a partir de la línea de regresión de MCO.

Predicción y análisis de residuos

- Se sabe que los residuos se usan para obtener la suma de los residuales cuadrados (SRC) y el R^2, por lo que son importantes para determinar la bondad de ajuste y los tests.

- Algunas veces, los economistas estudian los residuos de determinadas observaciones para obtener información acerca de individuos (empresas, viviendas, etc.) de la muestra.

Predicción

$$\hat{y}_i = \hat{\alpha} + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3 + \cdots + \hat{\beta}_k x_k$$

- **Cuando se sustituyen valores específicos de los regresores, se obtiene una predicción para $\boldsymbol{y_i}$**, la cual es una estimación del valor esperado de y_i dados los valores específicos de las variables explicativas (x_k). En la práctica, esto es fácil de calcular.

- **¿Cómo se puede obtener alguna medida de la incertidumbre de este valor predicho? Lo natural es construir un intervalo de confianza.**

Predicción

$$\hat{y}_i = \hat{\alpha} + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3 + \cdots + \hat{\beta}_k x_k$$

- **Este es el mismo problema discutido anteriormente: se necesita obtener un error estándar de una combinación lineal de los estimadores de MCO.**
- Sin embargo, se puede **reparametrizar** para facilitar las cosas.
- El valor predicho y, lo que es más importante, su error estándar, se obtienen del intercepto (o constante) de la regresión.
- Veamos un ejemplo…

Predicción e intervalos de confianza

- **Ejemplo: ¿Cuánto serán las ventas, V_0, de una empresa que invierte \$100 mill. en I&D si tiene un patrimonio de \$5.000 mill.?**
- **Procedimiento standard:**

1. **Estimar el modelo a partir de las empresas existentes:**

$$Ventas_i = \alpha_0 + \alpha_1 \text{I\&D}_{1i} + \alpha_2 Patrimonio_{2i} + \varepsilon_i$$

2. **Predecir:**

$$\widehat{V_0} = \widehat{\alpha_0} + \widehat{\alpha_1} \cdot 100 + \widehat{\alpha_2} \cdot 5000$$

3. **Estimar la varianza del error de predicción:**

$$\begin{aligned} Var(e) &= Var\left(V_0 - \widehat{V_0}\right) \\ &= Var\left((\alpha_0 - \widehat{\alpha_0}) + (\alpha_1 - \widehat{\alpha_1})100 + (\alpha_2 - \widehat{\alpha_2})5000 + \varepsilon_0\right) \\ &= Var(\widehat{\alpha_0} + \widehat{\alpha_1} \cdot 100 + \widehat{\alpha_2} \cdot 5000) + \sigma^2 \end{aligned}$$

4. **Construir intervalo de predicción:**

$$IP = \widehat{V_0} \pm vc_{t_{N-K-1},95\%,2colas} \cdot \sqrt{Var(e)}$$

Predicción: modelo reparametrizado

- **Problema:**
  - Para calcular $Var(e)$, se requiere estimar $\widehat{\sigma^2} = \frac{SRC}{N-K}$ y calcular la expresión:

$$Var(\widehat{\alpha_0} + \widehat{\alpha_1} \cdot 100 + \widehat{\alpha_2} \cdot 5000) = Var(\widehat{\alpha_0}) + 100^2 \cdot Var(\widehat{\alpha_1}) +$$
$$+5000^2 \cdot Var(\widehat{\alpha_2}) + 2 \cdot 100 \cdot Cov(\widehat{\alpha_0}, \widehat{\alpha_1}) + \cdots$$

- **Alternativa: Estimar un modelo reparametrizado!**

$$\boldsymbol{\theta = \alpha_0 + \alpha_1 \cdot 100 + \alpha_2 \cdot 5000}$$
$$\rightarrow \ \alpha_0 = \theta - (\alpha_1 \cdot 100 + \alpha_2 \cdot 5000)$$
$$\rightarrow \ Y_i = \theta + \alpha_1(X_{1i} - 100) + \alpha_2(X_{2i} - 5000) + \varepsilon_i$$

- **Luego, construimos el intervalo de confianza para la predicción $\widehat{V_0}$:**

$$\boldsymbol{IP_{\widehat{V_0}} = \widehat{\theta} \pm vc_{t_{N-K-1},95\%,2colas} \cdot \sqrt{Var(\widehat{\theta})}}$$

Predicción: modelo reparametrizado

```
. reg ventas_mill inversion_id_mill patrimonio_mill

      Source |       SS           df       MS      Number of obs   =     3,878
-------------+----------------------------------   F(2, 3875)      =   1635.81
       Model |  7.4145e+13         2  3.7073e+13   Prob > F        =    0.0000
    Residual |  8.7820e+13     3,875  2.2663e+10   R-squared       =    0.4578
-------------+----------------------------------   Adj R-squared   =    0.4575
       Total |  1.6197e+14     3,877  4.1776e+10   Root MSE        =    1.5e+05

------------------------------------------------------------------------------
     ventas_mill |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-----------------+------------------------------------------------------------
inversion_id_mill |   142.3963   3.053421    46.64   0.000     136.4099    148.3828
  patrimonio_mill |   .5713513   .0214898    26.59   0.000     .5292189    .6134836
            _cons |   11938.54   2438.636     4.90   0.000     7157.408    16719.67
------------------------------------------------------------------------------
```

Modelo original

```
. reg ventas_mill inversion_id_mill_v2 patrimonio_mill_v2

      Source |       SS           df       MS      Number of obs   =     3,878
-------------+----------------------------------   F(2, 3875)      =   1635.81
       Model |  7.4145e+13         2  3.7073e+13   Prob > F        =    0.0000
    Residual |  8.7820e+13     3,875  2.2663e+10   R-squared       =    0.4578
-------------+----------------------------------   Adj R-squared   =    0.4575
       Total |  1.6197e+14     3,877  4.1776e+10   Root MSE        =    1.5e+05

------------------------------------------------------------------------------
     ventas_mill |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-----------------+------------------------------------------------------------
inversion_id_mill_v2 |   142.3963   3.053421    46.64   0.000     136.4099    148.3828
  patrimonio_mill_v2 |   .5713513   .0214898    26.59   0.000     .5292189    .6134836
            _cons |   29034.93    2440.91    11.90   0.000     24249.34    33820.52
------------------------------------------------------------------------------
```

Modelo reparame-trizado

Predicción: modelo reparametrizado - Ejemplo

- **La única diferencia entre la regresión original y la del modelo reparametrizado es el intercepto, que es la predicción que se busca, junto con su error estándar.**

- No es una coincidencia que los coeficientes de pendiente, sus errores standard, R^2 y R^2_{Ajus}, etc., sean idénticas. De hecho, esto proporciona una manera simple de verificar que se hicieron las transformaciones correctas.

- Construir un intervalo de confianza al 95% para el nivel de ventas esperado resulta en:

$$IC_{\widehat{V_0}} = 29034.93 \pm 1.96 \cdot 2440.91 = [\mathbf{24249}\,, \mathbf{33821}]$$

Resumen de la Unidad 4

1. Análisis de la propiedad de insesgamiento
2. Formas funcionales, elección de regresores e interpretación de coeficientes
3. Más sobre R^2 y especificación de modelos
4. Predicción y análisis de residuos
5. **Multicolinealidad**
6. Heterocedasticidad
7. Causalidad, experimentos naturales y validez de los modelos
8. Resumiendo… con un ejemplo

Multicolinealidad

Colinealidad o Multicolinealidad: se refiere a una situación en la que dos o más variables explicativas se parecen mucho y, por lo tanto, resulta difícil medir sus efectos individuales sobre la variable explicada.

Tipos de multicolinealidad:

- **Exacta o perfecta:** Se da cuando los valores de una variable explicativa se obtienen como combinación lineal exacta de otras.
- **De grado o imperfecta:** Se da cuando los valores de diferentes variables están tan correlacionados que se hace casi imposible estimar con precisión los efectos individuales de cada uno de ellos.

Multicolinealidad perfecta o exacta

- Si la multicolinealidad es perfecta o exacta, el determinante:

$$|X'X| = 0$$

- Esto significa que el sistema de ecuaciones de los estimadores MCO

$$X'X\hat{\beta} = X'Y$$

  tiene infinitas soluciones.

- En términos simples, la matriz $X'X$ no es invertible, por lo que no se puede obtener ni los $\hat{\beta}$ ni sus errores standard.

Multicolinealidad imperfecta o de grado

- **La colinealidad imperfecta no es problema si nuestro objetivo es predecir, pero es un problema grave si queremos interpretar las estimaciones de los parámetros.**

- Cuando dos o más variables explicativas de un modelo **están altamente correlacionadas** en la muestra, es muy difícil separar el efecto parcial de cada una de estas variables sobre la variable explicada.

Multicolinealidad imperfecta o de grado

- La información muestral que incorpora una de estas variables es casi la misma que la del resto de las correlacionadas con ella.
- En este caso, el determinante $|X'X| \cong 0$.
- Matemáticamente, existirá una solución única al problema de la suma de mínimos cuadrados, pero también existirán muchas soluciones casi iguales a ella.

Multicolinealidad imperfecta o de grado: síntomas

- Las estimaciones de los parámetros MCO son muy sensibles a la muestra: pequeños cambios en los datos o en la especificación provocan grandes cambios en las estimaciones de los coeficientes.
- Las estimaciones de los coeficientes presentan signos distintos a los esperados o magnitudes poco razonables.

Multicolinealidad imperfecta o de grado: síntomas

- **Efecto más pernicioso: incremento las varianzas de los coeficientes estimados por MCO. Por lo tanto, los test t no son fiables (se tiende a concluir que las variables no son significativas individualmente).**

- Se obtienen valores altos del R^2 aun cuando los valores de los estadísticos t de significancia individual son bajos.

- **Puzzle: test t indivuales no significativos, pero test F conjuntos significativos**

Multicolinealidad imperfecta o de grado: diagnóstico

- **Estrategia 1:** obtener los coeficientes de correlación muestral simples para cada par de variables explicativas y ver si el grado de correlación entre estas variables es alto.
  - Ojo! Se puede dar el caso de tener una relación lineal casi perfecta entre tres o más variables y sin embargo, las correlaciones simples entre pares de variables no ser mayores que 0,5.
- **Estrategia 2:** realizar la regresión de cada variable explicativa sobre el resto. Se realizan k regresiones, y se obtienen los R_k^2 de cada regresión. Si alguno de ellos es alto, podemos sospechar la existencia de colinealidad.

Multicolinealidad imperfecta o de grado: soluciones

El problema de colinealidad se reduce a que la muestra no contiene suficiente información para estimar todos los parámetros. Algunas posibles soluciones son:

- **Añadir nuevas observaciones o cambiar de muestra**
- **Restringir parámetros:** Si la Teoría Económica o la experiencia sugieren algunas restricciones sobre los parámetros más afectados por la colinealidad, imponerlas permitirá reducir el problema. Obviamente, se corre el riesgo de imponer restricciones que no son ciertas.
- **Suprimir variables correlacionadas:** se pierde poca capacidad explicativa. Pero si la variable eliminada es realmente significativa, introducimos sesgo por omisión de variable relevante, y todos los estimadores de los coeficientes y sus varianzas estarán sesgados.
- **Transformar las variables del modelo**

Resumen de la Unidad 4

1. Análisis de la propiedad de insesgamiento
2. Formas funcionales, elección de regresores e interpretación de coeficientes
3. Más sobre R^2 y especificación de modelos
4. Predicción y análisis de residuos
5. Multicolinealidad
6. **Heterocedasticidad**
7. Causalidad, experimentos naturales y validez de los modelos
8. Resumiendo… con un ejemplo

Heterocedasticidad

- El Supuesto (S5) de **homocedasticidad**, sostenido hasta ahora, establece que **la varianza del error** no observable, condicional en las variables explicativas, **es constante**.
- La homocedasticidad no se satisface cuando la varianza de los no observables varía en los diversos segmentos de la población, donde los segmentos están determinados por los diversos valores de las variables explicativas.
- Por ejemplo, en una ecuación del ahorro, habrá heterocedasticidad si la varianza de los factores no observados que afectan el ahorro aumenta con el ingreso.

Heterocedasticidad

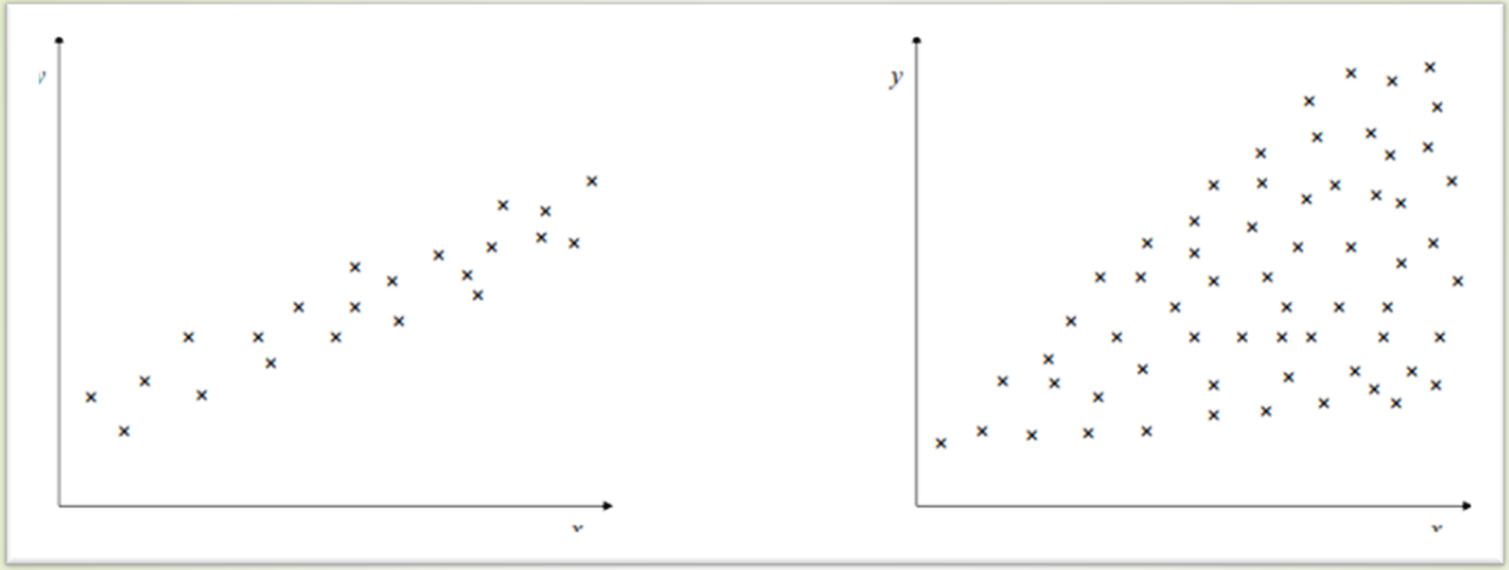

- A continuación, estudiaremos brevemente las **consecuencias de la heterocedasticidad** en las estimaciones por mínimos cuadrados ordinarios, aprenderemos formas de **probar su presencia**, y revisaremos algunos **tratamientos** con que se cuenta para recuperar las propiedades de los estimadores por MCO.

Supuestos de MCO en forma matricial

- ***Supuesto 1 (S1)***: **Linealidad en los parámetros:** $\mathrm{Y} = X\beta + \varepsilon$
- ***Supuesto 2 (S2)***: **Muestreo aleatorio**, es decir, $(X_i, Y_i) \sim iid$ (independientes e idénticamente distribuidas)
- ***Supuesto 3 (S3)***: **Ausencia de multicolinealidad perfecta**, es decir, que las columnas de X son linealmente independientes (no hay información redundante), o que $X'X\ es\ invertible$
- ***Supuesto 4 (S4)***: **Esperanza condicional nula:** $E[u|X_1, X_2, X_3, \dots, X_k] = 0$
- ***Supuesto 5 (S5)***: **Homocedasticidad y ausencia de correlación entre los errores**

$$Var(u|X) = \sigma^2 I_N = \begin{bmatrix} \sigma^2 & \dots & 0 \\ \vdots & \sigma^2 & \vdots \\ 0 & \dots & \sigma^2 \end{bmatrix}$$

- ***Supuesto 6 (S6)***: **Normalidad de los errores:** $\varepsilon|X \sim Normal(0, \sigma^2 I_N)$

Supuesto (S5): Consecuencias

- Es importante recordar que la **heterocedasticidad no ocasiona sesgo ni inconsistencia en los $\hat{\beta}_j$** , mientras que omitir una variable importante sí tendrá este efecto.

- La interpretación de las medidas de bondad de ajuste, $\boldsymbol{R^2}$ **y** $\boldsymbol{R^2_{Ajus}}$ **, tampoco se ve afectada** por la presencia de heterocedasticidad.

Supuesto (S5): Consecuencias

- **Sin el supuesto de homocedasticidad, los estimadores de las varianzas, $Var(\widehat{\beta}_j)$, son sesgados.**

- Como los errores estándar de MCO se basan directamente en estas varianzas, $Var(\widehat{\beta}_j)$, **éstos dejan de ser válidos para la construcción de intervalos de confianza y de estadísticos $\widehat{T}$.**

Supuesto (S5): Consecuencias

- En presencia de heterocedasticidad**, los estadísticos $\widehat{T}$ usuales de MCO no tienen distribuciones t_{df}**, y el problema no se resuelve empleando muestras grandes.

- De manera similar, **los estadísticos $\widehat{F}$ dejan de seguir una distribución F_{df_1,df_2}.**

Supuesto (S5): Consecuencias

- **En resumen, los estadísticos empleados en las pruebas de hipótesis bajo los supuestos de Gauss-Markov ya no son válidos en presencia de heterocedasticidad.**

- Adicionalmente, se sabe que el teorema de Gauss-Markov, que dice que MCO es mejor estimador lineal insesgado (MELI), depende de manera crucial del supuesto de homocedasticidad.

Detección del problema de Heterocedasticidad

Existen varios métodos para determinar si los residuos son heterocedásticos.

Algunos de ellos son:

- **Test de Breusch-Pagan-Godfrey / Cook-Weisberg**
  - Asumiendo normalidad de los errores $\sim\chi^2_{df}$
  - Para cualquier distribución de los errores $\sim F_{df_1,df_2}$
- Test General de Hetorocedasticidad de White
- Test de Matriz de Información de Cameron-Trivedi
- Test de Rango para Heterocedasticidad de Szroeter

Test de Heterocedasticidad de Breusch-Pagan-Godfrey

¿Cómo se puede determinar si se cumple el supuesto de homocedasticidad?

1. Estimar el modelo por MCO, como de costumbre: $\hat{\beta} = (X'X)^{-1}X'Y$.
2. Obtener los residuos al cuadrado de MCO, $\widehat{u_i}^2$ (uno para cada observación): $\widehat{U} = Y - X\hat{\beta}$

Test de Heterocedasticidad de Breusch-Pagan-Godfrey

3. Estimar una regresión utilizando $\widehat{u_i}^2$ como variable explicada y todos los regresores: $\hat{\alpha} = (\boldsymbol{X'X})^{-1}\boldsymbol{X'}\widehat{\boldsymbol{U^2}}$. Conservar el R^2 de esta regresión.

3. Testear la hipótesis: $\boldsymbol{H_o}: \widehat{\boldsymbol{\alpha}} = \vec{\boldsymbol{0}}\ \boldsymbol{Homocedasticidad.}$

   Formar el estadístico $\hat{F}$ (*test de significancia general de la regresión*) y calcular el valor-p (lo entrega STATA)

   Si el valor-p es suficientemente pequeño, es decir, menor que el nivel de significancia elegido, se rechaza la hipótesis nula de homocedasticidad.

Test de Heterocedasticidad de Breusch-Pagan-Godfrey

```
. reg ventas patrimonio trabajadores

      Source |       SS           df       MS      Number of obs   =     5,070
-------------+----------------------------------   F(2, 5067)      =    435.01
       Model |  2.3730e+19         2  1.1865e+19   Prob > F        =    0.0000
    Residual |  1.3820e+20     5,067  2.7275e+16   R-squared       =    0.1465
-------------+----------------------------------   Adj R-squared   =    0.1462
       Total |  1.6193e+20     5,069  3.1946e+16   Root MSE        =    1.7e+08

------------------------------------------------------------------------------
      ventas |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
  patrimonio |   .6695622   .0230636    29.03   0.000     .6243477    .7147768
trabajadores |    11884.7   2983.333     3.98   0.000     6036.077    17733.32
       _cons |   1.00e+07    2349976     4.27   0.000      5432701    1.46e+07
------------------------------------------------------------------------------
```

```
predict u, r
gen u2=u*u
reg u2 patrimonio trabajadores
```

Test de Heterocedasticidad de Breusch-Pagan-Godfrey

```
. reg u2 patrimonio trabajadores

      Source |       SS           df       MS      Number of obs   =     5,070
-------------+----------------------------------   F(2, 5067)      =     98.67
       Model |  1.4374e+38         2  7.1869e+37   Prob > F        =    0.0000
    Residual |  3.6906e+39     5,067  7.2837e+35   R-squared       =    0.0375
-------------+----------------------------------   Adj R-squared   =    0.0371
       Total |  3.8344e+39     5,069  7.5644e+35   Root MSE        =    8.5e+17

------------------------------------------------------------------------------
          u2 |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
  patrimonio |   1.67e+09   1.19e+08    13.98   0.000     1.43e+09    1.90e+09
trabajadores |   1.27e+13   1.54e+13     0.82   0.410    -1.75e+13    4.29e+13
       _cons |   6.73e+15   1.21e+16     0.55   0.580    -1.71e+16    3.05e+16
------------------------------------------------------------------------------
```

- *valor-p* correspondiente es 0.0000, que es una **fuerte evidencia contra la hipótesis nula.**
- **Se rechaza H_0: sí hay heteroscedasticidad**

Test de Heterocedasticidad de Breusch-Pagan-Godfrey

- **Implementación en STATA:** estat hettest patrimonio trabajadores, fstat

```
. reg ventas patrimonio trabajadores

      Source |       SS           df       MS      Number of obs   =     5,070
-------------+----------------------------------   F(2, 5067)      =    435.01
       Model |  2.3730e+19         2  1.1865e+19   Prob > F        =    0.0000
    Residual |  1.3820e+20     5,067  2.7275e+16   R-squared       =    0.1465
-------------+----------------------------------   Adj R-squared   =    0.1462
       Total |  1.6193e+20     5,069  3.1946e+16   Root MSE        =    1.7e+08

------------------------------------------------------------------------------
      ventas |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
  patrimonio |   .6695622   .0230636    29.03   0.000     .6243477    .7147768
trabajadores |    11884.7   2983.333     3.98   0.000     6036.077    17733.32
       _cons |   1.00e+07    2349976     4.27   0.000      5432701    1.46e+07
------------------------------------------------------------------------------

. estat hettest patrimonio trabajadores, fstat

Breusch-Pagan / Cook-Weisberg test for heteroskedasticity
         Ho: Constant variance
         Variables: patrimonio trabajadores

         F(2 , 5067)  =    98.67
         Prob > F     =   0.0000
```

Soluciones al problema de Heterocedasticidad

- **Re-especificación del modelo** (por ejemplo, variables omitidas)
- **Transformación** (logarítmica) **de variables**
- **Corrección de errores standard**
  - Es fácil de aplicar y se obtienen errores standard "robustos" para hacer inferencia → **Estimadores de Huber/White o Sandwich**
  - Sin embargo, no se cumple Teorema de Gauss Markov (estimador de MCO no es MELI)

Soluciones al problema de Heterocedasticidad

- **Mínimos cuadrados generalizados o ponderados (MCG)**
  - Requiere tener una idea de la forma funcional de la heteroscedasticidad, por lo que es más complejo que el anterior
  - **MCG entrega estimadores MELI**
  - Se aplica cuando se sospecha que la heteroscedasticidad es muy fuerte

Soluciones: Transformación logarítmica

¿Primera alternativa de solución? Modelo en logaritmos

```
gen ln_ventas=ln(ventas)
gen ln_patrimonio=ln(patrimonio)
gen ln_trabajadores=ln(trabajadores)

. reg ln_ventas ln_patrimonio ln_trabajadores

      Source |       SS           df       MS      Number of obs   =     4,490
-------------+----------------------------------   F(2, 4487)      =   5958.60
       Model |  19120.3654         2  9560.1827    Prob > F        =    0.0000
    Residual |  7199.09735     4,487  1.60443444   R-squared       =    0.7265
-------------+----------------------------------   Adj R-squared   =    0.7264
       Total |  26319.4627     4,489  5.86310153   Root MSE        =    1.2667

------------------------------------------------------------------------------
     ln_ventas |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
  ln_patrimonio |   .5695528   .0075124    75.82   0.000     .5548249    .5842807
ln_trabajadores |   .3515315   .0118951    29.55   0.000     .3282113    .3748517
          _cons |   5.796981   .0835612    69.37   0.000      5.63316    5.960802
------------------------------------------------------------------------------

predict u_ln, r
```

Soluciones: Transformación logarítmica

¿Primera alternativa de solución? Modelo en logaritmos

```
gen u_ln2=u_ln*u_ln
reg u_ln2 ln_patrimonio ln_trabajadores
```

```
. reg u_ln2 ln_patrimonio ln_trabajadores

      Source |       SS           df       MS      Number of obs   =     4,490
-------------+----------------------------------   F(2, 4487)      =      2.75
       Model |  83.9218178         2  41.9609089   Prob > F        =    0.0643
    Residual |  68578.7766     4,487  15.2838816   R-squared       =    0.0012
-------------+----------------------------------   Adj R-squared   =    0.0008
       Total |  68662.6985     4,489  15.2957671   Root MSE        =    3.9095

------------------------------------------------------------------------------
        u_ln2 |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
 ln_patrimonio |  -.0094173   .0231863    -0.41   0.685     -.054874    .0360393
ln_trabajadores |  -.0656234   .0367132    -1.79   0.074    -.1375994    .0063526
        _cons |   1.870251   .2579054     7.25   0.000     1.364629    2.375872
------------------------------------------------------------------------------
```

- Valor-p es 0.0643 → No es evidencia fuerte contra la hipótesis nula.
- Al 95%, NO SE RECHAZA H_0: No hay heterocedasticidad (errores homocedásticos)

Soluciones: Transformación logarítmica

- **Implementación en STATA:**

estat hettest ln_patrimonio ln_trabajadores, fstat

```
. reg ln_ventas ln_patrimonio ln_trabajadores

      Source |       SS           df       MS      Number of obs   =     4,490
-------------+----------------------------------   F(2, 4487)      =   5958.60
       Model |  19120.3654         2  9560.1827    Prob > F        =    0.0000
    Residual |  7199.09735     4,487  1.60443444   R-squared       =    0.7265
-------------+----------------------------------   Adj R-squared   =    0.7264
       Total |  26319.4627     4,489  5.86310153   Root MSE        =    1.2667

------------------------------------------------------------------------------
      ln_ventas |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
  ln_patrimonio |   .5695528   .0075124    75.82   0.000     .5548249    .5842807
ln_trabajadores |   .3515315   .0118951    29.55   0.000     .3282113    .3748517
          _cons |   5.796981   .0835612    69.37   0.000      5.63316    5.960802
------------------------------------------------------------------------------

. estat hettest ln_patrimonio ln_trabajadores, fstat

Breusch-Pagan / Cook-Weisberg test for heteroskedasticity
         Ho: Constant variance
         Variables: ln_patrimonio ln_trabajadores

         F(2 , 4487)  =     2.75
         Prob > F     =   0.0643
```

Soluciones: Transformación logarítmica

- **Ejemplo 2: peso (kg) en escolares**

```
. reg pesokl mujer edad area_estab tallacm

      Source |       SS           df       MS      Number of obs   = 1,318,800
-------------+----------------------------------   F(4, 1318795)   >  99999.00
       Model |  283574562         4  70893640.5   Prob > F        =    0.0000
    Residual |   79453995 1,318,795   60.247419   R-squared       =    0.7811
-------------+----------------------------------   Adj R-squared   =    0.7811
       Total |  363028557 1,318,799   275.27209   Root MSE        =    7.7619

------------------------------------------------------------------------------
      pesokl |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
       mujer |   .6693024   .0136328    49.10   0.000     .6425825    .6960222
        edad |   .1684626   .0029599    56.91   0.000     .1626612     .174264
  area_estab |  -.6518282   .0233142   -27.96   0.000    -.6975231   -.6061332
     tallacm |   .6853184   .0005058  1354.87   0.000     .6843271    .6863098
       _cons |  -56.27968   .0589621  -954.51   0.000    -56.39524   -56.16411
------------------------------------------------------------------------------
```

Soluciones: Transformación logarítmica

- **Ejemplo 2: peso (kg) en escolares**

- Revisamos la presencia de heterocedasticidad: p-value=0.0000 → Se rechaza H_0: **hay heterocedasticidad.**

```
. estat hettest mujer edad area_estab tallacm, fstat

Breusch-Pagan / Cook-Weisberg test for heteroskedasticity
         Ho: Constant variance
         Variables: mujer edad area_estab tallacm

         F(4 , 1318795)=  5524.38
         Prob > F      =   0.0000
```

Soluciones: corrección de los errores standard

- Aun con problemas de heterocedasticidad, MCO puede seguir siendo útil.
- Es posible ajustar los errores standard y los estadísticos t y F para que sean válidos en presencia de heterocedasticidad de forma desconocida.

Soluciones: corrección de los errores standard

- Esto es muy conveniente porque significa que se pueden reportar nuevos estadísticos que funcionen sin importar el tipo de heterocedasticidad presente en la población.

- Los métodos que se presentan a continuación se conocen como **procedimientos robustos a la heterocedasticidad**, debido a que son válidos —por lo menos para muestras grandes—, ya sea que los errores tengan o no varianza constante, sin necesidad de saber cuál es el caso.

Soluciones: corrección de los errores standard

- Los **errores estándar robustos a la heterocedasticidad** proporcionan un método simple para calcular estadísticos t que distribuyen asintóticamente t, ya sea que exista o no heterocedasticidad.

- También existen estadísticos F (además del los t) robustos a la heterocedasticidad.

Soluciones: corrección de los errores standard

- **Para realizar estas pruebas, no se requiere saber si existe o no heterocedasticidad.**

- A pesar de esto, hay razones para emplear pruebas sencillas que puedan detectar su presencia.

- **IMPORTANTE:** En presencia de heterocedasticidad, los estimadores de MCO ya no son los mejores estimadores lineales insesgados.

- **Cuando se conoce la forma de la heterocedasticidad, es posible obtener un estimador mejor que el de MCO.**

Soluciones: corrección de los errores standard

- **Errores estándar "robustos" a la heteroscedasticidad (White):**

- Un estimador consistente de la varianza es la matriz de Varianzas-Covarianza de White (o robusta a la heterocedasticidad):

$$\widehat{Var_{White}}\left(\widehat{\beta_{MCO}}\middle|X\right) = (X'X)^{-1}\left(\sum X_i X_i{}'\hat{\varepsilon}_i{}^2\right)(X'X)^{-1}$$

donde los residuos del modelo son $\hat{\varepsilon}_i = Y_i - X_i{}'\hat{\beta}$

Soluciones: corrección de los errores standard

- **Errores estándar “robustos” a la heteroscedasticidad (White):**

- Se les llama errores standard robustos a la heterocedasticidad, o simplemente errores estándar robustos.

- También se les llama *“Estimadores de Sandwich”*.

Soluciones: corrección de los errores standard

```
. reg pesokl mujer edad area_estab tallacm

      Source |       SS           df       MS      Number of obs   = 1,318,800
-------------+----------------------------------   F(4, 1318795)   >  99999.00
       Model |  283574562         4  70893640.5   Prob > F        =    0.0000
    Residual |   79453995 1,318,795   60.247419   R-squared       =    0.7811
-------------+----------------------------------   Adj R-squared   =    0.7811
       Total | 363028557 1,318,799   275.27209   Root MSE        =    7.7619

------------------------------------------------------------------------------
      pesokl |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
       mujer |   .6693024   .0136328    49.10   0.000     .6425825    .6960222
        edad |   .1684626   .0029599    56.91   0.000     .1626612     .174264
  area_estab |  -.6518282   .0233142   -27.96   0.000    -.6975231   -.6061332
     tallacm |   .6853184   .0005058  1354.87   0.000     .6843271    .6863098
       _cons |  -56.27968   .0589621  -954.51   0.000    -56.39524   -56.16411
------------------------------------------------------------------------------
```

```
. reg pesokl mujer edad area_estab tallacm, robust

Linear regression                               Number of obs     =  1,318,800
                                                F(4, 1318795)     >   99999.00
                                                Prob > F          =     0.0000
                                                R-squared         =     0.7811
                                                Root MSE          =     7.7619

------------------------------------------------------------------------------
             |               Robust
      pesokl |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
       mujer |   .6693024   .0135417    49.43   0.000     .6427611    .6958436
        edad |   .1684626   .0028202    59.73   0.000     .1629351    .1739902
  area_estab |  -.6518282   .0207653   -31.39   0.000    -.6925275   -.6111289
     tallacm |   .6853184   .0005831  1175.24   0.000     .6841755    .6864614
       _cons |  -56.27968   .0637339  -883.04   0.000    -56.40459   -56.15476
------------------------------------------------------------------------------
```

Permite reportar nuevos estadísticos que funcionen sin importar el tipo de heterocedasticidad presente en la población.

Soluciones: corrección de los errores standard

- Si los errores standard robustos a la heterocedasticidad son válidos más a menudo que los errores estándar usuales de MCO, **¿por qué molestarse en calcular los errores estándar usuales?**

- Se prefieren los **errores standard usuales**, asumiendo que el supuesto de homocedasticidad se satisface y los errores están distribuidos normalmente, porque los **estadísticos t usuales** tiene **distribuciones t exactas**, **sin importar el tamaño de muestra**.

Soluciones: corrección de los errores standard

- Por su parte, los **errores standard robustos** y los **estadísticos t robustos** se justifican **sólo si el tamaño de muestra se hace grande.** Con tamaños de muestra pequeños, el estadístico t robusto puede tener distribuciones que no estén muy próximas a la distribución t y que podrían echar a perder la inferencia.

Soluciones: Mínimos Cuadrados Generalizados

- En presencia de heterocedasticidad, NO SE CUMPLE el Teorema de Gauss Markov (estimador de MCO no es MELI)

¿Habrá otro estimador MELI?

SÍ. Estimador por **Mínimos Cuadrados Generalizados (MCG):**

Soluciones: Mínimos Cuadrados Generalizados

- Estimador por **Mínimos Cuadrados Generalizados (MCG):**
  - Si se conoce la forma de la heterocedasticidad, y ésta se representa a través de la matriz Ω, entonces…
  - **Fórmula general (con Ω conocida):**
  - $\widehat{\beta_{MCG}} = \left(X'\Omega^{-1}X\right)^{-1}X'\Omega^{-1}Y$
  - **<u>Alternativa</u>:** transformar el modelo original a fin de eliminar la heterocedasticidad, para luego estimar por MCO.
- ¿Qué implica esto?

Soluciones: MCG con Heterocedasticidad conocida

- **Supongamos el siguiente modelo:**

$$Y_i = \alpha_0 + \alpha_1 X_{1i} + \alpha_2 X_{2i} + \varepsilon_i$$
$$Var(\varepsilon_i|X) = \sigma^2 K_i \quad con\ K_i > 0$$

- El **Modelo Transformado** consiste en dividir la ecuación por $\sqrt{K_i}$:

$$\frac{Y_i}{\sqrt{K_i}} = \alpha_0 \frac{1}{\sqrt{K_i}} + \alpha_1 \frac{X_{1i}}{\sqrt{K_i}} + \alpha_2 \frac{X_{2i}}{\sqrt{K_i}} + \frac{\varepsilon_i}{\sqrt{K_i}}$$

Soluciones: MCG con Heterocedasticidad conocida

- **Ventaja: El modelo transformado no tiene heterocedasticidad**

$$Var\left(\frac{\varepsilon_i}{\sqrt{K_i}}|X\right) = \frac{\sigma^2 K_i}{\left(\sqrt{K_i}\right)^2} = \sigma^2$$

- El estimador por MCG equivale al estimador por MCO en este modelo transformado
  - En esencia, se toma la ecuación original que contiene errores heterocedásticos, y se transforma en una ecuación que tenga errores homocedásticos (y satisfaga los demás supuestos de Gauss-Markov).

Soluciones: MCG con Heterocedasticidad conocida

- Cada parámetro de pendiente en α_j multiplica una nueva variable que rara vez tiene una interpretación útil. **Esto no deberá causar ningún problema si se recuerda que, para interpretar los parámetros y el modelo, siempre se vuelve a la ecuación original (¡recuerde que el re-escalamiento no genera sesgo!)**

- Los estimadores de MCG para la corrección de la heterocedasticidad se denominan **Estimadores de Mínimos Cuadrados Ponderados** (MCP):

Soluciones: MCG con Heterocedasticidad conocida

$$\boldsymbol{Modelo}: \boldsymbol{pesokl_i} = \boldsymbol{\alpha_0 + \alpha_1 tallacm_i + \varepsilon_i}$$

```
. reg pesokl tallacm

      Source |       SS           df       MS      Number of obs   = 1,318,800
-------------+----------------------------------   F(1, 1318798)   >  99999.00
       Model |  283131987         1  283131987    Prob > F        =    0.0000
    Residual |   79896570 1,318,798  60.5828717   R-squared       =    0.7799
-------------+----------------------------------   Adj R-squared   =    0.7799
       Total | 363028557 1,318,799   275.27209   Root MSE        =    7.7835

------------------------------------------------------------------------------
      pesokl |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
     tallacm |    .707358   .0003272  2161.82   0.000     .7067167    .7079993
       _cons |  -57.35427   .0473218 -1212.00   0.000    -57.44702   -57.26152
------------------------------------------------------------------------------

. estat hettest tallacm, fstat

Breusch-Pagan / Cook-Weisberg test for heteroskedasticity
         Ho: Constant variance
         Variables: tallacm

         F(1 , 1318798)= 21353.97
         Prob > F      =   0.0000
```

- Una vez realizado el test, rechazo la hipótesis nula ante la fuerte evidencia de **presencia de heterocedasticidad**.
- Esto podría significar que, **a medida que aumenta la altura, aumenta la variabilidad en el peso**.
- **Si se cree que** $\boldsymbol{Var(u_i|tallacm) = \sigma^2 \cdot tallacm_i}$
- Luego, aplicamos la corrección aprendida…

Soluciones: MCG con Heterocedasticidad conocida

$$\frac{pesokl_i}{\sqrt{tallacm_i}} = \alpha_0 \frac{1}{\sqrt{tallacm_i}} + \alpha_1 \frac{tallacm_i}{\sqrt{tallacm_i}} + \frac{\varepsilon_i}{\sqrt{tallacm_i}}$$

$$Var\left(\frac{\varepsilon_i}{\sqrt{tallacm_i}} | tallacm\right) = \frac{\sigma^2 tallacm_i}{\left(\sqrt{tallacm_i}\right)^2} = \sigma^2$$

Soluciones: MCG con Heterocedasticidad conocida

```
. gen rtallacm=tallacm^0.5

. gen pesokl_mcg=pesokl/rtallacm

. gen tallacm_mcg=tallacm/rtallacm

. reg pesokl_mcg tallacm_mcg
```

$$\frac{pesokl_i}{\sqrt{tallacm_i}} = \alpha_0 \frac{1}{\sqrt{tallacm_i}} + \alpha_1 \frac{tallacm_i}{\sqrt{tallacm_i}} + \frac{\varepsilon_i}{\sqrt{tallacm_i}}$$

$$Var\left(\frac{\varepsilon_i}{\sqrt{tallacm_i}} | tallacm\right) = \frac{\sigma^2 tallacm_i}{\left(\sqrt{tallacm_i}\right)^2} = \sigma^2$$

Source	SS	df	MS
Model	1212599.56	1	1212599.56
Residual	530374.213	1,318,798	.40216486
Total	1742973.77	1,318,799	1.32163716

Number of obs	=	1,318,800
F(1, 1318798)	>	99999.00
Prob > F	=	0.0000
R-squared	=	0.6957
Adj R-squared	=	0.6957
Root MSE	=	.63416

pesokl_mcg	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
tallacm_mcg	1.103214	.0006353	1736.43	0.000	1.101969	1.104459
_cons	-9.555176	.007601	-1257.09	0.000	-9.570073	-9.540278

Soluciones: MCG con Heterocedasticidad desconocida

- **Si no se conoce su forma, la heterocedasticidad puede ser modelada como función de regresores:**

$$Var(\varepsilon_i|X) = exp(\delta_0 + \delta_1 X_{1i} + \delta_2 X_{2i})$$

Para aplicar MCG en este caso, se sigue el siguiente procedimiento:

Soluciones: MCG con Heterocedasticidad desconocida

- **Procedimiento:**

1) Estimar el modelo principal y obtener los residuos:

$$\widehat{\varepsilon_i} = Y_i - \widehat{\alpha_0} - \widehat{\alpha_1} X_{1i} - \widehat{\alpha_2} X_{2i}$$

2) Estimar el modelo a partir del logaritmo de los residuos al cuadrado y calcular K_i:

$$ln\left(\widehat{\varepsilon_i}^2\right) = \delta_0 + \delta_1 X_{1i} + \delta_2 X_{2i} + \omega_i$$

$$K_i = exp\left(\widehat{\delta_0} + \widehat{\delta_1} X_{1i} + \widehat{\delta_2} X_{2i}\right)$$

3) Dividir el modelo principal por $\sqrt{K_i}$ y estimar por MCO

Heterocedasticidad: resumen

Test de Heterocedasticidad

- Encuentro evidencia de heteroc.
  - **Alt 1:** Estimar por MCO, usando errores robustos **(¿ineficiente?)**
  - **Alt 2:** Modelar heteroc. y estimar por MCG **(requiere modelo)**
- NO encuentro evidencia
  - Estimar por MCO con errores habituales

Resumen de la Unidad 4

1. Análisis de la propiedad de insesgamiento
2. Formas funcionales, elección de regresores e interpretación de coeficientes
3. Más sobre R^2 y especificación de modelos
4. Predicción y análisis de residuos
5. Multicolinealidad
6. Heterocedasticidad
7. **Causalidad, experimentos naturales y validez de los modelos**
8. Resumiendo… con un ejemplo

Causalidad y experimentos naturales

¿Por qué es bueno estudiar experimentos aleatorios en Econometría?

- Permite encontrar efectos causales
- Los experimentos aleatorios puede ser muy influyentes por lo que es importante entender sus limitaciones
- La existencia de cuasi-experimentos o experimentos naturales pone en perspectiva la discusión de causalidad
- En las ciencias sociales, ¿tiene sentido hablar de causalidad?

Metodología

- **Tipo de datos**
  - Panel o cross-section
- **Efecto del tratamiento**
  - Dos grupos (al menos): control y bajo tratamiento
- **Métodos:**
  - Basados en el uso de variables *dummy* que identifican quién recibe el tratamiento y cuándo lo recibe
  - Estimadores antes-después
  - Estimadores control vs. tratados
  - Estimadores de diferencias-en-diferencias: ATE, LATE

Metodología: estimador dif-in-dif

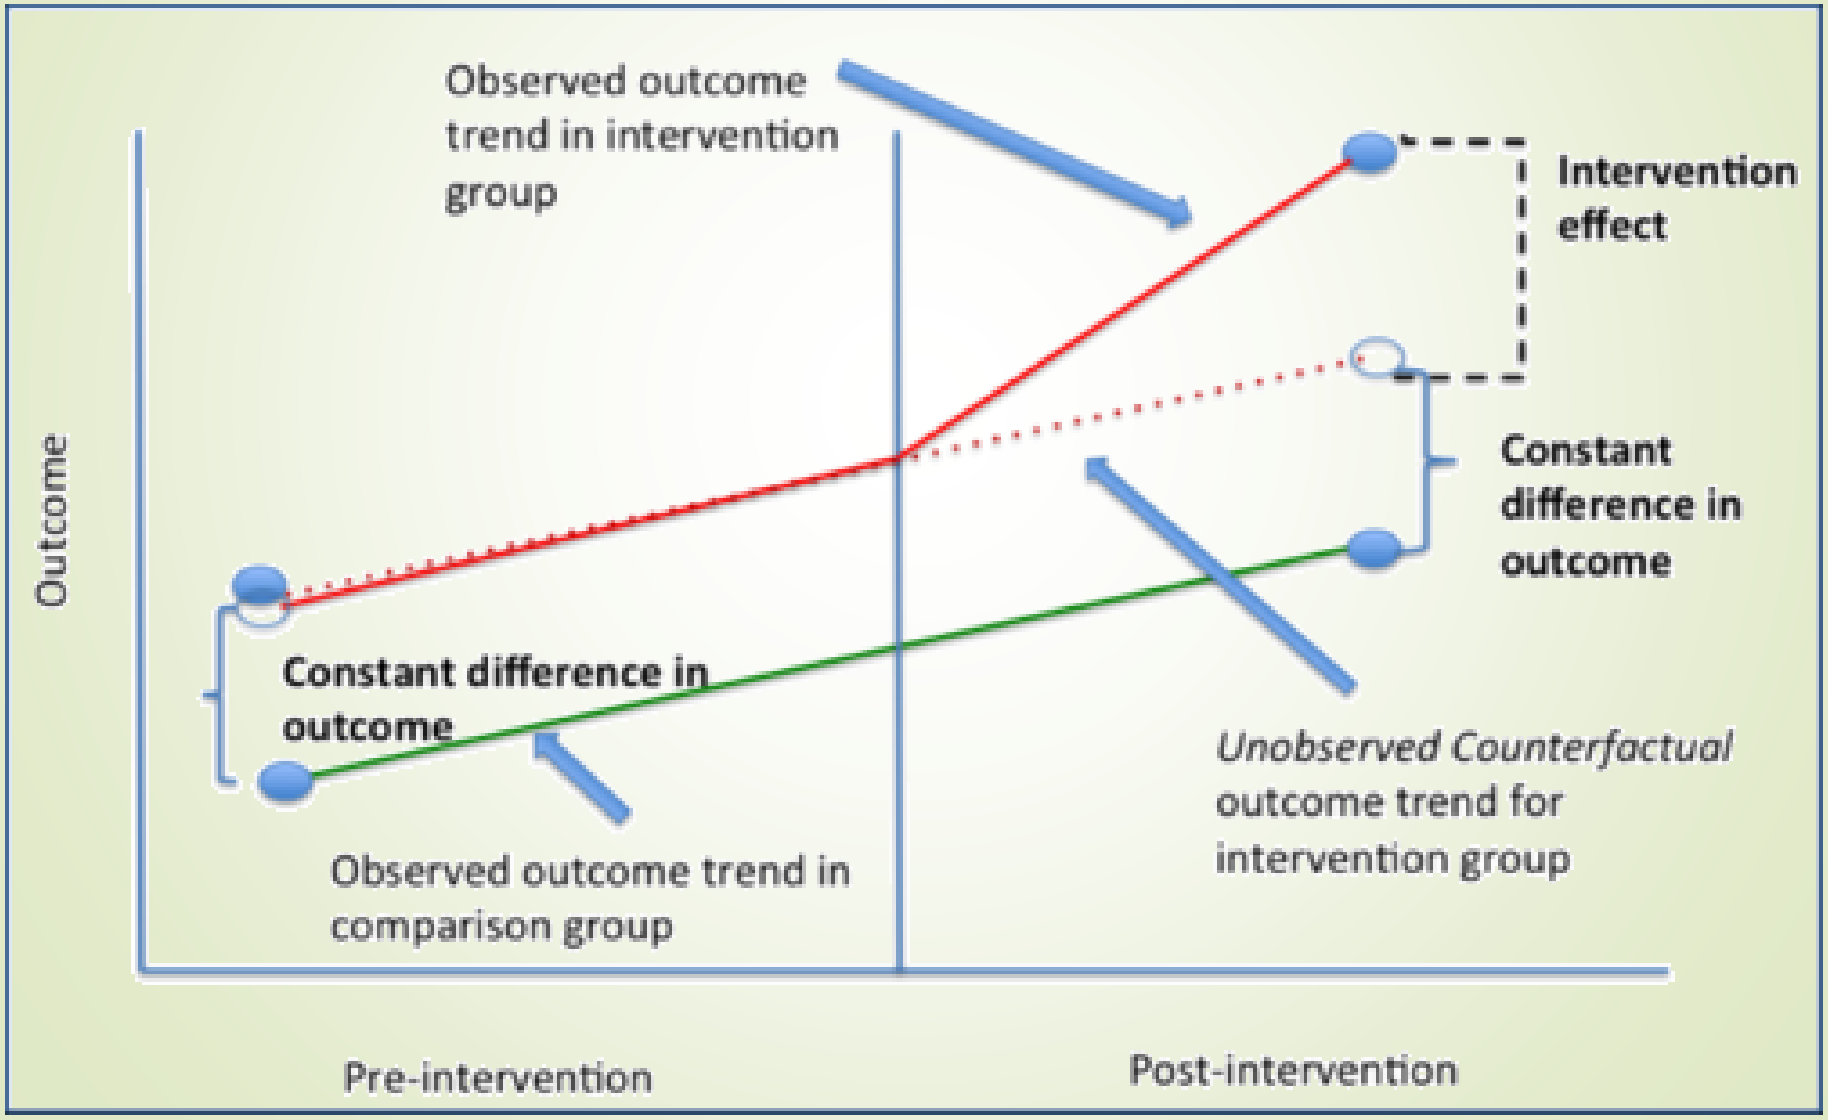

Ejemplo: Caso STAR

- Corte Transversal
- Muestra aleatoria → 11000 niños de 3 años
  - Clases con 22 niños vs 15 niños
  - Primeros resultados 0,3 a 0,6 desviaciones mejor
  - Sin embargo, resultado cae en el tiempo
- Análisis temporal con salario 1200-2000 dólares extras al año
  - Esto también ocurre con ingreso a la universidad, posibilidad comprar vivienda, movilidad entre estados, casarse, etc.
- Pero…¿tiene validez externa? ¿Se puede trasladar el resultado a otros contextos?

Validez interna vs. externa

- **Validez interna**
  - Se refiere al grado de confianza de que la relación causal que se está probando es confiable y no está influenciada por otros factores o variables.
- **Validez Externa**
  - Se refiere a la medida en que los resultados de un estudio pueden aplicarse (generalizarse) a otras situaciones, grupos o eventos.

Resumen de la Unidad 4

1. Análisis de la propiedad de insesgamiento
2. Formas funcionales, elección de regresores e interpretación de coeficientes
3. Más sobre R^2 y especificación de modelos
4. Predicción y análisis de residuos
5. Multicolinealidad
6. Heterocedasticidad
7. Causalidad, experimentos naturales y validez de los modelos
8. **Resumiendo… con un ejemplo**

Análisis del resultado de la prueba SIMCE Lenguaje de 2do. Medio

EJEMPLO RESUMEN: Modelo para explicar/predecir SIMCE LENGUAJE 2do MEDIO

- Formas funcionales con variables independientes continuas e interpretación de coeficientes
- Formas funcionales con variables independientes discretas e interpretación de coeficientes
- Predicción y construcción de intervalo de predicción
- Test Heteroscedasticidad
- Corrección Heterocedasticidad

Algunas estadísticas descriptivas…

```
. sum SIMCE_2TOT_len_2010 ingpc ive

    Variable |        Obs        Mean    Std. Dev.       Min        Max
-------------+---------------------------------------------------------
SIMCE_2TOT.. |    898,841     254.852    28.09758        168        342
       ingpc |  1,060,162    50984.76    41101.38          0    1375172
         ive |  1,185,090     70.7759    14.38406          0        100
```

```
. tab regco

 region del
establecimi
 ento segun
 directorio
    mineduc
       2006 |      Freq.     Percent        Cum.
------------+-----------------------------------
          1 |     23,952        1.83        1.83
          2 |     43,310        3.31        5.14
          3 |     26,826        2.05        7.18
          4 |     61,371        4.69       11.87
          5 |    129,509        9.89       21.76
          6 |     78,906        6.02       27.78
          7 |     91,203        6.96       34.75
          8 |    182,658       13.95       48.69
          9 |     95,257        7.27       55.97
         10 |     73,465        5.61       61.58
         11 |      9,647        0.74       62.31
         12 |     13,592        1.04       63.35
         13 |    426,710       32.58       95.93
         14 |     34,061        2.60       98.53
         15 |     19,241        1.47      100.00
------------+-----------------------------------
      Total |  1,309,708      100.00
```

```
. tab mujer

      mujer |      Freq.     Percent        Cum.
------------+-----------------------------------
          0 |    666,744       50.91       50.91
          1 |    642,964       49.09      100.00
------------+-----------------------------------
      Total |  1,309,708      100.00
```

```
       muni |      Freq.     Percent        Cum.
------------+-----------------------------------
          0 |    657,017       50.17       50.17
          1 |    652,691       49.83      100.00
------------+-----------------------------------
      Total |  1,309,708      100.00
```

Regresores continuos

VARIABLES	(1) SIMCE_2TOT_len_2010	(2) ln_SIMCE_2TOT_len_2010	(3) SIMCE_2TOT_len_2010
mujer	0.760***	0.00364***	0.809***
	(0.0656)	(0.000262)	(0.0654)
edad	-0.276***	-0.00109***	-0.252***
	(0.0124)	(4.96e-05)	(0.0124)
muni	-4.406***	-0.0199***	-4.612***
	(0.0699)	(0.000279)	(0.0699)
ingpc	-1.16e-05***		-1.33e-05***
	(8.67e-07)		(8.66e-07)
ive	-1.296***	-0.00514***	-2.056***
	(0.00275)	(1.11e-05)	(0.0195)
ln_ingpc		-0.00479***	
		(0.000191)	
ive2			0.00561***
			(0.000142)
Constant	347.2***	5.951***	371.6***
	(0.277)	(0.00250)	(0.678)
Observations	263,311	262,521	263,311
R-squared	0.532	0.528	0.534

- Interpretación general del modelo 1
- ¿Cómo cambia la interpretación del modelo 2 al estar en ln?
- ¿Para qué se incluye el IVE al cuadrado en el modelo 3? ¿cómo se interpreta?

Regresores discretos

	(1)	(2)	(3)
VARIABLES	SIMCE_2TOT_len_2010	SIMCE_2TOT_len_2010	SIMCE_2TOT_len_2010
mujer	0.760***	1.902***	-0.188
	(0.0656)	(0.118)	(0.537)
edad	-0.276***	-1.118***	-1.179***
	(0.0124)	(0.0161)	(0.0220)
muni	-4.406***	-13.53***	-13.44***
	(0.0699)	(0.127)	(0.0915)
ingpc	-1.16e-05***	0.000123***	0.000123***
	(8.67e-07)	(1.06e-06)	(1.06e-06)
ive	-1.296***		
	(0.00275)		
mujer_muni		0.189	
		(0.176)	
mujer_edad			0.129***
			(0.0313)
Constant	347.2***	266.1***	267.1***
	(0.277)	(0.284)	(0.377)
Observations	263,311	285,557	285,557
R-squared	0.532	0.157	0.157

- Interpretación general del modelo 1
- ¿Para que se incluye la interacción de mujer y dependencia? ¿cómo se interpreta? (intercepto)
- ¿Para que se incluye la interacción de mujer y edad? ¿cómo se interpreta? (pendiente)

Predicción e intervalo de confianza de la predicción

Reparametrizar modelo, estimar y construir intervalo de confianza

➨**CASO:**

$$mujer = 1$$
$$edad = 19$$
$$muni = 1$$
$$ingpc = 7500$$
$$ive = 89.85$$

```
.
. gen edad_reparamet=edad-19

. gen ingpc_reparamet=ingpc-7500
(100,824 missing values generated)

. gen ive_reparamet=ive-89.85
(49,459 missing values generated)

. gen mujer_reparamet=mujer-1

. gen muni_reparamet=muni-1

. reg SIMCE_2TOT_len_2010 mujer_reparamet edad_reparamet muni_reparamet ingpc_reparamet ive_reparamet

      Source |       SS           df       MS      Number of obs   =   263,311
-------------+----------------------------------   F(5, 263305)    =  59800.97
       Model |  84572874.2         5  16914574.8   Prob > F        =    0.0000
    Residual |  74475249.5   263,305  282.847836   R-squared       =    0.5317
-------------+----------------------------------   Adj R-squared   =    0.5317
       Total |   159048124   263,310  604.033739   Root MSE        =    16.818

------------------------------------------------------------------------------
SIMCE_2TOT_le~0 |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
----------------+-------------------------------------------------------------
mujer_reparamet |   .7598442   .0656047    11.58   0.000     .6312607    .8884276
 edad_reparamet |  -.2756488   .0123855   -22.26   0.000    -.2999241   -.2513736
 muni_reparamet |  -4.405632   .0698711   -63.05   0.000    -4.542577   -4.268686
ingpc_reparamet |  -.0000116   8.67e-07   -13.41   0.000    -.0000133   -9.93e-06
  ive_reparamet |  -1.295956   .0027479  -471.62   0.000    -1.301341    -1.29057
          _cons |   221.7528   .0727249  3049.20   0.000     221.6103    221.8954
------------------------------------------------------------------------------
```

La única diferencia entre la regresión original y la del modelo reparametrizado es el intercepto, que es la predicción que se busca, junto con su error estándar.

$$\hat{\theta} = 221.7528$$
$$sd(\hat{\theta}) = 0.0727249$$
$$IC = \hat{\theta} \pm vc_t \cdot \sqrt{Var(\hat{\theta})}$$
$$IC = [221.61, 221.9]$$

Test de heterocedasticidad con comando Stata

```
. reg ln_SIMCE_2TOT_len_2010 mujer edad muni ln_ingpc ive

      Source |       SS           df       MS      Number of obs   =   262,521
-------------+----------------------------------   F(5, 262515)    =  58674.23
       Model |  1323.5053         5  264.70106    Prob > F        =    0.0000
    Residual |  1184.3019   262,515  .004511368   R-squared       =    0.5278
-------------+----------------------------------   Adj R-squared   =    0.5277
       Total |  2507.8072   262,520  .009552823   Root MSE        =    .06717

------------------------------------------------------------------------------
ln_SIMC~2010 |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
       mujer |   .0036403   .0002624    13.87   0.000      .003126    .0041546
        edad |  -.0010863   .0000496   -21.92   0.000    -.0011834   -.0009891
        muni |  -.0199024   .0002795   -71.21   0.000    -.0204502   -.0193546
    ln_ingpc |  -.0047874   .0001913   -25.02   0.000    -.0051624   -.0044125
         ive |  -.0051364   .0000111  -464.62   0.000    -.0051581   -.0051147
       _cons |   5.950672   .0024971  2382.99   0.000     5.945777    5.955566
------------------------------------------------------------------------------

. estat hettest mujer edad muni ln_ingpc ive, fstat

Breusch-Pagan / Cook-Weisberg test for heteroskedasticity
         Ho: Constant variance
         Variables: mujer edad muni ln_ingpc ive

         F(5 , 262515)=   401.73
         Prob > F     =   0.0000
```

Test de heterocedasticidad manual

```
. reg ln_SIMCE_2TOT_len_2010 mujer edad muni ln_ingpc ive

      Source |       SS           df       MS      Number of obs   =   262,521
-------------+----------------------------------   F(5, 262515)    =  58674.23
       Model |  1323.5053         5  264.70106    Prob > F        =    0.0000
    Residual |  1184.3019   262,515  .004511368   R-squared       =    0.5278
-------------+----------------------------------   Adj R-squared   =    0.5277
       Total |  2507.8072   262,520  .009552823   Root MSE        =    .06717

------------------------------------------------------------------------------
ln_SIMC~2010 |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
       mujer |   .0036403   .0002624    13.87   0.000      .003126    .0041546
        edad |  -.0010863   .0000496   -21.92   0.000    -.0011834   -.0009891
        muni |  -.0199024   .0002795   -71.21   0.000    -.0204502   -.0193546
    ln_ingpc |  -.0047874   .0001913   -25.02   0.000    -.0051624   -.0044125
         ive |  -.0051364   .0000111  -464.62   0.000    -.0051581   -.0051147
       _cons |   5.950672   .0024971  2382.99   0.000     5.945777    5.955566
------------------------------------------------------------------------------

. predict u, r
(213,261 missing values generated)

. gen u2=u*u
(213,261 missing values generated)

. reg u2 mujer edad muni ln_ingpc ive

      Source |       SS           df       MS      Number of obs   =   262,521
-------------+----------------------------------   F(5, 262515)    =    401.73
       Model |  .09060469         5  .018120938   Prob > F        =    0.0000
    Residual |  11.8412302   262,515  .000045107   R-squared       =    0.0076
-------------+----------------------------------   Adj R-squared   =    0.0076
       Total |  11.9318349   262,520  .000045451   Root MSE        =    .00672

------------------------------------------------------------------------------
          u2 |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
       mujer |    -.00046   .0000262   -17.53   0.000    -.0005114   -.0004085
        edad |   .0000174   4.96e-06     3.50   0.000     7.64e-06    .0000271
        muni |   .0008341   .0000279    29.85   0.000     .0007794    .0008889
    ln_ingpc |   .0002742   .0000191    14.33   0.000     .0002367    .0003117
         ive |  -.0000275   1.11e-06   -24.88   0.000    -.0000297   -.0000253
       _cons |   .0031196   .0002497    12.49   0.000     .0026302     .003609
------------------------------------------------------------------------------
```

Corrección de heterocedasticidad: errores robustos

```
. reg ln_SIMCE_2TOT_len_2010 mujer edad muni ln_ingpc ive

      Source |       SS           df       MS      Number of obs   =   262,521
-------------+----------------------------------   F(5, 262515)    =  58674.23
       Model |  1323.5053         5  264.70106    Prob > F        =    0.0000
    Residual |  1184.3019   262,515  .004511368   R-squared       =    0.5278
-------------+----------------------------------   Adj R-squared   =    0.5277
       Total |  2507.8072   262,520  .009552823   Root MSE        =    .06717

------------------------------------------------------------------------------
ln_SIMC~2010 |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
       mujer |   .0036403   .0002624    13.87   0.000      .003126    .0041546
        edad |  -.0010863   .0000496   -21.92   0.000    -.0011834   -.0009891
        muni |  -.0199024   .0002795   -71.21   0.000    -.0204502   -.0193546
    ln_ingpc |  -.0047874   .0001913   -25.02   0.000    -.0051624   -.0044125
         ive |  -.0051364   .0000111  -464.62   0.000    -.0051581   -.0051147
       _cons |   5.950672   .0024971  2382.99   0.000     5.945777    5.955566
------------------------------------------------------------------------------

. reg ln_SIMCE_2TOT_len_2010 mujer edad muni ln_ingpc ive, robust

Linear regression                               Number of obs     =    262,521
                                                F(5, 262515)      =   55794.43
                                                Prob > F          =     0.0000
                                                R-squared         =     0.5278
                                                Root MSE          =     .06717

------------------------------------------------------------------------------
             |               Robust
ln_SIMC~2010 |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
       mujer |   .0036403   .0002627    13.86   0.000     .0031254    .0041551
        edad |  -.0010863   .0000491   -22.14   0.000    -.0011824   -.0009901
        muni |  -.0199024   .0002939   -67.71   0.000    -.0204785   -.0193263
    ln_ingpc |  -.0047874   .0001946   -24.60   0.000    -.0051689   -.0044059
         ive |  -.0051364   .0000127  -405.45   0.000    -.0051612   -.0051116
       _cons |   5.950672   .0025712  2314.38   0.000     5.945632    5.955711
------------------------------------------------------------------------------
```

Otras preguntas interesantes…

- R^2 y R^2_{Ajus}
- Chequeo de especificación del modelo
- Restricciones lineales simples (test t)
- Restricciones lineales múltiples (test F)
- Análisis de modelos anidados y no anidados
- Estimación mediante MCG (corrección de heterocedasticidad)
- **MUCHOS, PERO MUCHOS ETC…!**

Nivel de significación, valor p y α

- El **nivel** de significación es comúnmente representado por el símbolo griego **α** (alfa). Son comunes los niveles de significación del 0.05, 0.01 y 0.001. Si un contraste de hipótesis proporciona un **valor p** inferior a **α**, la hipótesis nula es rechazada, siendo tal resultado denominado estadísticamente significativo.
- El **nivel de significación** de una prueba estadística es un concepto estadístico asociado a la verificación de una hipótesis. En pocas palabras, se define como la probabilidad de tomar la decisión de rechazar la hipótesis nula cuando ésta es verdadera (decisión conocida como error de tipo I, o falso positivo).