# Econometría I

Prof. Carlos Briceño Sotelo

**UNIDAD 5:** Modelos de elección discreta

# Resumen de la Unidad 5

# Resumen de la Unidad 5

1. Una variable explicada binaria: el modelo de probabilidad lineal
2. Modelos Logit y Probit
3. Interpretación y predicción
4. Más acerca del análisis de políticas y evaluación de programas

# Resumen de la Unidad 5

1. **Una variable explicada binaria: el modelo de probabilidad lineal**
2. Modelos Logit y Probit
3. Interpretación y predicción
4. Más acerca del análisis de políticas y evaluación de programas

# Modelo de Probabilidad Lineal

- En las clases anteriores, vimos cómo incorporar **información cualitativa** al modelo de regresión múltiple en forma de **regresores dicotómicos** (variables binarias).

- En todos los modelos vistos hasta ahora, la variable explicada ha tenido un significado cuantitativo (por ejemplo, $y_i$ ha sido notas, ventas, ingreso, peso, etc.).

# Modelo de Probabilidad Lineal

- **¿Qué ocurre cuando se desea usar la regresión múltiple para explicar eventos cualitativos?**
- En el caso más sencillo (y bastante habitual), el evento que se desea explicar tiene un **resultado binario**.
- En otras palabras, la variable $y_i$ sólo toma dos valores: $0$ ó $1$.

# Modelo de Probabilidad Lineal

- Sea el modelo:

$$y_i = \alpha + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \cdots + \beta_k x_k + u_i$$

- Ejemplos de **"$y$" cualitativa**: terminó educación secundaria o no, fue madre adolescente o no, trabaja o no, ha recibido capacitación laboral o no, etc.

# Modelo de Probabilidad Lineal

- Como $y_i$ sólo puede tomar dos valores $(0/1)$, las $\boldsymbol{\beta_j}$ no pueden interpretarse como el cambio en $y_i$ para un aumento de$x_j$, permaneciendo constantes todos los demás factores: $y_i$ cambia de uno a cero, o de cero a uno (o no cambia).

- A pesar de esto, las $\boldsymbol{\beta_j}$ siguen teniendo una interpretación útil.

# Modelo de Probabilidad Lineal

- Si asumimos que se cumple el Supuesto 4 del Modelo Lineal Clásico, es decir, que se satisface que la media condicional de los residuos es cero, entonces:

$$Supuesto\ 4:\ \ E(u|x_1, x_2, x_3, \dots, x_k) = 0$$

$$\therefore\ \boldsymbol{E(y|x_1, x_2, x_3, \dots, x_k) = \alpha + \widehat{\beta_1}x_1 + \widehat{\beta_2}x_2 + \widehat{\beta_3}x_3 + \cdots + \widehat{\beta_k}x_k}$$

- Nótese que cuando $y_i$ es una variable binaria que toma los valores $0/1$, entonces se tiene siempre que:

$$\mathbf{Pr}(\boldsymbol{y = 1|X) = E(y|X) = \alpha + \widehat{\beta_1}x_1 + \widehat{\beta_2}x_2 + \widehat{\beta_3}x_3 + \cdots + \widehat{\beta_k}x_k}$$

# Modelo de Probabilidad Lineal

- Esta importante ecuación dice que **la probabilidad de éxito, es decir, $\mathbf{Pr}(\boldsymbol{X}) = \mathbf{Pr}(\boldsymbol{y} = \mathbf{1}|\boldsymbol{X})$, es función lineal de las variables $x_j$.**

- A esta probabilidad también se la conoce como la **"probabilidad de respuesta".**

- Dado que las probabilidades deben sumar uno, $\mathbf{Pr}(\boldsymbol{y} = \mathbf{0}|\boldsymbol{X}) = 1 - \mathbf{Pr}(\boldsymbol{y} = \mathbf{1}|\boldsymbol{X})$ también es una función lineal de las$x_j$.

# Modelo de Probabilidad Lineal

$$\mathbf{Pr}(\boldsymbol{y} = \mathbf{1}|\boldsymbol{X}) = \boldsymbol{E}(\boldsymbol{y}|\boldsymbol{X}) = \boldsymbol{\alpha} + \widehat{\boldsymbol{\beta}_1}\boldsymbol{x}_1 + \widehat{\boldsymbol{\beta}_2}\boldsymbol{x}_2 + \widehat{\boldsymbol{\beta}_3}\boldsymbol{x}_3 + \cdots + \widehat{\boldsymbol{\beta}_k}\boldsymbol{x}_k$$

- La variable explicada distribuye Bernoulli, con $k = 2$ valores posibles, y probabilidad $p$:

$$y \sim Bernoulli(k, p) = f(k, p) = \begin{cases} p & si\ k = 1 \\ q = 1 - p & si\ k = 0 \end{cases}$$

# Modelo de Probabilidad Lineal

- **Propiedades de las variables aleatorias Bernoulli:**

Si **Pr**$(\boldsymbol{y} = \mathbf{1}|\boldsymbol{X})$**=Pr**$(\boldsymbol{X})$, entonces:

1. $\Pr(y = 0|X) = 1 - \Pr(y = 1|X) = 1 - \Pr(X)$
2. $E(y|X) = \Pr(X)$
3. $Var(y|X) = \Pr(y = 1|X) \cdot [1 - \Pr(y = 1|X)]$, es decir, el **modelo siempre es heterocedástico**

# Modelo de Probabilidad Lineal

- A un modelo de regresión lineal múltiple en el que la variable dependiente es una variable binaria se le conoce como **modelo de probabilidad lineal (MPL),** debido a que la probabilidad de respuesta es lineal en los parámetros $\boldsymbol{\beta_j}$.

- **En el MPL, $\boldsymbol{\beta_j}$ mide la variación de la probabilidad de éxito al variar $\boldsymbol{x_j}$, permaneciendo todos los demás factores constantes.**

- Esto implica que, para interpretar las estimaciones, se debe recordar que una variación en el regresor $x_j$ modifica la probabilidad de que $y = 1$

# Modelo de Probabilidad Lineal: Ejemplo

## Modelo predictivo de la aprobación escolar

- Por ejemplo, el coeficiente de edad significa que un año más de edad hace que la probabilidad de aprobar el curso disminuya en 0.0054 (o 0,54%).

```
. reg aprueba mujer edad ive

      Source |       SS           df       MS      Number of obs   =   900,752
-------------+----------------------------------   F(3, 900748)    =   3658.25
       Model |  653.316574         3  217.772191   Prob > F        =    0.0000
    Residual |  53620.7382   900,748  .059529123   R-squared       =    0.0120
-------------+----------------------------------   Adj R-squared   =    0.0120
       Total |  54274.0548   900,751  .060254227   Root MSE        =    .24399

------------------------------------------------------------------------------
     aprueba |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
       mujer |   .0239721   .0005146    46.58   0.000     .0229634    .0249807
        edad |  -.0053654   .0000768   -69.86   0.000    -.0055159   -.0052149
         ive |  -.0010762   .0000179   -60.27   0.000    -.0011112   -.0010412
       _cons |   1.075265   .0016805   639.83   0.000     1.071971    1.078559
------------------------------------------------------------------------------
```

# Modelo de Probabilidad Lineal: Ejemplo

**Modelo de otorgamiento de crédito hipotecario**

- Los bancos analizan la relación entre rechazar/aceptar el crédito (variable binaria) y la razón entre pagos mensuales del préstamo y sus ingresos mensuales (variable continua)

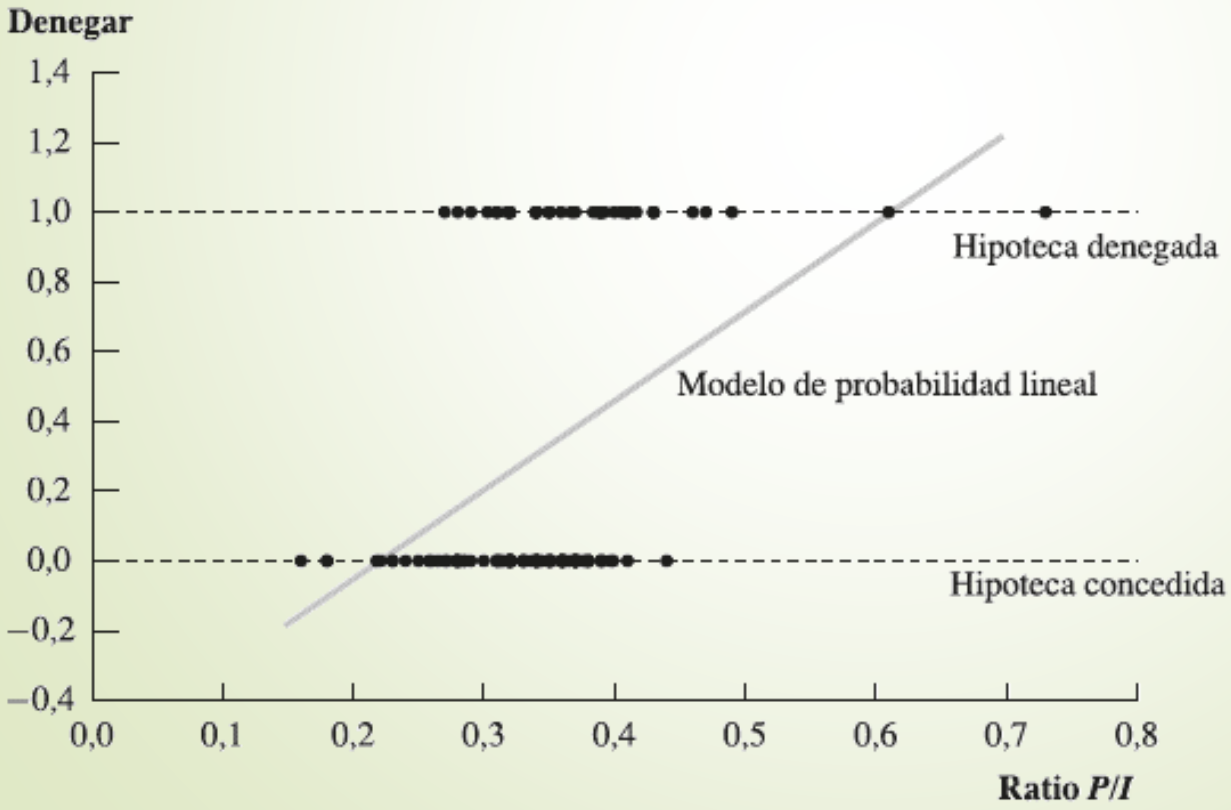


**Conclusión:** la mayoría de los solicitantes a quienes se les rechaza el crédito, han tenido una proporción de pagos/ingresos mayor a 0.3. **¡RARO!**

# Modelo de Probabilidad Lineal: Problemas

- El ejemplo anterior muestra lo fácil que es estimar e interpretar los modelos de probabilidad lineal, pero también pone de manifiesto **algunas desventajas** del MPL.

- Primero, es fácil ver que si en la ecuación anterior se sustituyen ciertas combinaciones de valores de los regresores, se pueden obtener **predicciones menores a cero o mayores a uno**.

# Modelo de Probabilidad Lineal: Problemas

- Otro problema es que la probabilidad no puede estar relacionada en forma lineal con los regresores para todos sus valores posibles: **puede salirse del rango entre 0 y 1.**

- **El $R^2$ ya no tiene sentido.**

- A pesar de estos problemas, el MPL es útil y suele emplearse con frecuencia en economía. Por lo general, este modelo funciona bien con valores de las variables independientes que estén cerca de los promedios en la muestra.

# Modelo de Probabilidad Lineal: Problemas

- **Soluciones a los problemas de rango:**
  - Se pueden utilizar las probabilidades estimadas mediante MPL para predecir un resultado cero o uno.
  - Defínase un valor predicho como

$$\tilde{y}_i = \begin{cases} 1 & si\ \hat{y}_i \geq 0.5 \\ 0 & si\ \hat{y}_i < 0.5 \end{cases}$$

# Modelo de Probabilidad Lineal: Problemas

- **Soluciones a los problemas de rango:**
  - Con los datos de las $y_i$ y las $\tilde{y}_i$ se pueden obtener las frecuencias con las que se preciden correctamente $y_i = 1$ e $y_i = 0$.
  - Este **porcentaje predicho correctamente** funciona como una medida de "bondad de ajuste"
- **Alternativa: modelos paramétricos no lineales, estimados mediante máxima verosimilitud, por ejemplo, Probit y Logit.**

# Resumen de la Unidad 5

1. Una variable explicada binaria: el modelo de probabilidad lineal
2. **Modelos Logit y Probit**
3. Interpretación y predicción
4. Más acerca del análisis de políticas y evaluación de programas

# Modelos de Elección Discreta: Motivación

- Para evitar las limitaciones del MPL, consideremos una clase de modelos de respuesta binaria de la forma:

$$\begin{aligned}\Pr(\boldsymbol{y} = \mathbf{1}|\boldsymbol{X}) &= \boldsymbol{G}(\boldsymbol{\alpha} + \boldsymbol{\beta}_1\boldsymbol{x}_1 + \boldsymbol{\beta}_2\boldsymbol{x}_2 + \boldsymbol{\beta}_3\boldsymbol{x}_3 + \cdots + \boldsymbol{\beta}_k\boldsymbol{x}_k) \\ &= \boldsymbol{G}(\boldsymbol{\alpha} + \boldsymbol{X}\boldsymbol{\beta})\end{aligned}$$

  donde $G(\cdot)$ es una función que asume valores estrictamente entre cero y uno, $0 \leq G(z) \leq 1$, para todos los números reales $z$.

- **Esto asegura que las probabilidades de respuesta estimada estén estrictamente entre cero y uno.**

# Modelos de Elección Discreta: Especificación

- Se han sugerido varias formas funcionales no lineales para $G(\cdot)$, con la finalidad de asegurar que las probabilidades estén entre cero y uno:
  - **Modelo Probit**: $G(\cdot)$ es la FDA normal estándar:

$$\boldsymbol{G(z) = \Phi(z) = \int_{-\infty}^{z} \phi(v)dv}$$

$$\text{con } \phi(z) = (2\pi)^{-1/2} \exp\left(-\frac{z^2}{2}\right)$$

  - **Modelo Logit**: $G(\cdot)$ es la FDA logística:

$$\boldsymbol{G(z) = \Lambda(z) = \frac{\exp(z)}{1 + \exp(z)} = \frac{1}{1 + \exp(-z)}}$$

- En análisis económico, suele ser más popular el modelo **Probit**, fundado en el supuesto de normalidad del error. Sin embargo, es un modelo que puede presentar problemas importantes en ciertos contextos.

# Modelos de Elección Discreta: Estimación

- **¿Cómo se deben estimar los modelos no lineales de respuesta binaria?**
- Para estimar los MPL, se pueden usar MCO o, en algunos casos, MCG. Sin embargo, debido a la naturaleza no lineal de $E(y|x)$, MCO y MCG no son aplicables.
- **Nueva metodología: Estimación por máxima verosimilitud (EMV)** (véase Wooldridge, 2010, Apéndice 17.A, para un breve análisis).
- Para estimar los modelos de variables explicadas limitadas, los Métodos de Máxima Verosimilitud son indispensables.
- **En este curso, sólo se usarán los resultados. Aplicar los modelos Logit y Probit es sencillo, siempre y cuando se comprenda lo que significan los estadísticos!**

# Estimadores de Máxima Verosimilitud (EMV)

- Sea $f(y|x,\beta)$ la función de densidad para una extracción aleatoria $y_i$ de la población, condicional en $\boldsymbol{x_i} = \boldsymbol{x}$.
- La **función de verosimilitud** es la distribución de probabilidad conjunta de los datos, y está dada por:

$$L(\beta, y_1, y_2, \dots, y_n) = f(y_1|x_1,\beta) \cdot f(y_2|x_2,\beta) \cdot \cdots \cdot f(y_n|x_n,\beta)$$

- que depende del conjunto de parámetros $\beta$, desconocidos.
- El **estimador de máxima verosimilitud (EMV)** corresponde a los valores de los parámetros $\beta$ que maximiza el valor de la función de verosimilitud o su logaritmo.
- La teoría general de EMV para muestras aleatorias implica que, bajo condiciones muy generales, **el EMV es consistente, asintóticamente normal y asintóticamente eficiente**.

# Estimadores de Máxima Verosimilitud (EMV)

- Para el caso de respuesta binaria (**logit y probit**), la densidad condicional se determina por dos valores:

$$f(1|x,\beta) = \Pr(y_i = 1|x_i) = G(x_i\beta)$$
$$f(0|x,\beta) = \Pr(y_i = 0|x_i) = 1 - G(x_i\beta)$$

- La densidad conjunta se puede escribir también como

$$f(y|x,\beta) = [G(x_i\beta)]^y \cdot [1 - G(x_i\beta)]^{(1-y)} \quad \forall \ y = 0,1$$

- Por lo tanto, el Estimador de Máxima Verosimilitud se obtiene como la solución al problema:

$$\max_{\{\hat{\beta}\}} \log L(\beta, y) = \sum_{i=1}^{n} \left\{(1 - y_i)\log\left[1 - G\left(x_i\hat{\beta}\right)\right] + y_i \log\left[G\left(x_i\hat{\beta}\right)\right]\right\}$$

- La solución se obtiene mediante <u>métodos numéricos</u>.

# Modelos de Elección Discreta: Ejemplos

**Modelo de otorgamiento de crédito hipotecario**

- Ajuste de modelo Logit y Probit para la respuesta discreta de otorgamiento de crédito hipotecario en función del ratio Pago/Ingreso.

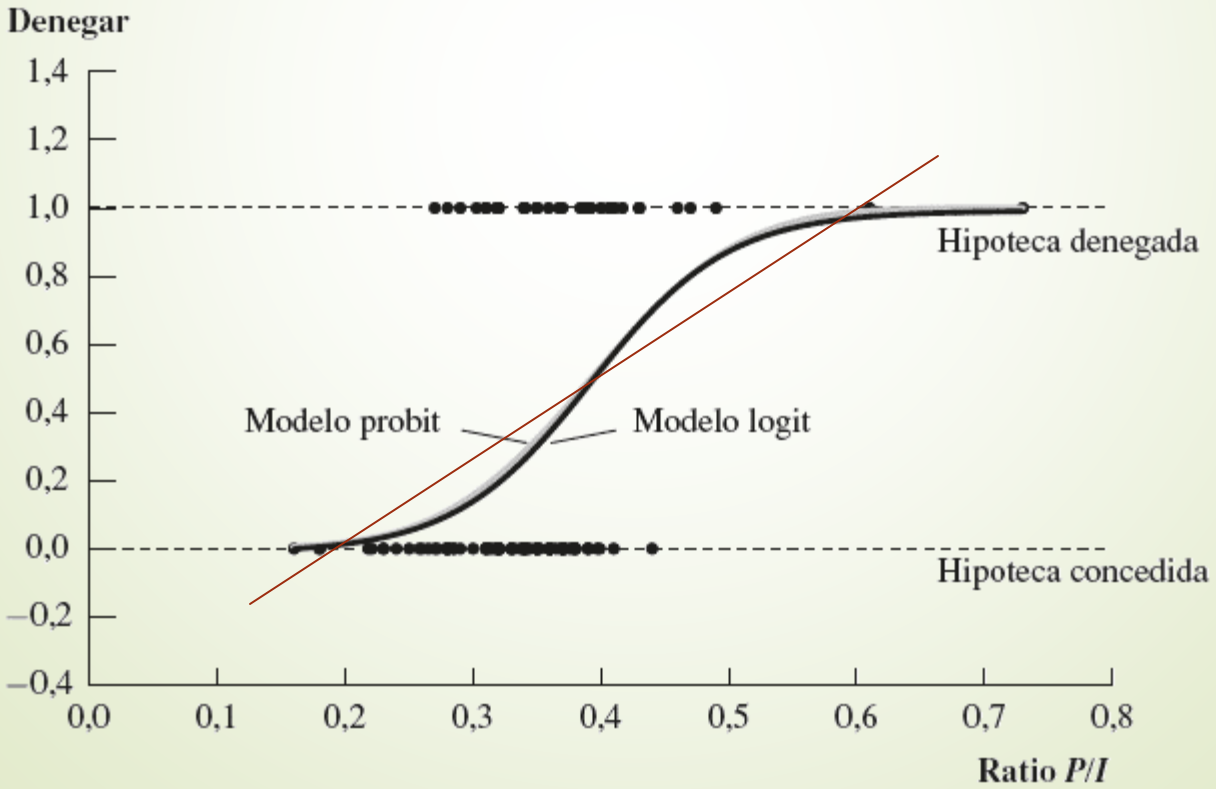

# 3. Interpretación y Predicción

# Interpretación de Logit y Probit

- En la mayoría de las aplicaciones de los modelos de respuesta binaria, la meta principal es explicar los efectos de las $\boldsymbol{x_j}$ sobre la probabilidad de respuesta $\Pr(y = 1|x)$
- Las magnitudes de cada $\boldsymbol{\beta_j}$ no son, por sí mismas, especialmente útiles en estos modelos (en contraste con el modelo de probabilidad lineal).
- **Al ser $G(\cdot)$ una función no lineal, los coeficientes NO corresponden a efectos marginales.**
- **Los efectos marginales varían según los valores que tomen las $x_j$**
- **Los coeficientes, sin embargo, tienen el mismo signo que los efectos marginales** ($G(\cdot)$ es siempre mayor o igual a 0)

# Interpretación de Logit y Probit

- **¿Cómo se obtienen los efectos marginales?**
- Para hallar el efecto parcial de las variables (aproximadamente) continuas sobre la probabilidad de respuesta, es necesario recurrir al cálculo.
- Al ser $G(\cdot)$ una función no lineal, tenemos:

$$\left.\frac{\partial Pr(Y_i = 1|X_i)}{\partial X_{ik}}\right|_{X_0} = \left.\frac{\partial G(X_i'\beta)}{\partial X_{ik}}\right|_{X_0} = g(X_0'\beta) \cdot \beta_k$$

donde $g(\cdot)$ es la función de densidad asociada a $G(\cdot)$

# Modelos de Elección Discreta: Ejemplos

**Modelo predictivo de la aprobación escolar**

¿Cómo se interpretan los coeficientes de los Modelos 2 (probit) y 3 (logit)?

| | (M1:MPL) | (M2: Probit) | (M3: Logit) |
|---|---|---|---|
| **VARIABLES** | **aprueba** | **aprueba** | **aprueba** |
| | | | |
| mujer | 0.0947*** | 0.257*** | 0.419*** |
| | (0.00274) | (0.00748) | (0.0122) |
| edad | -0.0347*** | -0.0950*** | -0.156*** |
| | (0.000444) | (0.00124) | (0.00208) |
| ive | -0.00401*** | -0.0111*** | -0.0181*** |
| | (9.79e-05) | (0.000271) | (0.000446) |
| carencia | 0.0301*** | 0.0862*** | 0.138*** |
| | (0.00291) | (0.00795) | (0.0129) |
| Constant | 1.262*** | 2.092*** | 3.428*** |
| | (0.0104) | (0.0292) | (0.0487) |
| | | | |
| Observations | 121,577 | 121,577 | 121,577 |
| R-squared | 0.0735 | | |
| Pseudo R2 | | 0.0566 | 0.0566 |

# 4. Análisis de políticas públicas y evaluación de programas

# Evaluación de programas y políticas públicas

- **¿Cómo podemos usar lo aprendido para hacer evaluación de políticas públicas?**
- Ejemplo: **Evaluación de Impacto de la utilización de medidas de adaptación hídrica en el sector agrícola.** Estudio de adaptación a la restricción de recursos hídricos en Chile. Diciembre de 2017.
- Pero antes… ¿qué es una evaluación de impacto?
- Las **evaluaciones de impacto** permiten dimensionar la magnitud del efecto de un programa y conocer estadísticamente la incertidumbre sobre dicha estimación. Este proceso genera evidencia robusta sobre qué programas funcionan, qué programas no lo hacen y cómo mejorarlos para optimizar los resultados en materia de desarrollo.

# Evaluación de impacto

- En la identificación de las **relaciones de causa-efecto entre el programa y los resultados obtenidos**, pueden existir otros factores que ocurren durante el periodo de intervención que están correlacionados con los resultados y que no han sido causados por el programa.
- Se intenta establecer la diferencia, en alguna variable que se ha escogido como indicador de resultados del programa, entre la situación que presenta un individuo (o el cambio en ésta) después de haber participado en un programa, versus la situación en que se encontraría (o el cambio en ésta) si no hubiese sido beneficiario (estado **contrafactual**)

# Evaluación de impacto

- **Impacto**: diferencia en la variable de resultado ($Y$) que registra el individuo ($i$) con y sin la intervención del programa:

$$\alpha = Y_{1i} - Y_{0i}$$

  Donde $Y_{1i}$ es el resultado al haber recibido la intervención, e $Y_{0i}$ es el resultado si no se recibe la intervención.

- **Problema de identificación**: en la realidad, para un mismo individuo, sólo se observa uno de los dos resultados, $Y_{1i}$ ó $Y_{0i}$, porque sólo se observa uno de los dos estados de la naturaleza: **recibir o no recibir tratamiento** (intervención del programa)

# Evaluación de impacto

**¿Cuál es el resultado "real" de un programa sobre los beneficiarios?**

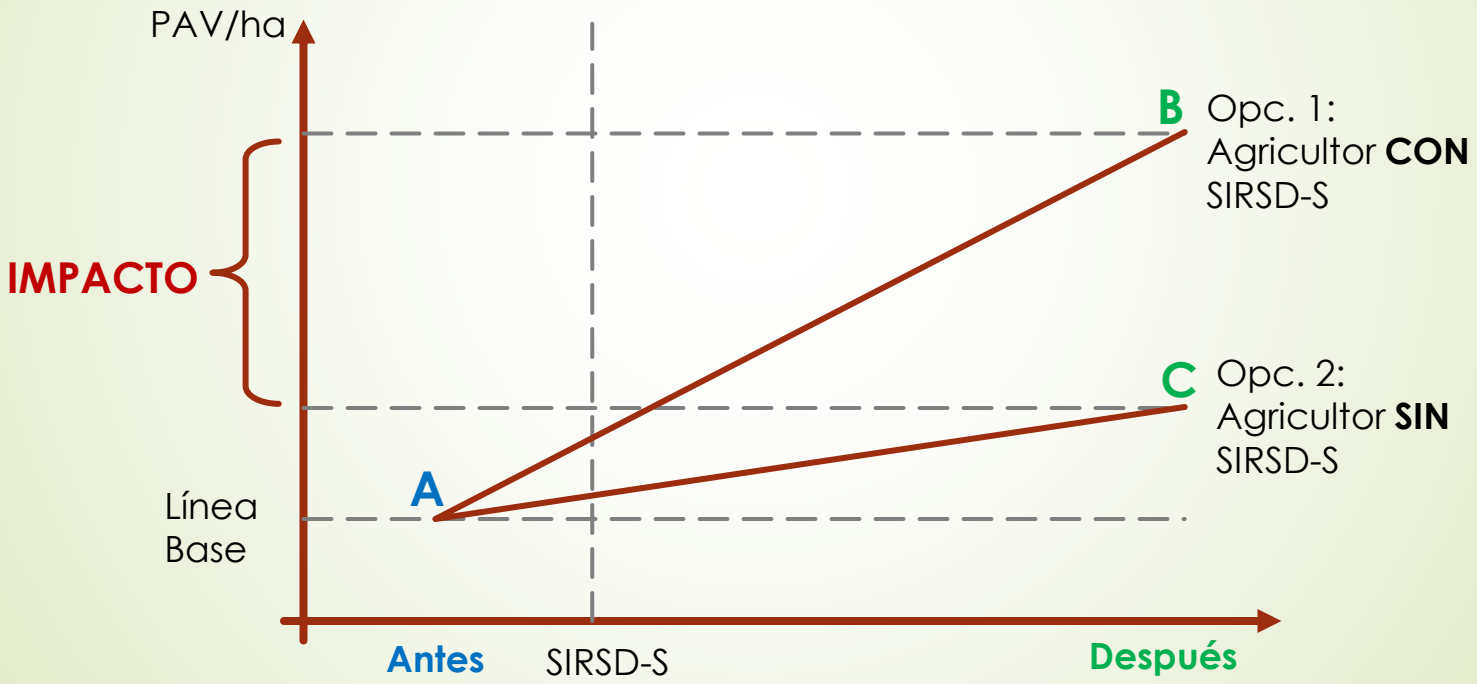

# Evaluación de impacto

- ¿Qué pasa si medimos el impacto esperado o promedio sobre un conjunto de individuos (participantes o no)?
- **Sesgo de selección:** los individuos que participan en un programa son distintos a los que no participan. Hay diferencias sistemáticas entre las características de aquellos que participan y no participan que afectan el resultado y la estimación de éstos.
- **¿Qué podemos hacer entonces?**
- Ese es el objetivo de la evaluación de impacto, y para eso existen distintas metodologías!

# Evaluación de impacto

- **Ante la imposibilidad de observar el contrafactual** (mismo individuo pero sin recibir el tratamiento), se debe construir una muestra que sirva para estos efectos:
  - **Diseño experimental:** Se asigna aleatoriamente a los beneficiarios y controles. Esto permitiría que los atributos de los individuos de ambas muestras (pre-tratamiento), sean, en promedio, iguales.
  - **Diseño cuasi-experimental:** Cuando los grupos de tratamiento y control no se pueden construir aleatoriamente, se recurren a distintos mecanismos que propenden a lograr esta igualdad de medias, pre-tratamiento, entre los atributos de los integrantes de estos grupos (*matching*, variables instrumentales, regresión discontinua)

# Evaluación de impacto: Ejemplo ODEPA

- Se desarrolla una evaluación del efecto (impacto) de la adopción de medidas contra la disminución de disponibilidad hídrica sobre la producción agrícola.
- Para evaluar el impacto de la implementación de medidas de adaptación de los agricultores para hacer frente a los problemas de disponibilidad de agua para riego, idealmente, se requeriría contar con 2 grupos de predios idénticos en todas sus variables (L, K, T, disponibilidad hídrica, ubicación geográfica, especie, características individuales del agricultor y su capacidad de gestión del predio, etc.), uno de los cuales utilice medida de adaptación y el otro no.
- **Sesgo de selección!!!**

https://www.odepa.gob.cl/seccion-destacados/estudio-de-adaptacion-la-restriccion-de-recursos-hidricos-en-chile-diciembre-de-2017

# Evaluación de impacto: Ejemplo ODEPA

- Alto grado de auto-focalización, ya que cada agricultor decide voluntariamente si adoptar o no una o más de las diferentes medidas de adaptación.
- Esto podría, en principio, generar un sesgo de selección entre los individuos que adoptan alguna(s) medida(s) de adaptación y aquellos que no, con atributos observables y/o no observables que los tornan en individuos y predios "diferentes", y por tanto no comparables de manera directa.
- En las evaluaciones de impacto a programas gubernamentales, esto es equivalente a aquellos programas voluntarios, donde, para encontrar el impacto sobre los beneficiarios debe revisarse la necesidad de corregir el sesgo de selección asociado.
- **¿Solución?**

# Evaluación de impacto: Ejemplo ODEPA

- Si la selección está basada en características observables es posible hacer uso de métodos de **pareamiento (*matching*) basado en el *propensity score*** o en las mismas características observables. Incluso es posible en algunos casos utilizar métodos de regresión para ajustar por diferencias entre las características observables de tratados y controles.
- **Paso 1:** Buscar individuos similares en todas las características que no sean el efecto del programa que se quiere evaluar (eliminar el sesgo de selección): **ecuación de participación (Probit)**
- **Paso 2:** Estimar el impacto del Programa en ausencia de sesgo de selección.

# Evaluación de impacto: Ejemplo ODEPA

- **Paso 1: Controlar sesgo de autoselección (*self-selection bias*)**
- Responde a la pregunta: **¿de qué depende que alguien decida utilizar una medida adaptativa?**
- Basado en este criterio, se buscan **agricultores que sean iguales en todo, excepto en utilizar la medida adaptativa.**
- **Esta estrategia elimina el sesgo de auto-selección y permite medir el impacto "real" de la política pública**

| VARIABLES | (1)<br>med1_2016 |
|---|---|
| med1_2012 | 1.293*** |
| | (0.188) |
| educ | 0.373*** |
| | (0.109) |
| P21_superficie_c_2012 | 0.0163 |
| | (0.0108) |
| P21_tract_2012 | 0.0627 |
| | (0.0793) |
| especie | 0.192*** |
| | (0.0675) |
| Constant | -1.396*** |
| | (0.409) |
| Observations | 376 |

Standard errors in parentheses
*** p<0.01, ** p<0.05, * p<0.1

# Evaluación de impacto: Ejemplo ODEPA

**¿Cómo se determina el Grupo de Control?**

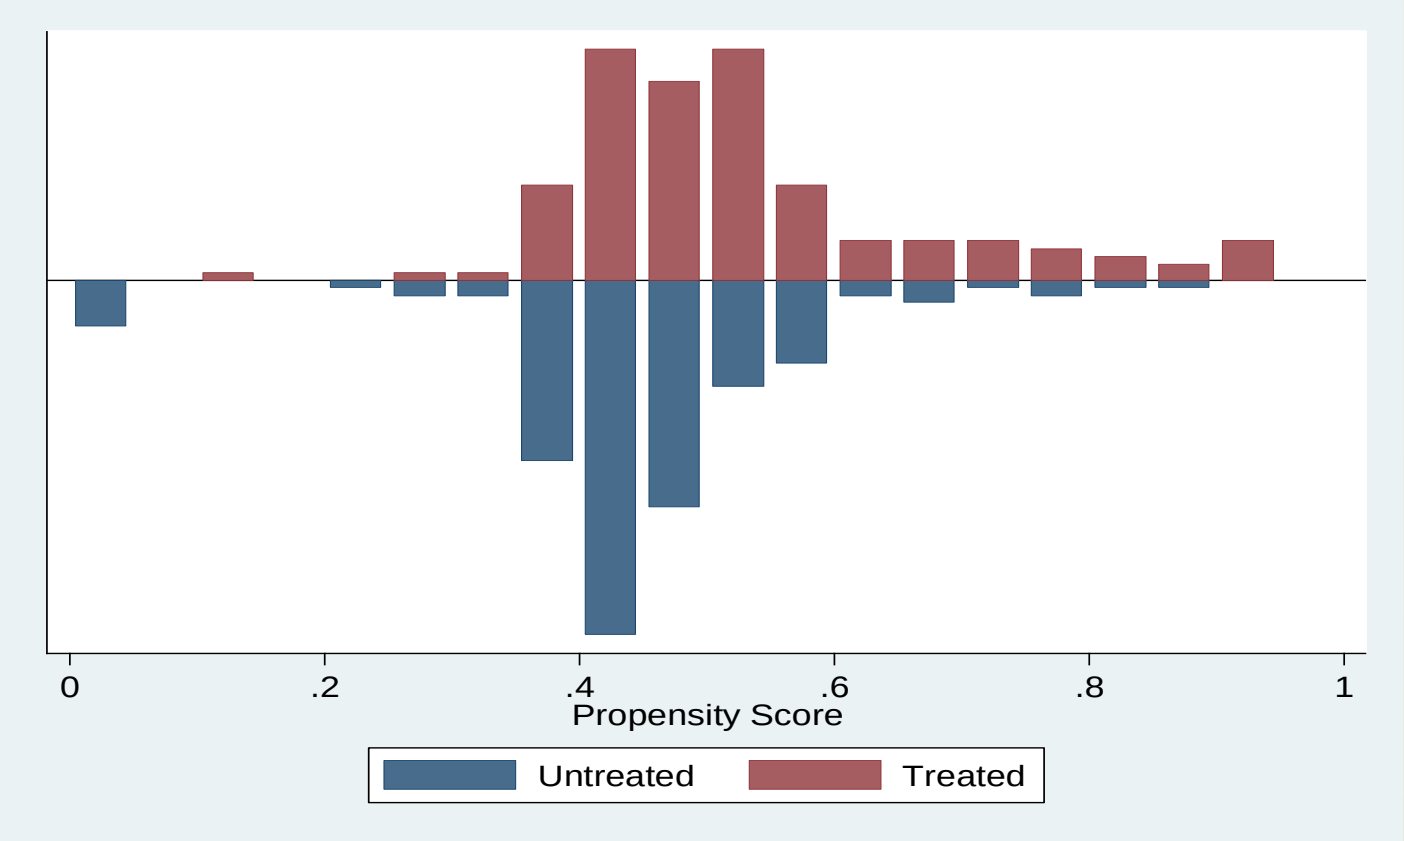

# Evaluación de impacto: Ejemplo ODEPA

- **Paso 2: Medir el impacto**
- En base a este análisis, NO hay un impacto estadísticamente significativo de la adopción de medidas de adaptación sobre el ingreso del predio agrícola (todas las variables en negrita son no significativas al 95%)

| VARIABLES | (1)<br>dif_ing | (2)<br>dif_ln_ing | (3)<br>dif_ing |
|---|---|---|---|
| **intmed1_2016** | **2.763e+07** | **0.0790** | **4.261e+06** |
| | **(2.162e+07)** | **(0.0725)** | **(2.205e+07)** |
| **intmed2_2016** | **-4.056e+06** | **-0.0333** | **-5.537e+06** |
| | **(2.193e+07)** | **(0.0749)** | **(2.163e+07)** |
| **intmed3_2016** | **-4.855e+07*** | **-0.102** | **-4.188e+07** |
| | **(2.736e+07)** | **(0.0923)** | **(2.728e+07)** |
| P21_superficie_c_2016 | | | 657,790 |
| | | | (399,555) |
| P21_tract_2016 | | | 2.935e+07** |
| | | | (1.247e+07) |
| P23C_DERECHOS_DE_AGUA | | | 0.434* |
| | | | (0.247) |
| Constant | 1.888e+07 | -0.00753 | -6.447e+06 |
| | (5.325e+07) | (0.177) | (5.278e+07) |
| Observations | 284 | 239 | 284 |
| R-squared | 0.016 | 0.010 | 0.076 |

Standard errors in parentheses
*** p<0.01, ** p<0.05, * p<0.1