Econometría I

Prof. Carlos Briceño Sotelo

Universidad Adolfo Ibañez

UNIDAD 6: Introducción a Big Data y Machine Learning

Resumen de la Unidad 6

Resumen de la Unidad 6

1. Big Data y análisis económico
2. Machine Learning: conceptos, aplicaciones
3. Machine Learning versus Econometría
4. Algoritmos más habituales en Machine Learning

Resumen de la Unidad 6

1. **Big Data y análisis económico**
2. Machine Learning: conceptos, aplicaciones
3. Machine Learning versus Econometría
4. Algoritmos más habituales en Machine Learning

Big Data: ¿qué es?

- ¿Qué es *big data*?
- **No hay consenso**
- ¿Bases de datos con muchos datos?
- ¿Datos estáticos (digitalizados, e.g. censos) o dinámicos (creados en tiempo real, e.g. redes sociales)?
  - "*Real time, socially-created and socially-driven data that could be harvested without having to purposely collect it or budget for its collection*" Raftree (2015)
- ¿Datos que tienen su propia vida?
- ¿No caben en un laptop y se necesitan destrezas especiales para analizarlos?

Big Data: ¿qué es?

1. ***Big Data*: las tres V's**
   a) Volumen
   b) Variedad
   c) Velocidad

2. **Análisis con *Big Data* (*Data Science*)**
   a) Conjunto de herramientas y metodologías
   b) Que transforman grandes cantidades de datos brutos
   c) En datos sobre los datos

Big Data: ¿qué es?

- Definiendo *Big Data*…

- ***Small data*** (estadística clásica)
  - Extraer lo máximo de **pocos** datos
  - Solución: **estructura** (muestreo, modelo)
  - Enfoque: muestreo complejo (**lento**). Teoría, experimentos, cuasi-experimentos

- ***Big data***
  - **Muchos** datos (Volumen)
  - Muchos datos **no estructurados** (Variedad)
  - Muchos datos no estructurados e **immediatos** (Velocidad)

Big Data: tipos de datos

- Tres tipos de datos
  1. Crudos: vienen directo de la fuente
  2. Procesados en casa (“*in house*”)
  3. Procesados fuera de casa (“*out of house*”)

Big Data: tipos de datos

- **Datos Crudos:** vienen directo de la fuente
- Ejemplo: Datos de satélites de la NASA con luminosidad

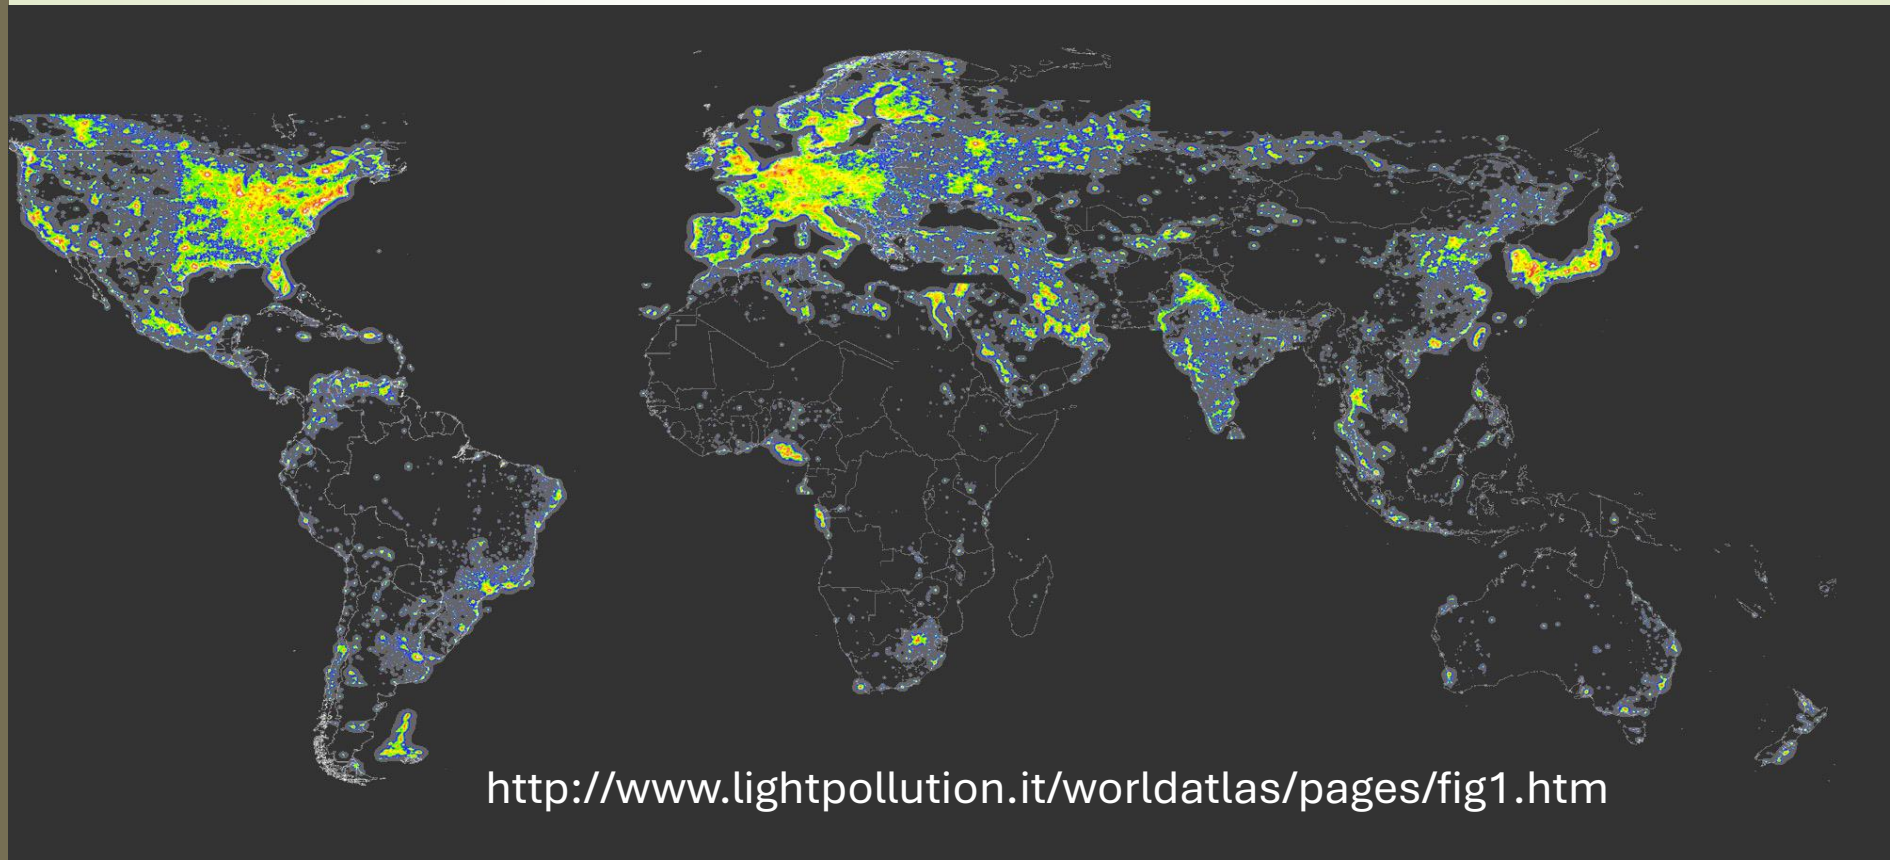

Big Data: tipos de datos

- **Datos Procesados:** Actividad de pesca para barcos en aguas internacionales combinada con zonas protegidas. Versión de tráfico aéreo pero para barcos.

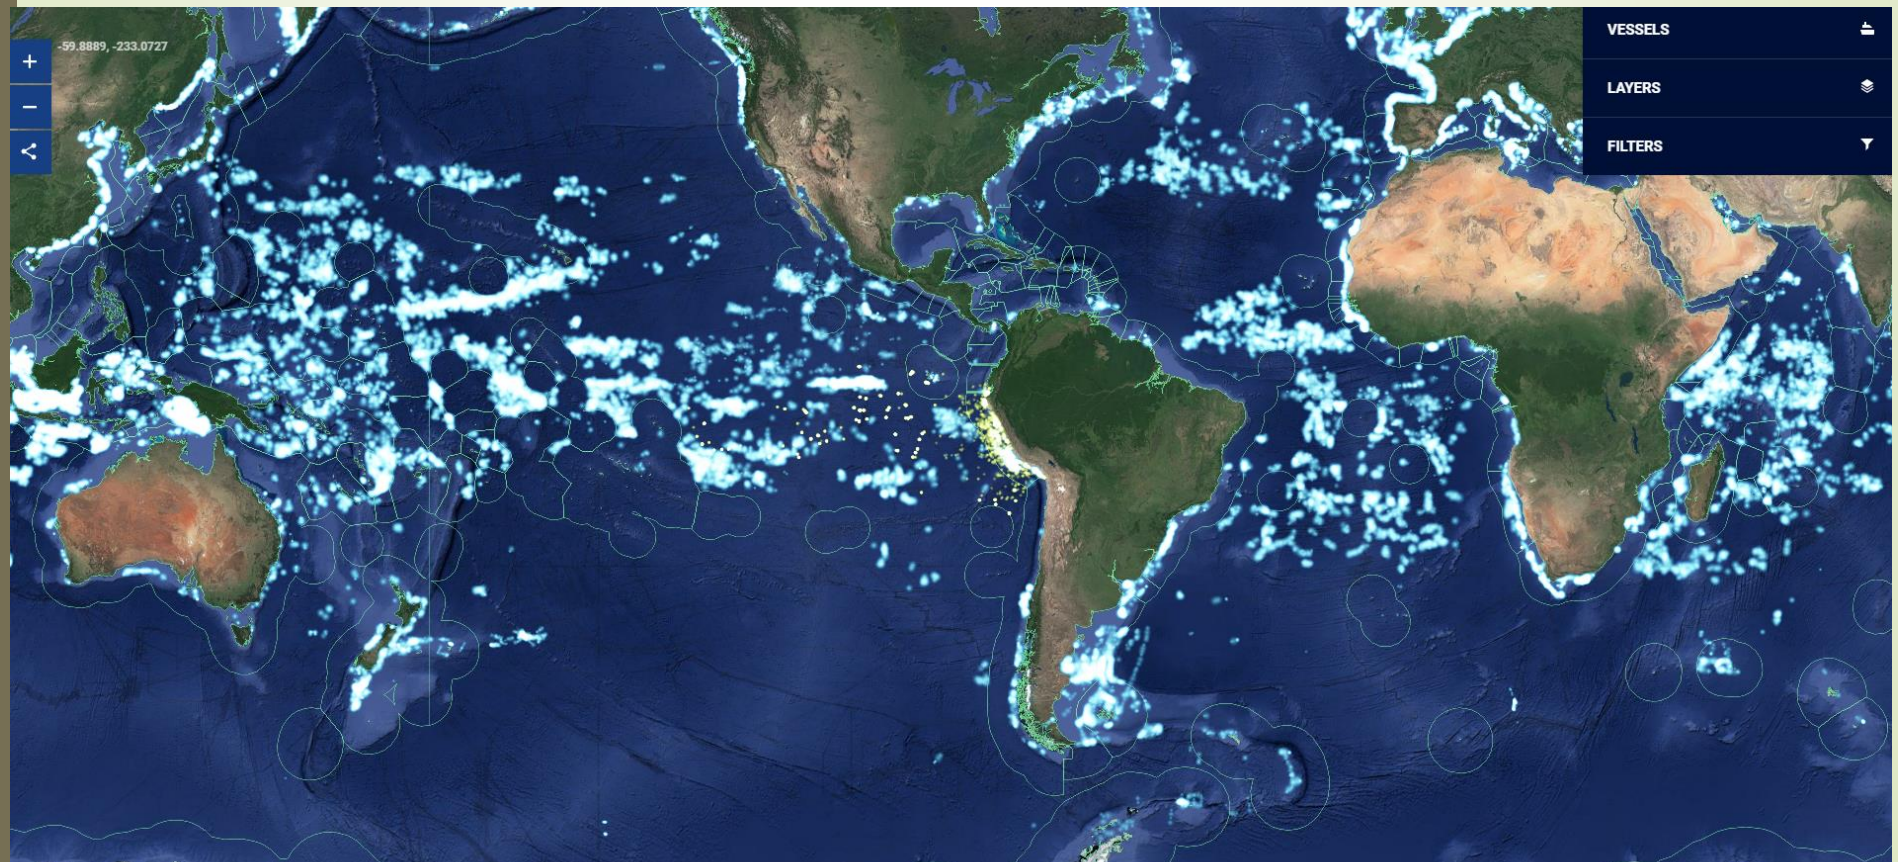

Big Data: tipos de datos

- *Big Data* está siendo cada día más grande!!!
- Ejemplo: Producción de datos provenientes de satélites por día a lo largo del tiempo

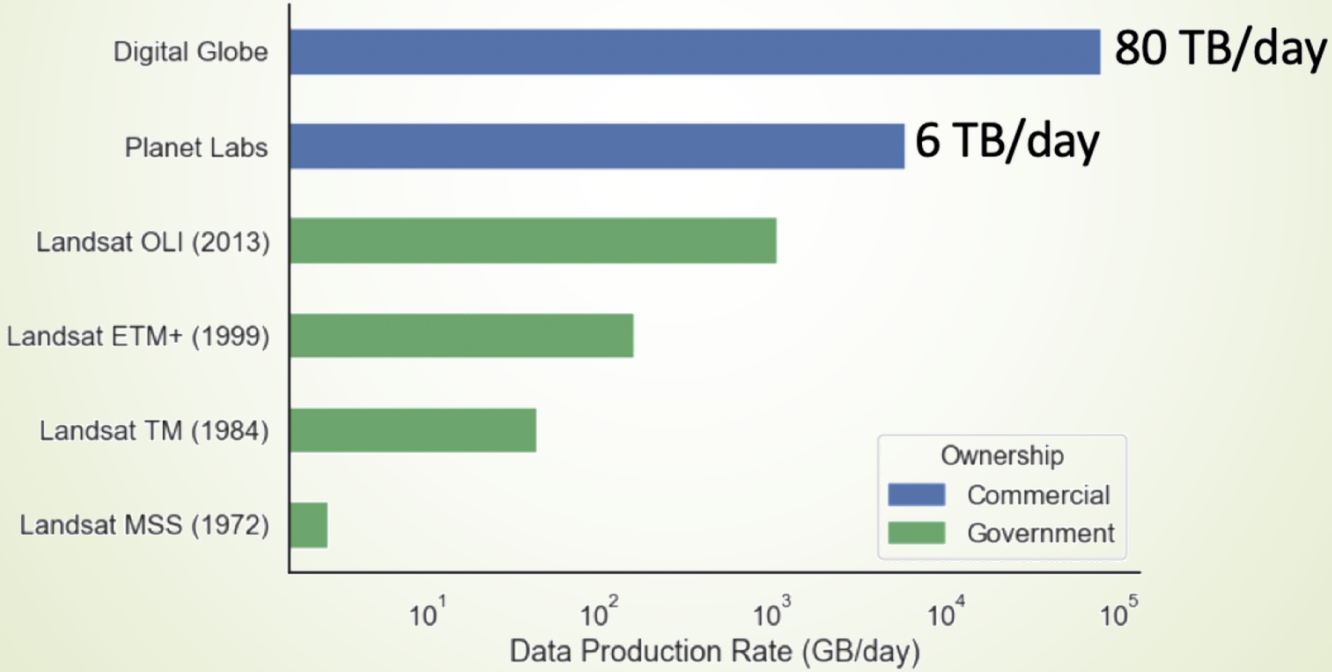

- Sin embargo, siempre hemos estado rodeados de datos.
- Es sólo que hoy podemos almacenarlos y usarlos mejor… ¿Cómo?

Resumen de la Unidad 6

1. Big Data y análisis económico
2. **Machine Learning: conceptos, aplicaciones**
3. Machine Learning versus Econometría
4. Algoritmos más habituales en Machine Learning

Machine learning: ¿qué es?

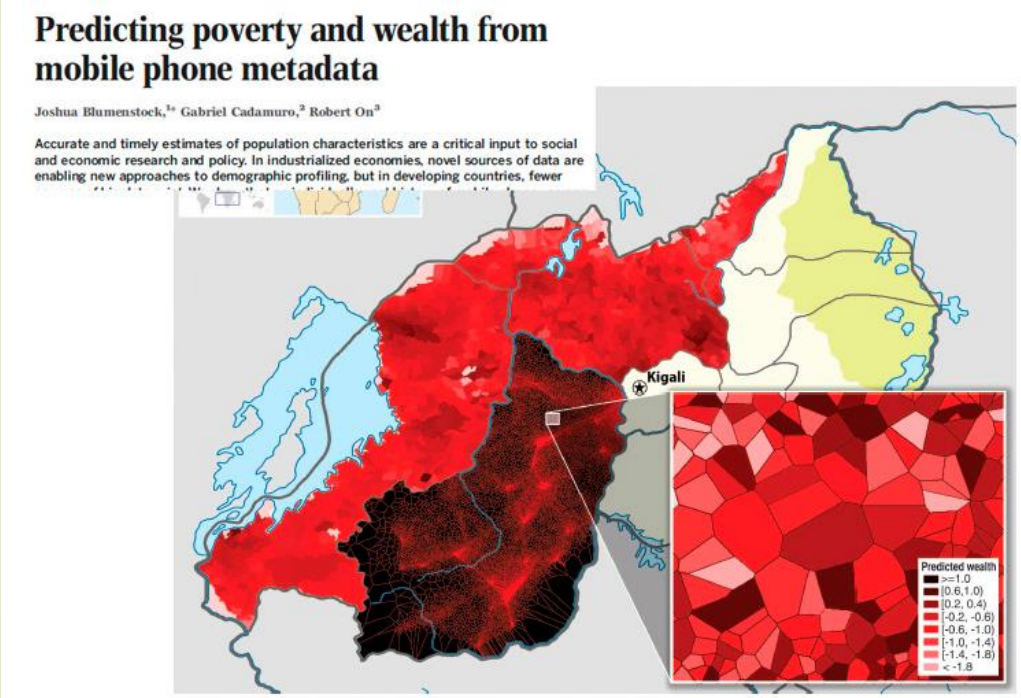

- Se puede hacer mucho combinando estos datos masivos con técnicas de estadística y ciencias de la computación, dado el creciente poder computacional

- Este es el contexto en que se desarrolla el aprendizaje automatizado o *machine learning*

Machine learning: ¿qué es?

- Es un rama del conocimiento en la intersección de las Ciencias de la Computación y la Estadística
- ¿Objetivo? Desarrollar algoritmos que predigan resultados Y de variables X (¿suena conocido?)

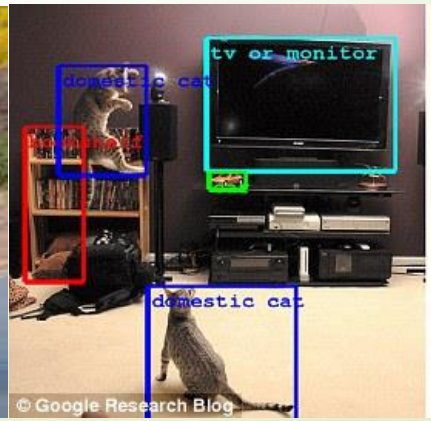

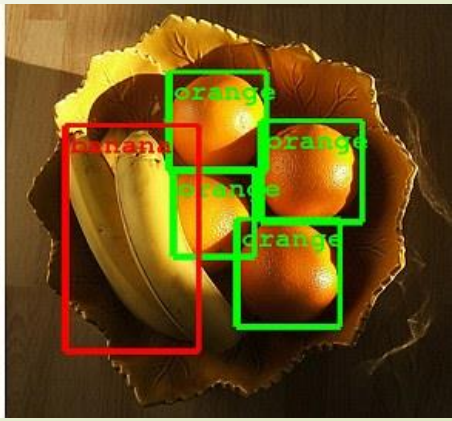

Machine learning: ¿qué es?

- **¿Dónde está el aprendizaje ("*learning*")?**
  - No se le indica al algoritmo (a la máquina) cómo exactamente predecir Y usando X
  - Se deja planteado como un problema empírico que la *"máquina"* puede *"aprender"*
  - ¿Cómo aprende? En base a la *"experiencia"* (*training*)
  - Es decir, es un proceso iterativo en que se registran errores que luego se corrigen en rondas siguientes

Machine learning: ¿qué es?

- En general, esto significa abstraerse de modelos de comportamiento (!)
  - Lo que sea que funciona, funciona
- Pero esos modelos de comportamiento son clave en Economía
- Y la Econometría combina Teoría Económica con Estadística y Matemáticas (clase 1!)
- **¿Entonces?**
- Debemos diferenciar **Causalidad** (foco tradicional en Econometría) de **Predicción** (*Machine Learning*)

Causalidad vs. Predicción

Dos escenarios relacionados con el clima

- **En el norte:** Frente a una sequía, ¿debería el gobierno invertir en una danza de la lluvia?

- Para este caso, es crucial poder explicar: importa la **causalidad**

- **En el sur:** Después de 10 días de lluvia, ¿debería salir con paraguas a la calle?

- Para este caso, es crucial poder pronosticar: importa la **predicción**

Resumen de la Unidad 6

1. Big Data y análisis económico
2. Machine Learning: conceptos, aplicaciones
3. **Machine Learning versus Econometría**
4. Algoritmos más habituales en Machine Learning

Machine Learning vs. Econometría

	Machine Learning	Econometría
Objeto de interés	Valores predichos $\widehat{y_i}$	Estimadores de los parámetros $\hat{\beta}$
Criterio de estimación	Ajuste óptimo, e.g. MSE mínimo ECM: $\frac{1}{n}\sum_{i=1}^{N}\left(y_i - \hat{f}(x_i)\right)^2$	Insesgadez: $E\left(\hat{\beta} - \beta\right) = 0$ Consistencia: $plim\left(\hat{\beta} - \beta\right) = 0$
Criterio de evaluación	Ajuste empírico de validación cruzada en datos de prueba	Supuestos conceptuales de alto nivel sobre el proceso generador de datos
Pregunta habitual	¿Es esto preciso?	¿Es esto causal?

Machine Learning vs. Econometría

Machine Learning	Econometría
Un problema de aprendizaje	Un problema empírico
Para entrenar un algoritmo	Para ejecutar un procedimiento de estimación
Datos de prueba o entrenamiento	Muestra para estimación
Regresión	Predicción de variables explicadas continuas
Clasificación	Predicción de variables explicadas discretas (limitadas)
Una característica	Una variable explicativa (x)
Una etiqueta	Una variable explicada categórica (y)
Una respuesta	Una variable explicada continua (y)

Resumen de la Unidad 6

1. Big Data y análisis económico
2. Machine Learning: conceptos, aplicaciones
3. Machine Learning versus Econometría
4. **Algoritmos más habituales en Machine Learning**

Trade-off entre sesgo y varianza

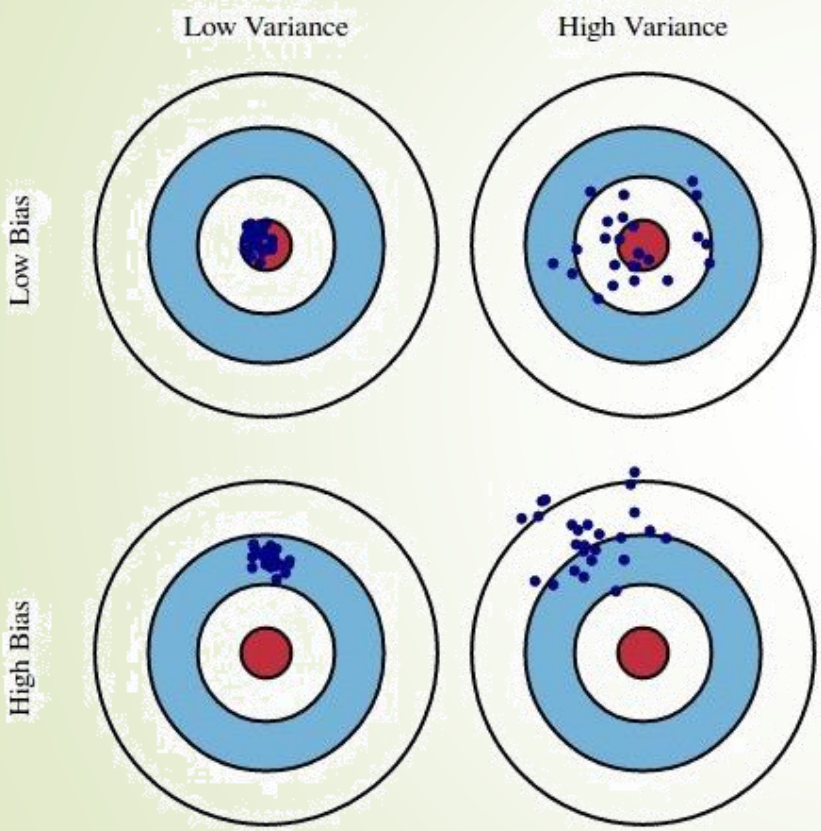

- **Complejidad:** ajuste en la muestra y fuera de la muestra
- **Sobre-ajuste / *overfitting*:** alta varianza, alta (demasiada) complejidad
- **Sub-ajuste / *underfitting*:** alto sesgo, baja (muy poca) complejidad

¿Qué tan precisa es la predicción?

- Si deseamos predecir $\hat{y}$, existe un compromiso (*trade-off*) entre sesgo y varianza que se debe resolver:

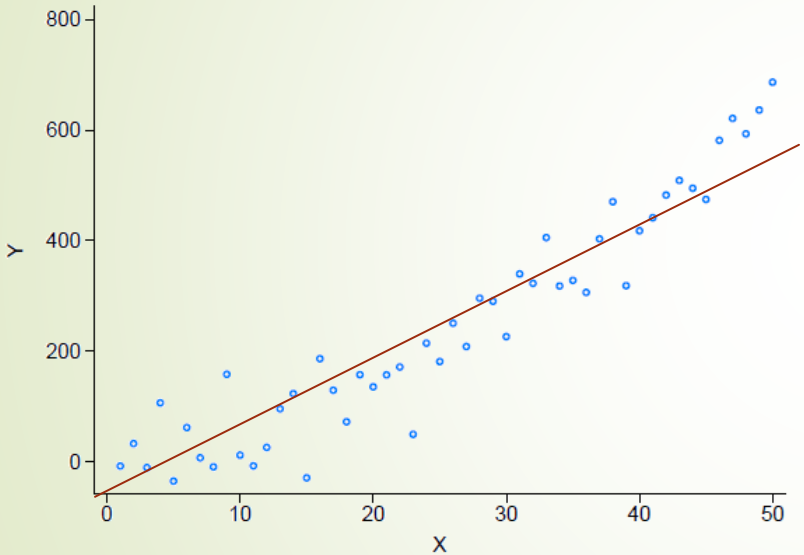

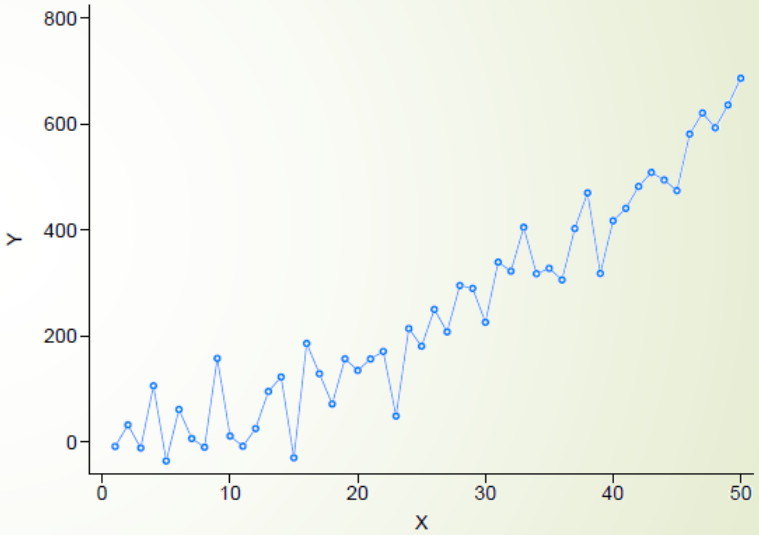

Sub-ajuste: demasiado general

- Mucho sesgo
- Muy poca complejidad
- Alto error dentro de muestra

Sobre-ajuste: demasiado específico

- Mucha varianza
- Demasiada complejidad
- Bajo error dentro de muestra

Alto error fuera de muestra

Taxonomía (no exhaustiva) de algoritmos

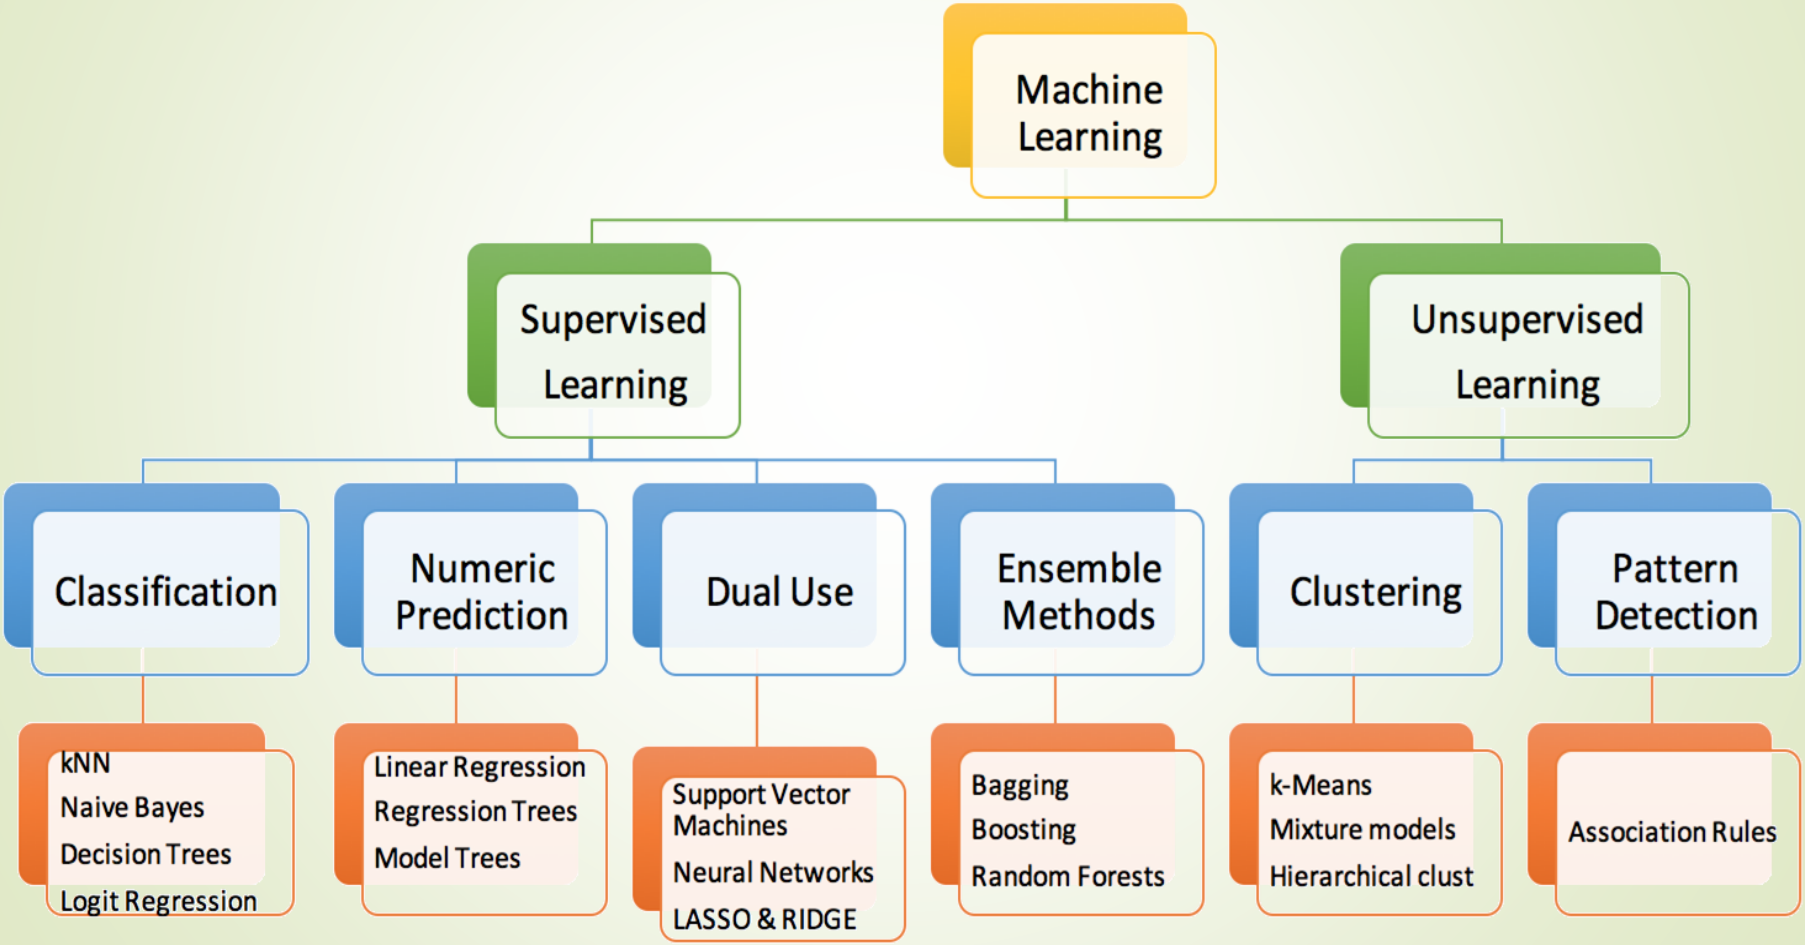

¿Cómo funciona un algoritmo de *ML*?

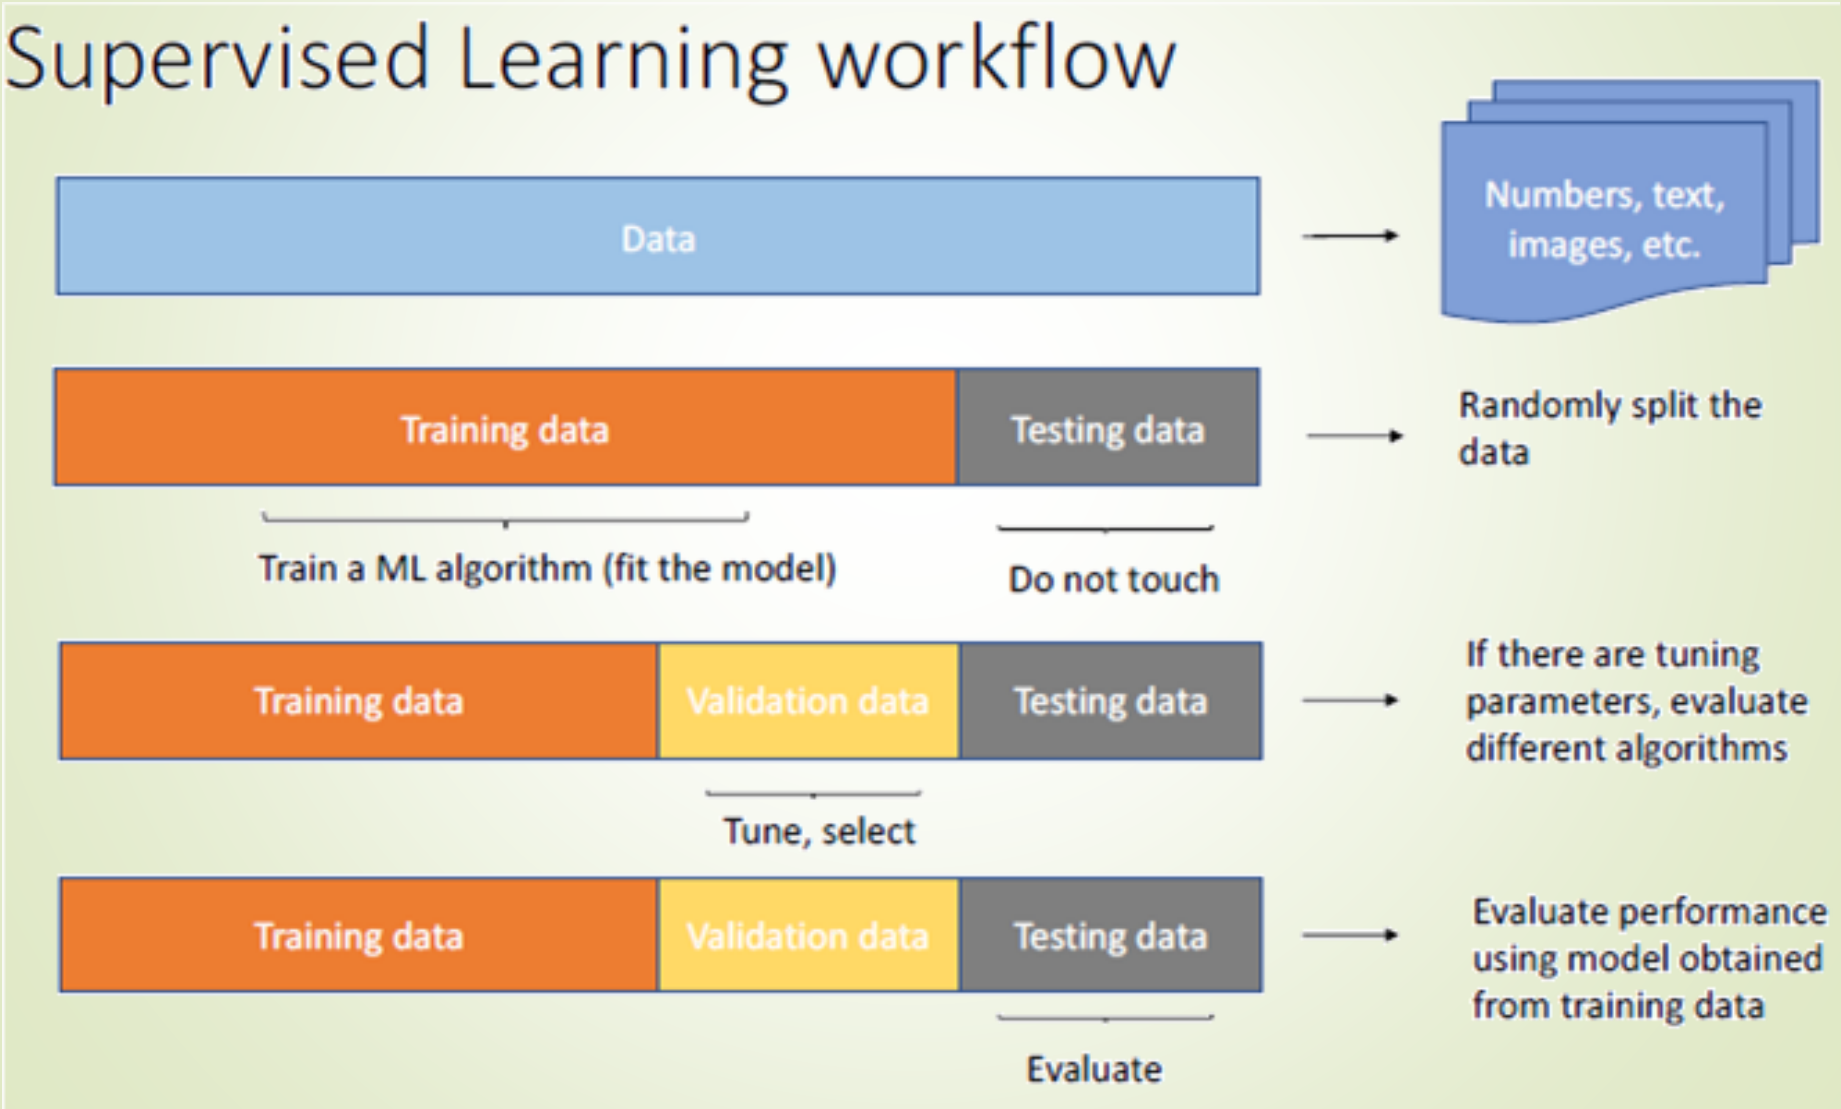

A modo de conclusión…

1. ***Big Data:***

- "*With Big Data comes Big responsibility*"
- *Big data* permite nuevas posibilidades de análisis
- Pero se requiere tiempo, capacidad computacional y mucho cuidado!
- Combinar datos de distintas fuentes (crudos, procesados en casa, fuera de casa) puede ser beneficioso

A modo de conclusión…

2. **Aprendizaje Automatizado (*Machine Learning*):**

- Se usa para predecir! (meta es $\hat{Y}$ de siempre)
- Queremos tener mejor predicción, pero cuidado con sobreajustar (*overfitting*)
- Ideas Clave: Sesgo, Varianza y su *trade-off*
- La combinación de herramientas y el cuidado en su interpretación, son el futuro!

FIN DEL CURSO